

人工智能数学基础

线性代数、概率与最优化

主编: Xinpei Zhang

编写者: Chenwenjun Cao、Haoran Cao、Zhe Cao、Haihui Li、Zhuodong Liao、
Yijia Liu、Yinghan Liu、Panpan Wu、Yunze Wu、Xinpei Zhang、Zhendan Zhang

最后更新: Sunday 20th September, 2026 11:07

目录

前言	vi
第一篇 矩阵代数	1
第一章 矩阵代数——矩阵与线性变换	2
本章导读	2
本章约定	4
1.1 数据、向量与矩阵	5
1.1.1 从数据到向量	5
1.1.2 数据矩阵	5
1.1.3 矩阵乘法的三种理解	6
1.2 向量空间与子空间	7
1.2.1 向量空间的定义	7
1.2.2 子空间与判别准则	8
1.3 张成、线性无关、基与维数	9
1.4 线性映射与矩阵表示	11
1.4.1 线性映射	11
1.4.2 矩阵表示	12
1.5 核空间、像空间与秩	13
1.6 矩阵的四个基本子空间	14
1.7 线性方程组的结构	16
1.8 内积、正交补与直和	17
1.9 正交投影	18
1.10 投影矩阵	20
1.10.1 标准正交基给出的公式	20
1.10.2 一般列空间上的投影	20
1.10.3 正交投影矩阵的刻画	21
1.11 最小二乘	21
1.11.1 先看几何：残差必须垂直于列空间	22

1.11.2 满列秩时的唯一解	23
1.12 特征映射	25
1.13 核技巧	27
1.14 AI 综合案例	28
1.14.1 核心案例：用子空间与正交补做去噪	28
1.14.2 延伸阅读：零样本学习中的子空间与最小二乘	29
1.15 本章小结	31
1.16 习题	32
1.16.1 基础题	32
1.16.2 证明题	33
1.16.3 计算题	34
1.16.4 AI 应用题	35
本章参考文献	36
第二章 矩阵代数——范数理论与正则化	38
2.1 向量范数与稀疏性	38
2.2 矩阵范数	38
2.3 内积空间、余弦相似度	38
2.4 案例：深度学习中的度量学习	38
本章参考文献	38
第三章 矩阵代数——矩阵分解	39
3.1 特征值分解	39
3.2 奇异值分解	39
3.3 低秩逼近	39
3.4 案例：大模型训练中的加速方法	39
本章参考文献	39
第四章 矩阵代数——矩阵微积分与反向传播	40
4.1 多元微分与 Jacobian 矩阵	40
4.2 标量、向量对矩阵的求导法则	40
4.3 迹函数与行列式的微分技巧	40
4.4 链式法则原理	40
4.5 案例：深度学习中的反向传播算法	40
本章参考文献	40

第五章 矩阵代数——特殊运算与张量基础	41
5.1 Kronecker 积和 Hadamard 积	41
5.2 广义逆矩阵与最小二乘解	41
5.3 张量的基本定义	41
5.4 案例：矩阵计算的 Python 实现	41
本章参考文献	41
 第二篇 概率论	 42
第六章 概率论——多元随机变量与高斯分布	43
6.1 随机向量与统计特征	43
6.2 多元高斯分布	43
6.3 分布变换	43
本章参考文献	43
第七章 概率论——参数估计与信息论基础	44
7.1 参数估计框架	44
7.2 信息论与损失函数	44
7.3 案例：生成式模型中的相关算法	44
本章参考文献	44
 第三篇 最优化方法	 45
第八章 最优化方法——优化视角下的 AI 模型	46
8.1 优化问题的直观理解	46
8.2 凸集与凸函数基础	46
8.3 全局最优和局部最优	46
8.4 案例：分类及回归的模型与算法	46
本章参考文献	46
第九章 最优化方法——一阶算法	47
9.1 梯度下降法	47
9.2 随机梯度下降	47
9.3 加速方法	47
9.4 自适应算法	47

9.5 案例：深度学习中的训练相关算法	47
本章参考文献	47
第十章 最优化方法——二阶算法	48
10.1 牛顿法与海森矩阵	48
10.2 曲率信息与收敛速度	48
10.3 案例：自然策略梯度	48
本章参考文献	48
第十一章 最优化方法——约束优化与对偶理论	49
11.1 拉格朗日乘子法	49
11.2 KKT 条件与对偶理论	49
11.3 增广拉格朗日法	49
11.4 案例：深度学习中的约束优化问题	49
本章参考文献	49
符号表	50
全书参考文献	50

前言

本笔记以数学系教材的逻辑组织课程内容：从定义出发，经由性质、引理与定理建立理论，再通过证明、例子与人工智能应用说明其意义。课程课件用于确定教学范围，参考教材与经典教科书用于补充理论细节。

《人工智能数学基础》
CC BY-NC-SA 4.0
禁止商业使用 · 著作权归全体署名作者共有

第一篇

矩阵代数

Chapter 1

矩阵代数——矩阵与线性变换

本章作者: Xinpei Zhang 初审: Haihui Li 二审: $\times \times \times$ 终审: $\times \times \times$

本章导读

线性代数是人工智能的第一门“母语”。一个样本是一支向量，一份数据集是一个矩阵，一层神经网络是一个线性映射复合上逐点的非线性，而几乎所有训练算法最终都要回答同一个问题：给定 A 与 b ，如何找到 x 使 Ax 尽量接近 b ？本章的目标不是罗列矩阵计算技巧，而是把这条主线的数学骨架搭起来：

向量 $\rightarrow$ 向量空间 $\rightarrow$ 子空间 $\rightarrow$ 张成 / 线性无关 / 基 / 维数 $\rightarrow$ 线性变换 $\rightarrow$ 矩阵表示 $\rightarrow$ 核 / 像 $\rightarrow$ 四个基本子空间 $\rightarrow$ 正交性 $\rightarrow$ 投影 $\rightarrow$ 最小二乘。

这条主线有一个刻意的次序：先讲向量空间与线性映射，再谈矩阵。矩阵不是“一张数字表格”，而是线性变换在给定基下的矩阵表示；只有先理解线性变换“是什么”，才能理解矩阵乘法的每一种算法为什么都有意义。图 1.1 给出本章的数学依赖关系；虚线右侧是本章的支线（特征映射与核技巧），它把线性方法推广到非线性模型，但它的每一个概念——内积、Gram 矩阵、半正定——都仍然落脚在主线之上。

内容边界

本书是教材而不是手册，因此有必要明确本章“不做什么”。凡是与本章主线（向量空间 $\rightarrow$ 线性变换 $\rightarrow$ 投影 $\rightarrow$ 最小二乘）无直接关系的内容，一律推迟到相应章节，见表 1.1。本章只保留后续章节必须用到的结构性结果：向量空间与子空间的定义、基与维数、线性映射与矩阵表示、秩-零化度定理、四个基本子空间、正交投影与最小二乘；其余技巧性内容交给后面的章节。这样安排的代价是本章暂时显得“窄”，收益是每一个概念都在正确的位置上被引入、被使用。




图 1.1: 本章的数学依赖关系：左侧为本章主线，右侧为特征映射与核技巧支线

表 1.1: 本章内容边界与后续章节的分工

内容	本章处理方式	去向
群、环与一般域上的模	压缩为一句注	节 1.2 的注
Gaussian 消元法	只作简要复习	节 1.7 的注
Hadamard 积、Kronecker 积	不展开	第 5 章（矩阵微积分与张量）
卷积	仅在例举中提及	第 5 章
Cayley–Hamilton 定理、特征值理论	不涉及	第 3 章（矩阵分解）
正定矩阵的系统理论	只给定义与半正定性的证明	第 2、3、8 章
行列式与迹的各类不等式	删除	附录 / 第 4 章
SVM 的优化模型与对偶	只给一句话说明	第 9–12 章（最优化）

本章约定

本章的英文题目为 *Matrix Algebra: Matrices and Linear Transformations*。为避免在全书中反复交代同一件事，下面把本章通用的约定一次列出；后续各章除非另行声明，也沿用这些约定。

- (1) **数域**。默认在实数域 $\mathbb{F} = \mathbb{R}$ 上讨论；只有在确有必要时才取 $\mathbb{F} = \mathbb{C}$ ，届时会明确声明。本课程出现的向量空间基本只有 $\mathbb{R}^d$ 、 $\mathbb{C}^d$ 、 $\mathbb{R}^{m \times n}$ 、多项式空间 P_d 与函数空间这几类。
- (2) **向量与内积**。 $x \in \mathbb{R}^d$ 一律指**列向量**， $x^\top$ 为对应的行向量。内积默认取欧氏内积 $\langle x, y \rangle = x^\top y$ ，范数默认取 $\|x\|_2 = \sqrt{\langle x, x \rangle}$ ；需要别的内积时会写清楚。
- (3) **数据矩阵**。行 = 样本、列 = 特征，即 $X \in \mathbb{R}^{N \times d}$ 的第 i 行是第 i 个样本（式 (1.2)）。有的教材与软件库取相反的约定（列 = 样本），读他人代码时先确认这一点。
- (4) **arg min 表示解集**。 $\arg \min_x f(x)$ 指使 f 取到最小值的集合，而不是某个点。只有当解唯一时才写成 $x^* = \arg \min_x f(x)$ ；解不唯一时写作 $\hat{x} \in \arg \min_x f(x)$ 。最小二乘解集式 (1.26) 就是前一种情形的典型例子： A 不满列秩时它含无穷多个元素。
- (5) **线性与仿射分开**。线性映射满足 $T(\alpha x + \beta y) = \alpha T(x) + \beta T(y)$ （定义 1.15），其中特别包含 $T(0) = 0$ ；形如 $x \mapsto Ax + \mathbf{b}$ ($\mathbf{b} \neq 0$) 的映射是**仿射映射**而不是线性映射。本章凡称“线性”，一律指前者。
- (6) **伪逆与逆**。 A^+ 一律指 Moore–Penrose 伪逆，不使用 $A^\dagger$ 等其它记号； A^{-1} 只用于可逆方阵。伪逆对任意矩阵都存在且唯一，满列秩时的公式 $A^+ = (A^\top A)^{-1} A^\top$ 只是它便于手算的一个特例，而不是另一个概念。
- (7) **核、像与四个基本子空间**。抽象线性映射用 $\text{Ker } T$ 、 $\text{Im } T$ ；具体矩阵用 $\text{Null}(A)$ 、 $\text{Col}(A)$ 、 $\text{Row}(A)$ 、 $\text{Null}(A^\top)$ （左零空间）。 $\text{rank}(A)$ 与 $\text{nullity}(A)$ 分别指 A 的秩与零化度。
- (8) **主线与支线**。本教材把“向量空间 $\rightarrow$ 线性变换 $\rightarrow$ 投影 $\rightarrow$ 最小二乘”这条链称为本章**主线**，把特征映射与核技巧称为**支线**（图 1.1）。

核心思想

“特征”一词有两个来源，本教材分别对待。一方面，机器学习借用线性代数的语言，把数据的一个属性叫作 *feature*，于是有**特征映射**（feature map）、**特征空间**（feature space）与**特征表示**（feature representation，文献中也作 feature vector）。另一方面，线性代数自身的 *eigen*- 系列在中文里同样译作“特征”：**特征值**（eigenvalue）、**特征向量**（eigenvector）、**特征空间**（eigenspace）。二者同名而含义无关。本章讲的都是前者；后一组概念属于特征值理论，将在第 3 章出现，届时一律写成“特征值（eigenvalue）”“特征向量（eigenvector）”并夹注英文，以免混淆。

1.1 数据、向量与矩阵

1.1.1 从数据到向量

在人工智能中，我们几乎总是从“数据”出发。设描述一个对象需要 d 个数值特征，我们就按照固定的顺序把这 d 个数排成一列：

$$x = (x_1, x_2, \dots, x_d)^\top \in \mathbb{R}^d. \quad (1.1)$$

这里 x_j 是第 j 个特征 (feature) 的取值，上标 $\top$ 表示转置，它把行写成列。一个样本就是一个向量，而 x_j 的含义与位置都是事先固定好的。

例 1.1 (两个样本) 描述一批学生，取身高 (厘米)、体重 (千克)、年龄 (岁) 三个特征，则

$$x_1 = (170, 65, 22)^\top, \quad x_2 = (180, 78, 24)^\top$$

是两个样本。 x_1 与 x_2 属于同一个 $\mathbb{R}^3$ ，因为二者使用了同一组特征、同一个顺序 (先身高、再体重、后年龄)。正是这种“同一坐标系下可比”的性质，使得我们可以对样本做加法、数乘与内积。

需要提醒的是，这种“可以做”是代数上的，不一定是统计上有意义的：身高以厘米计、体重以千克计、年龄以岁计，量纲不同，直接做内积会让数值大的特征 (这里是身高) 主导结果。实际建模中通常先做**标准化** (各特征减均值、除以标准差) 或**归一化** (缩放到固定区间)，也可以改用带权内积 $\langle u, v \rangle_W = u^\top W v$ (W 为对称正定矩阵) 来为不同特征指定权重。本章之后一律假设数据已经过适当的预处理。

注. 向量当然也可以被解释成平面上的位置或者位移，这是中学几何里最直观的图像。但这种几何直观并不是线性代数的基础：上面那支“身高-体重-年龄”向量画不出任何有意义的箭头，它依然是一个完全合法的向量。本章关心的是“数据向量”，而不是几何向量的历史。

1.1.2 数据矩阵

把 N 个样本按行堆叠起来，就得到**数据矩阵** (design matrix, 也译作设计矩阵)

$$X = \begin{bmatrix} x_1^\top \\ x_2^\top \\ \vdots \\ x_N^\top \end{bmatrix} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1d} \\ x_{21} & x_{22} & \cdots & x_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ x_{N1} & x_{N2} & \cdots & x_{Nd} \end{bmatrix} \in \mathbb{R}^{N \times d}. \quad (1.2)$$

按本章约定第 3 条， X 的第 i 行 $x_i^\top$ 是第 i 个样本，第 j 列是第 j 个特征在所有 N 个样本上的取值向量。凡牵涉“样本维度”与“特征维度”的公式，都以此为准。

AI 应用

问题：自然语言的句子长度不一，如何送进统一维度的线性代数框架？

数学建模：把每个 token 表示成 $\mathbb{R}^d$ 中的向量 (token embedding)，则一个长度为 L 的句子就是矩阵 $X \in \mathbb{R}^{L \times d}$ 。注意 L 是**序列长度**、 d 是**嵌入维度**，二者分别由句子本身和模型设定，并不由词表大小 V 决定 (V 只决定 embedding 表 $E \in \mathbb{R}^{V \times d}$ 的行数)。实际训练按 batch 进行，同批样本的 L 一般不同，通常先 padding 到统一长度 $L_{\max}$ ，再用 attention mask 把补齐位置屏蔽掉，使它们不参与计算。

理论联系：注意力机制的核心计算 $\text{softmax}(QK^\top/\sqrt{d_k})V$ 全部由矩阵乘法构成，其中 Q, K, V 分别是 X 经 W_Q, W_K, W_V 得到的线性变换结果， d_k 是 key 的维度，缩放因子 $\sqrt{d_k}$ 用来抵消内积随维度增长而增大的效应。而所谓“线性层” $XW + \mathbf{b}$ ——只要 $\mathbf{b} \neq 0$ ——其实不是线性映射而是**仿射映射**：它不满足 $T(0) = 0$ ，因而定义 1.15 的条件不成立；它是线性映射 $X \mapsto XW$ 与平移的复合。数据形状 (shape) 之所以成为深度学习中最常见的调试信息，正是因为每个 shape 都是一次线性映射的定义域与值域。

1.1.3 矩阵乘法的三种理解

设 $A \in \mathbb{R}^{m \times n}$ 、 $x \in \mathbb{R}^n$ ，考虑矩阵-向量乘积

$$y = Ax, \quad y \in \mathbb{R}^m. \quad (1.3)$$

同一个式子 $y = Ax$ 有三种完全不同的读法，它们分别对应三种推理方式。

(i) **行观点：内积。**把 A 按行分块为 $A = [a_1^\top; \dots; a_m^\top]$ (其中 $a_i \in \mathbb{R}^n$)，则

$$y_i = a_i^\top x = \langle a_i, x \rangle = \sum_{j=1}^n a_{ij}x_j, \quad i = 1, \dots, m. \quad (1.4)$$

每一行的元素是“权重”， y_i 是第 i 行与输入的内积。这就是线性回归、感知机与全连接层中“一个神经元输出一个数”的代数原型。

(ii) **列观点：线性组合。**把 A 按列分块为 $A = [a_1 \ a_2 \ \dots \ a_n]$ (其中 $a_j \in \mathbb{R}^m$)，则

$$Ax = x_1a_1 + x_2a_2 + \dots + x_na_n. \quad (1.5)$$

Ax 是 A 的各列以 x 的分量为系数的线性组合。于是“ $Ax = b$ 有解”等价于“ b 落在 A 的各列张成的集合里”——这句话将在节 1.7 变成关于解集结构的定理。

(iii) **线性变换观点：映射。**把 A 看作一个从 $\mathbb{R}^n$ 到 $\mathbb{R}^m$ 的函数

$$T_A: \mathbb{R}^n \rightarrow \mathbb{R}^m, \quad T_A(x) = Ax.$$

它保持加法与数乘： $T_A(\alpha x + \beta z) = \alpha T_A(x) + \beta T_A(z)$ 。线性代数真正研究的对象是这个映射，而 A 只是它在标准基下的矩阵表示 (节 1.4 会严格说明这一点)。

现在才给出元素公式。对 $A \in \mathbb{R}^{m \times n}$ 、 $B \in \mathbb{R}^{n \times p}$ ，定义乘法的第 (i, j) 个元素为

$$(AB)_{ij} = \sum_{k=1}^n a_{ik}b_{kj}. \quad (1.6)$$

这条公式并不是“定义本身”，而是上面三种观点的共同计算后果：

- 列的观点： AB 的第 j 列 $= (AB)_{\cdot j} = A(B_{\cdot j})$ ，即“矩阵乘矩阵 = 对右矩阵的每一列做矩阵-向量乘法”；
- 行的观点： AB 的第 i 行 $= (AB)_i = (A_i)B$ ，即左矩阵的每一行去“探测”右矩阵；
- 复合的观点：若 $S: \mathbb{R}^p \rightarrow \mathbb{R}^n$ 、 $T: \mathbb{R}^n \rightarrow \mathbb{R}^m$ 分别以 B, A 为矩阵，则复合映射 $T \circ S$ 的矩阵恰好是 AB 。这也解释了为什么矩阵乘法一般不可交换：映射的复合一般不可交换。

注. 矩阵乘法满足结合律 $(AB)C = A(BC)$ ，这从“复合映射的结合律”看是显然的，而用元素公式 (1.6) 验证则相当繁琐。这正是“先讲映射、再讲矩阵”的价值：恰当的抽象让结论变得透明。

1.2 向量空间与子空间

1.2.1 向量空间的定义

$\mathbb{R}^d$ 中能做加法与数乘， $\mathbb{R}^{N \times d}$ 中也能做加法与数乘；以次数不超过 d 的实系数多项式为元素构成的集合同样能做加法与数乘。把这些共同性质抽象出来，就得到向量空间。

这里的“次数不超过 d ”不能写成“ d 次”： d 次多项式 ($\deg p = d$) 的集合对加法不封闭—— t^d 与 $-t^d$ 之和是零多项式，而零多项式没有次数。为统一起见，本章记

$$P_d = \{p \in \mathbb{R}[t] : \deg p \leq d\}, \quad (1.7)$$

并约定 $\deg 0 = -\infty$ ，于是 P_d 对加法与数乘封闭，是向量空间（例 1.3 将正式验证）；其中 $\mathbb{R}[t]$ 表示全体实系数多项式。

定义 1.2 (向量空间) 设 $\mathbb{F}$ 是一个域（本书默认取 $\mathbb{F} = \mathbb{R}$ ，必要时取 $\mathbb{F} = \mathbb{C}$ ）。一个集合 V 若配备两种运算

$$+: V \times V \rightarrow V, \quad \cdot: \mathbb{F} \times V \rightarrow V$$

（分别称为加法与标量乘法），使得对任意 $x, y, z \in V$ 与任意 $\alpha, \beta \in \mathbb{F}$ 都有

- (A1) $x + y = y + x$;
- (A2) $(x + y) + z = x + (y + z)$;
- (A3) 存在元素 $0 \in V$ ，使得 $x + 0 = x$;
- (A4) 存在元素 $-x \in V$ ，使得 $x + (-x) = 0$;
- (A5) $\alpha(\beta x) = (\alpha\beta)x$;
- (A6) $1 \cdot x = x$;
- (A7) $\alpha(x + y) = \alpha x + \alpha y$;

$$(A8) (\alpha + \beta)x = \alpha x + \beta x,$$

则称 V (连同这两个运算) 是域 $\mathbb{F}$ 上的**向量空间** (或**线性空间**), V 中的元素称为**向量**, $\mathbb{F}$ 中的元素称为**标量**。

公理 (A3) 中的 0 称为零向量, 公理 (A4) 中的 $-x$ 称为 x 的负向量, 可以证明它们都是唯一的。此外, 下面两条常用等式并不是公理, 而是由分配律与单位元公理直接推出的:

$$0 \cdot x = 0, \quad (-1) \cdot x = -x. \quad (1.8)$$

它们在公理 (A3) 与 (A4) 的验证中会反复用到 (例如 命题 1.5 的证明)。

注. 公理 (A1)–(A4) 说的是 $(V, +)$ 构成一个交换群, 公理 (A5)–(A8) 说的是标量乘法与加法相容。一般域上的“模”与“结合代数”(环、域)的理论本书不展开; 本课程出现的向量空间基本只有 $\mathbb{R}^d$ 、 $\mathbb{C}^d$ 、 $\mathbb{R}^{m \times n}$ 以及多项式空间、函数空间这几种。

例 1.3 (三个基本例子) $\mathbb{R}^d$ (按分量加法与数乘)、 $\mathbb{R}^{m \times n}$ (按元素加法与数乘)、多项式空间 P_d (式 (1.7)), 都是 $\mathbb{R}$ 上的向量空间。前两个的验证是逐分量进行的, 这里只把 P_d 写清楚: 若 $\deg p \leq d$ 、 $\deg q \leq d$ 、 $\alpha \in \mathbb{R}$, 则 $p+q$ 与 αp 的次数都不超过 d (约定 $\deg 0 = -\infty$ 后, $p = -q$ 的情形也包含在内), 故八条公理按多项式的加法与数乘直接继承。而 $\{(x_1, x_2)^\top \in \mathbb{R}^2 : x_1 x_2 = 0\}$ (两条坐标轴之并) 不是向量空间: $(1, 0)^\top$ 与 $(0, 1)^\top$ 都在其中, 但它们的和 $(1, 1)^\top$ 不在。

1.2.2 子空间与判别准则

定义 1.4 (子空间) 设 V 是 $\mathbb{F}$ 上的向量空间。若 V 的子集 W 在 V 的加法与标量乘法下自身也构成 $\mathbb{F}$ 上的向量空间, 则称 W 是 V 的**子空间** (subspace)。

实际使用中依赖下面的判别准则, 它把“逐条验证八条公理”简化为“只验证一条封闭性”。

命题 1.5 (子空间判别准则) 设 V 是 $\mathbb{F}$ 上的向量空间, $W \subseteq V$ 。则

$$W \text{ 是 } V \text{ 的子空间} \iff W \neq \emptyset \text{ 且 } \alpha x + \beta y \in W, \quad \forall x, y \in W, \forall \alpha, \beta \in \mathbb{F}.$$

证明. 必要性是显然的: 子空间含零向量, 故非空; 又对加法与数乘封闭。充分性: 设 $W \neq \emptyset$ 且对加法与数乘封闭。由于 W 中的运算继承自 V , 公理 (A1)、(A2)、(A5)–(A8) 自动成立。取 $x \in W$ (W 非空), 由封闭性 $0 = 0 \cdot x \in W$, 故公理 (A3) 成立; 再由 $-x = (-1) \cdot x \in W$, 公理 (A4) 成立。于是 W 是向量空间。□

注. 非空条件不能省。若 $W = \emptyset$, “ $\alpha x + \beta y \in W$ 对一切 $x, y \in W$ ”空洞地成立, 但空集不含零向量, 不是子空间。

由此立刻得到一个常用的必要条件: 任何子空间都含有零向量。

例 1.6 (一个子空间) 在 $\mathbb{R}^3$ 中令

$$W = \{x = (x_1, x_2, x_3)^\top \in \mathbb{R}^3 : x_1 + x_2 + x_3 = 0\}.$$

由命题 1.5, W 是 $\mathbb{R}^3$ 的子空间: 记 $z = \alpha x + \beta y$, 则 $z_1 + z_2 + z_3 = \alpha(x_1 + x_2 + x_3) + \beta(y_1 + y_2 + y_3)$, 而 $x, y \in W$ 时右边两个括号都是零。又 $[1 \ 1 \ 1]x = x_1 + x_2 + x_3$, 故 $x \in W$ 当且仅当 $[1 \ 1 \ 1]x = 0$, 即

$$W = \text{Null}([1 \ 1 \ 1]).$$

例 1.7 (一个不是子空间的集合) 在 $\mathbb{R}^2$ 中令

$$S = \{x = (x_1, x_2)^\top \in \mathbb{R}^2 : x_1 + x_2 = 1\}.$$

则 S 不是 $\mathbb{R}^2$ 的子空间: $0 = (0, 0)^\top \notin S$, 因为 $0 + 0 = 0 \neq 1$ 。

注. S 虽然不构成子空间, 却有一个非常整齐的形状: 任取 $x_0 = (1, 0)^\top \in S$, 则

$$S = x_0 + \text{Null}([1 \ 1]).$$

也就是说, S 是子空间 $\text{Null}([1 \ 1])$ 平移一个特解得到的仿射子空间。这个观察将在节 1.7 中被推广成关于 $Ax = b$ 解集结构的定理, 并被节 1.11 用作讨论“ $Ax = b$ 无解时如何退而求其次”的背景。

核心思想

“ $0 \notin S$ ”是判断一个集合不是子空间最快捷的手段; 而“ $\alpha x + \beta y \in W$ ”是证明一个集合是子空间唯一要做的事。子空间必须过原点, 这是它与不过原点的仿射子空间最本质的区别。

1.3 张成、线性无关、基与维数

定义 1.8 (张成) 设 $v_1, \dots, v_m$ 是向量空间 V 中的向量。它们的全体线性组合所构成的集合

$$\text{span}\{v_1, \dots, v_m\} = \left\{ \sum_{i=1}^m c_i v_i : c_1, \dots, c_m \in \mathbb{F} \right\}$$

称为这组向量的张成 (span)。对一般的子集 $S \subseteq V$, $\text{span } S$ 定义为 S 中任意有限个向量的一切线性组合之集, 并约定 $\text{span } \emptyset = \{0\}$ 。

不难验证 $\text{span } S$ 是 V 的子空间: 若 $x, y \in \text{span } S$, $\alpha, \beta \in \mathbb{F}$, 则 $\alpha x + \beta y$ 仍是 S 中向量的有限线性组合, 故属于 $\text{span } S$, 由命题 1.5 即得。而且它是包含 S 的最小子空间: 任何包含 S 的子空间都必须包含 S 中向量的所有线性组合。

定义 1.9 (线性无关与线性相关) 称向量组 $v_1, \dots, v_m \in V$ 线性无关, 若

$$c_1 v_1 + c_2 v_2 + \dots + c_m v_m = 0 \implies c_1 = c_2 = \dots = c_m = 0.$$

否则称该向量组**线性相关**，即存在不全为零的系数 $c_1, \dots, c_m$ 使 $\sum_i c_i v_i = 0$ 。

线性相关的直观含义是“其中至少有一个向量是多余的”：若 $\sum_i c_i v_i = 0$ 且某个 $c_j \neq 0$ ，则

$$v_j = -\frac{1}{c_j} \sum_{i \neq j} c_i v_i,$$

即 v_j 可以被其余向量线性表示。

定义 1.10 (基与维数) 设 $B = \{v_1, \dots, v_n\}$ 是向量空间 V 的一个子集。若

- (1) B 线性无关；
- (2) $\text{span } B = V$ (即 B 生成 V)，

则称 B 是 V 的一组**基** (basis)，并称 V 是**有限维**的。此时称 V 的**维数**为 $\dim V = n$ ；约定**零子空间** (只含零向量的空间) $\{0\}$ 的维数为 0。

维数的定义要成立，必须先知道“不同的基含有同样多的向量”。这一点下面会给出 (定理 1.11 之后的推论)。

定理 1.11 (生成集包含基) 设 $S = \{v_1, \dots, v_m\}$ 是向量空间 V 的有限生成集, 即 $\text{span } S = V$ 。则 S 的某个子集是 V 的一组基。

证明. 若 S 已经线性无关, 则 S 本身就是基。否则由 定义 1.9, 存在不全为零的 $c_1, \dots, c_m$ 使 $\sum_{i=1}^m c_i v_i = 0$ 。取某个下标 j 使 $c_j \neq 0$, 则

$$v_j = -\frac{1}{c_j} \sum_{i \neq j} c_i v_i \in \text{span}(S \setminus \{v_j\}).$$

于是 v_j 可以被 $S \setminus \{v_j\}$ 线性表示。我们断言 $\text{span}(S \setminus \{v_j\}) = V$: 任意 $x \in V$ 写成 $x = \sum_i d_i v_i$, 再把 v_j 用它自己的表示代入, 就得到 x 的一个只用到 $S \setminus \{v_j\}$ 的线性组合。

于是从 S 中删去 v_j 后得到的更小的集合仍然生成 V 。若它线性无关, 就已是一组基; 否则重复上述删除步骤。由于 S 只有有限个元素, 过程必在有限步内终止, 终止时的集合生成 V 且线性无关, 即为 V 的一组基。□

定理 1.12 (基下坐标唯一) 设 $B = \{v_1, \dots, v_n\}$ 是 V 的一组基。则每个 $x \in V$ 都可以唯一地表示为

$$x = x_1 v_1 + x_2 v_2 + \dots + x_n v_n. \quad (1.9)$$

我们称 $(x_1, \dots, x_n)^\top \in \mathbb{F}^n$ 为 x 在基 B 下的坐标 (坐标向量)。

证明. 存在性由 $\text{span } B = V$ 直接得到。唯一性: 若

$$\sum_{i=1}^n a_i v_i = x = \sum_{i=1}^n b_i v_i,$$

则 $\sum_{i=1}^n (a_i - b_i) v_i = 0$ 。由 B 线性无关得 $a_i - b_i = 0$, 即 $a_i = b_i$ ($i = 1, \dots, n$)。□

推论 1.13 (维数唯一性) 有限维向量空间 $V \neq \{0\}$ 的任意两组基含有相同数目的向量, 故 $\dim V$ 由 V 本身唯一确定。

证明思路. 设 B_1, B_2 是 V 的两组基, $|B_1| = m, |B_2| = n$ 。由于 B_1 生成 V , B_2 的每个向量都可写成 B_1 的线性组合; 若 $n > m$, 则可推出 B_2 线性相关 (这是一个“齐次方程组未知量多于方程数必有非零解”的论证), 与 B_2 是基矛盾, 故 $n \leq m$ 。对称地 $m \leq n$, 于是 $m = n$ 。细节留作 习题 1.67。□

直观解释. 维数刻画的是向量空间“有多少个自由度”。基的选取方式有无穷多种, 但自由度的个数是空间固有的、与坐标系无关的几何量。 x 的坐标却依赖于基——同一支向量在不同基下有不同坐标, 这正是“换基”与“坐标变换”的起点。

例 1.14 (一组冗余的生成集) 在 $\mathbb{R}^3$ 中取 $v_1 = (1, 0, 1)^\top$ 、 $v_2 = (0, 1, 1)^\top$ 、 $v_3 = (1, 1, 2)^\top$ 。由于 $v_3 = v_1 + v_2$, 该向量组线性相关, 删去 v_3 后 $\{v_1, v_2\}$ 线性无关且张成同一个子空间, 故 $\text{span}\{v_1, v_2, v_3\}$ 的维数为 2 (见 习题 1.50)。

1.4 线性映射与矩阵表示

1.4.1 线性映射

定义 1.15 (线性映射) 设 V, W 是域 $\mathbb{F}$ 上的向量空间。映射 $T: V \rightarrow W$ 称为**线性映射** (或**线性变换**), 若

$$T(\alpha x + \beta y) = \alpha T(x) + \beta T(y), \quad \forall x, y \in V, \forall \alpha, \beta \in \mathbb{F}. \quad (1.10)$$

当 $W = \mathbb{F}$ 时称 T 为**线性泛函**; 当 $V = W$ 时称 T 为 V 上的**线性算子**。 $V \rightarrow W$ 的一切线性映射之集记为 $\mathcal{L}(V, W)$ 。

条件式 (1.10) 等价于同时成立的两条: 可加性 $T(x+y) = T(x)+T(y)$ 与齐次性 $T(\alpha x) = \alpha T(x)$ 。由定义立刻得到

$$T(0) = 0, \quad T\left(\sum_i c_i v_i\right) = \sum_i c_i T(v_i).$$

第二条说明: 线性映射保持一切线性组合, 因此它完全由“基上取什么值”决定。

定理 1.16 (线性映射由基上的像唯一确定) 设 V, W 是 $\mathbb{F}$ 上的向量空间, $B = \{v_1, \dots, v_n\}$ 是 V 的一组基, $w_1, \dots, w_n \in W$ 是任意给定的 n 个向量。则存在唯一的线性映射 $T: V \rightarrow W$ 使得

$$T(v_i) = w_i, \quad i = 1, \dots, n.$$

证明. 存在性. 因每个 x 的表示唯一 (定理 1.12), $T(\sum_i x_i v_i) = \sum_i x_i w_i$ 是良定义的; 由 T 保持线性组合 (式 (1.10) 下一式) 它自动线性, 且 $T(v_j) = w_j$ 。

唯一性. 若 T' 也满足 $T'(v_i) = w_i$, 则对任意 $x = \sum_i x_i v_i$ 有 $T'(x) = \sum_i x_i T'(v_i) = \sum_i x_i w_i = T(x)$, 故 $T' = T$ 。□

1.4.2 矩阵表示

固定 $V = \mathbb{F}^n$ 、 $W = \mathbb{F}^m$ ，并取 V 的标准基 $e_1, \dots, e_n$ (e_i 是第 i 个分量为 1、其余为 0 的向量)。设 $T: \mathbb{F}^n \rightarrow \mathbb{F}^m$ 线性。由定理 1.16，只要知道 $T(e_1), \dots, T(e_n)$ 就完全确定了 T 。把这 n 支向量按列排成一个 $m \times n$ 矩阵

$$A = \begin{bmatrix} T(e_1) & T(e_2) & \cdots & T(e_n) \end{bmatrix} \in \mathbb{F}^{m \times n}, \quad (1.11)$$

则对任意 $x = (x_1, \dots, x_n)^\top \in \mathbb{F}^n$,

$$T(x) = T\left(\sum_{i=1}^n x_i e_i\right) = \sum_{i=1}^n x_i T(e_i) = \begin{bmatrix} T(e_1) & \cdots & T(e_n) \end{bmatrix} \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} = Ax. \quad (1.12)$$

这里最后一步用的正是列观点式 (1.5)。

推论 1.17 (线性映射与矩阵的一一对应) $\mathbb{F}^n \rightarrow \mathbb{F}^m$ 的线性映射与 $\mathbb{F}^{m \times n}$ 的矩阵之间存在一一对应: $T \mapsto A = [T(e_1) \cdots T(e_n)]$, $A \mapsto T_A(x) = Ax$ 。特别地, $\mathcal{L}(\mathbb{F}^n, \mathbb{F}^m)$ 本身也是 $\mathbb{F}$ 上的向量空间, 且 $\dim \mathcal{L}(\mathbb{F}^n, \mathbb{F}^m) = mn$ 。

核心思想

矩阵不是一堆数字, 而是线性映射在给定基下的矩阵表示。 A 的第 j 列是 e_j 的像。理解了这一点, 矩阵乘法的可结合性 $A(BC) = (AB)C$ 、以及后面所有关于核与像的结论, 都不再需要背, 而可以“读”出来。

例 1.18 (旋转) 在 $\mathbb{R}^2$ 中, 把每个向量绕原点逆时针旋转角 θ 的映射

$$R_\theta(x_1, x_2)^\top = (x_1 \cos \theta - x_2 \sin \theta, x_1 \sin \theta + x_2 \cos \theta)^\top$$

是线性的。它的标准矩阵为

$$R_\theta = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix}, \quad (1.13)$$

即 $R_\theta = [R_\theta(e_1) \ R_\theta(e_2)] = [(\cos \theta, \sin \theta)^\top \ (-\sin \theta, \cos \theta)^\top]$ 。取 $\theta = \pi/2$ 得 $R_{\pi/2} = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}$, 它把 e_1 送到 e_2 、把 e_2 送到 $-e_1$; 这正是式 (1.11) 所说的“看列”。

注意. 并非所有自然的映射都是线性的。平移 $x \mapsto x + x_0$ ($x_0 \neq 0$) 不是线性的, 因为 $T(0) = x_0 \neq 0$; $x \mapsto x_1 x_2$ 、 $x \mapsto \|x\|_2$ 、 $x \mapsto \max_i x_i$ 也都不是线性的 (见习题 1.51 与习题 1.79)。判断线性只有一条路: 回到式 (1.10) 逐项检验。

1.5 核空间、像空间与秩

定义 1.19 (核与像) 设 $T: V \rightarrow W$ 是线性映射。称

$$\text{Ker } T = \{x \in V : T(x) = 0\} \subseteq V, \quad \text{Im } T = \{T(x) : x \in V\} \subseteq W$$

分别为 T 的**核空间** (简称核, null space) 与**像空间** (简称像, image / range)。二者分别是 V 与 W 的子空间。

核刻画“哪些输入被压成零”，像刻画“输出能落在哪里”。二者的大小之间有一个精确定量的关系，这就是线性代数中最基本的计数定理。

定理 1.20 (秩-零化度定理 (Rank-Nullity)) 设 V 是 $\mathbb{F}$ 上的有限维向量空间 ($\dim V = n < \infty$)， W 是 $\mathbb{F}$ 上任意向量空间， $T: V \rightarrow W$ 线性。则

$$\dim \text{Ker } T + \dim \text{Im } T = \dim V = n. \quad (1.14)$$

证明. 记 $k = \dim \text{Ker } T$ 。若 $k = 0$ ，取 V 的一组基 $v_1, \dots, v_n$ 。我们证明 $T(v_1), \dots, T(v_n)$ 线性无关：若 $\sum_i c_i T(v_i) = 0$ ，则由线性得 $T(\sum_i c_i v_i) = 0$ ，即 $\sum_i c_i v_i \in \text{Ker } T = \{0\}$ ，由基的线性无关性得全部 $c_i = 0$ 。又 $\text{Im } T = \text{span}\{T(v_1), \dots, T(v_n)\}$ ，故 $\dim \text{Im } T = n$ ，式 (1.14) 成立。

若 $k > 0$ ，取 $\text{Ker } T$ 的一组基 $u_1, \dots, u_k$ 。若它还不张成 V ，就不断从 V 中取出当前张成空间之外的向量添进去；由 $\dim V = n < \infty$ ，这一过程在 $n - k$ 步内必然停止，于是得到 V 的一组基

$$u_1, \dots, u_k, v_{k+1}, \dots, v_n,$$

其中 $v_{k+1}, \dots, v_n$ 是新添的 $n - k$ 个向量。下面证明 $\{T(v_{k+1}), \dots, T(v_n)\}$ 恰是 $\text{Im } T$ 的一组基。

(一) 它生成 $\text{Im } T$ 。任取 $y \in \text{Im } T$ ，有 $y = T(x)$ ，其中 $x = \sum_{i=1}^k a_i u_i + \sum_{i=k+1}^n a_i v_i$ 。由 $u_i \in \text{Ker } T$ 得

$$y = T(x) = \sum_{i=1}^k a_i T(u_i) + \sum_{i=k+1}^n a_i T(v_i) = \sum_{i=k+1}^n a_i T(v_i) \in \text{span}\{T(v_{k+1}), \dots, T(v_n)\}.$$

(二) 它线性无关。若 $\sum_{i=k+1}^n c_i T(v_i) = 0$ ，则 $T(\sum_{i=k+1}^n c_i v_i) = 0$ ，故 $z := \sum_{i=k+1}^n c_i v_i \in \text{Ker } T$ 。于是 z 可以由 $u_1, \dots, u_k$ 线性表示： $z = \sum_{i=1}^k d_i u_i$ ，即

$$\sum_{i=1}^k (-d_i) u_i + \sum_{i=k+1}^n c_i v_i = 0.$$

由 $\{u_1, \dots, u_k, v_{k+1}, \dots, v_n\}$ 是基 (线性无关) 得所有系数为零，特别是 $c_{k+1} = \dots = c_n = 0$ 。

综合 (一) (二)， $\dim \text{Im } T = n - k$ ，即 $\dim \text{Ker } T + \dim \text{Im } T = n$ 。□

推论 1.21 (矩阵形式) 设 $A \in \mathbb{R}^{m \times n}$ ，记 $T_A(x) = Ax$ 。则 $\text{Ker}(T_A) = \text{Null}(A)$ 、 $\text{Im}(T_A) =$

$\text{Col}(A)$ ，并且

$$\text{rank}(A) + \text{nullity}(A) = n, \quad (1.15)$$

其中 $\text{rank}(A) = \dim \text{Col}(A)$ 称为 A 的秩， $\text{nullity}(A) = \dim \text{Null}(A)$ 称为 A 的零化度。证明只是把式 (1.14) 用在 T_A 上： $x \in \text{Ker}(T_A)$ 当且仅当 $Ax = 0$ ，即 $\text{Ker}(T_A) = \text{Null}(A)$ ；而 $\text{Im}(T_A)$ 正是 A 的各列的一切线性组合（式 (1.5)），即 $\text{Col}(A)$ 。

直观解释. Rank-Nullity 定理说的是：定义域的 n 个自由度被分成两部分——被压掉的部分（ $\dim \text{Ker } T$ ，落在核里，对输出没有影响）与留在输出里的部分（ $\dim \text{Im } T$ ，即秩）。机器学习谈论一个模型的“有效维度”是多是少，说的就是这个分解中两项的相对大小。

1.6 矩阵的四个基本子空间

设 $A \in \mathbb{R}^{m \times n}$ 。 A 联系着两个空间： $\mathbb{R}^n$ （输入空间）与 $\mathbb{R}^m$ （输出空间）。在每个空间中， A 自然诱导出一个子空间和一个与之互补的子空间，合起来就是 Strang 所称的四个基本子空间（图 1.2）：

核心思想

$\mathbb{R}^n$ 中：行空间 $\text{Row}(A) = \text{Col}(A^T) \subseteq \mathbb{R}^n$ ，零空间 $\text{Null}(A) \subseteq \mathbb{R}^n$ ；
 $\mathbb{R}^m$ 中：列空间 $\text{Col}(A) = \text{Im}(T_A) \subseteq \mathbb{R}^m$ ，左零空间 $\text{Null}(A^T)$ (left null space) $\subseteq \mathbb{R}^m$ 。




图 1.2: 矩阵 $A \in \mathbb{R}^{m \times n}$ 的四个基本子空间及其维数 ($r = \text{rank}(A)$)

图中 $r = \text{rank}(A)$ 。 A 把行空间同构地映到列空间，把零空间整个压成 $\{0\}$ ；两个“ $\perp$ ”表示左（右）两块的元素互相正交，这正是下面的定理。

引理 1.22 (行秩等于列秩) 对任意 $A \in \mathbb{R}^{m \times n}$ ，有 $\dim \text{Row}(A) = \dim \text{Col}(A)$ 。故 $\text{rank}(A)$ 可以同时定义为行空间的维数与列空间的维数。

证明. 设 $\dim \text{Col}(A) = r$ 。交换 A 的列（这不改变行空间与列空间的维数）后不妨设 A 的前 r 列构成 $\text{Col}(A)$ 的一组基，记它们拼成的矩阵为 $A_1 \in \mathbb{R}^{m \times r}$ ，其余 $n - r$ 列拼成 A_2 ，即 $A = [A_1 \ A_2]$ 。由于 A_2 的每一列都属于 $\text{Col}(A_1) = \text{Col}(A)$ ，存在矩阵 $C \in \mathbb{R}^{r \times (n-r)}$ 使

$$A_2 = A_1 C, \quad \text{从而} \quad A = A_1 [I_r \ C].$$

于是 A 的每一行都是 $[I_r \ C]$ 的对应行的线性组合, 故 $\text{Row}(A) \subseteq \text{Row}([I_r \ C])$, 并且

$$\dim \text{Row}(A) \leq \dim \text{Row}([I_r \ C]) = r.$$

右端等号成立: $[I_r \ C] \in \mathbb{R}^{r \times n}$ 只有 r 行, 而它的前 r 列构成单位阵 I_r , 故 r 个行向量线性无关。把上述结论用于 $A^\top$ (注意 $\text{Row}(A^\top) = \text{Col}(A)$ 、 $\text{Col}(A^\top) = \text{Row}(A)$), 得 $\dim \text{Col}(A) \leq \dim \text{Row}(A)$ 。两式合并即得结论。□

定理 1.23 (线性代数基本定理, Fundamental Theorem of Linear Algebra) 设 $A \in \mathbb{R}^{m \times n}$ 。则

$$\text{Null}(A) = \text{Row}(A)^\perp, \quad \text{Null}(A^\top) = \text{Col}(A)^\perp. \quad (1.16)$$

特别地, 若 $r = \text{rank}(A)$, 则

$$\dim \text{Row}(A) = \dim \text{Col}(A) = r, \quad \dim \text{Null}(A) = n - r, \quad \dim \text{Null}(A^\top) = m - r.$$

证明. 第一步: $\text{Null}(A) = \text{Row}(A)^\perp$. 由式 (1.4), Ax 的第 i 个分量是 $\langle a_i, x \rangle$, 其中 $a_i^\top$ 是 A 的第 i 行。于是

$$x \in \text{Null}(A) \iff \langle a_i, x \rangle = 0 \quad (i = 1, \dots, m) \iff x \perp \text{span}\{a_1, \dots, a_m\} = \text{Row}(A),$$

即 $\text{Null}(A) = \text{Row}(A)^\perp$ 。一句话: $Ax = 0$ 无非是说 x 与 A 的每一行都正交。

第二步: $\text{Null}(A^\top) = \text{Col}(A)^\perp$. 把第一步用于 $A^\top$ (其行空间是 $\text{Col}(A)$) 即得。

第三步: 维数. 由引理 1.22, $\dim \text{Row}(A) = \dim \text{Col}(A) = r$ 。由矩阵形式的 Rank-Nullity (式 (1.15)) 得 $\dim \text{Null}(A) = n - r$; 再把它用于 $A^\top \in \mathbb{R}^{n \times m}$ 得 $\dim \text{Null}(A^\top) = m - r$ 。□

直观解释. 式 (1.16) 说的是: 零空间恰好是行空间的正交补。这为“ $Ax = 0$ 为什么难解、何时会有非零解”提供了一个几何图像—— $\text{Null}(A)$ 就是 $\mathbb{R}^n$ 中垂直于行空间的那一部分, 而 $\text{rank}(A)$ 量度的则是行空间“有多厚”。

AI 应用

问题: 一个 1000×1000 的权重矩阵能不能用一个更小的矩阵表示?

精确低秩分解: 若 $\text{rank}(W) = r \ll 1000$, 则存在列满秩的 $U, V \in \mathbb{R}^{1000 \times r}$ 使 $W = UV^\top$ 精确成立 (把 SVD $W = U_r \Sigma_r V_r^\top$ 中的 Σ_r 吸收进 U_r 或 V_r 即可), 这一步没有任何信息损失。

低秩近似: 但真实的权重矩阵通常不是精确低秩的, 此时只能追求近似 $W \approx U_r \Sigma_r V_r^\top$, 其最优解由截断 SVD 给出。这里“=”与“ $\approx$ ”的区别是本质的: 前者是分解, 后者是压缩, 必然伴随误差; 能否压缩取决于 W 的奇异值衰减得多快, 而不是它是否严格低秩。

理论联系: “秩低”意味着 W 的所有列都躺在一个低维子空间 $\text{Col}(W)$ 中 (引理 1.22), 因此输出永远无法铺满整个 $\mathbb{R}^{1000}$ 。

LoRA 的位置: 参数高效微调中的 LoRA 用的不是上面的“分解”, 而是“增量的低秩参数化”:

$$W = W_0 + \Delta W, \quad \Delta W = UV^\top, \quad U, V \in \mathbb{R}^{1000 \times r},$$

训练时 W_0 冻结、只学习 U 与 V 。这里被低秩参数化的是 ΔW 而不是 W 本身： W_0 一般满秩， W 也随之满秩；低秩只是对“改动量”的假设——微调所需要调整的方向往往比整个权重空间少得多。

1.7 线性方程组的结构

现在用“列观点”与“核”给出 $Ax = b$ 的可解性与解集的完整描述。这是本章第一次把前面的抽象概念转化为一个可以直接使用的定理。

定理 1.24 ($Ax = b$ 的相容性判据) 设 $A \in \mathbb{R}^{m \times n}$ 、 $b \in \mathbb{R}^m$ 。线性方程组 $Ax = b$ 有解当且仅当

$$b \in \text{Col}(A),$$

即 b 可以写成 A 的各列的一个线性组合。证明即式 (1.5)： $Ax = x_1 a_1 + \cdots + x_n a_n$ ，所以“存在 x 使 $Ax = b$ ”与“存在系数使 $b = \sum_i x_i a_i$ ”是同一句话。

定理 1.25 (解集的结构) 设 $A \in \mathbb{R}^{m \times n}$ 、 $b \in \mathbb{R}^m$ 。若 $x_0 \in \mathbb{R}^n$ 是 $Ax = b$ 的任一特解（即 $Ax_0 = b$ ），则方程组的解集恰为

$$\{x \in \mathbb{R}^n : Ax = b\} = x_0 + \text{Null}(A) = \{x_0 + z : z \in \text{Null}(A)\}. \quad (1.17)$$

反之，若解集非空，则它是 $\text{Null}(A)$ 的一个平移。

证明. (⊇) 设 $x = x_0 + z$ ，其中 $z \in \text{Null}(A)$ 。由线性性 $Ax = Ax_0 + Az = b + 0 = b$ ，故 x 是解。

(⊆) 设 $Ax = b$ 。令 $z = x - x_0$ ，则

$$Az = A(x - x_0) = Ax - Ax_0 = b - b = 0,$$

故 $z \in \text{Null}(A)$ ，从而 $x = x_0 + z$ 属于右端集合。□

注. 以上两个定理完全回答了“ $Ax = b$ 什么时候有解、解长什么样”，却没有给出如何计算一个解。实际计算依靠 Gaussian 消元法：对增广矩阵 $[A \ b]$ 做初等行变换化为行阶梯形，据此判断 $b \in \text{Col}(A)$ 是否成立，并读出特解与零空间的一组基。Gaussian 消元是数值线性代数的入门工具，但不属于本章主线，故仅作复习性提及。（第 3 章将说明为什么在实践中更愿意用 QR 分解或 SVD 求解。）

直观解释. 把式 (1.17) 与例 1.7 对照：那个不是子空间的集合 $S = \{x_1 + x_2 = 1\}$ 恰恰是 $\text{Null}([1 \ 1])$ 平移一个特解得到的。一般的线性方程组，只要把非齐次项移到右边，解集总是“一个仿射子空间”。“自由变量”的说法只是这一结构的坐标表述：自由变量的个数就是 $\text{nullity}(A) = n - \text{rank}(A)$ 。一句话记法：**通解 = 特解 + 齐次通解**；其中特解反映 b 在 $\text{Col}(A)$ 中的位置，齐次通解则是 A 压掉的方向，与 b 无关。

1.8 内积、正交补与直和

前面的讨论只用了“加法与数乘”，还没有用到 $\mathbb{R}^n$ 上的长度与角度。现在补上这一结构，它是投影与最小二乘的全部基础。

定义 1.26 (欧氏内积与正交) 对 $x, y \in \mathbb{R}^n$ ，定义欧氏内积

$$\langle x, y \rangle = x^\top y = \sum_{i=1}^n x_i y_i \in \mathbb{R},$$

并称 $\|x\|_2 = \sqrt{\langle x, x \rangle}$ 为 x 的欧氏范数。若 $\langle x, y \rangle = 0$ ，则称 x 与 y 正交，记作 $x \perp y$ 。

内积满足：对称性 $\langle x, y \rangle = \langle y, x \rangle$ ；对每个变元线性 $\langle \alpha x + \beta z, y \rangle = \alpha \langle x, y \rangle + \beta \langle z, y \rangle$ ；正定性 $\langle x, x \rangle \geq 0$ 且等号只在 $x = 0$ 时成立。由正定性可得 $\|x\|_2 = 0 \iff x = 0$ 。

定义 1.27 (正交补) 设 $M \subseteq \mathbb{R}^n$ 是任一子集，称

$$M^\perp = \{x \in \mathbb{R}^n : \langle x, y \rangle = 0, \forall y \in M\}$$

为 M 的正交补。

可以验证：无论 M 本身是不是子空间， $M^\perp$ 总是 $\mathbb{R}^n$ 的子空间。并且显然 $M \subseteq (M^\perp)^\perp$ ；当 M 本身是子空间时，二者相等。

为了证明 $\mathbb{R}^n$ 可以被一个子空间与其正交补“拼起来”，我们需要“每个子空间都有标准正交基”这一事实。

引理 1.28 (Gram-Schmidt 正交化) 设 $M \subseteq \mathbb{R}^n$ 是子空间， $\dim M = k \geq 1$ 。则存在 M 的一组标准正交基 $q_1, \dots, q_k$ ，即 $\langle q_i, q_j \rangle = \delta_{ij}$ ($i = j$ 时为 1，否则为 0) 且 $\text{span}\{q_1, \dots, q_k\} = M$ 。

证明. 取 M 的一组基 $a_1, \dots, a_k$ (定义 1.10)，按 $j = 1, 2, \dots, k$ 递归地定义

$$v_j = a_j - \sum_{i=1}^{j-1} \langle a_j, q_i \rangle q_i, \quad q_j = \frac{v_j}{\|v_j\|_2}.$$

归纳假设为： $\{q_1, \dots, q_{j-1}\}$ 标准正交，且 $\text{span}\{q_1, \dots, q_{j-1}\} = \text{span}\{a_1, \dots, a_{j-1}\}$ ($j = 1$ 时两者均为空，结论显然)。此时求和项落在 $\text{span}\{a_1, \dots, a_{j-1}\}$ 内，故若 $v_j = 0$ 则 $a_j \in \text{span}\{a_1, \dots, a_{j-1}\}$ ，与基的线性无关性矛盾；于是 $v_j \neq 0$ ， q_j 有意义。

再验证正交性。对 $i < j$ ，用归纳假设中的 $\langle q_l, q_i \rangle = \delta_{li}$ ，

$$\langle v_j, q_i \rangle = \langle a_j, q_i \rangle - \sum_{l=1}^{j-1} \langle a_j, q_l \rangle \langle q_l, q_i \rangle = \langle a_j, q_i \rangle - \langle a_j, q_i \rangle = 0,$$

故 $\langle q_j, q_l \rangle = 0$ ($l < j$) 且 $\langle q_j, q_j \rangle = 1$ ，归纳成立。最后， $q_j \in \text{span}\{a_1, \dots, a_j\}$ 保证张成空间不变，故 $\text{span}\{q_1, \dots, q_k\} = M$ 。□

定义 1.29 (直和) 设 U, W 是向量空间 V 的子空间。若每个 $x \in V$ 都能唯一地写成

$$x = u + w, \quad u \in U, w \in W,$$

则称 V 是 U 与 W 的直和, 记作 $V = U \oplus W$ 。等价的说法是: $V = U + W$ 且 $U \cap W = \{0\}$ 。

定理 1.30 (正交分解) 设 $M \subseteq \mathbb{R}^n$ 是子空间。则

$$\mathbb{R}^n = M \oplus M^\perp. \quad (1.18)$$

特别地, $\dim M + \dim M^\perp = n$ 。

证明. 交集为 $\{0\}$. 若 $x \in M \cap M^\perp$, 则 $\langle x, x \rangle = 0$ (因为 $x \in M$ 且 x 与 M 中一切向量正交), 由内积正定性得 $x = 0$ 。

和为 $\mathbb{R}^n$. 若 $M = \{0\}$ 则结论显然。否则取 M 的一组标准正交基 $q_1, \dots, q_k$ (引理 1.28)。对任意 $x \in \mathbb{R}^n$, 令

$$p = \sum_{i=1}^k \langle x, q_i \rangle q_i \in M, \quad r = x - p. \quad (1.19)$$

对每个 $j = 1, \dots, k$, 由标准正交性

$$\langle r, q_j \rangle = \langle x, q_j \rangle - \sum_{i=1}^k \langle x, q_i \rangle \langle q_i, q_j \rangle = \langle x, q_j \rangle - \langle x, q_j \rangle = 0.$$

由于 $q_1, \dots, q_k$ 张成 M , 任何 $y = \sum_j c_j q_j \in M$ 都满足 $\langle r, y \rangle = \sum_j c_j \langle r, q_j \rangle = 0$, 故 $r \in M^\perp$ 。于是 $x = p + r$ 落在 $M + M^\perp$ 中。

唯一性. 若 $x = u + w = u' + w'$ 是两种分解, 则 $u - u' = w' - w \in M \cap M^\perp = \{0\}$, 故 $u = u'$ 、 $w = w'$ 。因此 $\mathbb{R}^n = M \oplus M^\perp$ 。取两边的基拼起来即得 $n = \dim M + \dim M^\perp$ 。□

直观解释. 式 (1.18) 是“ $\mathbb{R}^n$ 可以按任意子空间 M 拆成两块互相垂直的部分”的严格表述。式 (1.19) 里的 p 就是把 x 在 M 的每个基向量方向上的投影分量分别取出、再重新组装起来, 这正是下一节正交投影的显式公式。

1.9 正交投影

定理 1.31 (投影定理) 设 $M \subseteq \mathbb{R}^n$ 是子空间。则对任意 $x \in \mathbb{R}^n$, 存在唯一的分解

$$x = \hat{x} + r, \quad \hat{x} \in M, \quad r \in M^\perp, \quad (1.20)$$

其中 $\hat{x}$ 由式 (1.19) 给出。进一步, $\hat{x}$ 是 M 中在欧氏范数下距 x 最近的点, 即

$$\hat{x} = \arg \min_{y \in M} \|x - y\|_2, \quad (1.21)$$

并且这个最小点是唯一的。

证明. 存在唯一性就是定理 1.30 的内容: $\mathbb{R}^n = M \oplus M^\perp$.

最小距离性质. 任取 $y \in M$. 因为 $\hat{x} - y \in M$ 、 $r = x - \hat{x} \in M^\perp$, 所以 $\hat{x} - y \perp r$. 由勾股定理 ($\|a + b\|_2^2 = \|a\|_2^2 + \|b\|_2^2$, 当 $a \perp b$) 得

$$\|x - y\|_2^2 = \|(x - \hat{x}) + (\hat{x} - y)\|_2^2 = \|r\|_2^2 + \|\hat{x} - y\|_2^2 \geq \|r\|_2^2 = \|x - \hat{x}\|_2^2. \quad (1.22)$$

等号成立当且仅当 $\|\hat{x} - y\|_2 = 0$, 即 $y = \hat{x}$. 因此 $\hat{x}$ 是唯一的最近点. $\square$

定义 1.32 (正交投影) 称式 (1.20) 中的 $\hat{x}$ 为 x 在 M 上的正交投影, 记作

$$\hat{x} = \text{proj}_M x = P_M x.$$

映射 $P_M : \mathbb{R}^n \rightarrow \mathbb{R}^n$ 称为到 M 的正交投影算子; 式 (1.20) 中的 $r = x - P_M x$ 称为残差 (residual). 当 $M = \text{span}\{u\}$ ($u \neq 0$) 是一条直线时, 式 (1.20) 给出闭式

$$\text{proj}_u x = \frac{\langle u, x \rangle}{\langle u, u \rangle} u = \frac{u^\top x}{u^\top u} u. \quad (1.23)$$

验证只需一步: 记右端为 $\hat{x}$, 则 $\hat{x} \in \text{span}\{u\}$, 且 $u^\top(x - \hat{x}) = u^\top x - \frac{u^\top x}{u^\top u} u^\top u = 0$, 由定理 1.31 中分解的唯一性即得. 它也是后面的一般公式 $P = QQ^\top$ 在 $k=1$ 时的特例.

例 1.33 (投影到一条直线) 取 $u = (1, 2)^\top$ 、 $x = (3, 1)^\top \in \mathbb{R}^2$. 则 $\langle u, x \rangle = 1 \cdot 3 + 2 \cdot 1 = 5$, $\langle u, u \rangle = 1^2 + 2^2 = 5$, 故

$$\hat{x} = \text{proj}_u x = \frac{5}{5} \begin{bmatrix} 1 \\ 2 \end{bmatrix} = \begin{bmatrix} 1 \\ 2 \end{bmatrix} = u, \quad r = x - \hat{x} = \begin{bmatrix} 3 \\ 1 \end{bmatrix} - \begin{bmatrix} 1 \\ 2 \end{bmatrix} = \begin{bmatrix} 2 \\ -1 \end{bmatrix}.$$

验证正交性: $\langle u, r \rangle = 1 \cdot 2 + 2 \cdot (-1) = 0$. 于是 $\|x\|_2^2 = 10 = \|\hat{x}\|_2^2 + \|r\|_2^2 = 5 + 5$, 与式 (1.22) 一致. 图 1.3 画出了这一投影的几何图像: 线段 $x\hat{x}$ (其长度即残差向量 $r = x - \hat{x}$ 的模 $\|r\|_2$) 是 x 到 M 的最短路径, 而 M 上任何别的点 (例如 y) 到 x 的距离都严格更长, 这正是勾股论证的直观内容.




图 1.3: $x = (3, 1)^\top$ 到直线 $M = \text{span}\{(1, 2)^\top\}$ 的正交投影: 垂线段 $x\hat{x}$ 最短, 而 M 上任何其他点 y 满足 $\|x - y\|_2 > \|x - \hat{x}\|_2$

直观解释. 投影定理的几何意义可以用一句话概括: “**直线段最短**”. 从 x 走向子空间 M 的任何一条路径都可以按勾股定理拆成 “垂直于 M 的那一段” 与 “在 M 内的那一段”, 只有

前者不可压缩。因此垂足 $\hat{x}$ 是唯一的最近点，而在式 (1.22) 中，被丢弃的 $\|r\|_2^2$ 就是近似的“代价”。

1.10 投影矩阵

投影算子 P_M 是 $\mathbb{R}^n \rightarrow \mathbb{R}^n$ 的线性映射，因此有矩阵表示；我们把它称为投影矩阵，仍记作 $P_M \in \mathbb{R}^{n \times n}$ 。

1.10.1 标准正交基给出的公式

定理 1.34 设 $Q \in \mathbb{R}^{n \times k}$ 的列向量标准正交，即 $Q^\top Q = I_k$ 。则 $P = QQ^\top \in \mathbb{R}^{n \times n}$ 是到子空间 $\text{Col}(Q)$ 的正交投影矩阵。

证明. 记 $Q = [q_1 \cdots q_k]$ ，则 $q_1, \dots, q_k$ 是 $\text{Col}(Q)$ 的一组标准正交基。由 $Q^\top Q = I_k$ 直接得 $P^2 = Q(Q^\top Q)Q^\top = P$ 与 $P^\top = P$ 。又

$$Px = \sum_{i=1}^k q_i(q_i^\top x) = \sum_{i=1}^k \langle x, q_i \rangle q_i$$

正是式 (1.19) 中的 $\hat{x}$ ，故 Px 是 x 在 $\text{Col}(Q)$ 上的正交投影；且 $y = Qz \in \text{Col}(Q)$ 时 $P y = Q(Q^\top Q)z = y$ ，故 $\text{Col}(P) = \text{Col}(Q)$ 。□

注. 在上面的记号下， $I - P$ 是到 $\text{Col}(Q)^\perp$ 的正交投影。一般地，若 P 是到 M 的正交投影矩阵，则 $I - P$ 是到 $M^\perp$ 的正交投影矩阵。

1.10.2 一般列空间上的投影

定理 1.35 (正交投影矩阵的显式公式) 设 $A \in \mathbb{R}^{m \times n}$ 满列秩 (即 $\text{rank}(A) = n$ ，特别地 $n \leq m$)。则 $A^\top A$ 可逆，且

$$P = A(A^\top A)^{-1}A^\top \in \mathbb{R}^{m \times m} \quad (1.24)$$

是到 $\text{Col}(A)$ 的正交投影矩阵。

证明. $A^\top A$ 可逆. 设 $z \in \text{Null}(A^\top A)$ ，则 $0 = z^\top A^\top A z = \|Az\|_2^2$ ，故 $Az = 0$ ，即 $z \in \text{Null}(A) = \{0\}$ (满列秩)。于是 $\text{Null}(A^\top A) = \{0\}$ ，由 Rank-Nullity (式 (1.15)) 方阵 $A^\top A$ 的秩为 n ，故可逆。

P 是正交投影. $A^\top A$ 对称，其逆也对称，于是直接验证

$$P^2 = A(A^\top A)^{-1}A^\top = P, \quad P^\top = A(A^\top A)^{-1}A^\top = P.$$

又 $\text{Col}(P) \subseteq \text{Col}(A)$ ；反过来对任意 $y = Az \in \text{Col}(A)$ 有 $P y = A(A^\top A)^{-1}(A^\top A)z = y$ ，故 $\text{Col}(P) = \text{Col}(A)$ 。于是 P 是幂等且对称的矩阵，且值域为 $\text{Col}(A)$ ，由下一小节的刻画 (定

理 1.37) 它就是到 $\text{Col}(A)$ 的正交投影矩阵。 $\square$

1.10.3 正交投影矩阵的刻画

定义 1.36 (投影矩阵与正交投影矩阵) 称 $P \in \mathbb{R}^{n \times n}$ 为**投影矩阵** (幂等矩阵), 若 $P^2 = P$; 若进一步满足 $P^\top = P$, 则称 P 为**正交投影矩阵**。

注意“投影矩阵”比定义 1.32 的“正交投影”宽: 任何幂等矩阵都是投影矩阵, 但只有对称的幂等矩阵才给出正交投影; 不对称的幂等矩阵给出的是沿某个倾斜方向的投影。

定理 1.37 设 $P \in \mathbb{R}^{n \times n}$ 。则 P 是到某子空间 M 的正交投影矩阵 (即 $Px = \text{proj}_M x$ 对一切 x 成立) 当且仅当

$$P^2 = P \quad \text{且} \quad P^\top = P. \quad (1.25)$$

此时 $M = \text{Col}(P)$, 并且 $\text{Null}(P) = \text{Col}(P)^\perp$ 。

证明. (必要性) 设 $P = P_M$, 则对任意 x 有 $Px \in M$ 、 $x - Px \in M^\perp$ 。幂等: $Px \in M$ 在投影下不动, 故 $P^2x = Px$ 。对称: 把 $y = Py + (y - Py)$ 与 $x = Px + (x - Px)$ 分别代入 $\langle Px, y \rangle$ 与 $\langle x, Py \rangle$, 两个正交项 $\langle Px, y - Py \rangle$ 与 $\langle x - Px, Py \rangle$ 都为零, 于是

$$\langle Px, y \rangle = \langle Px, Py \rangle = \langle x, Py \rangle,$$

即 $P^\top = P$ 。

(充分性) 设 $P^2 = P$ 、 $P^\top = P$, 令 $M = \text{Col}(P)$ 。显然 $Px \in M$; 又对任意 $y = Pz \in M$,

$$\langle y, x - Px \rangle = z^\top P^\top (I - P)x = z^\top (P - P^2)x = 0,$$

故 $x - Px \perp M$ 。于是 $x = Px + (x - Px)$ 是 x 关于 M 的正交分解, 由定理 1.31 中分解的唯一性得 $Px = \text{proj}_M x$ 。再由 $\text{Null}(P^\top) = \text{Col}(P)^\perp$ 与 $P = P^\top$ 得 $\text{Null}(P) = \text{Col}(P)^\perp$ 。 $\square$

核心思想

式 (1.25) 把“几何上的正交投影”翻译成了两条纯代数的等式: **幂等** ($P^2 = P$, 投影两次等于投影一次) 与 **对称** ($P^\top = P$, 投影方向与残差方向垂直)。反过来说, 一个幂等矩阵只要不对称, 它就是一个“斜投影”, 其残差不再垂直于像空间。

1.11 最小二乘

定义 1.38 (最小二乘问题) 给定 $A \in \mathbb{R}^{m \times n}$ 与 $b \in \mathbb{R}^m$, 称

$$\mathcal{S}_{\text{LS}} = \arg \min_{x \in \mathbb{R}^n} \|Ax - b\|_2^2 = \left\{ x \in \mathbb{R}^n : \|Ax - b\|_2^2 = \min_{z \in \mathbb{R}^n} \|Az - b\|_2^2 \right\} \quad (1.26)$$

为**最小二乘问题**, 并称其中任一元素 $\hat{x} \in \mathcal{S}_{\text{LS}}$ 为它的**最小二乘解**。按本章约定第 4 条, $\arg \min$ 表示的是**解集**而非某个点: 当 A 不满列秩时 $\mathcal{S}_{\text{LS}}$ 含无穷多个元素, 写 $\hat{x} = \arg \min \cdots$ 只是

习惯记法。当 $m > n$ 时方程个数多于未知量， $Ax = b$ 一般无解 ($b \notin \text{Col}(A)$)，最小二乘退而求其次：找一个 x 使 Ax 在欧氏范数下最接近 b 。

1.11.1 先看几何：残差必须垂直于列空间

由式 (1.5)，当 x 跑遍 $\mathbb{R}^n$ 时 Ax 跑遍子空间 $\text{Col}(A)$ ；被最小化的量是 $\|Ax - b\|_2^2$ ，即 b 到点 $Ax \in \text{Col}(A)$ 的距离的平方。于是式 (1.26) 等价于

$$\text{在 } \text{Col}(A) \text{ 中找距 } b \text{ 最近的点, 其解为 } A\hat{x} = P_{\text{Col}(A)}b. \quad (1.27)$$

由定理 1.31，这个最近点是 $\text{Col}(A)$ 上唯一的正交投影点。记残差

$$r = b - A\hat{x}.$$

由于 $A\hat{x} = \text{proj}_{\text{Col}(A)} b$ ，式 (1.20) 直接给出

$$r = b - A\hat{x} \in \text{Col}(A)^\perp. \quad (1.28)$$

由线性代数基本定理（式 (1.16)）， $\text{Col}(A)^\perp = \text{Null}(A^\top)$ ，于是式 (1.28) 等价于

$$A^\top r = 0 \iff A^\top(b - A\hat{x}) = 0 \iff A^\top A\hat{x} = A^\top b.$$

图 1.4 给出了这一几何图像： $\text{Col}(A)$ 是 $\mathbb{R}^m$ 中的一个子空间， b 一般不落在其中； $A\hat{x}$ 是 b 在 $\text{Col}(A)$ 上的正交投影，残差 $r = b - A\hat{x}$ 垂直于 $\text{Col}(A)$ 。若换成别的 x ，点 Ax 虽然在 $\text{Col}(A)$ 内，但连接点 Ax 与 b 的线段是斜的， $\|Ax - b\|_2$ 严格更长。




图 1.4: 最小二乘的几何解释: 在 $\text{Col}(A)$ 中寻找距 b 最近的点, 即正交投影 $A\hat{x}$; 残差 $r = b - A\hat{x}$ 垂直于 $\text{Col}(A)$, 而 $\text{Col}(A)$ 中任何其他点 (如 Ax) 到 b 的距离都更长

核心思想

最小二乘的全部内容就是一句话：残差垂直于列空间。从“ $r \perp \text{Col}(A)$ ”出发，只需一行代数就得到正规方程 $A^\top A\hat{x} = A^\top b$ 。反过来，对正规方程求导所得到的驻点条件，本质上与这个几何事实等价。先几何、后求导，是本教材处理最小二乘的一贯顺序。

定理 1.39 (正规方程) 设 $A \in \mathbb{R}^{m \times n}$ 、 $b \in \mathbb{R}^m$ 。则最小二乘问题的解集 式 (1.26) 恰为正规

方程

$$A^T Ax = A^T b \quad (1.29)$$

的解集, 即

$$\mathcal{S}_{LS} = \{x \in \mathbb{R}^n : A^T Ax = A^T b\}.$$

该集合总是非空; 并且其中所有元素都给出同一个拟合值 $A\hat{x} = P_{\text{Col}(A)}b$ 。

证明. 等价性. $\hat{x}$ 满足式 (1.29) 即 $A^T(b - A\hat{x}) = 0$, 也就是 $b - A\hat{x} \in \text{Null}(A^T) = \text{Col}(A)^\perp$ 。于是 $A\hat{x} \in \text{Col}(A)$ 与 $b - A\hat{x}$ 构成 b 关于 $\text{Col}(A)$ 的正交分解, 由定理 1.31 中分解的唯一性得 $A\hat{x} = \text{proj}_{\text{Col}(A)} b$, 故 $\hat{x}$ 是最小二乘解; 反之由同样的几何论证即得式 (1.29)。

存在性. 只需证明 $A^T b \in \text{Col}(A^T A)$, 而这由 $\text{Col}(A^T A) = \text{Col}(A^T)$ 保证。包含关系 $\subseteq$ 显然; 反过来, 若 $A^T Az = 0$, 则 $0 = z^T A^T Az = \|Az\|_2^2$, 故 $Az = 0$, 即 $\text{Null}(A^T A) = \text{Null}(A)$ 。于是由 Rank-Nullity 与引理 1.22,

$$\text{rank}(A^T A) = n - \dim \text{Null}(A^T A) = n - \dim \text{Null}(A) = \text{rank}(A) = \text{rank}(A^T),$$

两个列空间维数相同且一个包含另一个, 故相等。

拟合值唯一. 若 $\hat{x}_1, \hat{x}_2$ 都是解, 则 $A(\hat{x}_1 - \hat{x}_2)$ 同时属于 $\text{Col}(A)$ 与 $\text{Null}(A^T) = \text{Col}(A)^\perp$, 故为零。□

1.11.2 满列秩时的唯一解

定理 1.40 (最小二乘解的唯一性) 设 $A \in \mathbb{R}^{m \times n}$ 满列秩 ($\text{rank}(A) = n$), $b \in \mathbb{R}^m$ 。则最小二乘问题式 (1.26) 有唯一解

$$\hat{x} = (A^T A)^{-1} A^T b = A^+ b, \quad (1.30)$$

其中 A^+ 是 A 的 Moore-Penrose 伪逆, 在满列秩情形下它恰有显式公式

$$A^+ = (A^T A)^{-1} A^T, \quad \text{且} \quad A^+ A = I_n.$$

此时拟合值、投影矩阵与残差分别为

$$A\hat{x} = Pb, \quad P = A(A^T A)^{-1} A^T, \quad r = (I - P)b,$$

并且 $A^T r = 0$ 、 $\|b\|_2^2 = \|A\hat{x}\|_2^2 + \|r\|_2^2$ 。

证明. 由定理 1.35, $A^T A$ 可逆, 故正规方程式 (1.29) 的解存在且唯一, 就是式 (1.30)。又由定理 1.35, $P = A(A^T A)^{-1} A^T$ 是到 $\text{Col}(A)$ 的正交投影, 于是 $A\hat{x} = A(A^T A)^{-1} A^T b = Pb = \text{proj}_{\text{Col}(A)} b$, 并且

$$r = b - A\hat{x} = b - Pb = (I - P)b \in \text{Col}(P)^\perp = \text{Col}(A)^\perp.$$

$\text{Col}(A)$ 中的向量可以写成 Az 的形式, 因此 $r \perp \text{Col}(A)$ 与 $A^T r = 0$ 等价; 正交分解的勾股定理给出最后一条范数等式。□

注 (不满列秩时如何选解). 若 A 不满列秩, 则 $\text{Null}(A) \neq \{0\}$, 于是由 定理 1.25, 最小二乘解构成一个仿射集合

$$\mathcal{S}_{\text{LS}} = \hat{x}_0 + \text{Null}(A),$$

解不唯一 (但由 定理 1.39, 所有解对应同一个拟合值 $A\hat{x} = P_{\text{Col}(A)}b$). 若还想挑出唯一的 $\hat{x}$, 需要附加一个准则; 最常用的准则是 “取范数最小者”:

$$x_{\min} = \arg \min_{x \in \mathcal{S}_{\text{LS}}} \|x\|_2. \quad (1.31)$$

这个唯一的解恰好是 $x_{\min} = A^+b$.

按本章约定第 6 条, A^+ 是 Moore–Penrose 伪逆, 对任意矩阵都存在且唯一; 满列秩时式 (1.30) 的公式只是它便于手算的特例 (一般情形由 SVD 给出, 见第 3 章). 因此 A 不满列秩时问题不在于 A^+ 不存在, 而在于 $(A^T A)^{-1}A^T$ 这个公式失效了.

例 1.41 (最小二乘直线拟合) 给定三个数据点 $(0, 1)$ 、 $(1, 2)$ 、 $(2, 2)$, 用直线 $y = \beta_0 + \beta_1 x$ 拟合. 把模型写成 $A\beta = b$:

$$A = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{bmatrix}, \quad \beta = \begin{bmatrix} \beta_0 \\ \beta_1 \end{bmatrix}, \quad b = \begin{bmatrix} 1 \\ 2 \\ 2 \end{bmatrix}.$$

(A 的第一列是全 1 向量, 对应截距 β_0 ; 第二列是自变量取值, 对应斜率 β_1 .) 计算

$$A^T A = \begin{bmatrix} 3 & 3 \\ 3 & 5 \end{bmatrix}, \quad A^T b = \begin{bmatrix} 5 \\ 6 \end{bmatrix}.$$

解正规方程 $\begin{bmatrix} 3 & 3 \\ 3 & 5 \end{bmatrix} \begin{bmatrix} \beta_0 \\ \beta_1 \end{bmatrix} = \begin{bmatrix} 5 \\ 6 \end{bmatrix}$: 两式相减得 $2\beta_1 = 1$, 故

$$\beta_1 = \frac{1}{2}, \quad \beta_0 = \frac{5 - 3 \cdot \frac{1}{2}}{3} = \frac{7}{6}.$$

于是最佳拟合直线为 $y = \frac{7}{6} + \frac{1}{2}x$, 拟合值为

$$A\hat{\beta} = \left(\frac{7}{6}, \frac{5}{3}, \frac{13}{6}\right)^T, \quad r = b - A\hat{\beta} = \left(-\frac{1}{6}, \frac{1}{3}, -\frac{1}{6}\right)^T.$$

直接验证 $A^T r = (\sum_i r_i, \sum_i x_i r_i)^T = (0, 0)^T$: 这就是 式 (1.28) 所说的 “残差垂直于列空间”. 从几何上看, $A^T r = 0$ 的第一个分量说明残差之和为零, 第二个分量说明残差关于自变量的加权和为零——最小二乘把误差 “平均地” 分给了三个点. 图 1.5 画出了这组数据与最佳拟合直线: 三个点到直线的竖直小段正是残差分量: 记拟合值 $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$, 则

$$r_i = y_i - \hat{y}_i = y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i).$$

最小二乘让 $\sum_i r_i^2$ 最小, 并使正、负残差恰好抵消.




图 1.5: 例 1.41 的数据点与最小二乘拟合直线 $y = \frac{7}{6} + \frac{1}{2}x$: 竖直虚线段为各点的残差分量, 最小二乘使 $\sum_i r_i^2$ 最小

注 (为什么实践中不用 $(A^\top A)^{-1}$). 公式 (1.30) 在数学上是完美的, 但直接计算 $(A^\top A)^{-1}$ 在数值上是不明智的: 形成 $A^\top A$ 会把条件数平方化,

$$\kappa_2(A^\top A) = \kappa_2(A)^2$$

(见习题 1.61), 这会显著放大舍入误差。实践中通常先做 QR 分解 $A = QR$ (Q 列正交、 R 为上三角), 于是

$$\hat{x} = R^{-1}Q^\top b,$$

或者用 SVD 得到伪逆 A^+ 。这样既可以避免条件数平方化, 也能自然地处理 A 不满列秩的情形。这一数值视角将在第 3 章系统展开。

1.12 特征映射

前面的线性模型有一个天然局限: 决策面必须是平直的 (直线、平面、超平面)。许多实际问题中类别之间的分界是弯曲的, 此时“先把数据搬到另一个空间, 再在新空间里做线性方法”是标准套路。搬到新空间所依赖的映射, 就是**特征映射**。

定义 1.42 (特征映射) 设 $\mathcal{X}$ 是原始输入集合 (例如 $\mathcal{X} = \mathbb{R}^d$), $\mathcal{H}$ 是一个配备了内积的向量空间 (称为**特征空间**)。映射

$$\phi: \mathcal{X} \rightarrow \mathcal{H}, \quad x \mapsto \phi(x)$$

称为**特征映射**。 $\phi(x)$ 称为 x 的**特征表示** (feature representation, 文献中也作 feature vector)。

注意

特征映射 ϕ 一般不是线性映射。线性映射必须定义在向量空间上、并且满足 $T(\alpha x + \beta y) = \alpha T(x) + \beta T(y)$ (式 (1.10))。而特征映射

- 其定义域 $\mathcal{X}$ 可以只是任意集合 (例如字符串集合、图的集合), 并不必是向量空间;
- 即使 $\mathcal{X} = \mathbb{R}^d$, 也可以不满足线性性。例如 $\phi(x) = (x_1^2, x_2^2)^\top$ 满足 $\phi(2x) = 4\phi(x) \neq 2\phi(x)$, 因此不是线性的。

定义 1.15 中的线性变换与这里的特征映射是两个不同层次的概念: 前者是“保持结构的映射”, 后者是“把数据搬到更好用的空间去的映射”。二者唯一的联系是: 在特征空间

里我们依旧使用线性方法（线性分类、线性回归、内积），于是线性代数的结论全部可以复用。

最后提醒一个术语上的巧合：这里的“特征”来自机器学习的 *feature*，与线性代数中 *eigen*-系列译作“特征值”“特征向量”的“特征”只是中文译名相同，含义毫无关系（见本章约定）。后者属于特征值理论，将在第 3 章出现。

例 1.43 (XOR: 一个线性不可分的例子) 取四个样本

$$(1, 1)^T, (-1, -1)^T \text{ 属于类 } +1, \quad (1, -1)^T, (-1, 1)^T \text{ 属于类 } -1.$$

在 $\mathbb{R}^2$ 中，任何一条直线都不能把两类分开（同号乘积的两个点位于第一、三象限，异号的两个点位于第二、四象限）。但取特征映射

$$\phi(x_1, x_2) = x_1 x_2 \in \mathbb{R},$$

则

$$\phi(1, 1) = \phi(-1, -1) = +1, \quad \phi(1, -1) = \phi(-1, 1) = -1.$$

在特征空间 $\mathbb{R}$ 中，只需一个阈值 0 就能完美分开两类。分类器

$$f(x) = \text{sign}(\phi(x)) = \text{sign}(x_1 x_2)$$

对应到原空间的决策边界是 $x_1 x_2 = 0$ ——两条坐标轴之并，这是一条非线性的决策边界（图 1.6）。




图 1.6: XOR 问题：特征映射 $\phi(x_1, x_2) = x_1 x_2$ 把线性不可分变为线性可分

核心思想

特征映射的思路可以概括为：**用非线性映射换取线性可分**。代价是特征空间的维数可能远高于原始空间（甚至是无穷维），而显式地写出 $\phi(x)$ 并计算内积可能极其昂贵。节 1.13 的核技巧正是为了绕过这一代价。

1.13 核技巧

定义 1.44 (核函数与 Gram 矩阵) 设 $k : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ 。若存在特征空间 $\mathcal{H}$ 与特征映射 $\phi : \mathcal{X} \rightarrow \mathcal{H}$ 使得

$$k(x, z) = \langle \phi(x), \phi(z) \rangle_{\mathcal{H}}, \quad \forall x, z \in \mathcal{X}, \quad (1.32)$$

则称 k 是一个**核函数**。给定样本 $x_1, \dots, x_N \in \mathcal{X}$, 称对称矩阵

$$K = (k(x_i, x_j))_{i,j=1}^N \in \mathbb{R}^{N \times N}$$

为该核对应的 **Gram 矩阵**。

核技巧的全部力量来自一个观察：许多线性算法只依赖样本之间的内积，而不需要样本的坐标本身。如果能用 $k(x, z)$ 直接算出 $\langle \phi(x), \phi(z) \rangle$ ，就不必显式构造 ϕ 。下面用一个完全可手算的例子说明这一点。

例 1.45 (二次多项式核) 在 $\mathbb{R}^2$ 上取特征映射

$$\phi(x) = (x_1^2, \sqrt{2}x_1x_2, x_2^2)^\top \in \mathbb{R}^3.$$

则对任意 $x, z \in \mathbb{R}^2$,

$$\phi(x)^\top \phi(z) = x_1^2 z_1^2 + 2x_1 x_2 z_1 z_2 + x_2^2 z_2^2 = (x_1 z_1 + x_2 z_2)^2 = (x^\top z)^2. \quad (1.33)$$

因此

$$k(x, z) = (x^\top z)^2$$

是一个核函数，它对应的是 $\mathbb{R}^3$ 中的内积，但计算只需 $\mathbb{R}^2$ 上的一次内积与一次平方。这就是核方法“隐式地工作在高维空间”的含义。

上式是 $c = 0, q = 2$ 的特例。更一般地， $k(x, z) = (x^\top z + c)^q$ 在

$$c \geq 0, \quad q \in \mathbb{N}_+$$

时是合法核（当 $c > 0$ 时可把它展开成所有次数不超过 q 的单项式的内积，维数为 $\binom{d+q}{q}$ ；当 $c = 0$ 时只能保留总次数恰为 q 的单项式，维数为 $\binom{d+q-1}{q}$ ）。无论哪种情形，计算量都只与 d 与 q 有关，而不依赖特征空间的维数。

AI 应用

问题：支持向量机（SVM）要在高维特征空间里找最大间隔超平面，但特征空间的维数可能极高甚至无穷，超平面根本写不出来。

做法：这个优化问题的解可以只用样本之间的内积来表达。把其中出现的 $\langle \phi(x_i), \phi(x_j) \rangle$ 一律换成 $k(x_i, x_j)$ ，就不必显式构造 ϕ ：优化变量从可能无穷维的 w 变成 N 个乘子，计算量只取决于 $N \times N$ 的 Gram 矩阵 K 。

本章的位置：这里用到的只是式 (1.32) 中“核就是特征空间里的内积”这一定义。如何

解这个优化问题属于最优化部分（第 9–12 章），本章只负责说明 K 必须具备什么性质。

定理 1.46 (Gram 矩阵半正定) 设 $k : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ 是核函数, $x_1, \dots, x_N \in \mathcal{X}$ 任意给定, $K = (k(x_i, x_j))$ 为对应的 Gram 矩阵。则 K 对称且半正定, 即

$$K^\top = K, \quad c^\top K c = \sum_{i=1}^N \sum_{j=1}^N c_i c_j k(x_i, x_j) \geq 0, \quad \forall c \in \mathbb{R}^N. \quad (1.34)$$

证明. 对称性由 $K_{ij} = k(x_i, x_j) = \langle \phi(x_i), \phi(x_j) \rangle = \langle \phi(x_j), \phi(x_i) \rangle = K_{ji}$ 得到。半正定性: 由式 (1.32) 与内积的双线性性,

$$c^\top K c = \sum_{i,j} c_i c_j \langle \phi(x_i), \phi(x_j) \rangle = \left\| \sum_{i=1}^N c_i \phi(x_i) \right\|_{\mathcal{H}}^2 \geq 0,$$

最后一步用了内积的正定性。 $\square$

注 (Moore–Aronszajn 定理 (有限样本版本)). 定理 1.46 说明 “核函数 $\Rightarrow$ Gram 矩阵半正定”。反过来, 一个对称函数 k 只要对任意有限样本集 $x_1, \dots, x_N$ 都给出半正定的 Gram 矩阵, 就必定存在特征空间 $\mathcal{H}$ 与特征映射 ϕ 使式 (1.32) 成立。这是 Moore–Aronszajn 定理的有限样本版本, 其证明需要对所有有限样本一致地构造 ϕ , 不属于本章范围。因此实践中往往直接用 “任意有限 Gram 矩阵都半正定” 作为判断 k 是否为合法核函数的准则, 例如 RBF 核 $k(x, z) = \exp(-\|x - z\|_2^2 / (2\sigma^2))$ ($\sigma > 0$) 可由此验证, 见习题 1.81。

这里的判据常被称作 “Mercer 条件”, 严格说并不准确: Mercer 定理处理的是定义在紧集上、关于某个有限测度平方可积的连续核 k , 结论是该核可以展开成

$$k(x, z) = \sum_{n \geq 1} \lambda_n \psi_n(x) \psi_n(z), \quad \lambda_n \geq 0,$$

即 $\{\psi_n\}$ 构成 L^2 的一组正交基。它比上面的有限样本判据强, 也额外用到了紧致性、连续性与积分算子等分析条件。本章只用到有限样本版本, 故不引用 Mercer 的名字。

核心思想

核技巧把 “构造高维特征 $\phi(x)$ ” 这件事, 替换成了 “设计一个满足半正定性的二元函数 $k(x, z)$ ”。线性代数为这一替换提供了判据 (式 (1.34)), 也提供了算法 (一切只依赖内积的线性算法都可以 “核化”)。本章支线的终点就是这句话。

1.14 AI 综合案例

1.14.1 核心案例: 用子空间与正交补做去噪

AI 应用 1.47 (子空间去噪) 问题: 观测到的信号往往被噪声污染, 希望把 “真实信号” 与 “噪声” 分离开。

建模. 设观测向量 $x \in \mathbb{R}^n$ 满足

$$x = s + n, \quad s \in S, \quad n \in S^\perp, \quad (1.35)$$

其中 $S \subseteq \mathbb{R}^n$ 是已知（或由数据估计得到）的信号子空间，它刻画“真实信号可能长什么样”， $n \in S^\perp$ 则是与它正交的那部分。由正交分解定理式 (1.18)， $\mathbb{R}^n = S \oplus S^\perp$ ，故式 (1.35) 中的分解是唯一的。

结论. 设 P_S 为到 S 的正交投影（节 1.10）。对 $x = s + n$ 作用 P_S ，由 $P_S s = s$ ($s \in S$ 在投影下不动) 与 $P_S n = 0$ ($n \in S^\perp$ 被压成零) 得

$$P_S x = s, \quad (I - P_S)x = n.$$

这就是去噪的全部内容：把观测投到信号子空间上，残差就是噪声。

理论联系. 用的是定理 1.30 ($S \oplus S^\perp$)、定理 1.31 (投影唯一且使距离最小) 与定理 1.34 (若 Q 的列是 S 的一组标准正交基，则 $P_S = QQ^\top$)。在实际中， S 常取数据协方差的前 k 个主方向 (PCA 去噪)。

例 1.48 (数值算例) 取 $S = \text{span}\{q\}$ ，其中 $q = \frac{1}{\sqrt{2}}(1, 1)^\top$ ，观测 $x = (4, 2)^\top$ 。因为 $q^\top q = 1$ ，故 $P_S = qq^\top$ ，于是

$$\begin{aligned} \hat{s} = P_S x &= q(q^\top x) = q \cdot \frac{4+2}{\sqrt{2}} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix} \cdot \frac{6}{\sqrt{2}} \\ &= 3 \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 3 \\ 3 \end{bmatrix}, \quad \hat{n} = (I - P_S)x = \begin{bmatrix} 4 \\ 2 \end{bmatrix} - \begin{bmatrix} 3 \\ 3 \end{bmatrix} = \begin{bmatrix} 1 \\ -1 \end{bmatrix}. \end{aligned}$$

验证： $\langle \hat{n}, q \rangle = \frac{1}{\sqrt{2}}(1 - 1) = 0$ ，即 $\hat{n} \perp S$ ；并且 $\hat{s} + \hat{n} = x$ 。三个公式——正交补、投影、分解——在这个小例子里完全对齐。

1.14.2 延伸阅读：零样本学习中的子空间与最小二乘

问题. 在零样本学习 (zero-shot learning) 中，训练时只能见到一部分类别 (已见类 $\mathcal{L}_s$)，测试时需要识别从未出现过的类别 (未见类 $\mathcal{L}_u$ ，且 $\mathcal{L}_s \cap \mathcal{L}_u = \emptyset$)。没有未见类的任何图像样本，模型凭什么能识别它们？答案是：借助类别语义向量。

建模. 每个类别 t 都配有一个语义向量 $a_t \in \mathbb{R}^k$ (例如由“有翅膀、会飞、有羽毛”等属性的人工打分构成)，已见类与未见类共用同一套属性。训练样本是视觉特征向量 $s_1, \dots, s_N \in \mathbb{R}^d$ (N 为训练样本数)， s_i 的类别标号为 $y_i \in \mathcal{L}_s$ 。目标是在语义空间里做识别：学一个映射

$$F: \mathbb{R}^d \rightarrow \mathbb{R}^k,$$

使 $F(s_i) \approx a_{y_i}$ 。训练完成后，对测试样本 s_t 按语义空间中的欧氏距离取最近者，

$$\hat{t} = \arg \min_{t \in \mathcal{L}_u} \|F(s_t) - a_t\|_2. \quad (1.36)$$

为什么要拆成子空间。 视觉特征的不同部分往往对应不同的语义属性，用一个矩阵笼统地处理，难以让“翅膀”那一部分只影响“有翅膀”这个属性。自然的改进是先把视觉空间拆成若干子空间，再分别映射：

$$U_j = \text{Col}(W_j) \subseteq \mathbb{R}^d, \quad W_j \in \mathbb{R}^{d \times c} \text{ 取满列秩}, \quad j = 1, \dots, M,$$

并令 P_j 为到 U_j 的正交投影算子，由 定理 1.35

$$P_j = W_j(W_j^\top W_j)^{-1}W_j^\top. \quad (1.37)$$

于是 s 被拆成 M 个分量 $P_j s \in U_j$ ；每个分量各配一个线性映射 $A_j: \mathbb{R}^d \rightarrow \mathbb{R}^k$ ，映射 F 就取为它们的叠加

$$F(s) = v = \sum_{j=1}^M A_j P_j s. \quad (1.38)$$

若诸 U_j 两两正交且 $\sum_j \dim U_j = d$ ，则 $\mathbb{R}^d = U_1 \oplus \dots \oplus U_M$ （定义 1.29），每个 s 有唯一分解 $s = \sum_j P_j s$ ， F 不丢信息。但满列秩给出 $\dim U_j = c$ ，即维数条件就是 $Mc = d$ ；在更常见的 $Mc < d$ 情形下，诸 U_j 只能张成 $\mathbb{R}^d$ 的一个真子空间

$$U := \sum_{j=1}^M U_j \subseteq \mathbb{R}^d, \quad \dim U = Mc < d,$$

于是 s 总有一部分落在 U 之外，需要一个重构项把它压小。

训练：一个最小二乘问题。 在已见类上，我们希望 $F(s_i)$ 接近 a_{y_i} ，同时希望 $U = \sum_j U_j$ 把 s_i 尽量“装下”——注意是 s_i 到整个和空间 U 的距离小，而不是到各个 U_j 的距离之和：后者会迫使每个 U_j 单独去逼近整个 s_i ，与“由若干子空间共同分解”的意图相反。再加一项促使各 U_j 互不重叠的正则项 R_{corr} （例如 $\sum_{i \neq j} \|P_i P_j\|_F^2$ ），损失函数取

$$\begin{aligned} \min_{\{P_j, A_j\}} \quad & \sum_{i=1}^N \|v_i - a_{y_i}\|_2^2 + \lambda_{\text{rec}} \sum_{i=1}^N \|s_i - P_U s_i\|_2^2 \\ & + \lambda_{\text{corr}} R_{\text{corr}}, \end{aligned} \quad (1.39)$$

其中 $v_i = F(s_i)$ 由 式 (1.38) 给出， P_U 是到和空间 $U = \sum_j U_j$ 的正交投影（存在性由 定理 1.31 保证）， $\lambda_{\text{rec}}, \lambda_{\text{corr}} \geq 0$ 是权重。三项分别对应语义对齐、信息保真与子空间解耦。

优化变量 $\{P_j\}$ 不是任意矩阵，而是**正交投影算子**，须满足

$$P_j^2 = P_j = P_j^\top, \quad \text{rank}(P_j) = c, \quad j = 1, \dots, M. \quad (1.40)$$

前两条由 式 (1.25) 恰好等价于“ P_j 是到某个子空间 U_j 的正交投影”，第三条则固定了每个子空间的维数。有了这组约束， P_j 与 U_j 才互相对应；若固定 $\{P_j\}$ 只优化 $\{A_j\}$ ，式 (1.39) 的第一项关于 $\{A_j\}$ 就是一个标准的最小二乘问题，其正规方程由 式 (1.29) 给出——这正是 节 1.11 的结论在此处的直接应用。

推断。 未见类没有样本，只能为它造一个语义表示 $v_t \in \mathbb{R}^k$ ：最简单的做法是直接取

$v_t = a_t$; 若希望更贴近 F 的像空间, 可先用一个反演映射 $G: \mathbb{R}^k \rightarrow \mathbb{R}^d$ 把 a_t 映回视觉空间得虚拟特征 $\tilde{s}_t = G(a_t)$, 再令 $v_t = F(\tilde{s}_t)$ 。有了 v_t 后, 对测试样本 s_t 算出 $F(s_t)$, 按式 (1.36) 取距离最近者即可。注意送入 P_j 的必须是 $\mathbb{R}^d$ 中的向量—— P_j 作用在视觉特征空间上, 不能直接把 $a_t \in \mathbb{R}^k$ 代进去。

小结. 这个案例把本章的数学结构完整地用了一遍: 子空间与直和 (定义 1.29) 用来划分视觉特征, 正交投影 (定理 1.31、式 (1.37)) 用来取出各分量, 线性映射与矩阵表示 (定理 1.16) 给出 $F = \sum_j A_j P_j$, 最小二乘 (式 (1.29)) 用于训练。它也是“把节 1.11 的结论用到真实问题上”的一个例子。

1.15 本章小结

本章围绕一条主线展开: 从数据向量出发, 建立向量空间与子空间的语言, 用线性映射描述“线性”, 再用矩阵把它记录下来, 最后通过内积、正交补与投影得到最小二乘。要点如下。

- (1) **样本即向量, 数据集即矩阵。** 一个样本是 $x \in \mathbb{R}^d$, 一份数据集是 $X \in \mathbb{R}^{N \times d}$, 约定“行 = 样本、列 = 特征” (式 (1.2))。矩阵乘法有行观点、列观点与线性变换观点: $y = Ax$ 既可以读成 $y_i = a_i^\top x$, 也可以读成 $Ax = \sum_j x_j a_j$, 还可以读成映射 $T_A: \mathbb{R}^n \rightarrow \mathbb{R}^m$ (式 (1.4)–式 (1.5))。
- (2) **向量空间与子空间。** 向量空间的八条公理 (定义 1.2) 是所有线性结论的共同来源; 判定子集 W 是不是子空间, 只需验证 $W \neq \emptyset$ 且 $\alpha x + \beta y \in W$ (命题 1.5), 而“ $0 \notin W$ ”是最快的反例 (例 1.7)。
- (3) **基与维数。** 有限生成集必含基, 删去冗余向量即可得到 (定理 1.11); 在给定基下, 每个向量的坐标是唯一的 (定理 1.12); 因此维数 $\dim V$ 由空间本身唯一确定 (推论 1.13)。
- (4) **线性映射与矩阵的一一对应。** 线性映射由它在基上的像唯一确定 (定理 1.16); 在标准基下有 $A = [T(e_1) \cdots T(e_n)]$ 且 $T(x) = Ax$ (式 (1.12))。这条结论是本章“先讲映射、再讲矩阵”的关键。
- (5) **核、像与秩。** $\text{Ker } T$ 与 $\text{Im } T$ 都是子空间, Rank-Nullity 定理 $\dim \text{Ker } T + \dim \text{Im } T = \dim V$ (定理 1.20) 是线性代数的基本计数律; 矩阵形式为 $\text{rank}(A) + \text{nullity}(A) = n$ (式 (1.15))。 $\text{rank}(A)$ 同时等于行空间与列空间的维数 (引理 1.22)。
- (6) **四个基本子空间与方程组的结构。** 线性代数基本定理断言 $\text{Null}(A)$ 是行空间的正交补、 $\text{Null}(A^\top)$ 是列空间的正交补 (式 (1.16)), 四个子空间的维数分别为 $\dim \text{Row}(A) = r$ 、 $\dim \text{Null}(A) = n - r$ 、 $\dim \text{Col}(A) = r$ 、 $\dim \text{Null}(A^\top) = m - r$, 其中 $r = \text{rank}(A)$ 。方程 $Ax = b$ 有解当且仅当 $b \in \text{Col}(A)$ (定理 1.24), 且通解为“特解 + 齐次通解”: $x_0 + \text{Null}(A)$ (式 (1.17))。
- (7) **正交分解、投影与投影矩阵。** 对任意子空间 M 有 $\mathbb{R}^n = M \oplus M^\perp$ (式 (1.18)); 投影定理断言 x 有唯一分解 $x = \hat{x} + r$, 且 $\hat{x} = \arg \min_{y \in M} \|x - y\|_2$ (定理 1.31)。投影矩阵由两条代数等式刻画: $P^2 = P$ 且 $P^\top = P$ (式 (1.25)); 具体公式为 $P = QQ^\top$ (Q 列标准正交) 或 $P = A(A^\top A)^{-1}A^\top$ (A 满列秩)。
- (8) **最小二乘。** 最小二乘的几何内容就是“残差垂直于列空间”: $r = b - A\hat{x} \perp \text{Col}(A)$, 由此得正规方程 $A^\top A\hat{x} = A^\top b$ (式 (1.29)); 当 A 满列秩时解唯一, $\hat{x} = (A^\top A)^{-1}A^\top b = A^+b$ (式 (1.30))。

- (9) **支线：特征映射与核技巧。** 特征映射 ϕ 把数据搬到高维空间以换取线性可分，但它一般不是线性映射（定义 1.42 后的注意框，例 1.43）；核函数 $k(x, z) = \langle \phi(x), \phi(z) \rangle$ 让我们无需显式构造 ϕ ，而合法核的判据是其全部 Gram 矩阵半正定（式 (1.34)），这正是二次型 $\|\sum_i c_i \phi(x_i)\|^2 \geq 0$ 的另一种写法。

1.16 习题

以下习题分为基础题、证明题、计算题与 AI 应用题四类，难度大体递进。标 ★ 者为进一步的思考题，仅给一句提示；其余题目只给题干，请读者独立完成。

1.16.1 基础题

习题 1.49 (子空间判定) 判断下列两个集合是否为 $\mathbb{R}^3$ 的子空间，并给出证明：

$$W_1 = \{x = (x_1, x_2, x_3)^\top \in \mathbb{R}^3 : x_1 + 2x_2 - x_3 = 0\}, \quad W_2 = \{x \in \mathbb{R}^3 : x_1 + 2x_2 - x_3 = 1\}.$$

习题 1.50 (Span 与线性无关) 设 $v_1 = (1, 0, 1)^\top$, $v_2 = (0, 1, 1)^\top$, $v_3 = (1, 1, 2)^\top \in \mathbb{R}^3$ 。求 $\text{span}\{v_1, v_2, v_3\}$ 的一组基与维数，并说明这三个向量是否线性无关。

习题 1.51 (线性映射的判定) 设 $T: \mathbb{R}^2 \rightarrow \mathbb{R}^2$, $T(x_1, x_2) = (x_1 + x_2, x_1 x_2)^\top$ 。 T 是否为线性映射？请从式 (1.10) 出发给出证明。

习题 1.52 (更多子空间判定) 判断下列集合是否为相应空间中的子空间，并说明理由：

- (a) $\{(x_1, x_2)^\top \in \mathbb{R}^2 : x_1 x_2 = 0\}$;
- (b) $\{(x_1, x_2)^\top \in \mathbb{R}^2 : x_1^2 + x_2^2 = 1\}$;
- (c) $\{(x_1, x_2, x_3)^\top \in \mathbb{R}^3 : x_1 = x_3\}$;
- (d) $\{(x_1, x_2)^\top \in \mathbb{R}^2 : |x_1| \leq 1\}$ 。

习题 1.53 (子空间的交与和) 设 W_1, W_2 是向量空间 V 的子空间。判断 $W_1 \cap W_2$ 与 $W_1 + W_2 = \{u + v : u \in W_1, v \in W_2\}$ 是否都是 V 的子空间，并给出理由。

习题 1.54 (换基与坐标) 在 $\mathbb{R}^2$ 中取基 $B = \{v_1, v_2\}$ ，其中 $v_1 = (1, 1)^\top$ 、 $v_2 = (1, -1)^\top$ 。求 $x = (3, 1)^\top$ 在标准基下的坐标与在基 B 下的坐标，并解释两个坐标向量为什么不同。

习题 1.55 (线性相关性的判断) 判断下列各组向量是否线性无关：

- (a) $(1, 0, 0)^\top, (0, 1, 0)^\top, (0, 0, 1)^\top \in \mathbb{R}^3$;
- (b) $(1, 2)^\top, (2, 4)^\top \in \mathbb{R}^2$;
- (c) $(1, 1, 0)^\top, (0, 1, 1)^\top, (1, 2, 1)^\top \in \mathbb{R}^3$;
- (d) $(1, 2, 3)^\top, (4, 5, 6)^\top, (7, 8, 9)^\top \in \mathbb{R}^3$ 。

习题 1.56 (内积、范数与正交) 设 $x = (1, 1, 1)^\top$ 、 $y = (1, -2, 1)^\top \in \mathbb{R}^3$ 。计算 $\langle x, y \rangle$ 、 $\|x\|_2$ 、 $\|y\|_2$ ，判断二者是否正交，并验证此时勾股定理 $\|x + y\|_2^2 = \|x\|_2^2 + \|y\|_2^2$ 是否成立。

1.16.2 证明题

习题 1.57 (零空间的包含关系) 设 $A \in \mathbb{R}^{m \times n}$ 、 $B \in \mathbb{R}^{n \times p}$ 。证明

$$\text{Null}(B) \subseteq \text{Null}(AB),$$

并给出一个使 $\text{Null}(AB) = \text{Null}(B)$ 成立的充分条件。(提示: Null 的维数由秩决定, 比较 $\text{rank}(AB)$ 与 $\text{rank}(B)$ 。)

习题 1.58 (解集何时是子空间) 设 $A \in \mathbb{R}^{m \times n}$ 、 $b \in \mathbb{R}^m$, 且 $Ax = b$ 有解。(i) 证明解集非空时必形如 $x_0 + \text{Null}(A)$, 其中 x_0 是任一特解; (ii) 证明这个解集是 $\mathbb{R}^n$ 的子空间当且仅当 $b = 0$ 。

习题 1.59 (直和分解) 设 $U = \text{span}\{(1, 1)^\top\}$ 、 $W = \text{span}\{(1, -1)^\top\}$ 。证明 $\mathbb{R}^2 = U \oplus W$, 并对任意 $x = (a, b)^\top$ 求出它在 $U \oplus W$ 下的唯一分解 $x = u + w$ ($u \in U$ 、 $w \in W$)。

习题 1.60 (核函数的封闭性) 设 $k_1, k_2: \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ 都是核函数, $a, b \geq 0$ 。证明 $ak_1 + bk_2$ 与 k_1k_2 也都是核函数。(提示: 用式 (1.32) 把 k_i 写成 ϕ_i 的内积; 对乘积可考虑 $\phi(x) = \phi_1(x) \otimes \phi_2(x)$, 即两个特征向量的张量积。)

习题 1.61 (★ 条件数的平方) 设 $A \in \mathbb{R}^{m \times n}$ 满列秩, $\kappa_2(A)$ 表示 A 的谱条件数 (等于最大奇异值与最小奇异值之比)。证明

$$\kappa_2(A^\top A) = \kappa_2(A)^2.$$

提示: 由奇异值分解 $A = U\Sigma V^\top$, 有 $A^\top A = V\Sigma^2 V^\top$, 故 $A^\top A$ 的奇异值为 $\sigma_i(A)^2$ 。

习题 1.62 (正交向量组线性无关) 证明: 若 $v_1, \dots, v_m$ 两两正交且都非零, 则它们线性无关。

习题 1.63 (Span 的最小性) 设 $S \subseteq V$ 。证明 $\text{span } S$ 是 V 中包含 S 的最小子空间, 即: (i) $\text{span } S$ 是子空间且 $S \subseteq \text{span } S$; (ii) 若 W 是 V 的子空间且 $S \subseteq W$, 则 $\text{span } S \subseteq W$ 。

习题 1.64 (秩的不等式) 设 $A \in \mathbb{R}^{m \times n}$ 、 $B \in \mathbb{R}^{n \times p}$ 、 $C \in \mathbb{R}^{m \times n}$ 。证明

$$\text{rank}(AB) \leq \min\{\text{rank}(A), \text{rank}(B)\}, \quad \text{rank}(A + C) \leq \text{rank}(A) + \text{rank}(C).$$

习题 1.65 (投影矩阵的等价刻画) 设 $P \in \mathbb{R}^{n \times n}$ 满足 $P^2 = P$ 且 $P^\top = P$ 。证明 $I - P$ 也是正交投影矩阵, 并指出它投影到哪个子空间; 另外证明 $\|Px\|_2 \leq \|x\|_2$ 对一切 x 成立。

习题 1.66 (直和与维数公式) 设 U, W 是有限维向量空间 V 的子空间。证明

$$\dim(U + W) + \dim(U \cap W) = \dim U + \dim W,$$

并由此证明: $U + W = U \oplus W$ 当且仅当 $\dim(U + W) = \dim U + \dim W$ 。

习题 1.67 (★ 基的等势性) 设有限维向量空间 V 有两组基 $B_1 = \{u_1, \dots, u_m\}$ 与 $B_2 = \{v_1, \dots, v_n\}$ 。证明 $m = n$ 。提示: 把 $v_1, \dots, v_n$ 用 B_1 表出, 得到 n 个含 m 个未知量的齐次线性方程组; 若 $n > m$, 这类方程组必有非零解, 从而 B_2 线性相关, 矛盾。

习题 1.68 (正交补的性质) 设 $M, N \subseteq \mathbb{R}^n$ 是子空间。证明:

- (a) $M \subseteq N \implies N^\perp \subseteq M^\perp$;
- (b) $(M^\perp)^\perp = M$;
- (c) $(M + N)^\perp = M^\perp \cap N^\perp$ 。

1.16.3 计算题

习题 1.69 (四个基本子空间的基与维数) 设

$$A = \begin{bmatrix} 1 & 2 & 3 \\ 0 & 1 & 1 \end{bmatrix}.$$

分别求 $\text{Null}(A)$ 、 $\text{Col}(A)$ 、 $\text{Row}(A)$ 的一组基与维数, 并验证 Rank-Nullity 定理 $\text{rank}(A) + \text{nullity}(A) = n$ 。再求 $\text{Null}(A^\top)$ 的一组基, 并验证四个维数之和的分解 $n = r + (n - r)$ 、 $m = r + (m - r)$ 。

习题 1.70 (由基上的像确定线性映射) 设 $T: \mathbb{R}^2 \rightarrow \mathbb{R}^2$ 是线性映射, 且 $T(e_1) = (1, 2)^\top$ 、 $T(e_2) = (3, 1)^\top$ 。写出 T 的矩阵表示 A , 计算 $T((2, -1)^\top)$, 并验证 $T((2, -1)^\top) = 2T(e_1) - T(e_2)$ 。

习题 1.71 (点到直线的投影) 设 $x = (2, 3)^\top$ 、 $u = (1, 1)^\top \in \mathbb{R}^2$ 。求 x 在直线 $\text{span}\{u\}$ 上的正交投影 $\hat{x}$ 与残差 $r = x - \hat{x}$, 并验证 $\hat{x} \perp r$ 、 $\hat{x} + r = x$ 。

习题 1.72 (秩一投影矩阵) 设 $u = \frac{1}{\sqrt{5}}(1, 2)^\top \in \mathbb{R}^2$, $P = uu^\top$ 。验证 $P^2 = P$ 、 $P^\top = P$, 并求 $\text{rank}(P)$ 、 $\text{tr}(P)$ 以及 P 的全部特征值。解释为什么 P 是到 $\text{span}\{u\}$ 的正交投影矩阵。

习题 1.73 (一般列空间上的投影矩阵) 设

$$A = \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{bmatrix}.$$

计算 $A^\top A$ 与其逆, 求出 $P = A(A^\top A)^{-1}A^\top$, 并直接验证 $P^2 = P$ 与 $P^\top = P$ 。指出 $\text{Col}(P)$ 的维数。

习题 1.74 (最小二乘直线拟合) 给定数据点 $(0, 2)$ 、 $(1, 1)$ 、 $(2, 3)$, 用模型 $y = \beta_0 + \beta_1 x$ 做最小二乘拟合。请

- (a) 写出 A 与 b , 用正规方程 $A^\top A\hat{\beta} = A^\top b$ 求出 $\hat{\beta}$;
- (b) 用正交投影的观点求出 $\hat{b} = A\hat{\beta}$ 与残差 $r = b - \hat{b}$, 验证 $A^\top r = 0$;
- (c) 解释残差的分量为什么有正有负, 以及 $\sum_i r_i = 0$ 的含义。

习题 1.75 (三次齐次核的显式特征映射) 证明 $k(x, z) = (x^\top z)^3$ ($x, z \in \mathbb{R}^2$) 是核函数, 具体求出一个显式的特征映射 $\phi: \mathbb{R}^2 \rightarrow \mathbb{R}^4$ 使 $k(x, z) = \phi(x)^\top \phi(z)$ 。(提示: 把 $(x_1 z_1 + x_2 z_2)^3$ 按多项式展开, 再把每一项拆成“只含 x 的因子”与“只含 z 的因子”的乘积。)

习题 1.76 (Gram 矩阵的计算) 设 $x_1 = (1, 0)^\top$, $x_2 = (0, 1)^\top$, $x_3 = (1, 1)^\top \in \mathbb{R}^2$, 取核

$k(x, z) = (x^\top z)^2$ 。写出 Gram 矩阵 $K \in \mathbb{R}^{3 \times 3}$ ，求 $\text{rank}(K)$ ，并验证 $\text{rank}(K)$ 不大于特征映射的像空间维数。再直接验证 $c^\top K c \geq 0$ 对一切 $c \in \mathbb{R}^3$ 成立。

习题 1.77 (Gram-Schmidt 正交化) 对 $\mathbb{R}^3$ 中的向量组 $a_1 = (1, 1, 0)^\top$ 、 $a_2 = (1, 0, 1)^\top$ 、 $a_3 = (0, 1, 1)^\top$ 施行 Gram-Schmidt 正交化 (引理 1.28)，求出 $\text{span}\{a_1, a_2, a_3\}$ 的一组标准正交基。

习题 1.78 (二次多项式的最小二乘拟合) 给定数据点 $(0, 1)$ 、 $(1, 2)$ 、 $(2, 2)$ 、 $(3, 4)$ ，用二次多项式模型 $y = \beta_0 + \beta_1 x + \beta_2 x^2$ 做最小二乘拟合。写出数据矩阵 A ，求出 $\hat{\beta}$ ，并说明此时 $A^\top A$ 是否可逆、最小二乘解是否唯一。

1.16.4 AI 应用题

习题 1.79 (特征映射的非线性) 设特征映射 $\phi(x_1, x_2) = (x_1, x_2, x_1 x_2)^\top \in \mathbb{R}^3$ 。

- 判断 ϕ 是否为线性映射，并给出证明；
- 对于分类器 $w^\top \phi(x) + b = 0$ ($w = (w_1, w_2, w_3)^\top$)，写出它在原空间 $\mathbb{R}^2$ 中的决策边界方程，说明它是什么曲线。

习题 1.80 (子空间去噪) 设信号子空间 $S = \text{span}\{\frac{1}{\sqrt{5}}(1, 2)^\top\} \subseteq \mathbb{R}^2$ ，观测向量 $x = (5, 0)^\top$ 。已知 $x = s + n$ ，其中真实信号 $s \in S$ 、噪声 $n \in S^\perp$ 。求 $P_S x$ 、 $\hat{s} = P_S x$ 与 $\hat{n} = (I - P_S)x$ ，并验证 $\hat{s} \in S$ 、 $\hat{n} \in S^\perp$ 、 $\hat{s} + \hat{n} = x$ 。

习题 1.81 (核函数的合法性判定) 判断下列函数是否为合法的核函数，即是否存在特征空间 $\mathcal{H}$ 与特征映射 ϕ 使 $k(x, z) = \langle \phi(x), \phi(z) \rangle$ (式 (1.32))，并说明理由：

- $k(x, z) = (x^\top z + c)^q$ ，其中 $c \geq 0$ 、 q 为正整数；
- $k(x, z) = x^\top z - 1$ ， $x, z \in \mathbb{R}^2$ ；
- $k(x, z) = \exp(-\|x - z\|_2^2 / (2\sigma^2))$ ，其中 $\sigma > 0$ (RBF 核。提示：把 $\|x - z\|_2^2$ 展开，将指数拆成“只含 x ”“只含 z ”“含 $\langle x, z \rangle$ ”三部分的乘积，再用 (a) 的结论。)

习题 1.82 (最小二乘分类器) 二分类问题中，每个样本是一个向量 $a_i \in \mathbb{R}^d$ ，带一个标签 $y_i \in \{-1, +1\}$ ($i = 1, \dots, N$)。线性分类器取 $\text{sign}(\langle w, a_i \rangle + b)$ 的形式： $\langle w, a_i \rangle + b > 0$ 判为 $+1$ ，否则判为 -1 。一个朴素的想法是直接用最小二乘去拟合标签，即求解

$$\min_{w \in \mathbb{R}^d, b \in \mathbb{R}} \sum_{i=1}^N (\langle w, a_i \rangle + b - y_i)^2.$$

- 取 $z = (w^\top, b)^\top \in \mathbb{R}^{d+1}$ ，写出矩阵 A 与向量 y ，使上式等于 $\|Az - y\|_2^2$ ；
- 写出正规方程，并在 A 满列秩时给出 z 的表达式；
- 另一类做法是最大间隔分类器 (SVM)：它只要求 $\langle w, a_i \rangle + b$ 与 y_i 同号且绝对值不小于 1，对已经满足这一条件的样本不再施加任何惩罚。据此说明：当某个样本被正确分类且离分界线很远 (即 $y_i(\langle w, a_i \rangle + b) \gg 1$) 时，最小二乘仍会把它计入平方误差，从而在拟合中被“过度惩罚”。

习题 1.83 (加权最小二乘) 设权重 $w_i > 0$ ($i = 1, \dots, N$), 考虑加权最小二乘问题

$$\min_{x \in \mathbb{R}^n} \sum_{i=1}^N w_i (a_i^\top x - b_i)^2.$$

- (a) 令 $W = \text{diag}(w_1, \dots, w_N)$, 把目标函数写成 $\|W^{1/2}(Ax - b)\|_2^2$ 的形式;
- (b) 导出加权正规方程 $A^\top W A \hat{x} = A^\top W b$;
- (c) 说明“给某个样本很大的权重”在几何上意味着什么。

习题 1.84 (词向量的子空间结构) 在自然语言处理中, 每个词被表示为一个向量 (词向量), 语义相关的词其向量也相关。经验上常观察到如下的类比关系:

$$\text{king} - \text{man} + \text{woman} \approx \text{queen}.$$

本题给出一个可以用本章语言逐项检验的具体版本。设四个词的词向量都在 $\mathbb{R}^2$ 中:

$$\text{man} = (1, 0)^\top, \quad \text{woman} = (1, 1)^\top, \quad \text{king} = (3, 0)^\top, \quad \text{queen} = (3, 1)^\top.$$

- (a) 验证 $\text{king} - \text{man} = \text{queen} - \text{woman}$; 令 $M = \text{span}\{(1, 0)^\top\}$, 说明这四个词向量分别落在哪两条形如 $a + M$ 的仿射子空间上, 这两条子空间的关系是什么。
- (b) 令 $N = \text{span}\{(0, 1)^\top\}$ 。验证 $\mathbb{R}^2 = M \oplus N$ (定义 1.29), 并写出 queen 在该直和下的唯一分解。
- (c) 用正交投影的语言解释: “去掉性别、只保留与‘人/君主’有关的信息”这件事, 可以写成往 M 作正交投影。算出 P_M 在这四个词向量上的作用, 并说明它为什么把 man 与 woman 映到同一点、把 king 与 queen 映到同一点。

本章参考文献

- [1] Carl D. Meyer. *Matrix Analysis and Applied Linear Algebra*, 2nd ed. SIAM, 2023.
- [2] Carl D. Meyer. *Study and Solutions Guide for Matrix Analysis and Applied Linear Algebra*. SIAM, 2023.
- [3] Stephen Boyd and Lieven Vandenbergh. *Introduction to Applied Linear Algebra: Vectors, Matrices, and Least Squares*. Cambridge University Press, 2018.
- [4] Lloyd N. Trefethen and David Bau III. *Numerical Linear Algebra*, 25th Anniversary Edition. SIAM, 2022.
- [5] Marc Peter Deisenroth, A. Aldo Faisal, and Cheng Soon Ong. *Mathematics for Machine Learning*. Cambridge University Press, 2020.
- [6] Bernhard Schölkopf and Alexander J. Smola. *Learning with Kernels: Support Vector Machines, Regularization, Optimization, and Beyond*. MIT Press, 2002.
- [7] Gilbert Strang. *Linear Algebra and Its Applications*, 4th ed. Cengage Learning, 2006.

- [8] Sheldon Axler. *Linear Algebra Done Right*, 3rd ed. Springer, 2015.
- [9] 张贤达. 矩阵分析与应用 (第 2 版). 清华大学出版社, 2013.
- [10] 耿修瑞. 矩阵之美. 科学出版社, 2022.
- [11] 韩丛英, 李伯男. 人工智能基础数学理论和算法 · 第一篇矩阵代数 (课程课件). 中国科学院大学, 2025.

《人工智能数学基础》
CC BY-NC-SA 4.0
禁止商业使用 · 著作权归全体署名作者共有

Chapter 2

矩阵代数——范数理论与正则化

本章作者：××× 初审：××× 二审：××× 终审：×××

2.1 向量范数与稀疏性

2.2 矩阵范数

2.3 内积空间、余弦相似度

2.4 案例：深度学习中的度量学习

本章参考文献

- [1] 作者. 书名或论文名. 出版信息.
- [2] 作者. 书名或论文名. 出版信息.

Chapter 3

矩阵代数——矩阵分解

本章作者：××× 初审：××× 二审：××× 终审：×××

3.1 特征值分解

3.2 奇异值分解

3.3 低秩逼近

3.4 案例：大模型训练中的加速方法

本章参考文献

- [1] 作者. 书名或论文名. 出版信息.
- [2] 作者. 书名或论文名. 出版信息.

Chapter 4

矩阵代数——矩阵微积分与反向传播

本章作者: $\times \times \times$ 初审: $\times \times \times$ 二审: $\times \times \times$ 终审: $\times \times \times$

4.1 多元微分与 Jacobian 矩阵

4.2 标量、向量对矩阵的求导法则

4.3 迹函数与行列式的微分技巧

4.4 链式法则原理

4.5 案例: 深度学习中的反向传播算法

本章参考文献

- [1] 作者, 书名或论文名, 出版信息.
- [2] 作者, 书名或论文名, 出版信息.

Chapter 5

矩阵代数——特殊运算与张量基础

本章作者：××× 初审：××× 二审：××× 终审：×××

5.1 Kronecker 积和 Hadamard 积

5.2 广义逆矩阵与最小二乘解

5.3 张量的基本定义

5.4 案例：矩阵计算的 Python 实现

本章参考文献

- [1] 作者. 书名或论文名. 出版信息.
- [2] 作者. 书名或论文名. 出版信息.

第二篇

概率论

Chapter 6

概率论——多元随机变量与高斯分布

本章作者：××× 初审：××× 二审：××× 终审：×××

6.1 随机向量与统计特征

6.2 多元高斯分布

6.3 分布变换

本章参考文献

- [1] 作者. 书名或论文名. 出版信息.
- [2] 作者. 书名或论文名. 出版信息.

Chapter 7

概率论——参数估计与信息论基础

本章作者：××× 初审：××× 二审：××× 终审：×××

7.1 参数估计框架

7.2 信息论与损失函数

7.3 案例：生成式模型中的相关算法

本章参考文献

- [1] 作者. 书名或论文名. 出版信息.
- [2] 作者. 书名或论文名. 出版信息.

第三篇

最优化方法

Chapter 8

最优化方法——优化视角下的 AI 模型

本章作者：××× 初审：××× 二审：××× 终审：×××

8.1 优化问题的直观理解

8.2 凸集与凸函数基础

8.3 全局最优和局部最优

8.4 案例：分类及回归的模型与算法

本章参考文献

- [1] 作者. 书名或论文名. 出版信息.
- [2] 作者. 书名或论文名. 出版信息.

Chapter 9

最优化方法——一阶算法

本章作者：××× 初审：××× 二审：××× 终审：×××

9.1 梯度下降法

9.2 随机梯度下降

9.3 加速方法

9.4 自适应算法

9.5 案例：深度学习中的训练相关算法

本章参考文献

- [1] 作者. 书名或论文名. 出版信息.
- [2] 作者. 书名或论文名. 出版信息.

Chapter 10

最优化方法——二阶算法

本章作者：××× 初审：××× 二审：××× 终审：×××

10.1 牛顿法与海森矩阵

10.2 曲率信息与收敛速度

10.3 案例：自然策略梯度

本章参考文献

- [1] 作者. 书名或论文名. 出版信息.
- [2] 作者. 书名或论文名. 出版信息.

Chapter 11

最优化方法——约束优化与对偶理论

本章作者：××× 初审：××× 二审：××× 终审：×××

11.1 拉格朗日乘子法

11.2 KKT 条件与对偶理论

11.3 增广拉格朗日法

11.4 案例：深度学习中的约束优化问题

本章参考文献

- [1] 作者. 书名或论文名. 出版信息.
- [2] 作者. 书名或论文名. 出版信息.

符号表

$\mathbb{R}$	实数域。
$\mathbb{R}^n$	n 维欧氏空间。
$A^\top$	矩阵 A 的转置。
$A^\dagger$	Moore–Penrose 广义逆。
$\ x\ _p$	向量 p -范数。
$\mathbb{E}[X]$	随机变量 X 的数学期望。
$\text{Cov}(X)$	随机向量 X 的协方差矩阵。
$\nabla f(x)$	标量函数 f 在 x 处的梯度。
$\nabla^2 f(x)$	f 在 x 处的 Hessian 矩阵。

全书参考文献

- [1] Gilbert Strang. *Linear Algebra and Its Applications*.
- [2] Sheldon Axler. *Linear Algebra Done Right*.
- [3] Roger A. Horn and Charles R. Johnson. *Matrix Analysis*.
- [4] Stephen Boyd and Lieven Vandenberghe. *Convex Optimization*.
- [5] Jorge Nocedal and Stephen J. Wright. *Numerical Optimization*.
- [6] Thomas M. Cover and Joy A. Thomas. *Elements of Information Theory*.
- [7] 茆诗松, 程依明, 濮晓龙, 《概率论与数理统计教程 (第三版)》.
- [8] 林宙辰, 李欢, 方聪, 《机器学习中的加速一阶优化算法》.