人工智能数学基础

线性代数、概率与最优化

《人工智能数学基础》
CC BY-NC-SA 4.0
禁止商业使用，著作权归全体署名作者共有

主编：Xinpei Zhang

编写者：Chenwenjun Cao、Haoran Cao、Zhe Cao、Haihui Li、Zhuodong Liao、Yijia Liu、Yinghan Liu、Panpan Wu、Yunze Wu、Xinpei Zhang、Zhendan Zhang

最后更新：Wednesday 4th November, 2026 13:16

目录

前言 **viii**

人工智能使用声明 **xiii**

第一篇　矩阵代数 **1**

第一章　矩阵代数——矩阵与线性变换 **2**

本章导读 2
本章约定 4
1.1　数据、向量与矩阵 5
1.1.1　从数据到向量 5
1.1.2　数据矩阵 5
1.1.3　矩阵乘法的三种理解 6
1.2　向量空间与子空间 7
1.2.1　向量空间的定义 7
1.2.2　子空间与判别准则 8
1.3　张成、线性无关、基与维数 9
1.4　线性映射与矩阵表示 11
1.4.1　线性映射 11
1.4.2　矩阵表示 12
1.5　核空间、像空间与秩 13
1.6　内积、正交补与直和 14
1.7　矩阵的四个基本子空间 16
1.8　线性方程组的结构 18
1.9　正交投影 19
1.10　投影矩阵 20
1.10.1　标准正交基给出的公式 20
1.10.2　一般列空间上的投影 21
1.10.3　正交投影矩阵的刻画 21

《人工智能数学基础》 CC BY-NC-SA 4.0 禁止商业使用 · 著作权归全体署名作者共有

1.10.4 补充：可逆性、特征值与正定矩阵 22
1.11 最小二乘 22
1.11.1 先看几何：残差必须垂直于列空间 23
1.11.2 满列秩时的唯一解 24
1.12 特征映射 26
1.13 核技巧 28
1.14 AI 综合案例 29
1.14.1 核心案例：用子空间与正交补做去噪 29
1.14.2 延伸阅读：零样本学习中的子空间与最小二乘 31
1.15 本章小结 33
1.16 习题 34
1.16.1 基础题 34
1.16.2 证明题 35
1.16.3 计算题 36
1.16.4 AI 应用题 37
本章参考文献 39

第二章 矩阵代数——范数理论与正则化 40
本章导读 40
本章约定 41
2.1 向量范数与稀疏性 41
2.1.1 范数：长度的三个基本要求 42
2.1.2 三种常用范数与单位球 42
2.1.3 从参数大小到正则化 44
2.1.4 手算例子：软阈值与平方范数收缩 45
2.2 矩阵范数 48
2.2.1 Frobenius 范数：把矩阵看成一个向量 48
2.2.2 诱导范数：线性映射的最大放大倍数 48
2.2.3 谱范数、Frobenius 范数与扰动 49
2.3 内积空间、余弦相似度 50
2.3.1 从内积到范数 50
2.3.2 加权内积与距离 51
2.3.3 余弦相似度与单位球上的距离 52
2.3.4 从向量归一化看 LayerNorm 与 RMSNorm 53

《人工智能数学基础》 CC BY-NC-SA 4.0 禁止商业使用，著作权归全体署名作者共有

2.4 案例：度量学习中的距离与三元组损失 54
2.4.1 从固定距离到学习表示 54
2.4.2 完整算例：距离、间隔与损失 55
2.4.3 条件、退化情形与正则化 56
2.5 本章小结 57
2.6 习题 57
2.6.1 基础题 57
2.6.2 证明题 57
2.6.3 计算题 58
2.6.4 AI 应用题 58
进阶阅读 60

第三章 矩阵代数——矩阵分解 62

本章导读 62
本章约定 64
3.1 特征值分解 65
3.1.1 动机：寻找变换的不变方向 65
3.1.2 特征值与特征向量 65
3.1.3 可对角化与特征值分解 67
3.1.4 实对称矩阵的谱定理 69
3.1.5 相关分解：Cholesky 与 QR 71
3.2 奇异值分解 73
3.2.1 动机：长方形矩阵与两个空间 73
3.2.2 秩一模式 73
3.2.3 奇异值分解定理 74
3.2.4 三种形态 75
3.2.5 奇异值的极值刻画与外积形式 76
3.2.6 矩阵范数、条件数与秩 77
3.2.7 截断 SVD 与 Eckart–Young 定理 78
3.2.8 AI 应用：主成分分析与隐语义模型 80
3.3 低秩逼近 81
3.3.1 潜在因素模型 81
3.3.2 从截断 SVD 到因子模型 82
3.3.3 交替最小二乘 82

《人工智能数学基础》 CC BY-NC-SA 4.0 禁止商业使用 · 著作权归全体署名作者共有

3.3.4 尺度非唯一性与正则化 . . . 83
3.3.5 AI 应用：LoRA 的位置 . . . 83
3.4 案例：大模型训练中的加速方法 . . . 84
3.5 本章小结 . . . 85
3.6 习题 . . . 86
3.6.1 基础题 . . . 86
3.6.2 证明题 . . . 86
3.6.3 计算题 . . . 87
3.6.4 AI 应用题 . . . 87
本章参考文献 . . . 88

第四章 矩阵代数——矩阵微积分与反向传播 89
4.1 多元微分与 Jacobian 矩阵 . . . 89
4.2 标量、向量对矩阵的求导法则 . . . 89
4.3 迹函数与行列式的微分技巧 . . . 89
4.4 链式法则原理 . . . 89
4.5 案例：深度学习中的反向传播算法 . . . 89
本章参考文献 . . . 89

第五章 矩阵代数——特殊运算与张量基础 90
5.1 Kronecker 积和 Hadamard 积 . . . 90
5.2 广义逆矩阵与最小二乘解 . . . 90
5.3 张量的基本定义 . . . 90
5.4 案例：矩阵计算的 Python 实现 . . . 90
本章参考文献 . . . 90

第二篇 概率论 91

第六章 概率论——多元随机变量与高斯分布 92
6.1 随机向量与统计特征 . . . 92
6.2 多元高斯分布 . . . 92
6.3 分布变换 . . . 92
本章参考文献 . . . 92

第七章 概率论——参数估计与信息论基础 93

《人工智能数学基础》 CC BY-NC-SA 4.0 禁止商业使用·著作权归全体署名作者共有

7.1 参数估计框架 93
7.2 信息论与损失函数 93
7.3 案例：生成式模型中的相关算法 93
本章参考文献 93

第三篇 最优化方法 94

第八章 最优化方法——优化视角下的 AI 模型 95
8.1 优化问题的直观理解 95
8.2 凸集与凸函数基础 95
8.3 全局最优和局部最优 95
8.4 案例：分类及回归的模型与算法 95
本章参考文献 95

第九章 最优化方法——一阶算法 96
9.1 梯度下降法 96
9.2 随机梯度下降 96
9.3 加速方法 96
9.4 自适应算法 96
9.5 案例：深度学习中的训练相关算法 96
本章参考文献 96

第十章 最优化方法——二阶算法 97
10.1 牛顿法与海森矩阵 97
10.2 曲率信息与收敛速度 97
10.3 案例：自然策略梯度 97
本章参考文献 97

第十一章 最优化方法——约束优化与对偶理论 98
11.1 拉格朗日乘子法 98
11.2 KKT 条件与对偶理论 98
11.3 增广拉格朗日法 98
11.4 案例：深度学习中的约束优化问题 98
本章参考文献 98

模型案例集 99

《人工智能数学基础》 CC BY-NC-SA 4.0 禁止商业使用 · 著作权归全体署名作者共有

A.1 多层感知机：仿射映射与逐点非线性的复合 99
A.2 卷积网络：把结构约束写进线性算子 100
A.3 视觉 Transformer：把图像变成序列的注意力块 102
A.4 CLIP：对比对齐＝度量学习与信息论损失 103
A.5 四个模型的对照 104
本章参考文献 105

符号表 **106**

全书参考文献 **106**

《人工智能数学基础》
CC BY-NC-SA 4.0
禁止商业使用 · 著作权归全体署名作者共有

前言

人工智能时代，学习数学的新范式

人工智能时代，我们应该如何学习数学？需要学习多少数学？当机器已经能够完成越来越复杂的计算、推导乃至证明时，人为什么还要花费大量时间学习数学？人工智能又会怎样改变数学教育和数学研究？

这些问题目前并没有标准答案。我们希望通过这份教材对它们进行一次回答，这也同样是一场仍在进行中的教学实验。

这场实验来自一个很朴素的起点：十几位仍在求学阶段的博士研究生，因为共同学习数学、共同面对人工智能带来的变化而聚集在一起，希望一起整理一份更适合今天学习方式的数学教材。我们中的每个人都有自己的研究方向和学习经历，对数学也有不同的理解。编写这份教材的过程，本身也是一个不断讨论、互相质疑、反复修改的过程。

因此，这不是一份独立完成的教材，也不是一份试图一次性写完的知识汇编。它更像是十几位学习者共同留下的一份学习记录。我们希望把这种共同整理、共同讨论和共同审查的过程，也留给后来阅读这份教材的人。

从 AlphaGo 之后说起

2016 年 3 月，AlphaGo 战胜围棋世界冠军李世石。那场比赛后来常常被视为人工智能发展史上的一个标志性事件。许多人第一次如此直观地意识到：一些长期以来被认为高度依赖经验、直觉和人类智慧的活动，机器也可能达到甚至超过人类顶尖水平。

十年过去，类似的变化已经发生在越来越多的领域。数学作为一个大量使用形式化语言、明确规则和严密推理的学科，也正在经历类似的变化。

其实，人们很早以前就在思考机器最终能够走多远。1950 年，Alan Turing 在著名论文 *Computing Machinery and Intelligence* 的结尾写道：

> "We can only see a short distance ahead, but we can see plenty there that needs to be done."

我们只能看见前方不远的地方，但仅仅在那里，就已经有许多事情需要去做。[1]

七十多年过去，这句话所表达的谨慎与开放，依然适合我们今天面对人工智能时的处境。

计算机参与数学并不是今天才开始的。数值计算、符号计算、计算机辅助证明，以及计算数学和数据密集型科学的发展，都已经深刻改变了数学和科学研究。近年来，大语言模型、自动定理证明、证明辅助工具以及形式化数学的发展，又进一步扩大了机器参与数学活动的

《人工智能数学基础》 CC BY-NC-SA 4.0 © 著作权归全体著作者所有
禁止商业使用；著作权归全体著作者所有

范围。计算、检索、构造例子、寻找反例、检查推导、形成猜想乃至尝试证明，都可以不同程度地获得机器的帮助。

我们正在逐渐进入一个新的阶段：数学活动越来越可能成为人与计算工具、人工智能共同工作的过程。

当接近数学知识的门槛开始降低，当一篇原本需要扎实的数学基础、花费数小时才能读懂的论文，可以借助大语言模型在几分钟内获得一个初步而通俗的解释；当人工智能开始参与形式化证明、猜想生成和数学研究，一些过去只有经过长期专业训练才能开展的数学活动，也越来越多地得到机器的帮助。我们由此面对两个更加根本的问题：

如果机器越来越会做数学，我们为什么还要学习数学？

如果人与人工智能共同参与数学活动正在成为可能，我们又应该怎样学习数学？

为什么还要学习数学？

一个直接的回答是，现代人工智能本身建立在大量数学理论之上。从理解和研究人工智能的角度看，数学仍然具有基础性的作用。

线性代数、概率论、统计学、最优化、信息论等数学工具，是理解现代机器学习的重要基础。本书主要讨论其中与人工智能基础课程关系最密切的线性代数、概率论与最优化，并在需要时涉及相关数学工具。与此同时，人工智能中仍然存在大量“实践中有效、理论上尚未被充分理解”的现象。一个模型为什么有效，在什么条件下有效，又会在什么条件下失效，仍然是数学和人工智能研究中十分重要的问题。

但数学的价值还可以从更宽的范围来理解。

人工智能处理的是信息，而数学本身就是人类发展出来的一套极为精炼的信息表达、组织和推理体系。定义试图准确划定概念的边界；定理描述条件与结论之间的关系；证明则把这种关系转化为可以一步一步检查的推理。

数学训练真正留下来的，除了求导、积分、矩阵分解或者概率计算这些枯燥的技巧，还包括一些更基本的习惯：面对一个问题，先弄清研究的对象；面对一个概念，先检查它的定义；面对一个结论，先寻找它成立的条件；面对一段推导，逐步检查其中的依据；面对一个看似漂亮的答案，再问一句：有没有反例？

George Pólya 长期研究数学中的问题求解和发现。他曾强调，数学教育应当系统地给学生机会，让他们自己去发现。[2]

在人工智能时代，这句话可能具有新的含义。过去，“自己发现”常常意味着人类独立完成计算和推导；今天，它还可以意味着在人工智能辅助下自己提出问题、识别条件、检查论证、寻找反例、比较不同解释，并判断机器给出的答案是否真正解决了原来的问题。

这也为“我们需要学习多少数学”提供了一个方向。基础知识仍然需要扎实掌握，因为没有这些基础，我们很难判断机器的回答究竟是否合理。但学习数学的目标也可以更加丰富。随着机器越来越擅长执行标准化过程，我们可以把更多时间用于理解数学结构、建立概念之间的联系、提出问题和形成判断。

《人工智能数学基础》 CC BY-NC-SA 4.0 本书版权归全体著作者共有 禁止商业使用

某些过去以熟练计算为主要目的的训练，将来也许会更多地表现为一种“思维体操”。这并不意味着这些训练失去意义，而是提醒我们进一步思考它们的作用：练习计算可以帮助我们建立必要的数学感觉，也可以帮助我们理解抽象概念；当计算本身越来越容易自动完成时，这些练习的意义更需要从更高层次去理解。

再进一步说，数学也是一种认识世界的方法。它要求我们区分假设与事实、直觉与证明、相关与因果、局部经验与一般结论。从这个意义上说，即使许多具体的计算工作逐渐交给机器，数学仍然具有工具之外的价值。

以上只是我们在这个阶段的一些思考。人工智能正在改变我们理解和使用数学的方式，也正在进入数学研究本身。面对这些变化，应该怎样学习数学，又应该怎样做数学，对我们而言，乃至对整个数学共同体而言，都仍然是值得继续探索的问题。

人工智能时代，我们应该怎样做数学？

传统上，我们很容易把数学学习理解成一个近似线性的过程：

学习定义 → 掌握定理 → 理解证明 → 完成习题。

数学研究则往往从问题出发，经历探索、猜想、验证和证明。

人工智能加入以后，这些基本环节仍然存在，但它们之间的工作分配正在发生变化。一种越来越容易实现的工作方式是：

探索 → 猜想 → 人工智能辅助检索、计算与验证 → 尝试证明 → 人工审核 → 修改猜想或证明 → 再次探索。

我们需要判断：什么问题值得研究？一个定义是否自然？这个猜想为什么值得相信？一个计算实验能够说明什么，又不能说明什么？证明中是否遗漏了条件？有没有没有想到的反例？一个结论能否推广？不同方法之间的差异究竟是技术上的，还是反映了更深的结构？

因此，在人与人工智能共同工作的环境中，人可能会更多地承担几种角色：问题的提出者、猜想的形成者、探索过程的组织者、结果的审核者，以及知识结构的整理者。

这种变化并不会削弱证明和推导的重要性。恰恰因为机器可以迅速生成大量形式完整、语言流畅、甚至十分“像数学”的内容，我们更需要理解一个严格的定义是什么，一个完整的证明需要哪些条件，以及什么样的证据足以支持一个数学结论。

2026 年发布的《莱顿人工智能与数学宣言》（*Leiden Declaration on Artificial Intelligence and Mathematics*）集中讨论了人工智能进入数学研究以后带来的这些问题。宣言将理解、清晰性和判断力，以及数学论证的透明性和独立可验证性，视为数学研究中值得维护的重要价值。[3] 它同时提醒我们，当前的自动化工具可能产生看似合理、实际上却不可靠甚至错误的论证；当自动化技术参与正式发表的数学研究时，论证和结果正确性的责任仍由人类作者承担。[3]

学生以后遇到的问题，很可能越来越多地变成：“我能不能判断眼前这个答案？”人工智能可以参与探索，可以提供候选结果，也可以帮助我们检查自己的工作；但接受什么、怀疑什么、怎样验证，以及最终为什么相信一个结论，仍然要求人作出判断。

《人工智能数学基础》 CC BY-NC-SA 4.0 著作权归全体署名作者共有

因此，在人工智能时代，一种很朴素但可能越来越重要的能力是：

当答案越来越容易生成时，我们仍然知道为什么相信一个答案。

从知识的接受者，到知识的整理者：我们的实践

人工智能的加入，也使我们需要重新思考数学学习的过程。

今天的大学数学课程通常以教材、教学大纲、课堂讲授、习题和考试为基本结构。这套模式能够把经过长期积累形成的知识体系，以稳定、系统的方式传递给学生。与此同时，学生获得解释、例子和解题思路的渠道正在迅速增加。人工智能可以帮助我们查找资料、生成例子、比较不同解释、尝试不同思路，也可以参与检查推导和发现问题。

这使学习者有机会承担更主动的角色。

过去，一个学生通常先阅读教材，再完成题目；现在，他也可以自己整理知识，要求人工智能解释概念，比较不同教材中的定义，检查一段证明，然后重新组织成自己的表述。学习由此可以形成一个不断循环的过程：

生成 → 阅读 → 质疑 → 验证 → 修改 → 再生成。

人工智能显著降低了生成候选内容的成本，但候选内容本身并不等于理解。真正的学习仍然发生在阅读、质疑、验证和修改之中。要判断一个定义是否严谨，需要真正理解定义；要发现证明是否遗漏条件，需要理解定理成立的原因；要构造反例，需要知道一个结论可能在哪些边界上失效。

因此，“审核”本身也可以成为一种学习。

这份教材也试图把这种学习方式落实到具体的编写过程中。

教材的整理、讨论和编写本身也是共同学习的过程。课程课件帮助我们确定教学范围，成熟教材和经典教科书帮助我们确定理论深度，论文和公开资料帮助我们了解一些较新的发展；人工智能则参与部分内容生成、资料整理、解释、推导和审校。关于具体工具、参与范围以及责任划分，另见本书的《人工智能使用声明》。

在内容组织上，我们仍尽力尊重数学长期形成的基本结构：

定义 → 命题与定理 → 证明 → 例子与反例 → 方法与应用。

我们希望尽量说明一个概念为什么出现，它解决什么问题，与已有概念有什么关系；说明一个公式在什么条件下成立，一个证明依赖哪些假设，一个方法又会在什么地方失效。人工智能参与了生成过程，但所有内容仍需要经过阅读、核查、讨论和修改。

不同研究背景带来的差异，也使这种共同审核成为学习的一部分。一个人的疑问可能促成一段证明的重写，一个看似微小的错误也可能让我们重新检查整个推导。我们也希望读者保留同样的主动检查习惯：教材中的定义、证明、计算和一般性结论，都应当能够被重新检查和质疑。

《人工智能数学基础》
CC BY-NC-SA 4.0
禁止商业使用，著作权归全体署名作者共有

因此，这份教材被设计成一份可以持续维护的数学学习记录。新的内容可以被加入，旧的表述可以被重写，错误可以被发现和修正，必要的修订过程也可以被保留下来。学习者也可以参与其中，成为教材的开发者、审稿人和共同维护者。

这种方式当然也有风险。人工智能会产生错误，持续更新可能带来新的疏漏，过度依赖工具也可能削弱独立探索和思考。因此，这种学习方式的效果仍然需要实践检验，而教材本身也应当继续接受检查、质疑和修改。

写在最后

人工智能究竟会怎样改变数学，我们今天还很难给出确定的答案。

现在的数学家、工程师和学生，已经拥有远强于过去的数学工具和计算工具。未来，也将如此。但工具能力的增长并不能替代我们对数学的理解和品味。当答案越来越容易获得时，理解答案、判断答案以及提出新的问题，会变得越来越重要。

我们希望通过这份教材学习的，不只是一些数学知识，也包括：

如何提出问题，如何组织知识，如何理解定义，如何检查论证，如何发现错误，如何与工具合作，以及如何对自己的判断负责。

Turing 在七十多年前说，我们只能看到前方不远的地方。或许，前方不远的地方也难以看见。只有不断前行，方能发现道路。

这份教材不试图回答人工智能时代数学教育的全部问题。它只是从一门课程、一些数学知识和一次共同学习的具体实践开始，试着向前走一点。

如果在这个过程中，我们和学习者都能够更认真地重新以一种新形式去学习和认识数学，那么这次尝试就已经有了意义。

引用来源

[1] Alan M. Turing, “Computing Machinery and Intelligence,” *Mind*, Vol. 59, No. 236, 1950, pp. 433–460.

[2] George Pólya, *How to Solve It*, Princeton University Press, 1945；另参见其关于数学发现与数学教育的相关著作。

[3] *Leiden Declaration on Artificial Intelligence and Mathematics*, 2 June 2026.

《人工智能数学基础》 CC BY-NC-SA 4.0 禁止商业使用 · 著作权归全体著作者所有

人工智能使用声明

本教材在撰写、编辑与排版过程中使用了人工智能工具。**正文文案由人与人工智能协作生成，**经署名作者核验、修改后定稿。我们认为这类工具的使用应当公开——读者有权知道一本书是怎样写出来的。所用工具、参与范围与责任归属，声明如下。

一、所用工具

工具	提供方	在本项目中的用途
×××	×××	×××
×××	×××	×××
×××	×××	×××

本表列出本项目实际使用过的全部大语言模型与 agent 工具；留空处待补。

二、参与范围

人工智能工具参与：直接参与**文案的生成与修改**——各章初稿的起草、段落的撰写与改写、表述的润色与术语的规范化；资料梳理与章节提纲的拟定；LaTeX 排版代码与工程脚本（`tools/`）的编写；编译日志检查、交叉引用完整性核对、版面留白扫描等辅助校验。

由署名作者负责，未交由人工智能决定：数学内容的选择与取舍；定义、定理与证明的陈述；例题与习题的设计及全部数值算例的核算；全书体例与行文风格的确立；书稿的最终审定。各章分工与审校记录见章首署名栏与各章 `CHANGELOG.md`，外部专家审查报告见 `docs/expert_inspection/`。

三、责任

人工智能生成的内容均经作者逐条核验与修改后采用，文责由署名作者承担。书中若仍有错误，属作者审定不周，与所用工具及其提供方无关。

四、致谢

感谢上述工具及其开发者：它们承担了本书相当篇幅的文案起草与改写，以及大量繁琐的梳理、排版与校验工作，使作者得以把精力集中在数学内容本身。同样感谢参与本书审阅的专家与同行——这一环是任何工具都无法替代的。

《人工智能数学基础》
CC BY-NC-SA 4.0
禁止商业使用 · 署名权归全体署名作者共有

第一篇

矩阵代数

《人工智能数学基础》
CC BY-NC-SA 4.0
禁止商业使用，著作权归全体署名作者共有

Chapter 1

矩阵代数——矩阵与线性变换

本章作者：Xinpei Zhang　初审：Haihui Li　二审：Panpan Wu

终审：Yijia Liu　人工智能例子审核：Haoran Cao、Zhendan Zhang

本章导读

线性代数是人工智能的第一门“母语”。一个样本是一支向量，一份数据集是一个矩阵，一层神经网络是一个线性映射复合上逐点的非线性，而几乎所有训练算法最终都要回答同一个问题：给定 A 与 b，如何找到 x 使 Ax 尽量接近 b？本章的目标是搭起这条主线的数学骨架：

向量 → 向量空间 → 子空间 → 张成 / 线性无关 / 基 / 维数 → 线性变换 → 矩阵表示 → 核 / 像 → 内积与正交性 → 四个基本子空间 → 投影 → 最小二乘。

这条主线有一个刻意的次序：**先讲向量空间与线性映射，再谈矩阵**。矩阵是线性变换在给定基下的矩阵表示；理解了线性变换，矩阵乘法的每一种算法才有意义。图 1.1 给出本章的数学依赖关系；虚线右侧是本章的支线（特征映射与核技巧），它把线性方法推广到非线性模型，但它的每一个概念——内积、Gram 矩阵、半正定——都仍然落脚在主线之上。

内容边界

本书是教材而不是手册，因此有必要明确本章“不做什么”。凡是与本章主线（向量空间 → 线性变换 → 投影 → 最小二乘）无直接关系的内容，一律推迟到相应章节，见表 1.1。本章只保留后续章节必须用到的结构性结果：向量空间与子空间的定义、基与维数、线性映射与矩阵表示、秩-零化度定理、四个基本子空间、正交投影与最小二乘；其余技巧性内容交给后面的章节。这样安排的代价是本章暂时显得“窄”，收益是每一个概念都在正确的位置上被引入、被使用。

《人工智能数学基础》 CC BY-NC-SA 4.0 署名-非商业使用-相同方式共享 作者：作者名

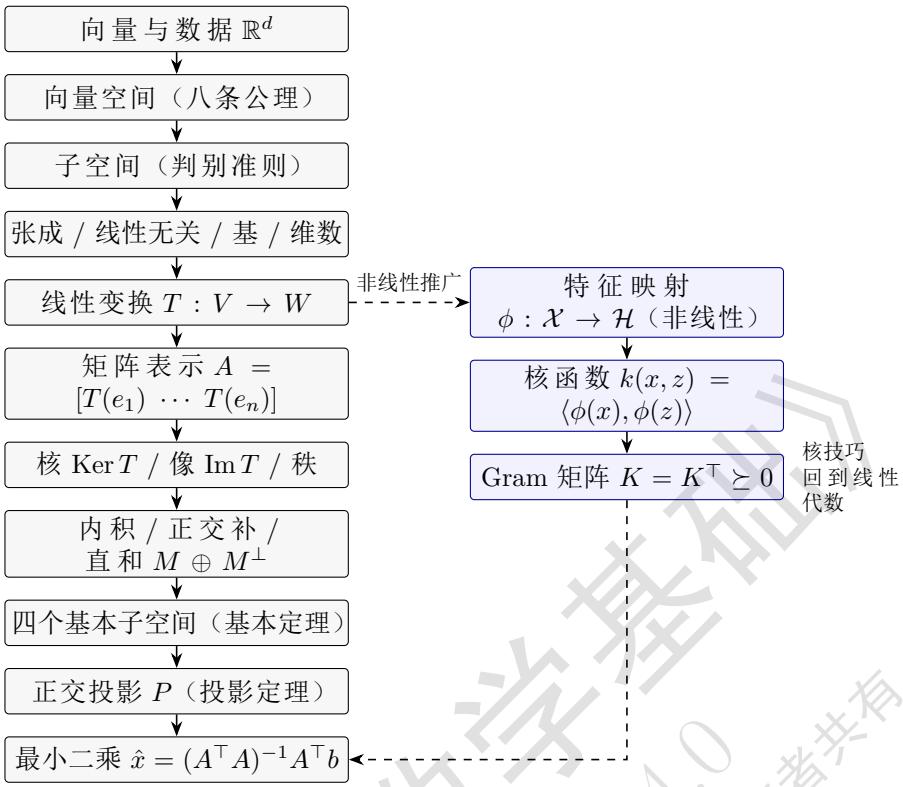


图 1.1: 本章的数学依赖关系：左侧为本章主线，右侧为特征映射与核技巧支线

表 1.1: 本章内容边界与后续章节的分工

内容	本章处理方式	去向
群、环与一般域上的模	压缩为一句注	节 1.2 的注
Gaussian 消元法	只作简要复习	节 1.8 的注
Hadamard 积、Kronecker 积	不展开	第 5 章（特殊运算与张量基础）
卷积	仅在例举中提及	第 5 章
Cayley–Hamilton 定理、特征值理论	不涉及	第 3 章（矩阵分解）
正定矩阵的系统理论	只给定义与半正定性的证明	第 2、3、8 章
行列式与迹的各类不等式	删除	附录 / 第 4 章
SVM 的优化模型与对偶	只给一句话说明	第 8–11 章（最优化方法）

《人工智能数学基础》 CC BY-NC-SA 4.0 禁止商业用途，衍生作品须以相同协议共享，著作权归全体署名作者共有

本章约定

本章的英文题目为 *Matrix Algebra: Matrices and Linear Transformations*。为避免在全书中反复交代同一件事，下面把本章通用的约定一次列出；后续各章除非另行声明，也沿用这些约定。

(1) **数域。**默认在实数域 $\mathbb{F}=\mathbb{R}$ 上讨论；只有在确有必要时才取 $\mathbb{F}=\mathbb{C}$，届时会明确声明。本课程出现的向量空间基本只有 $\mathbb{R}^d$、$\mathbb{C}^d$、$\mathbb{R}^{m\times n}$、多项式空间 P_d 与函数空间这几类。

(2) **向量与内积。**$x\in\mathbb{R}^d$ 一律指**列向量**，$x^\top$ 为对应的行向量。内积默认取欧氏内积 $\langle x,y\rangle = x^\top y$，范数默认取 $\|x\|_2=\sqrt{\langle x,x\rangle}$；需要别的内积时会写清楚。

(3) **数据矩阵。**行 = 样本、列 = 特征，即 $X\in\mathbb{R}^{N\times d}$ 的第 i 行是第 i 个样本（式 (1.2)）。有的教材与软件库取相反的约定（列 = 样本），读他人代码时先确认这一点。

(4) $\arg\min$ **表示解集。**$\arg\min_x f(x)$ 指使 f 取到最小值的集合。当最小值点唯一时，可将该集合与其唯一元素等同，记作 $x^*=\arg\min_x f(x)$；不唯一时写作 $\hat{x}\in\arg\min_x f(x)$。最小二乘解集 式 (1.26) 属于后一种情形：A 不满列秩时它含无穷多个元素。

(5) **线性与仿射。**线性映射满足 $T(\alpha x+\beta y)=\alpha T(x)+\beta T(y)$（定义 1.15），特别地 $T(0)=0$。形如 $x\mapsto Ax+\mathbf{b}$（$\mathbf{b}\neq 0$）的映射称为**仿射映射**。本章凡称“线性”，一律指前者。

(6) **伪逆。**A^+ 一律指 Moore–Penrose 伪逆，不使用 $A^\dagger$ 等其它记号；A^{-1} 只用于可逆方阵。伪逆对任意矩阵都存在且唯一。若 A 满列秩，则 $A^+=(A^\top A)^{-1}A^\top$。

(7) **核、像与四个基本子空间。**抽象线性映射用 $\operatorname{Ker}T$、$\operatorname{Im}T$；具体矩阵用 $\operatorname{Null}(A)$、$\operatorname{Col}(A)$、$\operatorname{Row}(A)$、$\operatorname{Null}(A^\top)$（左零空间）。$\operatorname{rank}(A)$ 与 $\operatorname{nullity}(A)$ 分别指 A 的秩与零化度。

(8) **主线与支线。**本教材把“向量空间 → 线性变换 → 投影 → 最小二乘”这条链称为本章**主线**，把特征映射与核技巧称为**支线**（图 1.1）。

核心思想

“特征”一词有两个来源，本教材分别对待。一方面，机器学习借用线性代数的语言，把数据的一个属性叫作 *feature*，于是有**特征映射**（feature map）、**特征空间**（feature space）与**特征表示**（feature representation，文献中也作 feature vector）。另一方面，线性代数自身的 *eigen-* 系列在中文里同样译作“特征”：**特征值**（eigenvalue）、**特征向量**（eigenvector）、**特征空间**（eigenspace）。二者同名而含义无关。本章讲的都是前者；后一组概念属于特征值理论，将在第 3 章系统展开。本章只在 节 1.10 末尾用到投影矩阵这一个特例，届时一律写成“特征值（eigenvalue）”“特征向量（eigenvector）”并夹注英文，以免混淆。

《人工智能数学基础》 CC BY-NC-SA 4.0 著作权归作者所有 禁止商业用途

1.1 数据、向量与矩阵

1.1.1 从数据到向量

在人工智能中，我们几乎总是从“数据”出发。设描述一个对象需要 d 个数值特征，我们就按照固定的顺序把这 d 个数排成一列：

$$x = (x_1, x_2, \dots, x_d)^\top \in \mathbb{R}^d. \tag{1.1}$$

这里 x_j 是第 j 个特征（feature）的取值，上标 $\top$ 表示转置，它把行写成列。一个样本就是一个向量，而 x_j 的含义与位置都是事先固定好的。

例 1.1 (两个样本) 描述一批学生，取身高（厘米）、体重（千克）、年龄（岁）三个特征，则

$$x_1 = (170,\, 65,\, 22)^\top, \qquad x_2 = (180,\, 78,\, 24)^\top$$

是两个样本。x_1 与 x_2 属于同一个 $\mathbb{R}^3$，因为二者使用了同一组特征、同一个顺序（先身高、再体重、后年龄）。正是这种“同一坐标系下可比”的性质，使得我们可以对样本做加法、数乘与内积。

需要提醒的是，这种“可以做”是代数上的，不一定是统计上有意义的：身高以厘米计、体重以千克计、年龄以岁计，量纲不同，直接做内积会让数值大的特征（这里是身高）主导结果。实际建模中通常先做**标准化**（各特征减均值、除以标准差）或**归一化**（缩放到固定区间），也可以改用带权内积 $\langle u, v\rangle_W = u^\top W v$（$W$ 为对称正定矩阵）来为不同特征指定权重。本章之后一律假设数据已经过适当的预处理。

注. 向量当然也可以被解释成平面上的位置或者位移，这是中学几何里最直观的图像。但几何直观只是向量的一种特例：上面那支“身高–体重–年龄”向量画不出任何有意义的箭头，它依然是一个完全合法的向量。本章处理的是数据向量。

1.1.2 数据矩阵

把 N 个样本按行堆叠起来，就得到**数据矩阵**（design matrix，也译作设计矩阵）

$$X = \begin{bmatrix} x_1^\top \\ x_2^\top \\ \vdots \\ x_N^\top \end{bmatrix} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1d} \\ x_{21} & x_{22} & \cdots & x_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ x_{N1} & x_{N2} & \cdots & x_{Nd} \end{bmatrix} \in \mathbb{R}^{N\times d}. \tag{1.2}$$

按本章约定第 3 条，X 的第 i 行 $x_i^\top$ 是第 i 个样本，第 j 列是第 j 个特征在所有 N 个样本上的取值向量。凡牵涉“样本维度”与“特征维度”的公式，都以此为准。

《人工智能数学基础》 CC BY-NC-SA 4.0 禁止商业使用，著作权归全体作者所有

AI 应用

问题：自然语言的句子长度不一，如何送进统一维度的线性代数框架？

数学建模：把每个 token 表示成 $\mathbb{R}^d$ 中的向量（token embedding），则一个长度为 L 的句子就是矩阵 $X \in \mathbb{R}^{L\times d}$，其中 L 是**序列长度**、d 是**嵌入维度**。实际训练按 batch 进行，同批样本的 L 一般不同，通常先 padding 到统一长度 $L_{\max}$，再用 attention mask 把补齐位置屏蔽掉，使它们不参与计算。

理论联系：注意力机制的核心计算 $\mathrm{softmax}(QK^\top/\sqrt{d_k})V$ 由矩阵乘法、缩放与**逐行 softmax** 组成，其中 Q,K,V 分别是 X 经 W_Q,W_K,W_V 得到的线性变换结果，d_k 是 key 的维度，缩放因子 $\sqrt{d_k}$ 用来抵消内积随维度增长而增大的效应。softmax 对矩阵的每一行做归一化、是非线性运算，它把这几步矩阵乘法串成一个非线性映射。深度学习中的 linear layer 通常形如 $X \mapsto XW+\mathbf{b}$，它是**仿射映射**，其线性部分为 $X \mapsto XW$。数据形状（shape）之所以是深度学习中最常用的调试信息之一，是因为张量算子对输入输出的形状有明确要求：线性映射与矩阵乘法把这一要求体现得最直接，$\mathbb{R}^n \to \mathbb{R}^m$ 的线性映射，其定义域与值域的维数就写在 shape 上；逐元素运算（ReLU、GELU、Sigmoid）要求输入输出同形，归约运算则消去某一维。

1.1.3　矩阵乘法的三种理解

设 $A \in \mathbb{R}^{m\times n}$、$x \in \mathbb{R}^n$，考虑矩阵–向量乘积

$$y = Ax, \qquad y \in \mathbb{R}^m. \tag{1.3}$$

同一个式子 $y = Ax$ 有三种完全不同的读法，它们分别对应三种推理方式。

（i）行观点：内积。把 A 按行分块为 $A = [a_1^\top; \dots; a_m^\top]$（其中 $a_i \in \mathbb{R}^n$），则

$$y_i = a_i^\top x = \langle a_i, x\rangle = \sum_{j=1}^{n} a_{ij}x_j, \qquad i = 1,\dots,m. \tag{1.4}$$

每一行的元素是“权重”，y_i 是第 i 行与输入的内积。这就是线性回归、感知机与全连接层中“一个神经元输出一个数”的代数原型。

（ii）列观点：线性组合。把 A 按列分块为 $A = [a_1\ a_2\ \cdots\ a_n]$（其中 $a_j \in \mathbb{R}^m$），则

$$Ax = x_1a_1 + x_2a_2 + \cdots + x_na_n. \tag{1.5}$$

Ax 是 A 的各列以 x 的分量为系数的线性组合。于是“$Ax = b$ 有解”等价于“b 落在 A 的各列张成的集合里”——这句话将在 节 1.8 变成关于解集结构的定理。

（iii）线性变换观点：映射。把 A 看作一个从 $\mathbb{R}^n$ 到 $\mathbb{R}^m$ 的**函数**

$$T_A : \mathbb{R}^n \to \mathbb{R}^m, \qquad T_A(x) = Ax.$$

它保持加法与数乘：$T_A(\alpha x+\beta z) = \alpha T_A(x) + \beta T_A(z)$。线性代数真正研究的对象是这个映射，

《人工智能数学基础》 CC BY-NC-SA 4.0 著作权归全体署名作者共有 禁止商业使用

而 A 只是它在标准基下的矩阵表示（节 1.4 会严格说明这一点）。

现在才给出元素公式。对 $A \in \mathbb{R}^{m\times n}$、$B \in \mathbb{R}^{n\times p}$，定义乘法的第 (i,j) 个元素为

$$(AB)_{ij} = \sum_{k=1}^{n} a_{ik} b_{kj}. \tag{1.6}$$

这条元素公式有下面三种等价的读法：

- 列的观点： AB 的第 j 列 $= (AB)_{\cdot j} = A\,(B_{\cdot j})$，即“矩阵乘矩阵 = 对右矩阵的每一列做矩阵–向量乘法”；
- 行的观点： AB 的第 i 行 $= (AB)_{i\cdot} = (A_{i\cdot})B$，即左矩阵的每一行去“探测”右矩阵；
- 复合的观点：若 $S : \mathbb{R}^p \to \mathbb{R}^n$、$T : \mathbb{R}^n \to \mathbb{R}^m$ 分别以 B, A 为矩阵，则复合映射 $T \circ S$ 的矩阵恰好是 AB。这也解释了为什么矩阵乘法一般不可交换：映射的复合一般不可交换。

注. 矩阵乘法满足结合律 $(AB)C = A(BC)$：从复合映射的角度看这是显然的，用元素公式式 (1.6) 逐项验证则相当繁琐。

1.2 向量空间与子空间

1.2.1 向量空间的定义

$\mathbb{R}^d$ 中能做加法与数乘，$\mathbb{R}^{N\times d}$ 中也能做加法与数乘；以**次数不超过 d 的实系数多项式**为元素构成的集合同样能做加法与数乘。把这些共同性质抽象出来，就得到向量空间。

本章记

$$P_d = \{p \in \mathbb{R}[t] : \deg p \le d\}, \qquad \deg 0 = -\infty, \tag{1.7}$$

其中 $\mathbb{R}[t]$ 表示全体实系数多项式。多项式添上通常的加法与数乘之后，P_d 构成 $\mathbb{R}$ 上的向量空间（例 1.3 将正式验证）。

定义 1.2 (向量空间) 设 $\mathbb{F}$ 是一个域（本书默认取 $\mathbb{F} = \mathbb{R}$，必要时取 $\mathbb{F} = \mathbb{C}$）。一个集合 V 若配备两种运算

$$+ : V \times V \to V, \qquad \cdot : \mathbb{F} \times V \to V$$

（分别称为加法与标量乘法），使得对任意 $x, y, z \in V$ 与任意 $\alpha, \beta \in \mathbb{F}$ 都有

(A1) $x + y = y + x$；
(A2) $(x + y) + z = x + (y + z)$；
(A3) 存在元素 $0 \in V$，使得 $x + 0 = x$；
(A4) 存在元素 $-x \in V$，使得 $x + (-x) = 0$；
(A5) $\alpha(\beta x) = (\alpha\beta)x$；
(A6) $1 \cdot x = x$；
(A7) $\alpha(x + y) = \alpha x + \alpha y$；
(A8) $(\alpha + \beta)x = \alpha x + \beta x$，

则称 V（连同这两个运算）是域 $\mathbb{F}$ 上的**向量空间**（或线性空间），V 中的元素称为**向量**，$\mathbb{F}$ 中

《人工智能数学基础》 CC BY-NC-SA 4.0 禁止商业使用 著作权归全体署名作者共有

的元素称为**标量**。

公理 (A3) 中的 0 称为零向量，公理 (A4) 中的 $-x$ 称为 x 的负向量，可以证明它们都是唯一的。下面两条常用等式由分配律与单位元公理直接推出：

$$0 \cdot x = 0, \qquad (-1) \cdot x = -x. \tag{1.8}$$

它们在公理 (A3) 与 (A4) 的验证中会反复用到（例如 命题 1.5 的证明）。

注. 公理 (A1)–(A4) 说的是 $(V, +)$ 构成一个交换群，公理 (A5)–(A8) 说的是标量乘法与加法相容。本书只讨论 $\mathbb{R}$ 或 $\mathbb{C}$ 上的向量空间，不讨论抽象代数。

例 1.3 (三个基本例子) $\mathbb{R}^d$（按分量加法与数乘）、$\mathbb{R}^{m\times n}$（按元素加法与数乘）、多项式空间 P_d（式 (1.7)），都是 $\mathbb{R}$ 上的向量空间。前两个的验证是逐分量进行的，这里只把 P_d 写清楚：若 $\deg p \le d$、$\deg q \le d$、$\alpha \in \mathbb{R}$，则 $p+q$ 与 αp 的次数都不超过 d（约定 $\deg 0 = -\infty$ 后，$p = -q$ 的情形也包含在内），故八条公理按多项式的加法与数乘直接继承。而 $\{(x_1, x_2)^\top \in \mathbb{R}^2 : x_1 x_2 = 0\}$（两条坐标轴之并）不是向量空间：$(1,0)^\top$ 与 $(0,1)^\top$ 都在其中，但它们的和 $(1,1)^\top$ 不在。

1.2.2　子空间与判别准则

定义 1.4 (子空间) 设 V 是 $\mathbb{F}$ 上的向量空间。若 V 的子集 W 在 V 的加法与标量乘法下自身也构成 $\mathbb{F}$ 上的向量空间，则称 W 是 V 的**子空间**（subspace）。

实际使用中依赖下面的判别准则，它把“逐条验证八条公理”简化为“只验证一条封闭性”。

命题 1.5 (子空间判别准则) 设 V 是 $\mathbb{F}$ 上的向量空间，$W \subseteq V$。则

$$W \text{ 是 } V \text{ 的子空间} \iff W \neq \varnothing \text{ 且 } \alpha x + \beta y \in W, \qquad \forall\, x, y \in W,\ \forall\, \alpha, \beta \in \mathbb{F}.$$

证明. 必要性是显然的：子空间含零向量，故非空；又对加法与数乘封闭。充分性：设 $W \neq \varnothing$ 且对加法与数乘封闭。由于 W 中的运算继承自 V，公理 (A1)、(A2)、(A5)–(A8) 自动成立。取 $x \in W$（W 非空），由封闭性 $0 = 0 \cdot x \in W$，故公理 (A3) 成立；再由 $-x = (-1)\cdot x \in W$，公理 (A4) 成立。于是 W 是向量空间。 □

注. 非空条件不能省。若 $W = \varnothing$，“$\alpha x + \beta y \in W$ 对一切 $x, y \in W$”空洞地成立，但空集不含零向量，不是子空间。

由此立刻得到一个常用的必要条件：**任何子空间都含有零向量。**

例 1.6 (一个子空间) 在 $\mathbb{R}^3$ 中令

$$W = \big\{ x = (x_1, x_2, x_3)^\top \in \mathbb{R}^3 :\ x_1 + x_2 + x_3 = 0 \big\}.$$

由 命题 1.5，W 是 $\mathbb{R}^3$ 的子空间：记 $z = \alpha x + \beta y$，则 $z_1 + z_2 + z_3 = \alpha(x_1+x_2+x_3) + \beta(y_1+y_2+y_3)$，而 $x, y \in W$ 时右边两个括号都是零。又 $[1\ 1\ 1]x = x_1 + x_2 + x_3$，故 $x \in W$ 当且仅当

《人工智能数学基础》 CC BY-NC-SA 4.0 著作权归全体著作者共有 禁止商业使用

$[1\ 1\ 1]x = 0$，即

$$W = \mathrm{Null}\big([1\ \ 1\ \ 1]\big).$$

这里，Null 指零空间（即所有使得该矩阵作用后为零的向量的集合）。

例 1.7 (一个不是子空间的集合) 在 $\mathbb{R}^2$ 中令

$$S = \big\{x = (x_1, x_2)^\top \in \mathbb{R}^2 :\ x_1 + x_2 = 1\big\}.$$

则 S 不是 $\mathbb{R}^2$ 的子空间：$0 = (0,0)^\top \notin S$，因为 $0 + 0 = 0 \neq 1$。

注. S 虽然不构成子空间，却有一个非常整齐的形状：任取 $x_0 \in S$，如 $x_0 = (1,0)^\top \in S$，则

$$S = x_0 + \mathrm{Null}\big([1\ \ 1]\big).$$

也就是说，S 是子空间 $\mathrm{Null}([1\ 1])$ 平移一个特解得到的**仿射子空间**。这个观察将在 节 1.8 中被推广成关于 $Ax = b$ 解集结构的定理，并被 节 1.11 用作讨论“$Ax = b$ 无解时如何退而求其次”的背景。

核心思想

“$0 \notin S$”是判断一个集合不是子空间最快捷的手段；而“$\alpha x + \beta y \in W$”是证明一个集合是子空间唯一要做的事。子空间必须过原点，这是它与不过原点的仿射子空间最本质的区别。

1.3 张成、线性无关、基与维数

定义 1.8 (张成) 设 $v_1, \ldots, v_m$ 是向量空间 V 中的向量。它们的全体线性组合所构成的集合

$$\mathrm{span}\{v_1, \ldots, v_m\} = \Big\{\textstyle\sum_{i=1}^m c_i v_i :\ c_1, \ldots, c_m \in \mathbb{F}\Big\}$$

称为这组向量的**张成**（span）。对一般的子集 $S \subseteq V$，$\mathrm{span}\, S$ 定义为 S 中任意有限个向量的一切线性组合之集，并约定 $\mathrm{span}\, \varnothing = \{0\}$。

不难验证 $\mathrm{span}\, S$ 是 V 的子空间：若 $x, y \in \mathrm{span}\, S$、$\alpha, \beta \in \mathbb{F}$，则 $\alpha x + \beta y$ 仍是 S 中向量的有限线性组合，故属于 $\mathrm{span}\, S$，由 命题 1.5 即得。而且它是包含 S 的最小子空间：任何包含 S 的子空间都必须包含 S 中向量的所有线性组合。

定义 1.9 (线性无关与线性相关) 称向量组 $v_1, \ldots, v_m \in V$ **线性无关**，若

$$c_1 v_1 + c_2 v_2 + \cdots + c_m v_m = 0 \quad \Longrightarrow \quad c_1 = c_2 = \cdots = c_m = 0.$$

否则称该向量组**线性相关**，即存在不全为零的系数 $c_1, \ldots, c_m$ 使 $\sum_i c_i v_i = 0$。

线性相关的直观含义是“其中至少有一个向量是多余的”：若 $\sum_i c_i v_i = 0$ 且某个 $c_j \neq 0$，

《人工智能数学基础》 CC BY-NC-SA 4.0 禁止商业使用 著作权归全体署名作者共有

则

$$v_j = -\frac{1}{c_j}\sum_{i\neq j} c_i v_i,$$

即 v_j 可以被其余向量线性表示。

定义 1.10 (基与维数) 设 $B=\{v_1,\dots,v_n\}$ 是向量空间 V 的一个子集。若

(1) B 线性无关；

(2) $\operatorname{span} B = V$（即 B 生成 V），

则称 B 是 V 的一组**基**（basis），并称 V 是**有限维**的。此时称 V 的**维数**为 $\dim V = n$；约定**零子空间**（只含零向量的空间）$\{0\}$ 的维数为 0。

注. 无限维向量空间的基与维数的定义和性质更复杂，本书不讨论。

维数的定义要成立，必须先知道“不同的基含有同样多的向量”。这一点由下面的推论给出。

基还有一条性质直接由定义得到，用起来却极频繁，即基坐标表示的唯一性。设 $B=\{v_1,\dots,v_n\}$ 是 V 的一组基，则每个 $x\in V$ 可唯一地写成

$$x = x_1v_1 + x_2v_2 + \cdots + x_nv_n. \tag{1.9}$$

系数 $(x_1,\dots,x_n)^{\top}\in\mathbb{F}^n$ 称为 x 在基 B 下的坐标（坐标向量）。存在性来自 $\operatorname{span}B=V$；唯一性来自 B 线性无关——若 $\sum_i a_iv_i = x = \sum_i b_iv_i$，则 $\sum_i (a_i-b_i)v_i = 0$，故 $a_i=b_i$。

引理 1.11 (Steinitz 替换定理) 设 $v_1,\dots,v_m\in V$ 线性无关，$w_1,\dots,w_n\in V$ 生成 V。则 $m\le n$；并且可以用 $v_1,\dots,v_m$ 替换 $\{w_1,\dots,w_n\}$ 中的 m 个向量，使所得 n 个向量仍然生成 V。

证明. 设当前有一个含 n 个向量的生成集 G_i，其中已经含有 $v_1,\dots,v_i$。从 $G_0=\{w_1,\dots,w_n\}$ 出发，逐步把 v_{i+1} 换进去。

v_{i+1} 可由 G_i 线性表示：

$$v_{i+1} = \sum_{j\le i} c_jv_j + \sum_{w\in G_i\setminus\{v_1,\dots,v_i\}} d_w w.$$

右边关于 w 的系数不可能全为零，否则 v_{i+1} 可由 $v_1,\dots,v_i$ 线性表示，与这 $i+1$ 个向量线性无关矛盾。取一个 $d_w\neq 0$ 的 w，把上式解出 w，即知 w 可由 G_i 中其余向量与 v_{i+1} 线性表示。于是

$$G_{i+1} = \big(G_i\setminus\{w\}\big)\cup\{v_{i+1}\}$$

仍生成 V——任何原先用到 w 的表示，都可先用上式把 w 替换掉。

先定出 m 与 n 的大小关系。当 $m\ge n$ 时，$v_1,\dots,v_n$ 都存在，上述归纳可以一路走到 $i=n$：每换一次，属于 $\{w_1,\dots,w_n\}$ 的向量就少一个，故 $G_n=\{v_1,\dots,v_n\}$，它生成 V。若还有 $m>n$，则 v_{n+1} 可由 $v_1,\dots,v_n$ 线性表示，与 $v_1,\dots,v_m$ 线性无关矛盾。故 $m\le n$。

《人工智能数学基础》 CC BY-NC-SA 4.0 禁止商业使用 · 著作权归作者共有

既然 $m \le n$，上述归纳在 $i < m$ 的每一步都成功。走到 $i = m$ 得

$$G_m = \{v_1, \dots, v_m\} \cup W', \qquad W' \subseteq \{w_1, \dots, w_n\}, \quad |W'| = n - m,$$

它含 n 个向量且生成 V，即为所需的替换。 □

定理 1.12 (基的扩充) 设 V 是有限维向量空间，$u_1, \dots, u_k \in V$ 线性无关。则 V 中存在向量 $u_{k+1}, \dots, u_n$，使 $u_1, \dots, u_n$ 构成 V 的一组基。

证明. 取 V 的一个有限生成集 S，记 $|S| = n_0$。由 引理 1.11，V 中任何线性无关组的元素个数都不超过 n_0。

从 $u_1, \dots, u_k$ 出发。若它们已张成 V，就是一组基。否则 $\operatorname{span}\{u_1, \dots, u_k\} \neq V$，取

$$u_{k+1} \in V \setminus \operatorname{span}\{u_1, \dots, u_k\}.$$

若 $\sum_{i \le k+1} c_i u_i = 0$ 而 $c_{k+1} \neq 0$，则 u_{k+1} 可写成 $u_1, \dots, u_k$ 的线性组合，与取法矛盾；故 $c_{k+1} = 0$，再由 $u_1, \dots, u_k$ 线性无关得 $c_1 = \cdots = c_k = 0$。于是 $u_1, \dots, u_{k+1}$ 仍线性无关。

重复这一步骤：每重复一次，线性无关组的元素个数增加 1，而由 引理 1.11 它不超过 n_0，故过程必在有限步内停止。停止时该组线性无关且张成 V，即为 V 的一组基。 □

推论 1.13 (维数唯一性) 有限维向量空间 $V \neq \{0\}$ 的任意两组基含有相同数目的向量，故 $\dim V$ 由 V 本身唯一确定。

证明. 设 B_1, B_2 是 V 的两组基，$|B_1| = m$、$|B_2| = n$。B_2 线性无关而 B_1 生成 V，由 引理 1.11 得 $n \le m$；交换两者的角色得 $m \le n$。故 $m = n$。 □

直观解释. 维数刻画的是向量空间“有多少个自由度”。基的选取方式有无穷多种，但自由度的个数是空间固有的、与坐标系无关的几何量。x 的坐标却依赖于基——同一支向量在不同基下有不同坐标，这正是“换基”与“坐标变换”的起点。

例 1.14 (一组冗余的生成集) 在 $\mathbb{R}^3$ 中取 $v_1 = (1, 0, 1)^\top$、$v_2 = (0, 1, 1)^\top$、$v_3 = (1, 1, 2)^\top$，令 $V = \operatorname{span}\{v_1, v_2, v_3\}$。由于 $v_3 = v_1 + v_2$，这组向量线性相关，且 $V = \operatorname{span}\{v_1, v_2\}$；而 v_1, v_2 不成比例，线性无关。故 $\{v_1, v_2\}$ 是 V 的一组基，$\dim V = 2$。

1.4 线性映射与矩阵表示

1.4.1 线性映射

定义 1.15 (线性映射) 设 V, W 是域 $\mathbb{F}$ 上的向量空间。映射 $T : V \to W$ 称为**线性映射**（或线性变换），若

$$T(\alpha x + \beta y) = \alpha T(x) + \beta T(y), \qquad \forall\, x, y \in V,\ \forall\, \alpha, \beta \in \mathbb{F}. \tag{1.10}$$

《人工智能数学基础》 CC BY-NC-SA 4.0 仅供个体署名作者 禁止商业使用与著作权归合体署名作者

当 $W=\mathbb{F}$ 时称 T 为**线性泛函**；当 $V=W$ 时称 T 为 V 上的**线性算子**。$V\to W$ 的一切线性映射之集记为 $\mathcal{L}(V,W)$。

注. 什么是泛函？泛函是函数的函数。线性泛函是从向量空间到标量域的线性映射。它们在泛函分析中有更深的研究，本书不讨论。

条件 式 (1.10) 等价于同时成立的两条：可加性 $T(x+y)=T(x)+T(y)$ 与齐次性 $T(\alpha x)=\alpha T(x)$。由定义立刻得到

$$T(0)=0,\qquad T\Big(\sum_i c_i v_i\Big)=\sum_i c_i T(v_i).$$

第二条说明：线性映射保持一切线性组合，因此它完全由“基上取什么值”决定。

定理 1.16 (线性映射由基上的像唯一确定) 设 V,W 是 $\mathbb{F}$ 上的向量空间，$B=\{v_1,\dots,v_n\}$ 是 V 的一组基，$w_1,\dots,w_n\in W$ 是任意给定的 n 个向量。则存在唯一的线性映射 $T:V\to W$ 使得

$$T(v_i)=w_i,\qquad i=1,\dots,n.$$

证明. *存在性.* 因每个 x 在给定基下的坐标表示唯一（式 (1.9)），$T\big(\sum_i x_i v_i\big)=\sum_i x_i w_i$ 是良定义的；由 T 保持线性组合（式 (1.10) 下一式）它自动线性，且 $T(v_j)=w_j$。

唯一性. 若 T' 也满足 $T'(v_i)=w_i$，则对任意 $x=\sum_i x_i v_i$ 有 $T'(x)=\sum_i x_i T'(v_i)=\sum_i x_i w_i=T(x)$，故 $T'=T$。 □

1.4.2 矩阵表示

固定 $V=\mathbb{F}^n$、$W=\mathbb{F}^m$，并取 V 的标准基 $e_1,\dots,e_n$（e_i 是第 i 个分量为 1、其余为 0 的向量）。设 $T:\mathbb{F}^n\to\mathbb{F}^m$ 线性。由 定理 1.16，只要知道 $T(e_1),\dots,T(e_n)$ 就完全确定了 T。把这 n 支向量按列排成一个 $m\times n$ 矩阵

$$A=\begin{bmatrix} T(e_1) & T(e_2) & \cdots & T(e_n)\end{bmatrix}\in\mathbb{F}^{m\times n},\tag{1.11}$$

则对任意 $x=(x_1,\dots,x_n)^{\top}\in\mathbb{F}^n$，

$$T(x)=T\Big(\sum_{i=1}^{n}x_i e_i\Big)=\sum_{i=1}^{n}x_i T(e_i)=\begin{bmatrix} T(e_1) & \cdots & T(e_n)\end{bmatrix}\begin{bmatrix} x_1\\ \vdots\\ x_n\end{bmatrix}=Ax.\tag{1.12}$$

这里最后一步用的正是列观点 式 (1.5)。

推论 1.17 (线性映射与矩阵的一一对应) $\mathbb{F}^n\to\mathbb{F}^m$ 的线性映射与 $\mathbb{F}^{m\times n}$ 的矩阵之间存在一一对应：$T\mapsto A=[T(e_1)\ \cdots\ T(e_n)]$，$A\mapsto T_A(x)=Ax$。特别地，$\mathcal{L}(\mathbb{F}^n,\mathbb{F}^m)$ 本身也是 $\mathbb{F}$ 上的向量空间，且 $\dim\mathcal{L}(\mathbb{F}^n,\mathbb{F}^m)=mn$。

《人工智能数学基础》 CC BY-NC-SA 4.0 © 版权归全体署名作者共有 禁止商业使用

核心思想

矩阵是线性映射在给定基下的矩阵表示，A 的第 j 列就是 e_j 的像。理解了这一点，矩阵乘法的可结合性 $A(BC)=(AB)C$ 以及后面所有关于核与像的结论，都可以直接“读”出来。

例 1.18 (旋转) 在 $\mathbb{R}^2$ 中，把每个向量绕原点逆时针旋转角 θ 的映射

$$R_\theta(x_1,x_2)^\top=(x_1\cos\theta-x_2\sin\theta,\ x_1\sin\theta+x_2\cos\theta)^\top$$

是线性的。它的标准矩阵为

$$R_\theta=\begin{bmatrix}\cos\theta & -\sin\theta\\ \sin\theta & \cos\theta\end{bmatrix},\tag{1.13}$$

即 $R_\theta=\begin{bmatrix}R_\theta(e_1) & R_\theta(e_2)\end{bmatrix}=\begin{bmatrix}(\cos\theta,\sin\theta)^\top & (-\sin\theta,\cos\theta)^\top\end{bmatrix}$。取 $\theta=\pi/2$ 得 $R_{\pi/2}=\begin{bmatrix}0 & -1\\ 1 & 0\end{bmatrix}$，它把 e_1 送到 e_2、把 e_2 送到 $-e_1$；这正是 式 (1.11) 所说的“看列”。

注意. 并非所有自然的映射都是线性的。平移 $x\mapsto x+x_0$（$x_0\neq 0$）不是线性的，因为 $T(0)=x_0\neq 0$。$x\mapsto x_1x_2$ 也不是（见 习题 1.50 与 习题 1.78）；$x\mapsto\|x\|_2$ 与 $x\mapsto\max_i x_i$ 同样不是，二者都栽在**负标量的齐次性**上：$\|-x\|_2=\|x\|_2\neq-\|x\|_2$，而 $\max_i(-x_i)=-\min_i x_i\neq-\max_i x_i$。判断线性只有一条路：回到 式 (1.10) 逐项检验。

1.5 核空间、像空间与秩

定义 1.19 (核与像) 设 $T:V\to W$ 是线性映射。称

$$\operatorname{Ker}T=\{x\in V:\ T(x)=0\}\subseteq V,\qquad \operatorname{Im}T=\{T(x):\ x\in V\}\subseteq W$$

分别为 T 的**核空间**（简称核，null space）与**像空间**（简称像，image / range）。二者分别是 V 与 W 的子空间。

核刻画“哪些输入被压成零”，像刻画“输出能落在哪里”。二者的大小之间有一个精确定量的关系，这就是线性代数中最基本的计数定理。

定理 1.20 (秩–零化度定理（Rank–Nullity）) 设 V 是 $\mathbb{F}$ 上的有限维向量空间（$\dim V=n<\infty$），W 是 $\mathbb{F}$ 上任意向量空间，$T:V\to W$ 线性。则

$$\dim\operatorname{Ker}T+\dim\operatorname{Im}T=\dim V=n.\tag{1.14}$$

证明. 记 $k=\dim\operatorname{Ker}T$。若 $k=0$，取 V 的一组基 $v_1,\dots,v_n$。我们证明 $T(v_1),\dots,T(v_n)$ 线性无关：若 $\sum_i c_iT(v_i)=0$，则由线性得 $T\big(\sum_i c_iv_i\big)=0$，即 $\sum_i c_iv_i\in\operatorname{Ker}T=\{0\}$，由基的线性无关性得全部 $c_i=0$。又 $\operatorname{Im}T=\operatorname{span}\{T(v_1),\dots,T(v_n)\}$，故 $\dim\operatorname{Im}T=n$，式 (1.14) 成立。

若 $k>0$，取 $\operatorname{Ker}T$ 的一组基 $u_1,\dots,u_k$。若它还不张成 V，就不断从 V 中取出当前张

《人工智能数学基础》 CC BY NC-SA 4.0 禁止商业使用；著作权归全体署名作者所有

成空间之外的向量添进去；由 $\dim V = n < \infty$，这一过程在 $n-k$ 步内必然停止，于是得到 V 的一组基

$$u_1, \dots, u_k,\ v_{k+1}, \dots, v_n,$$

其中 $v_{k+1}, \dots, v_n$ 是新添的 $n-k$ 个向量。下面证明 $\{T(v_{k+1}), \dots, T(v_n)\}$ 恰是 $\operatorname{Im} T$ 的一组基。

（一）它生成 $\operatorname{Im} T$. 任取 $y \in \operatorname{Im} T$，有 $y = T(x)$，其中 $x = \sum_{i=1}^{k} a_i u_i + \sum_{i=k+1}^{n} a_i v_i$。由 $u_i \in \operatorname{Ker} T$ 得

$$y = T(x) = \sum_{i=1}^{k} a_i T(u_i) + \sum_{i=k+1}^{n} a_i T(v_i) = \sum_{i=k+1}^{n} a_i T(v_i) \in \operatorname{span}\{T(v_{k+1}), \dots, T(v_n)\}.$$

（二）它线性无关. 若 $\sum_{i=k+1}^{n} c_i T(v_i) = 0$，则 $T\big(\sum_{i=k+1}^{n} c_i v_i\big) = 0$，故 $z := \sum_{i=k+1}^{n} c_i v_i \in \operatorname{Ker} T$。于是 z 可以由 $u_1, \dots, u_k$ 线性表示：$z = \sum_{i=1}^{k} d_i u_i$，即

$$\sum_{i=1}^{k} (-d_i) u_i + \sum_{i=k+1}^{n} c_i v_i = 0.$$

由 $\{u_1, \dots, u_k, v_{k+1}, \dots, v_n\}$ 是基（线性无关）得所有系数为零，特别是 $c_{k+1} = \cdots = c_n = 0$。

综合（一）（二），$\dim \operatorname{Im} T = n-k$，即 $\dim \operatorname{Ker} T + \dim \operatorname{Im} T = n$。 □

推论 1.21 (矩阵形式) 设 $A \in \mathbb{R}^{m\times n}$，记 $T_A(x) = Ax$。则 $\operatorname{Ker}(T_A) = \operatorname{Null}(A)$、$\operatorname{Im}(T_A) = \operatorname{Col}(A)$，并且

$$\operatorname{rank}(A) + \operatorname{nullity}(A) = n, \tag{1.15}$$

其中 $\operatorname{rank}(A) = \dim \operatorname{Col}(A)$ 称为 A 的秩，$\operatorname{nullity}(A) = \dim \operatorname{Null}(A)$ 称为 A 的零化度。证明只是把式 (1.14) 用在 T_A 上：$x \in \operatorname{Ker}(T_A)$ 当且仅当 $Ax = 0$，即 $\operatorname{Ker}(T_A) = \operatorname{Null}(A)$；而 $\operatorname{Im}(T_A)$ 正是 A 的各列的一切线性组合（式 (1.5)），即 $\operatorname{Col}(A)$。

直观解释. Rank–Nullity 定理说的是：定义域的 n 个自由度被分成两部分——被压掉的部分（$\dim \operatorname{Ker} T$，落在核里，对输出没有影响）与留在输出里的部分（$\dim \operatorname{Im} T$，即秩）。机器学习中谈论一个模型的“有效维度”是高是低，说的就是这个分解中两项的相对大小。

1.6 内积、正交补与直和

向量空间本身只带加法与数乘两种运算。内积是一层额外附加的结构——本章约定第 1 条已默认取欧氏内积，本节把它正式定义下来，并由此得到长度、角度与正交的概念。它是投影与最小二乘的全部基础。

定义 1.22 (欧氏内积与正交) 对 $x, y \in \mathbb{R}^n$，定义**欧氏内积**

$$\langle x, y \rangle = x^{\top} y = \sum_{i=1}^{n} x_i y_i \in \mathbb{R},$$

《人工智能数学基础》 CC BY-NC-SA 4.0 禁止商业使用 著作权归全体署名作者共有

并称 $\|x\|_2 = \sqrt{\langle x, x\rangle}$ 为 x 的**欧氏范数**。若 $\langle x, y\rangle = 0$，则称 x 与 y **正交**，记作 $x \perp y$。

内积满足：对称性 $\langle x, y\rangle = \langle y, x\rangle$；对每个变元线性 $\langle \alpha x + \beta z, y\rangle = \alpha\langle x, y\rangle + \beta\langle z, y\rangle$；正定性 $\langle x, x\rangle \geq 0$ 且等号只在 $x = 0$ 时成立。由正定性可得 $\|x\|_2 = 0 \iff x = 0$。

定义 1.23 (正交补) 设 $M \subseteq \mathbb{R}^n$ 是任一子集，称

$$M^{\perp} = \{x \in \mathbb{R}^n : \langle x, y\rangle = 0,\ \forall y \in M\}$$

为 M 的**正交补**。

可以验证：无论 M 本身是不是子空间，$M^{\perp}$ 总是 $\mathbb{R}^n$ 的子空间。并且显然 $M \subseteq (M^{\perp})^{\perp}$；当 M 本身是子空间时，二者相等。

为了证明 $\mathbb{R}^n$ 可以被一个子空间与其正交补“拼起来”，我们需要“每个子空间都有标准正交基”这一事实。

引理 1.24 (Gram–Schmidt 正交化) 设 $M \subseteq \mathbb{R}^n$ 是子空间，$\dim M = k \geq 1$。则存在 M 的一组标准正交基 $q_1, \ldots, q_k$，即 $\langle q_i, q_j\rangle = \delta_{ij}$（$i = j$ 时为 1，否则为 0）且 $\operatorname{span}\{q_1, \ldots, q_k\} = M$。

证明. 取 M 的一组基 $a_1, \ldots, a_k$（定义 1.10），按 $j = 1, 2, \ldots, k$ 递归地定义

$$v_j = a_j - \sum_{i=1}^{j-1} \langle a_j, q_i\rangle\, q_i, \qquad q_j = \frac{v_j}{\|v_j\|_2}.$$

归纳假设为：$\{q_1, \ldots, q_{j-1}\}$ 标准正交，且 $\operatorname{span}\{q_1, \ldots, q_{j-1}\} = \operatorname{span}\{a_1, \ldots, a_{j-1}\}$（$j = 1$ 时两者均为空，结论显然）。此时求和项落在 $\operatorname{span}\{a_1, \ldots, a_{j-1}\}$ 内，故若 $v_j = 0$ 则 $a_j \in \operatorname{span}\{a_1, \ldots, a_{j-1}\}$，与基的线性无关性矛盾；于是 $v_j \neq 0$，q_j 有意义。

再验证正交性。对 $i < j$，用归纳假设中的 $\langle q_l, q_i\rangle = \delta_{li}$，

$$\langle v_j, q_i\rangle = \langle a_j, q_i\rangle - \sum_{l=1}^{j-1} \langle a_j, q_l\rangle \langle q_l, q_i\rangle = \langle a_j, q_i\rangle - \langle a_j, q_i\rangle = 0,$$

故 $\langle q_j, q_l\rangle = 0$（$l < j$）且 $\langle q_j, q_j\rangle = 1$，归纳成立。最后，$q_j \in \operatorname{span}\{a_1, \ldots, a_j\}$ 保证张成空间不变，故 $\operatorname{span}\{q_1, \ldots, q_k\} = M$。 □

定义 1.25 (直和) 设 U, W 是向量空间 V 的子空间。若每个 $x \in V$ 都能**唯一**地写成

$$x = u + w, \qquad u \in U,\ w \in W,$$

则称 V 是 U 与 W 的**直和**，记作 $V = U \oplus W$。等价的说法是：$V = U + W$ 且 $U \cap W = \{0\}$。

定理 1.26 (正交分解) 设 $M \subseteq \mathbb{R}^n$ 是子空间。则

$$\mathbb{R}^n = M \oplus M^{\perp}. \tag{1.16}$$

特别地，$\dim M + \dim M^{\perp} = n$。

人工智能数学基础 CC BY-NC-SA 4.0 禁止商业用·署名权归全体署名作者共有

证明. 交集为 $\{0\}$. 若 $x \in M \cap M^{\perp}$，则 $\langle x, x\rangle = 0$（因为 $x \in M$ 且 x 与 M 中一切向量正交），由内积正定性得 $x = 0$。

和为 $\mathbb{R}^n$. 若 $M = \{0\}$ 则结论显然。否则取 M 的一组标准正交基 $q_1, \dots, q_k$（引理 1.24）。对任意 $x \in \mathbb{R}^n$，令

$$p = \sum_{i=1}^{k} \langle x, q_i\rangle\, q_i \in M, \qquad r = x - p. \tag{1.17}$$

对每个 $j = 1, \dots, k$，由标准正交性

$$\langle r, q_j\rangle = \langle x, q_j\rangle - \sum_{i=1}^{k} \langle x, q_i\rangle \langle q_i, q_j\rangle = \langle x, q_j\rangle - \langle x, q_j\rangle = 0.$$

由于 $q_1, \dots, q_k$ 张成 M，任何 $y = \sum_j c_j q_j \in M$ 都满足 $\langle r, y\rangle = \sum_j c_j \langle r, q_j\rangle = 0$，故 $r \in M^{\perp}$。于是 $x = p + r$ 落在 $M + M^{\perp}$ 中。

唯一性. 若 $x = u + w = u' + w'$ 是两种分解，则 $u - u' = w' - w \in M \cap M^{\perp} = \{0\}$，故 $u = u'$、$w = w'$。因此 $\mathbb{R}^n = M \oplus M^{\perp}$。取两边的基拼起来即得 $n = \dim M + \dim M^{\perp}$。 □

直观解释. 式 (1.16) 是“$\mathbb{R}^n$ 可以按任意子空间 M 拆成两块互相垂直的部分”的严格表述。式 (1.17) 里的 p 就是把 x 在 M 的每个基向量方向上的投影分量分别取出、再重新组装起来，这正是正交投影（节 1.9）的显式公式。

1.7 矩阵的四个基本子空间

设 $A \in \mathbb{R}^{m\times n}$。$A$ 联系着两个空间：$\mathbb{R}^n$（输入空间）与 $\mathbb{R}^m$（输出空间）。在每个空间中，A 自然诱导出一个子空间和一个与之互补的子空间，合起来就是 Strang 所称的四个基本子空间（图 1.2）：

核心思想

$\mathbb{R}^n$ 中：　行空间 $\mathrm{Row}(A) = \mathrm{Col}(A^{\top}) \subseteq \mathbb{R}^n$，　零空间 $\mathrm{Null}(A) \subseteq \mathbb{R}^n$；
$\mathbb{R}^m$ 中：　列空间 $\mathrm{Col}(A) = \mathrm{Im}(T_A) \subseteq \mathbb{R}^m$，　左零空间 $\mathrm{Null}(A^{\top})$（left null space）$\subseteq \mathbb{R}^m$。

图中 $r = \mathrm{rank}(A)$。A 把行空间同构地映到列空间，把零空间整个压成 $\{0\}$；两个“$\perp$”表示左（右）两块的元素互相正交，这正是下面的定理。

引理 1.27 (行秩等于列秩) 对任意 $A \in \mathbb{R}^{m\times n}$，有 $\dim \mathrm{Row}(A) = \dim \mathrm{Col}(A)$。故 $\mathrm{rank}(A)$ 可以同时定义为行空间的维数与列空间的维数。

证明. 设 $\dim \mathrm{Col}(A) = r$。交换 A 的列（这不改变行空间与列空间的维数）后不妨设 A 的前 r 列构成 $\mathrm{Col}(A)$ 的一组基，记它们拼成的矩阵为 $A_1 \in \mathbb{R}^{m\times r}$，其余 $n - r$ 列拼成 A_2，即 $A = [A_1\ A_2]$。由于 A_2 的每一列都属于 $\mathrm{Col}(A_1) = \mathrm{Col}(A)$，存在矩阵 $C \in \mathbb{R}^{r\times(n-r)}$ 使

$$A_2 = A_1 C, \qquad \text{从而} \qquad A = A_1[\,I_r \;\; C\,].$$

《人工智能数学基础》 CC BY-NC-SA 4.0 署名-非商业使用-禁止演绎 · 著作权归全体署名作者所有

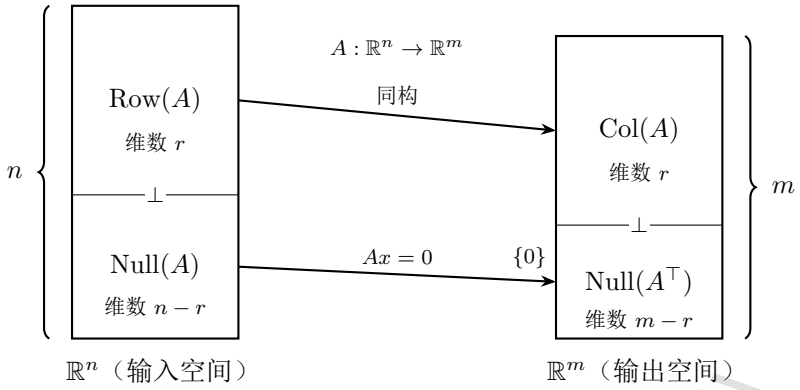


图 1.2: 矩阵 $A\in\mathbb{R}^{m\times n}$ 的四个基本子空间及其维数（$r=\operatorname{rank}(A)$）

于是 A 的每一行都是 $[I_r\ \ C]$ 的对应行的线性组合，故 $\operatorname{Row}(A)\subseteq\operatorname{Row}([I_r\ C])$，并且

$$\dim\operatorname{Row}(A)\le\dim\operatorname{Row}([I_r\ \ C])=r.$$

右端等号成立：$[I_r\ C]\in\mathbb{R}^{r\times n}$ 只有 r 行，而它的前 r 列构成单位阵 I_r，故 r 个行向量线性无关。把上述结论用于 $A^\top$（注意 $\operatorname{Row}(A^\top)=\operatorname{Col}(A)$、$\operatorname{Col}(A^\top)=\operatorname{Row}(A)$），得 $\dim\operatorname{Col}(A)\le\dim\operatorname{Row}(A)$。两式合并即得结论。 □

定理 1.28 (线性代数基本定理，Fundamental Theorem of Linear Algebra) 设 $A\in\mathbb{R}^{m\times n}$。则

$$\operatorname{Null}(A)=\operatorname{Row}(A)^\perp,\qquad \operatorname{Null}(A^\top)=\operatorname{Col}(A)^\perp. \tag{1.18}$$

特别地，若 $r=\operatorname{rank}(A)$，则

$$\dim\operatorname{Row}(A)=\dim\operatorname{Col}(A)=r,\qquad \dim\operatorname{Null}(A)=n-r,\qquad \dim\operatorname{Null}(A^\top)=m-r.$$

证明. **第一步**：$\operatorname{Null}(A)=\operatorname{Row}(A)^\perp$. 由式 (1.4)，$Ax$ 的第 i 个分量是 $\langle a_i,x\rangle$，其中 $a_i^\top$ 是 A 的第 i 行。于是

$$x\in\operatorname{Null}(A)\iff\langle a_i,x\rangle=0\ \ (i=1,\dots,m)\iff x\perp\operatorname{span}\{a_1,\dots,a_m\}=\operatorname{Row}(A),$$

即 $\operatorname{Null}(A)=\operatorname{Row}(A)^\perp$。一句话：$Ax=0$ 无非是说 x 与 A 的每一行都正交。

第二步：$\operatorname{Null}(A^\top)=\operatorname{Col}(A)^\perp$. 把第一步用于 $A^\top$（其行空间是 $\operatorname{Col}(A)$）即得。

第三步：维数. 由引理 1.27，$\dim\operatorname{Row}(A)=\dim\operatorname{Col}(A)=r$。由矩阵形式的 Rank–Nullity（式 (1.15)）得 $\dim\operatorname{Null}(A)=n-r$；再把它用于 $A^\top\in\mathbb{R}^{n\times m}$ 得 $\dim\operatorname{Null}(A^\top)=m-r$。 □

直观解释. 式 (1.18) 说的是：**零空间恰好是行空间的正交补**。这为“$Ax=0$ 为什么难解、何时有非零解”提供了一个几何图像——$\operatorname{Null}(A)$ 就是 $\mathbb{R}^n$ 中垂直于行空间的那一部分，而 $\operatorname{rank}(A)$ 量度的则是行空间“有多厚”。

《人工智能数学基础》 CC BY-NC-SA 4.0 禁止商业使用·著作权归全体著作者共有

AI 应用

问题：一个 1000×1000 的权重矩阵能不能用一个更小的矩阵表示？
精确低秩分解：若 $\operatorname{rank}(W) = r \ll 1000$，则存在列满秩的 $U, V \in \mathbb{R}^{1000\times r}$ 使 $W = UV^\top$ 精确成立（把 SVD $W = U_r\Sigma_r V_r^\top$ 中的 Σ_r 并入 U_r 或 V_r 即可），这一步没有任何信息损失。
低秩近似：真实的权重矩阵一般只是近似低秩，此时取 $W \approx U_r\Sigma_r V_r^\top$，其最优解由截断 SVD 给出。这里“$=$”与“$\approx$”的区别是本质的：前者是分解，后者是压缩，必然伴随误差。能否压缩，取决于 W 的奇异值衰减得多快。
理论联系：“秩低”意味着 W 的所有列都落在同一个低维子空间 $\operatorname{Col}(W)$ 中（引理 1.27），因此输出永远无法铺满整个 $\mathbb{R}^{1000}$。

1.8　线性方程组的结构

下面用“列观点”与“核”给出 $Ax = b$ 的可解性与解集的完整描述。

定理 1.29 (线性方程组的结构) 设 $A \in \mathbb{R}^{m\times n}$、$b \in \mathbb{R}^m$，记 $r = \operatorname{rank}(A)$。

（可解性）下列三条等价：

$$Ax = b \text{ 有解} \iff b \in \operatorname{Col}(A) \iff \operatorname{rank}(A) = \operatorname{rank}\big([\,A\ \ b\,]\big).$$

（解集的结构）若 x_0 是 $Ax = b$ 的任一特解（即 $Ax_0 = b$），则解集恰为

$$\big\{x \in \mathbb{R}^n :\ Ax = b\big\} = x_0 + \operatorname{Null}(A) = \big\{x_0 + z :\ z \in \operatorname{Null}(A)\big\}. \tag{1.19}$$

即解集是 $\operatorname{Null}(A)$ 的一个平移；它是子空间当且仅当 $b = 0$。

（解何时唯一）解唯一当且仅当 $\operatorname{Null}(A) = \{0\}$，即 $r = n$（A 满列秩）。

证明. *可解性.* 由式 (1.5)，$Ax = x_1a_1 + \cdots + x_na_n$，故 $Ax = b$ 有解当且仅当 b 是 A 的各列的线性组合，即 $b \in \operatorname{Col}(A)$。又 $\operatorname{Col}([\,A\ b\,]) = \operatorname{Col}(A) + \operatorname{span}\{b\}$：当 $b \in \operatorname{Col}(A)$ 时它就是 $\operatorname{Col}(A)$，秩为 r；当 $b \notin \operatorname{Col}(A)$ 时 $\operatorname{span}\{b\} \cap \operatorname{Col}(A) = \{0\}$，秩为 $r+1$。故 $\operatorname{rank}([\,A\ b\,]) = r$ 当且仅当 $b \in \operatorname{Col}(A)$，这就证明了第二个等价。

解集的结构. ($\supseteq$) 设 $x = x_0 + z$、$z \in \operatorname{Null}(A)$，由线性性 $Ax = Ax_0 + Az = b + 0 = b$。($\subseteq$) 设 $Ax = b$，令 $z = x - x_0$，则 $Az = A(x - x_0) = b - b = 0$，故 $z \in \operatorname{Null}(A)$，从而 $x = x_0 + z$。最后，$x_0 + \operatorname{Null}(A)$ 是子空间当且仅当它含零向量，即 $0 = x_0 + z$ 对某个 $z \in \operatorname{Null}(A)$ 成立，等价于 $x_0 \in \operatorname{Null}(A)$，等价于 $b = Ax_0 = 0$。

解何时唯一. 由式 (1.19)，解集是 $\operatorname{Null}(A)$ 的平移，故它只含一个元素当且仅当 $\operatorname{Null}(A) = \{0\}$；由秩–零化度 $\operatorname{nullity}(A) = n - r$，这等价于 $r = n$。 □

《人工智能数学基础》 CC BY-NC-SA 4.0 禁止商业使用，著作权归全体署名作者共有

1.9 正交投影

定理 1.30 (投影定理) 设 $M \subseteq \mathbb{R}^n$ 是子空间。则对任意 $x \in \mathbb{R}^n$，存在唯一的分解

$$x = \hat{x} + r, \qquad \hat{x} \in M, \qquad r \in M^{\perp}, \tag{1.20}$$

其中 $\hat{x}$ 由 式 (1.17) 给出。进一步，$\hat{x}$ 是 M 中在欧氏范数下距 x 最近的点，即

$$\hat{x} = \arg\min_{y \in M} \|x - y\|_2 , \tag{1.21}$$

并且这个最小点是唯一的。

证明. 存在唯一性就是 定理 1.26 的内容：$\mathbb{R}^n = M \oplus M^{\perp}$。

最小距离性质. 任取 $y \in M$。因为 $\hat{x} - y \in M$、$r = x - \hat{x} \in M^{\perp}$，所以 $\hat{x} - y \perp r$。由勾股定理（$\|a+b\|_2^2 = \|a\|_2^2 + \|b\|_2^2$，当 $a \perp b$）得

$$\|x - y\|_2^2 = \|(x - \hat{x}) + (\hat{x} - y)\|_2^2 = \|r\|_2^2 + \|\hat{x} - y\|_2^2 \;\geq\; \|r\|_2^2 = \|x - \hat{x}\|_2^2. \tag{1.22}$$

等号成立当且仅当 $\|\hat{x} - y\|_2 = 0$，即 $y = \hat{x}$。因此 $\hat{x}$ 是唯一的最近点。 □

定义 1.31 (正交投影) 称 式 (1.20) 中的 $\hat{x}$ 为 x 在 M 上的**正交投影**，记作

$$\hat{x} = \operatorname{proj}_M x = P_M x.$$

映射 $P_M : \mathbb{R}^n \to \mathbb{R}^n$ 称为到 M 的**正交投影算子**；式 (1.20) 中的 $r = x - P_M x$ 称为**残差**（residual）。当 $M = \operatorname{span}\{u\}$（$u \neq 0$）是一条直线时，式 (1.20) 给出闭式

$$\operatorname{proj}_u x = \frac{\langle u, x\rangle}{\langle u, u\rangle}\, u = \frac{u^{\top} x}{u^{\top} u}\, u. \tag{1.23}$$

验证只需一步：记右端为 $\hat{x}$，则 $\hat{x} \in \operatorname{span}\{u\}$，且 $u^{\top}(x - \hat{x}) = u^{\top}x - \frac{u^{\top}x}{u^{\top}u} u^{\top}u = 0$，由 定理 1.30 中分解的唯一性即得。它也是后面的一般公式 $P = QQ^{\top}$ 在 $k = 1$ 时的特例。

例 1.32 (投影到一条直线) 取 $u = (1, 2)^{\top}$、$x = (3, 1)^{\top} \in \mathbb{R}^2$。则 $\langle u, x\rangle = 1 \cdot 3 + 2 \cdot 1 = 5$，$\langle u, u\rangle = 1^2 + 2^2 = 5$，故

$$\hat{x} = \operatorname{proj}_u x = \frac{5}{5} \begin{bmatrix} 1 \\ 2 \end{bmatrix} = \begin{bmatrix} 1 \\ 2 \end{bmatrix} = u, \qquad r = x - \hat{x} = \begin{bmatrix} 3 \\ 1 \end{bmatrix} - \begin{bmatrix} 1 \\ 2 \end{bmatrix} = \begin{bmatrix} 2 \\ -1 \end{bmatrix}.$$

验证正交性：$\langle u, r\rangle = 1 \cdot 2 + 2 \cdot (-1) = 0$。于是 $\|x\|_2^2 = 10 = \|\hat{x}\|_2^2 + \|r\|_2^2 = 5 + 5$，与 式 (1.22) 一致。图 1.3 画出了这一投影的几何图像：线段 $x\hat{x}$（其长度即残差向量 $r = x - \hat{x}$ 的模 $\|r\|_2$）是 x 到 M 的最短路径，而 M 上任何别的点（例如 y）到 x 的距离都严格更长，这正是勾股论证的直观内容。

直观解释. 投影定理的几何意义可以用一句话概括：**“直线段最短”**。从 x 走向子空间 M 的

《人工智能数学基础》 CC BY-NC-SA 4.0 禁止商业使用，衍生作品须署名并以相同协议发布，版权归全体著作者共有

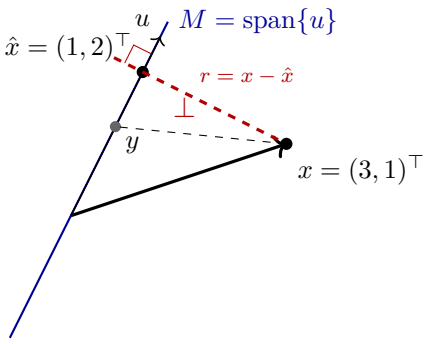


图 1.3: $x = (3,1)^\top$ 到直线 $M = \mathrm{span}\{(1,2)^\top\}$ 的正交投影：垂线段 $x\hat{x}$ 最短，而 M 上任何其他点 y 满足 $\|x-y\|_2 > \|x-\hat{x}\|_2$

任何一条路径都可以按勾股定理拆成“垂直于 M 的那一段”与“在 M 内的那一段”，只有前者不可压缩。因此垂足 $\hat{x}$ 是唯一的最近点，而在 式 (1.22) 中，被丢弃的 $\|r\|_2^2$ 就是近似的“代价”。

1.10 投影矩阵

投影算子 P_M 是 $\mathbb{R}^n \to \mathbb{R}^n$ 的线性映射，因此有矩阵表示；我们把它称为投影矩阵，仍记作 $P_M \in \mathbb{R}^{n\times n}$。

1.10.1 标准正交基给出的公式

定理 1.33 设 $Q \in \mathbb{R}^{n\times k}$ 的列向量标准正交，即 $Q^\top Q = I_k$。则 $P = QQ^\top \in \mathbb{R}^{n\times n}$ 是到子空间 $\mathrm{Col}(Q)$ 的正交投影矩阵。

证明. 记 $Q = [q_1 \ \cdots \ q_k]$，则 $q_1, \ldots, q_k$ 是 $\mathrm{Col}(Q)$ 的一组标准正交基。由 $Q^\top Q = I_k$ 直接得 $P^2 = Q(Q^\top Q)Q^\top = P$ 与 $P^\top = P$。又

$$Px = \sum_{i=1}^{k} q_i (q_i^\top x) = \sum_{i=1}^{k} \langle x, q_i \rangle \, q_i$$

正是 式 (1.17) 中的 $\hat{x}$，故 Px 是 x 在 $\mathrm{Col}(Q)$ 上的正交投影；且 $y = Qz \in \mathrm{Col}(Q)$ 时 $Py = Q(Q^\top Q)z = y$，故 $\mathrm{Col}(P) = \mathrm{Col}(Q)$。 □

注. 在上面的记号下，$I - P$ 是到 $\mathrm{Col}(Q)^\perp$ 的正交投影。一般地，若 P 是到 M 的正交投影矩阵，则 $I - P$ 是到 $M^\perp$ 的正交投影矩阵。

《人工智能数学基础》 CC BY NC-SA 4.0 禁止商业使用 著作权归全体署名作者共有

1.10.2 一般列空间上的投影

定理 1.34 (正交投影矩阵的显式公式) 设 $A \in \mathbb{R}^{m\times n}$ 满列秩（即 $\operatorname{rank}(A) = n$，特别地 $n \le m$）。则 $A^\top A$ 可逆，且

$$P = A(A^\top A)^{-1}A^\top \in \mathbb{R}^{m\times m} \tag{1.24}$$

是到 $\operatorname{Col}(A)$ 的正交投影矩阵。

证明. $A^\top A$ 可逆. 设 $z \in \operatorname{Null}(A^\top A)$，则 $0 = z^\top A^\top Az = \|Az\|_2^2$，故 $Az = 0$，即 $z \in \operatorname{Null}(A) = \{0\}$（满列秩）。于是 $\operatorname{Null}(A^\top A) = \{0\}$，由 Rank–Nullity（式 (1.15)）方阵 $A^\top A$ 的秩为 n，故可逆。

P 是正交投影. $A^\top A$ 对称，其逆也对称，于是直接验证

$$P^2 = A(A^\top A)^{-1}\,(A^\top A)\,(A^\top A)^{-1}A^\top = A(A^\top A)^{-1}A^\top = P,$$

即把中间的 $A^\top A$ 与其逆配成对消去（这一步用到 $A^\top A$ 可逆，即满列秩）；又

$$P^\top = A(A^\top A)^{-1}A^\top = P.$$

又 $\operatorname{Col}(P) \subseteq \operatorname{Col}(A)$；反过来对任意 $y = Az \in \operatorname{Col}(A)$ 有 $Py = A(A^\top A)^{-1}(A^\top A)z = y$，故 $\operatorname{Col}(P) = \operatorname{Col}(A)$。于是 P 是幂等且对称的矩阵，且值域为 $\operatorname{Col}(A)$，由下一小节的刻画（定理 1.36）它就是到 $\operatorname{Col}(A)$ 的正交投影矩阵。 □

1.10.3 正交投影矩阵的刻画

定义 1.35 (投影矩阵与正交投影矩阵) 称 $P \in \mathbb{R}^{n\times n}$ 为**投影矩阵**（幂等矩阵），若 $P^2 = P$；若进一步满足 $P^\top = P$，则称 P 为**正交投影矩阵**。

注意“投影矩阵”比 定义 1.31 的“正交投影”宽：任何幂等矩阵都是投影矩阵，但只有对称的幂等矩阵才给出正交投影；不对称的幂等矩阵给出的是沿某个倾斜方向的投影。

定理 1.36 设 $P \in \mathbb{R}^{n\times n}$。则 P 是到某子空间 M 的正交投影矩阵（即 $Px = \operatorname{proj}_M x$ 对一切 x 成立）当且仅当

$$P^2 = P \quad \text{且} \quad P^\top = P. \tag{1.25}$$

此时 $M = \operatorname{Col}(P)$，并且 $\operatorname{Null}(P) = \operatorname{Col}(P)^\perp$。

证明.（必要性）设 $P = P_M$，则对任意 x 有 $Px \in M$、$x - Px \in M^\perp$。幂等：$Px \in M$ 在投影下不动，故 $P^2x = Px$。对称：把 $y = Py + (y - Py)$ 与 $x = Px + (x - Px)$ 分别代入 $\langle Px, y\rangle$ 与 $\langle x, Py\rangle$，两个正交项 $\langle Px, y - Py\rangle$ 与 $\langle x - Px, Py\rangle$ 都为零，于是

$$\langle Px, y\rangle = \langle Px, Py\rangle = \langle x, Py\rangle,$$

即 $P^\top = P$。

人工智能数学基础公式 CC BY-NC-SA 4.0 禁止商业用途 著作权归全体著作者共有

（充分性）设 $P^2=P$、$P^\top=P$，令 $M=\mathrm{Col}(P)$。显然 $Px\in M$；又对任意 $y=Pz\in M$，

$$\langle y, x-Px\rangle = z^\top P^\top (I-P)x = z^\top (P-P^2)x = 0,$$

故 $x-Px\perp M$。于是 $x=Px+(x-Px)$ 是 x 关于 M 的正交分解，由 定理 1.30 中分解的唯一性得 $Px=\mathrm{proj}_M x$。再由 $\mathrm{Null}(P^\top)=\mathrm{Col}(P)^\perp$ 与 $P=P^\top$ 得 $\mathrm{Null}(P)=\mathrm{Col}(P)^\perp$。 □

核心思想

式 (1.25) 把“几何上的正交投影”翻译成了两条纯代数的等式：幂等（$P^2=P$，投影两次等于投影一次）与 对称（$P^\top=P$，投影方向与残差方向垂直）。反过来说，一个幂等矩阵只要不对称，它就是一个“斜投影”，其残差不再垂直于像空间。

1.10.4　补充：可逆性、特征值与正定矩阵

前面反复用到 $A^\top A$ 可逆（定理 1.34）。它为什么必然可逆？这涉及三个本章尚未引入的概念。本节只给出定义与本章主线用得上的基本事实；系统的理论——特征值分解、相似与对角化、二次型与合同变换——留到第 3 章。

可逆矩阵。称方阵 $A\in\mathbb{R}^{n\times n}$ 可逆，若存在 B 使 $AB=BA=I$，并记 $B=A^{-1}$。这等价于以 A 为矩阵的线性映射是一一对应，也等价于 $\mathrm{Null}(A)=\{0\}$；由秩–零化度，又等价于 $\mathrm{rank}(A)=n$。

正定矩阵。称对称矩阵 A 正定，若对一切 $z\neq 0$ 有 $z^\top Az>0$；若只要求 $z^\top Az\geq 0$，则称半正定。满列秩的 A 给出的 $A^\top A$ 正是正定的：当 $z\neq 0$ 时 $Az\neq 0$，故 $z^\top(A^\top A)z=\|Az\|_2^2>0$。对称且正定的矩阵必可逆——这就是 $A^\top A$ 可逆的原因。

特征值与特征向量。设 $A\in\mathbb{R}^{n\times n}$。若存在非零向量 v 与数 λ 使 $Av=\lambda v$，则称 λ 为 A 的特征值（eigenvalue），v 为属于 λ 的特征向量（eigenvector）。几何上，特征向量是作用后方向不变的向量，λ 是伸缩的倍数。正交投影矩阵是最好的例子：M 中的向量满足 $Pv=v$，$M^\perp$ 中的向量满足 $Pv=0$，故 P 的特征值只有 1 与 0，且 $\mathrm{tr}(P)=\dim M$。

1.11　最小二乘

定义 1.37 (最小二乘问题)　给定 $A\in\mathbb{R}^{m\times n}$ 与 $b\in\mathbb{R}^m$，称

$$\mathcal{S}_{\mathrm{LS}}=\arg\min_{x\in\mathbb{R}^n}\ \|Ax-b\|_2^2=\Big\{x\in\mathbb{R}^n:\ \|Ax-b\|_2^2=\min_{z\in\mathbb{R}^n}\|Az-b\|_2^2\Big\}\tag{1.26}$$

为**最小二乘问题**，并称其中任一元素 $\hat{x}\in\mathcal{S}_{\mathrm{LS}}$ 为它的**最小二乘解**。按本章约定第 4 条，$\arg\min$ 表示的是**解集**：当 A 不满列秩时 $\mathcal{S}_{\mathrm{LS}}$ 含无穷多个元素，写 $\hat{x}=\arg\min\cdots$ 只是习惯记法。当 $b\notin\mathrm{Col}(A)$——最典型的情形是 $m>n$，即方程个数多于未知量——时 $Ax=b$ 无解，最小二乘退而求其次：找一个 x 使 Ax 在欧氏范数下最接近 b。注意**有没有解只取决于 b 是否落在 $\mathrm{Col}(A)$ 里，与 m,n 的大小没有必然联系**：$m\leq n$ 时也可能无解；反过来，$m>n$ 且 A 满列秩时，$b\in\mathrm{Col}(A)$ 就意味着有唯一解（这正是 定理 1.34 中 $A^\top A$ 可逆的场景）。至于解是否唯一，判据在 $\mathrm{Null}(A)$：A 满列秩时唯一，否则有无穷多解。

《人工智能数学基础》CC BY-NC-SA 4.0 禁止商业使用 转载请联系作者 署名作者共有

1.11.1 先看几何：残差必须垂直于列空间

由 式 (1.5)，当 x 跑遍 $\mathbb{R}^n$ 时 Ax 跑遍子空间 $\mathrm{Col}(A)$；被最小化的量是 $\|Ax-b\|_2^2$，即 b 到点 $Ax\in\mathrm{Col}(A)$ 的距离的平方。于是 式 (1.26) 等价于

$$\text{在 } \mathrm{Col}(A) \text{ 中找距 } b \text{ 最近的点}, \qquad \text{其解为} \quad A\hat{x}=P_{\mathrm{Col}(A)}b. \tag{1.27}$$

由 定理 1.30，这个最近点是 $\mathrm{Col}(A)$ 上唯一的正交投影点。记残差

$$r=b-A\hat{x}.$$

由于 $A\hat{x}=\mathrm{proj}_{\mathrm{Col}(A)}\,b$，式 (1.20) 直接给出

$$r=b-A\hat{x}\in\mathrm{Col}(A)^{\perp}. \tag{1.28}$$

由线性代数基本定理（式 (1.18)），$\mathrm{Col}(A)^{\perp}=\mathrm{Null}(A^{\top})$，于是 式 (1.28) 等价于

$$A^{\top}r=0 \quad\Longleftrightarrow\quad A^{\top}(b-A\hat{x})=0 \quad\Longleftrightarrow\quad A^{\top}A\hat{x}=A^{\top}b.$$

图 1.4 给出了这一几何图像：$\mathrm{Col}(A)$ 是 $\mathbb{R}^m$ 中的一个子空间，b 一般不落在其中；$A\hat{x}$ 是 b 在 $\mathrm{Col}(A)$ 上的正交投影，残差 $r=b-A\hat{x}$ 垂直于 $\mathrm{Col}(A)$。若换成满足 $Ax\neq A\hat{x}$ 的 x，点 Ax 虽然仍在 $\mathrm{Col}(A)$ 内，但连接点 Ax 与 b 的线段是斜的，$\|Ax-b\|_2$ 严格更长（A 不满列秩时，不同的 x 可以给出同一个 Ax，这时距离并不更长）。

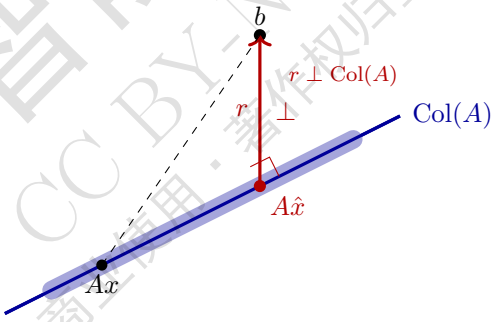


图 1.4: 最小二乘的几何解释：在 $\mathrm{Col}(A)$ 中寻找距 b 最近的点，即正交投影 $A\hat{x}$；残差 $r=b-A\hat{x}$ 垂直于 $\mathrm{Col}(A)$，而 $\mathrm{Col}(A)$ 中任何其他点（如 Ax）到 b 的距离都更长

核心思想

最小二乘的全部内容就是一句话：残差垂直于列空间。从“$r\perp\mathrm{Col}(A)$”出发，只需一行代数就得到正规方程 $A^{\top}A\hat{x}=A^{\top}b$。反过来，对正规方程求导所得到的驻点条件，本质上与这个几何事实等价。先几何、后求导，是本教材处理最小二乘的一贯顺序。

定理 1.38 (正规方程) 设 $A\in\mathbb{R}^{m\times n}$、$b\in\mathbb{R}^m$。则最小二乘问题的解集 式 (1.26) 恰为正规方程

$$A^{\top}Ax=A^{\top}b \tag{1.29}$$

《人工智能数学基础》 CC BY-NC-SA 4.0 署名-非商业性使用-相同方式共享 作者保留全部权利

的解集，即

$$\mathcal{S}_{\mathrm{LS}} = \{x \in \mathbb{R}^n : \ A^\top A x = A^\top b\}.$$

该集合总是非空；并且其中所有元素都给出同一个拟合值 $A\hat{x} = P_{\mathrm{Col}(A)}b$。

证明. 等价性. $\hat{x}$ 满足 式 (1.29) 即 $A^\top(b - A\hat{x}) = 0$，也就是 $b - A\hat{x} \in \mathrm{Null}(A^\top) = \mathrm{Col}(A)^\perp$。于是 $A\hat{x} \in \mathrm{Col}(A)$ 与 $b - A\hat{x}$ 构成 b 关于 $\mathrm{Col}(A)$ 的正交分解，由 定理 1.30 中分解的唯一性得 $A\hat{x} = \mathrm{proj}_{\mathrm{Col}(A)}\, b$，故 $\hat{x}$ 是最小二乘解；反之由同样的几何论证即得 式 (1.29)。

存在性. 只需证明 $A^\top b \in \mathrm{Col}(A^\top A)$，而这由 $\mathrm{Col}(A^\top A) = \mathrm{Col}(A^\top)$ 保证。包含关系 $\subseteq$ 显然；反过来，若 $A^\top A z = 0$，则 $0 = z^\top A^\top A z = \|Az\|_2^2$，故 $Az = 0$，即 $\mathrm{Null}(A^\top A) = \mathrm{Null}(A)$。于是由 Rank–Nullity 与 引理 1.27，

$$\mathrm{rank}(A^\top A) = n - \dim \mathrm{Null}(A^\top A) = n - \dim \mathrm{Null}(A) = \mathrm{rank}(A) = \mathrm{rank}(A^\top),$$

两个列空间维数相同且一个包含另一个，故相等。

拟合值唯一. 若 $\hat{x}_1, \hat{x}_2$ 都是解，则 $A(\hat{x}_1 - \hat{x}_2)$ 同时属于 $\mathrm{Col}(A)$ 与 $\mathrm{Null}(A^\top) = \mathrm{Col}(A)^\perp$，故为零。 □

1.11.2　满列秩时的唯一解

本节要用到 A^+，先明确它究竟是什么。

称矩阵 $X \in \mathbb{R}^{n\times m}$ 为 $A \in \mathbb{R}^{m\times n}$ 的 Moore–Penrose 伪逆,若它满足下面四条 *Penrose* 条件：

$$AXA = A, \qquad XAX = X, \qquad (AX)^\top = AX, \qquad (XA)^\top = XA.$$

后两条要求 AX 与 XA 对称；由前两条又可推出 AX 幂等：

$$(AX)^2 = AXAX = A(XAX) = AX.$$

幂等且对称，故 AX 与 XA 都是正交投影矩阵——四条条件就这样把伪逆与本章的正交投影理论接上了。对任意矩阵 A，满足这四条条件的 X 都存在且唯一，记作 A^+；一般构造借助 SVD，见第 3 章。A 满列秩时它有一个便于手算的显式公式，正是下面定理用到的。

定理 1.39 (最小二乘解的唯一性) 设 $A \in \mathbb{R}^{m\times n}$ 满列秩（$\mathrm{rank}(A) = n$），$b \in \mathbb{R}^m$。则最小二乘问题 式 (1.26) 有唯一解

$$\hat{x} = (A^\top A)^{-1} A^\top b = A^+ b, \tag{1.30}$$

其中 A^+ 是上面定义的伪逆，在满列秩情形下它恰有显式公式

$$A^+ = (A^\top A)^{-1} A^\top, \qquad \text{且} \qquad A^+ A = I_n.$$

此时拟合值、投影矩阵与残差分别为

$$A\hat{x} = Pb, \qquad P = A(A^\top A)^{-1} A^\top, \qquad r = (I - P)b,$$

仅工智能数学基础 CC BY-NC-SA 4.0 禁止商业用 著作权归全体署名作者共有

并且 $A^\top r = 0$、$\|b\|_2^2 = \|A\hat{x}\|_2^2 + \|r\|_2^2$。

证明. 由 定理 1.34，$A^\top A$ 可逆，故正规方程 式 (1.29) 的解存在且唯一，就是 式 (1.30)。又由 定理 1.34，$P = A(A^\top A)^{-1}A^\top$ 是到 $\mathrm{Col}(A)$ 的正交投影，于是 $A\hat{x} = A(A^\top A)^{-1}A^\top b = Pb = \mathrm{proj}_{\mathrm{Col}(A)}\, b$，并且

$$r = b - A\hat{x} = b - Pb = (I - P)b \in \mathrm{Col}(P)^\perp = \mathrm{Col}(A)^\perp.$$

$\mathrm{Col}(A)$ 中的向量可以写成 Az 的形式，因此 $r \perp \mathrm{Col}(A)$ 与 $A^\top r = 0$ 等价；正交分解的勾股定理给出最后一条范数等式。

该公式确实给出伪逆. 记 $X = (A^\top A)^{-1}A^\top$，逐条核对四条 Penrose 条件：

$$AXA = A(A^\top A)^{-1}(A^\top A) = A, \qquad XAX = (A^\top A)^{-1}(A^\top A)(A^\top A)^{-1}A^\top = X;$$

对称性方面，$AX = A(A^\top A)^{-1}A^\top$ 与 $XA = I_n$ 都显然对称（这里用到 $A^\top A$ 及其逆的对称性）。四条都满足，故 $X = A^+$。 □

注 (不满列秩时如何选解). 若 A 不满列秩，则 $\mathrm{Null}(A) \neq \{0\}$，于是由 定理 1.29，最小二乘解构成一个仿射集合

$$\mathcal{S}_{\mathrm{LS}} = \hat{x}_0 + \mathrm{Null}(A),$$

解不唯一（但由 定理 1.38，所有解对应同一个拟合值 $A\hat{x} = P_{\mathrm{Col}(A)}b$）。若还想挑出唯一的 $\hat{x}$，需要附加一个准则；最常用的准则是“取范数最小者”：

$$x_{\min} = \operatorname*{arg\,min}_{x \in \mathcal{S}_{\mathrm{LS}}} \|x\|_2 . \tag{1.31}$$

这个唯一的解恰好是 $x_{\min} = A^+ b$。

A^+ 对任意矩阵都存在且唯一（见本节开头的四条 Penrose 条件）；满列秩时 式 (1.30) 的公式只是它便于手算的特例。A 不满列秩时 A^+ 依然存在，失效的是 $(A^\top A)^{-1}A^\top$ 这个公式本身（$A^\top A$ 不可逆）。

例 1.40 (最小二乘直线拟合) 给定三个数据点 $(0,1)$、$(1,2)$、$(2,2)$，用直线 $y = \beta_0 + \beta_1 x$ 拟合。把模型写成 $A\beta = b$：

$$A = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{bmatrix}, \qquad \beta = \begin{bmatrix} \beta_0 \\ \beta_1 \end{bmatrix}, \qquad b = \begin{bmatrix} 1 \\ 2 \\ 2 \end{bmatrix}.$$

（A 的第一列是全 1 向量，对应截距 β_0；第二列是自变量取值，对应斜率 β_1。）计算

$$A^\top A = \begin{bmatrix} 3 & 3 \\ 3 & 5 \end{bmatrix}, \qquad A^\top b = \begin{bmatrix} 5 \\ 6 \end{bmatrix}.$$

《人工智能数学基础》 CC BY-NC-SA 4.0 禁止商业使用，著作权归全体署名作者共有

解正规方程 $\begin{bmatrix}3 & 3\\ 3 & 5\end{bmatrix}\begin{bmatrix}\beta_0\\ \beta_1\end{bmatrix}=\begin{bmatrix}5\\ 6\end{bmatrix}$：两式相减得 $2\beta_1=1$，故

$$\beta_1=\frac{1}{2},\qquad \beta_0=\frac{5-3\cdot\frac{1}{2}}{3}=\frac{7}{6}.$$

于是最佳拟合直线为 $y=\dfrac{7}{6}+\dfrac{1}{2}x$，拟合值为

$$A\hat\beta=\left(\tfrac{7}{6},\ \tfrac{5}{3},\ \tfrac{13}{6}\right)^{\top},\qquad r=b-A\hat\beta=\left(-\tfrac{1}{6},\ \tfrac{1}{3},\ -\tfrac{1}{6}\right)^{\top}.$$

直接验证 $A^{\top}r=\left(\sum_i r_i,\ \sum_i x_i r_i\right)^{\top}=(0,0)^{\top}$：这就是 式 (1.28) 所说的“残差垂直于列空间”。从几何上看，$A^{\top}r=0$ 的第一个分量说明残差之和为零，第二个分量说明残差关于自变量的加权和为零——最小二乘把误差“平均地”分给了三个点。图 1.5 画出了这组数据与最佳拟合直线：三个点到直线的竖直小段正是残差分量：记拟合值 $\hat y_i=\hat\beta_0+\hat\beta_1 x_i$，则

$$r_i=y_i-\hat y_i=y_i-\left(\hat\beta_0+\hat\beta_1 x_i\right).$$

最小二乘让 $\sum_i r_i^2$ 最小，并使正、负残差恰好抵消。

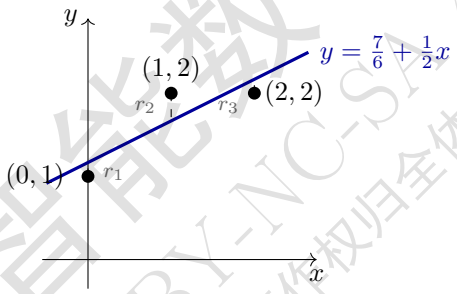


图 1.5: 例 1.40 的数据点与最小二乘拟合直线 $y=\frac{7}{6}+\frac{1}{2}x$：竖直虚线段为各点的残差分量，最小二乘使 $\sum_i r_i^2$ 最小

1.12 特征映射

前面的线性模型有一个天然局限：决策面必须是平直的（直线、平面、超平面）。许多实际问题中类别之间的分界是弯曲的，此时“先把数据搬到另一个空间，再在新空间里做线性方法”是标准套路。搬到新空间所依赖的映射，就是特征映射。

定义 1.41 (特征映射) 设 $\mathcal{X}$ 是原始输入集合（例如 $\mathcal{X}=\mathbb{R}^d$），$\mathcal{H}$ 是一个配备了内积的向量空间（称为**特征空间**）。映射

$$\phi:\mathcal{X}\to\mathcal{H},\qquad x\mapsto\phi(x)$$

称为**特征映射**。$\phi(x)$ 称为 x 的**特征表示**（feature representation，文献中也作 feature vector）。

《人工智能数学基础》 CC BY-NC-SA 4.0 禁止商业使用 著作权归全体署名作者共有

注意

特征映射 ϕ 一般不是线性映射。线性映射必须定义在向量空间上、并且满足 $T(\alpha x+\beta y)=\alpha T(x)+\beta T(y)$（式 (1.10)）。而特征映射

- **其定义域 $\mathcal{X}$ 可以只是任意集合（例如字符串集合、图的集合），并不必是向量空间；**
- **即使 $\mathcal{X}=\mathbb{R}^d$，也可以不满足线性性。例如 $\phi(x)=(x_1^2,\ x_2^2)^\top$ 满足 $\phi(2x)=4\phi(x)\neq 2\phi(x)$，因此不是线性的。**

例 1.42 (XOR：一个线性不可分的例子) 取四个样本

$$(1,1)^\top,\ (-1,-1)^\top \text{ 属于类 } +1, \qquad (1,-1)^\top,\ (-1,1)^\top \text{ 属于类 } -1.$$

在 $\mathbb{R}^2$ 中，任何一条直线都不能把两类分开（同号乘积的两个点位于第一、三象限，异号的两个点位于第二、四象限）。但取特征映射

$$\phi(x_1,x_2)=x_1x_2\in\mathbb{R},$$

则

$$\phi(1,1)=\phi(-1,-1)=+1, \qquad \phi(1,-1)=\phi(-1,1)=-1.$$

在特征空间 $\mathbb{R}$ 中，只需一个阈值 0 就能完美分开两类。分类器

$$f(x)=\operatorname{sign}\big(\phi(x)\big)=\operatorname{sign}(x_1x_2)$$

对应到原空间的决策边界是 $x_1x_2=0$——两条坐标轴之并，这是一条非线性的决策边界（图 1.6）。

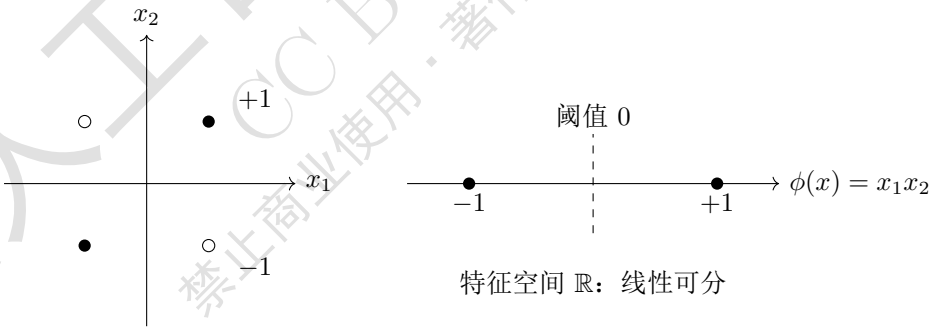


图 1.6: XOR 问题：特征映射 $\phi(x_1,x_2)=x_1x_2$ 把线性不可分变为线性可分

核心思想

特征映射的思路可以概括为：用非线性映射换取线性可分。代价是特征空间的维数可能远高于原始空间（甚至是无穷维），而显式地写出 $\phi(x)$ 并计算内积可能极其昂贵。节 1.13 的核技巧正是为了绕过这一代价。

《人工智能数学基础》 CC BY-NC-SA 4.0 禁止商业使用·著作权归全体署名作者共有

1.13 核技巧

定义 1.43 (核函数与 Gram 矩阵) 设 $k : \mathcal{X} \times \mathcal{X} \to \mathbb{R}$。若存在特征空间 $\mathcal{H}$ 与特征映射 $\phi : \mathcal{X} \to \mathcal{H}$ 使得

$$k(x, z) = \langle \phi(x), \phi(z) \rangle_{\mathcal{H}}, \qquad \forall\, x, z \in \mathcal{X}, \tag{1.32}$$

则称 k 是一个**核函数**。给定样本 $x_1, \dots, x_N \in \mathcal{X}$，称对称矩阵

$$K = \big(k(x_i, x_j)\big)_{i,j=1}^{N} \in \mathbb{R}^{N \times N}$$

为该核对应的 **Gram 矩阵**。

核技巧的全部力量来自一个观察：许多线性算法只依赖样本之间的内积，而不需要样本的坐标本身。如果能用 $k(x, z)$ 直接算出 $\langle \phi(x), \phi(z) \rangle$，就不必显式构造 ϕ。下面用一个完全可手算的例子说明这一点。

例 1.44 (二次多项式核) 在 $\mathbb{R}^2$ 上取特征映射

$$\phi(x) = \big(x_1^2,\ \sqrt{2}\, x_1 x_2,\ x_2^2\big)^{\top} \in \mathbb{R}^3.$$

则对任意 $x, z \in \mathbb{R}^2$，

$$\phi(x)^{\top} \phi(z) = x_1^2 z_1^2 + 2 x_1 x_2 z_1 z_2 + x_2^2 z_2^2 = (x_1 z_1 + x_2 z_2)^2 = (x^{\top} z)^2. \tag{1.33}$$

因此

$$k(x, z) = (x^{\top} z)^2$$

是一个核函数，它对应的是 $\mathbb{R}^3$ 中的内积，但计算只需 $\mathbb{R}^2$ 上的一次内积与一次平方。这就是核方法“隐式地工作在高维空间”的含义。

上式是 $c = 0,\ q = 2$ 的特例。更一般地，$k(x, z) = (x^{\top} z + c)^q$ 在

$$c \geq 0, \qquad q \in \mathbb{N}_+$$

时是合法核（当 $c > 0$ 时可把它展开成所有次数不超过 q 的单项式的内积，维数为 $\binom{d+q}{q}$；当 $c = 0$ 时只能保留总次数恰为 q 的单项式，维数为 $\binom{d+q-1}{q}$）。无论哪种情形，计算量都只与 d 与 q 有关，而不依赖特征空间的维数。

AI 应用

问题：支持向量机（SVM）要在高维特征空间里找最大间隔超平面，但特征空间的维数可能极高甚至无穷，超平面往往无法显式写出。
做法：这个优化问题的解可以只用样本之间的内积来表达。把其中出现的 $\langle \phi(x_i), \phi(x_j) \rangle$ 一律换成 $k(x_i, x_j)$，就不必显式构造 ϕ：优化变量从可能无穷维的 w 变成 N 个乘子，计算量由 $N \times N$ 的 Gram 矩阵 K 决定，与特征空间的维数无关。
本章的位置：这里用到的只是 式 (1.32) 中“核就是特征空间里的内积”这一定义。如何

《人工智能数学基础》 CC BY-NC-SA 4.0 署名-非商业使用·著作权归全体署名作者共有

解这个优化问题属于最优化部分（第 8–11 章），本章只负责说明 K 必须具备什么性质。

定理 1.45 (Gram 矩阵半正定) 设 $k : \mathcal{X} \times \mathcal{X} \to \mathbb{R}$ 是核函数，$x_1, \dots, x_N \in \mathcal{X}$ 任意给定，$K = \big(k(x_i, x_j)\big)$ 为对应的 *Gram* 矩阵。则 K 对称且半正定，即

$$K^\top = K, \qquad c^\top K c = \sum_{i=1}^{N}\sum_{j=1}^{N} c_i c_j k(x_i, x_j) \;\geq\; 0, \qquad \forall\, c \in \mathbb{R}^N. \tag{1.34}$$

证明. 对称性由 $K_{ij} = k(x_i, x_j) = \langle \phi(x_i), \phi(x_j) \rangle = \langle \phi(x_j), \phi(x_i) \rangle = K_{ji}$ 得到。半正定性：由式 (1.32) 与内积的双线性性，

$$c^\top K c = \sum_{i,j} c_i c_j \, \langle \phi(x_i), \phi(x_j) \rangle = \Big\| \sum_{i=1}^{N} c_i \phi(x_i) \Big\|_{\mathcal{H}}^2 \geq\; 0,$$

最后一步用了内积的正定性。 □

注 (Moore–Aronszajn 定理（有限样本版本）). 定理 1.45 说明“核函数 $\Rightarrow$ Gram 矩阵半正定”。反过来，一个对称函数 k 只要对任意有限样本集 $x_1, \dots, x_N$ 都给出半正定的 Gram 矩阵，就必定存在特征空间 $\mathcal{H}$ 与特征映射 ϕ 使式 (1.32) 成立。这是 Moore–Aronszajn 定理的有限样本版本，其证明需要对所有有限样本一致地构造 ϕ，不属于本章范围。因此实践中往往直接用“**任意有限 Gram 矩阵都半正定**”作为判断 k 是否为合法核函数的准则，例如 RBF 核 $k(x, z) = \exp(-\|x - z\|_2^2/(2\sigma^2))$（$\sigma > 0$）可由此验证，见 习题 1.80。

核心思想

核技巧把“构造高维特征 $\phi(x)$”这件事，替换成了“设计一个满足半正定性的二元函数 $k(x, z)$”。线性代数为这一替换提供了判据（式 (1.34)），也提供了算法（一切只依赖内积的线性算法都可以“核化”）。本章支线的终点就是这句话。

1.14 AI 综合案例

1.14.1 核心案例：用子空间与正交补做去噪

AI 应用 1.46 (子空间去噪) **问题：**观测到的信号往往被噪声污染，希望把“真实信号”与“噪声”分离开。

建模. 设观测向量 $x \in \mathbb{R}^n$ 满足

$$x = s + n, \qquad s \in S, \qquad n \in S^\perp, \tag{1.35}$$

其中 $S \subseteq \mathbb{R}^n$ 是已知（或由数据估计得到）的**信号子空间**，它刻画“真实信号可能长什么样”，$n \in S^\perp$ 则是与它正交的那部分。由正交分解定理 式 (1.16)，$\mathbb{R}^n = S \oplus S^\perp$，故 式 (1.35) 中的分解是唯一的。

结论. 设 P_S 为到 S 的正交投影（节 1.10）。对 $x = s + n$ 作用 P_S，由 $P_S s = s$（$s \in S$

在投影下不动）与 $P_S n = 0$（$n \in S^\perp$ 被压成零）得

$$P_S x = s, \qquad (I - P_S)x = n.$$

在这个模型下，这就是子空间去噪的全部内容：*把观测投到信号子空间上，残差就是噪声*。

理论联系. 用的是 定理 1.26（$S \oplus S^\perp$）、定理 1.30（投影唯一且使距离最小）与 定理 1.33（若 Q 的列是 S 的一组标准正交基，则 $P_S = QQ^\top$）。在实际中，S 常取数据协方差的前 k 个主方向（PCA 去噪）。

例 1.47 (数值算例：二维信号子空间) 取 $\mathbb{R}^3$ 中由两个向量张成的信号子空间

$$S = \operatorname{span}\{a_1, a_2\}, \qquad a_1 = \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}, \qquad a_2 = \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix},$$

观测向量 $x = (1, 2, 2)^\top$。要把 x 拆成 S 中的信号与 $S^\perp$ 中的噪声。

第一步：认清 S 与 $S^\perp$ 的维数。 a_1, a_2 不成比例，故线性无关，$\dim S = 2$——这里的“信号”是三维空间里的一个*平面*。由正交分解定理 式 (1.16)，$\mathbb{R}^3 = S \oplus S^\perp$，于是

$$\dim S^\perp = \dim \mathbb{R}^3 - \dim S = 3 - 2 = 1.$$

所以噪声只能沿这个平面的法方向，是一维的。记住这个 $2 + 1 = 3$：投影矩阵后面会“不动两个方向、压掉一个方向”。

第二步：求到 S 的正交投影矩阵。 a_1, a_2 彼此不正交（$\langle a_1, a_2 \rangle = 1 \neq 0$），不能直接用 $P = QQ^\top$，要用 定理 1.34 的一般公式 式 (1.24)。记 $A = [a_1\ a_2] \in \mathbb{R}^{3\times 2}$：

$$A = \begin{bmatrix} 1 & 1 \\ 1 & 0 \\ 0 & 1 \end{bmatrix}, \qquad A^\top A = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}, \qquad \det(A^\top A) = 3 \neq 0,$$

行列式非零印证了 A 满列秩、$A^\top A$ 可逆（正是 定理 1.34 的前提），故

$$(A^\top A)^{-1} = \frac{1}{3}\begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix}, \qquad P_S = A(A^\top A)^{-1}A^\top = \frac{1}{3}\begin{bmatrix} 2 & 1 & 1 \\ 1 & 2 & -1 \\ 1 & -1 & 2 \end{bmatrix}.$$

第三步：验证 P_S 确实是正交投影矩阵。按 式 (1.25) 的两条逐一核对：矩阵显然对称，即 $P_S^\top = P_S$；再看幂等性，

$$P_S^2 = \frac{1}{9}\begin{bmatrix} 2 & 1 & 1 \\ 1 & 2 & -1 \\ 1 & -1 & 2 \end{bmatrix}^2 = \frac{1}{9}\begin{bmatrix} 6 & 3 & 3 \\ 3 & 6 & -3 \\ 3 & -3 & 6 \end{bmatrix} = \frac{1}{3}\begin{bmatrix} 2 & 1 & 1 \\ 1 & 2 & -1 \\ 1 & -1 & 2 \end{bmatrix} = P_S.$$

（中间那步：对角元是各行模长的平方 $2^2 + 1^2 + 1^2 = 6$，非对角元是两行的内积，如 $2 \cdot 1 + 1 \cdot$

《人工智能数学基础》 CC BY-NC-SA 4.0 禁止商业使用，著作权归全体署名作者共有

$2+1\cdot(-1)=3$。）另外 $\operatorname{tr}(P_S)=\frac{1}{3}(2+2+2)=2=\dim S$，与第一步的维数账一致。

第四步：做投影。

$$\hat{s}=P_S x=\frac{1}{3}\begin{bmatrix}2&1&1\\1&2&-1\\1&-1&2\end{bmatrix}\begin{bmatrix}1\\2\\2\end{bmatrix}=\frac{1}{3}\begin{bmatrix}6\\3\\3\end{bmatrix}=\begin{bmatrix}2\\1\\1\end{bmatrix},$$

$$\hat{n}=(I-P_S)x=x-\hat{s}=\begin{bmatrix}1\\2\\2\end{bmatrix}-\begin{bmatrix}2\\1\\1\end{bmatrix}=\begin{bmatrix}-1\\1\\1\end{bmatrix}.$$

第五步：逐条验证。

(a) $\hat{s}$ 确实落在 S 里. 解 $c_1a_1+c_2a_2=\hat{s}$，即 $c_1+c_2=2$、$c_1=1$、$c_2=1$，有解，且 $\hat{s}=a_1+a_2$。

(b) $\hat{n}$ 确实落在 $S^{\perp}$ 里. 只需对 S 的两个生成元验证正交性：

$$\langle\hat{n},a_1\rangle=-1+1+0=0,\qquad \langle\hat{n},a_2\rangle=-1+0+1=0.$$

(c) 分解无损. $\hat{s}+\hat{n}=(2,1,1)^{\top}+(-1,1,1)^{\top}=(1,2,2)^{\top}=x$。

第六步：投影对 S 与 $S^{\perp}$ 分别“不动”与“归零”。把 $x=\hat{s}+\hat{n}$ 代回去：

$$P_S\hat{s}=P_S^2x=P_Sx=\hat{s},\qquad P_S\hat{n}=P_S(x-\hat{s})=P_Sx-P_S^2x=\hat{s}-\hat{s}=0.$$

S 中的向量投影后原样保留，$S^{\perp}$ 中的向量投影后清零——这正是 AI 应用 1.46 里那句“$P_Ss=s$、$P_Sn=0$”的来历，也是 $I-P_S$ 成为到 $S^{\perp}$ 的正交投影的原因（节 1.10.1）。

换用第 3 章的语言说（本章不展开）：P_S 的特征值（eigenvalue）只能是 1 与 0——1 对应 S 中的方向，0 对应 $S^{\perp}$ 中的方向。这里 $\dim S=2$、$\dim S^{\perp}=1$，所以 1 是二重的、0 是一重的，这恰好解释了 $\operatorname{tr}(P_S)=2$。

另解：先求标准正交基。也可以先对 a_1,a_2 做 Gram–Schmidt 正交化（引理 1.24），得到 S 的一组标准正交基

$$q_1=\frac{1}{\sqrt{2}}\begin{bmatrix}1\\1\\0\end{bmatrix},\qquad q_2=\frac{1}{\sqrt{6}}\begin{bmatrix}1\\-1\\2\end{bmatrix},$$

再用 定理 1.33 的 $P_S=q_1q_1^{\top}+q_2q_2^{\top}$，得到的矩阵与上面完全相同。两条路等价，按手算方便程度选：生成元已经正交时用后者，否则要先求 $A^{\top}A$ 的逆。当 S 退化成一条直线（$S=\operatorname{span}\{q\}$、$\|q\|_2=1$）时，后者进一步退化成 $P_S=qq^{\top}$，这就是 定理 1.33 中 $k=1$ 的情形。

1.14.2 延伸阅读：零样本学习中的子空间与最小二乘

问题．在零样本学习（zero-shot learning）中，训练时只能见到一部分类别（已见类 $\mathcal{L}_s$），测试时需要识别从未出现过的类别（未见类 $\mathcal{L}_u$，且 $\mathcal{L}_s\cap\mathcal{L}_u=\varnothing$）。没有未见类的任何图像样本，模型凭什么能识别它们？答案是：借助类别语义向量。

《人工智能数学基础》 CC BY-NC-SA 4.0 禁止商业使用，著作权归全体署名作者共有

建模. 每个类别 t 都配有一个语义向量 $a_t \in \mathbb{R}^k$（例如由“有翅膀、会飞、有羽毛”等属性的人工打分构成），已见类与未见类共用同一套属性。训练样本是视觉特征向量 $s_1, \dots, s_N \in \mathbb{R}^d$（$N$ 为训练样本数），s_i 的类别标号为 $y_i \in \mathcal{L}_s$。目标是在语义空间里做识别：学一个映射

$$F : \mathbb{R}^d \to \mathbb{R}^k,$$

使 $F(s_i) \approx a_{y_i}$。训练完成后，对测试样本 s_t 按语义空间中的欧氏距离取最近者，

$$\hat{t} = \arg\min_{t \in \mathcal{L}_u} \ \|F(s_t) - a_t\|_2 \,. \tag{1.36}$$

为什么要拆成子空间. 视觉特征的不同部分往往对应不同的语义属性，用一个矩阵笼统地处理，难以让“翅膀”那一部分只影响“有翅膀”这个属性。自然的改进是先把视觉空间拆成若干子空间，再分别映射：

$$U_j = \mathrm{Col}(W_j) \subseteq \mathbb{R}^d, \qquad W_j \in \mathbb{R}^{d \times c} \text{ 取满列秩}, \qquad j = 1, \dots, M,$$

并令 P_j 为到 U_j 的正交投影算子，由 **定理 1.34**

$$P_j = W_j (W_j^\top W_j)^{-1} W_j^\top. \tag{1.37}$$

于是 s 被拆成 M 个分量 $P_j s \in U_j$；每个分量各配一个线性映射 $A_j : \mathbb{R}^d \to \mathbb{R}^k$，映射 F 就取为它们的叠加

$$F(s) = v = \sum_{j=1}^{M} A_j P_j s. \tag{1.38}$$

若诸 U_j 两两正交且 $\sum_j \dim U_j = d$，则 $\mathbb{R}^d = U_1 \oplus \cdots \oplus U_M$（**定义 1.25**），每个 s 有唯一分解 $s = \sum_j P_j s$，这一步不丢信息。这一步同时用到了直和与正交性两件事：仅有直和时，分解 $s = \sum_j u_j$ 中的分量 u_j 未必等于 $P_j s$（例如 $\mathbb{R}^2$ 中 $U_1 = \mathrm{span}\{(1,0)^\top\}$、$U_2 = \mathrm{span}\{(1,1)^\top\}$ 是直和，但 $s = (0,1)^\top = (-1,0)^\top + (1,1)^\top$ 而 $P_1 s = 0$）。

上面是理想情形。一般地，满列秩只给出 $\dim U_j = c$，于是诸 U_j 张成 $\mathbb{R}^d$ 的一个子空间

$$U := \sum_{j=1}^{M} U_j \subseteq \mathbb{R}^d, \qquad \dim U \ \le \ \sum_{j=1}^{M} \dim U_j = Mc.$$

这里只能写不等号。一般只有 $\dim \sum_j U_j \le \sum_j \dim U_j$，等号成立要求诸 U_j 的和是直和，即对每个 k 有 $U_k \cap \sum_{j \neq k} U_j = \{0\}$——而“两两相交为 $\{0\}$”并不足以保证这一点（$M \ge 3$ 时二者不等价）。例如 $\mathbb{R}^3$ 中取 $U_1 = \mathrm{span}\{e_1, e_2\}$、$U_2 = \mathrm{span}\{e_2, e_3\}$，则 $c = 2$、$Mc = 4$，但 $U = \mathbb{R}^3$、$\dim U = 3 < 4$。反过来，$U = \mathbb{R}^d$ 当且仅当 $\dim U = d$，由 $\dim U \le Mc$ 知这要求 $Mc \ge d$；特别地，若诸 U_j 的和是直和且 $Mc = d$，则 $\dim U = Mc = d$，即 $U = \mathbb{R}^d$。

当 $U \neq \mathbb{R}^d$ 时（$Mc < d$ 的常见情形必然如此），无法保证任意输入都完整落在 U 中：对具体的 s，遗漏分量是 $(I - P_U)s$，它可能为零，也可能不小。需要一个重构项把它压小。以下除特别说明外，不假设诸 U_j 两两正交，它们的正交化程度由正则项 R_{corr} 去促；相应地，等式 $P_U = \sum_j P_j$ 只在诸 U_j 两两正交时成立。

《人工智能数学基础》 CC BY-NC-SA 4.0 禁止商业使用，著作权归全体署名作者共有

训练：一个最小二乘问题． 在已见类上，我们希望 $F(s_i)$ 接近 a_{y_i}，同时希望和空间 $U=\sum_j U_j$ 能尽量完整地保留 s_i：重构项取 s_i 到整个和空间 U 的距离，而不逐个子空间计算。再加一项促使各 U_j 互不重叠的正则项 R_{corr}（例如 $\sum_{i\neq j}\|P_iP_j\|_F^2$），损失函数取

$$\begin{aligned}\min_{\{P_j,A_j\}}\quad &\sum_{i=1}^{N}\big\|v_i-a_{y_i}\big\|_2^2\;+\;\lambda_{\text{rec}}\sum_{i=1}^{N}\Big\|s_i-P_U s_i\Big\|_2^2\\ &+\;\lambda_{\text{corr}}\,R_{\text{corr}},\end{aligned}\tag{1.39}$$

其中 $v_i=F(s_i)$ 由 式 **(1.38)** 给出，P_U 是到和空间 $U=\sum_j U_j$ 的正交投影（存在性由 定理 **1.30** 保证），$\lambda_{\text{rec}},\lambda_{\text{corr}}\geq 0$ 是权重。三项分别对应语义对齐、信息保真与子空间解耦。

优化变量 $\{P_j\}$ 取正交投影算子，须满足

$$P_j^2=P_j=P_j^{\top},\qquad \operatorname{rank}(P_j)=c,\qquad j=1,\dots,M.\tag{1.40}$$

前两条由 式 **(1.25)** 恰好等价于“P_j 是到某个子空间 U_j 的正交投影”，第三条则把该子空间的维数固定为 c。这里要分清第三条的作用：正交投影算子与子空间本来就一一对应（定理 **1.36**），第三条把维数锁定成建模假设中的 c，使 P_j 所对应的 U_j 与“每个子空间维数都是 c”这一设定保持一致。若固定 $\{P_j\}$ 只优化 $\{A_j\}$，式 **(1.39)** 的第一项关于 $\{A_j\}$ 就是一个标准的最小二乘问题，其正规方程由 式 **(1.29)** 给出——这正是 节 **1.11** 的结论在此处的直接应用。

推断． 未见类没有样本，只能为它造一个语义表示 $v_t\in\mathbb{R}^k$：最简单的做法是直接取 $v_t=a_t$；若希望更贴近 F 的像空间，可先用一个反演映射 $G:\mathbb{R}^k\to\mathbb{R}^d$ 把 a_t 映回视觉空间得虚拟特征 $\tilde{s}_t=G(a_t)$，再令 $v_t=F(\tilde{s}_t)$。有了 v_t 后，对测试样本 s_t 算出 $F(s_t)$，按式 **(1.36)** 取距离最近者即可。（P_j 作用在视觉特征空间 $\mathbb{R}^d$ 上，而 a_t 属于语义空间 $\mathbb{R}^k$。）

小结．这个案例把本章的数学结构完整地用了一遍：子空间与直和（定义 **1.25**）用来划分视觉特征，正交投影（定理 **1.30**、式 **(1.37)**）用来取出各分量，线性映射与矩阵表示（定理 **1.16**）给出 $F=\sum_j A_jP_j$，最小二乘（式 **(1.29)**）用于训练。它也是“把 节 **1.11** 的结论用到真实问题上”的一个例子。

1.15 本章小结

本章围绕一条主线展开：从数据向量出发，建立向量空间与子空间的语言，用线性映射描述“线性”，再用矩阵把它记录下来，最后通过内积、正交补与投影得到最小二乘。要点如下。

(1) 样本即向量，数据集即矩阵。一个样本是 $x\in\mathbb{R}^d$，一份数据集是 $X\in\mathbb{R}^{N\times d}$，约定“行 = 样本、列 = 特征”（式 **(1.2)**）。矩阵乘法有行观点、列观点与线性变换观点三种读法：$y=Ax$ 既可以读成 $y_i=a_i^{\top}x$（式 **(1.4)**），也可以读成 $Ax=\sum_j x_ja_j$（式 **(1.5)**），还可以读成映射 $T_A:\mathbb{R}^n\to\mathbb{R}^m$。

(2) 向量空间与子空间。八条公理（定义 **1.2**）是所有线性结论的共同来源。子空间判别准则（命题 **1.5**）把它归结为两条：$W\neq\varnothing$，且对任意 $x,y\in W$、$\alpha,\beta\in\mathbb{F}$ 有 $\alpha x+\beta y\in W$。

检验时“$0 \notin W$”是最快的反例（例 **1.7**）。

(3) 基与维数。 ***Steinitz*** 替换定理（引理 **1.11**）断言线性无关组的元素个数不超过任一生成集，且可把生成集中的向量逐个换成该无关组。由此得到两条结论：基的扩充定理（定理 **1.12**）——线性无关组可扩充为基，与维数唯一性（推论 **1.13**）——任意两组基含同样多的向量，故维数由空间本身确定。在给定基下，每个向量的坐标表示唯一（式 **(1.9)**）。

(4) 线性映射与矩阵的一一对应。 线性映射由它在基上的像唯一确定（定理 **1.16**）；取标准基即得 $A = [T(e_1)\ \cdots\ T(e_n)]$ 与 $T(x) = Ax$（式 **(1.12)**）。这是本章“先讲映射、再讲矩阵”的关键。

(5) 核、像与秩。核与像都是子空间；秩–零化度定理（定理 **1.20**）$\dim \operatorname{Ker} T + \dim \operatorname{Im} T = \dim V$ 是线性代数的基本计数律，矩阵形式为 $\operatorname{rank}(A) + \operatorname{nullity}(A) = n$（式 **(1.15)**）。又由行秩等于列秩（引理 **1.27**），$\operatorname{rank}(A)$ 同时是行空间与列空间的维数。

(6) 四个基本子空间与方程组的结构。 线性代数基本定理（式 **(1.18)**）断言零空间是行空间的正交补、左零空间是列空间的正交补；四个子空间的维数依次为 r、$n-r$、r、$m-r$，其中 $r = \operatorname{rank}(A)$。线性方程组的结构定理（定理 **1.29**）给出：$Ax = b$ 有解当且仅当 $b \in \operatorname{Col}(A)$，也当且仅当 $\operatorname{rank}(A) = \operatorname{rank}\big([\,A\ b\,]\big)$；有解时通解为“特解 + 齐次通解” $x_0 + \operatorname{Null}(A)$（式 **(1.19)**），且解唯一当且仅当 A 满列秩。

(7) 正交分解、投影与投影矩阵。对任意子空间 M 有 $\mathbb{R}^n = M \oplus M^{\perp}$（式 **(1.16)**）；投影定理（定理 **1.30**）断言 x 有唯一分解 $x = \hat{x} + r$（$\hat{x} \in M$、$r \perp M$），且 $\hat{x}$ 是 M 中离 x 最近的点。正交投影矩阵的刻画（式 **(1.25)**）由 $P^2 = P$ 与 $P^{\top} = P$ 两条代数等式给出；具体公式为 $P = QQ^{\top}$（Q 的列标准正交）或 $P = A(A^{\top}A)^{-1}A^{\top}$（$A$ 满列秩）。

(8) 最小二乘。几何内容就是“残差垂直于列空间”，由此得正规方程（式 **(1.29)**）$A^{\top}A\hat{x} = A^{\top}b$；当 A 满列秩时解唯一，$\hat{x} = (A^{\top}A)^{-1}A^{\top}b = A^{+}b$（式 **(1.30)**）。

(9) 支线：特征映射与核技巧。特征映射（定义 **1.41**）把数据搬到高维空间以换取线性可分，它一般不是线性映射，异或问题是典型例子（例 **1.42**）。核函数 $k(x,z) = \langle \phi(x), \phi(z) \rangle$ 让算法无需显式构造 ϕ；合法核的判据（***Moore–Aronszajn*** 定理的有限样本版本，式 **(1.34)**）是全部 **Gram** 矩阵半正定，这等价于二次型 $\|\sum_i c_i \phi(x_i)\|^2 \geq 0$。

1.16　习题

以下习题分为基础题、证明题、计算题与 **AI** 应用题四类，难度大体递进。标 ★ 者为进一步的思考题，仅给一句提示；其余题目只给题干，请读者独立完成。

1.16.1　基础题

习题 1.48 (子空间判定) 判断下列两个集合是否为 $\mathbb{R}^3$ 的子空间，并给出证明：

$$W_1 = \big\{x = (x_1, x_2, x_3)^{\top} \in \mathbb{R}^3 :\ x_1 + 2x_2 - x_3 = 0\big\}, \qquad W_2 = \big\{x \in \mathbb{R}^3 :\ x_1 + 2x_2 - x_3 = 1\big\}.$$

习题 1.49 (Span 与线性无关) 设 $v_1 = (1,0,1)^{\top}$，$v_2 = (0,1,1)^{\top}$，$v_3 = (1,1,2)^{\top} \in \mathbb{R}^3$。求 $\operatorname{span}\{v_1, v_2, v_3\}$ 的一组基与维数，并说明这三个向量是否线性无关。

习题 1.50 (线性映射的判定) 设 $T : \mathbb{R}^2 \to \mathbb{R}^2$，$T(x_1, x_2) = (x_1 + x_2,\ x_1 x_2)^{\top}$。$T$ 是否为线性

映射？请从 式 (1.10) 出发给出证明。

习题 1.51 (更多子空间判定) 判断下列集合是否为相应空间中的子空间，并说明理由：

(a) $\{(x_1,x_2)^\top \in \mathbb{R}^2 :\ x_1 x_2 = 0\}$；
(b) $\{(x_1,x_2)^\top \in \mathbb{R}^2 :\ x_1^2 + x_2^2 = 1\}$；
(c) $\{(x_1,x_2,x_3)^\top \in \mathbb{R}^3 :\ x_1 = x_3\}$；
(d) $\{(x_1,x_2)^\top \in \mathbb{R}^2 :\ |x_1| \le 1\}$。

习题 1.52 (子空间的交与和) 设 W_1, W_2 是向量空间 V 的子空间。判断 $W_1 \cap W_2$ 与 $W_1 + W_2 = \{u+v : u \in W_1,\ v \in W_2\}$ 是否都是 V 的子空间，并给出理由。

习题 1.53 (换基与坐标) 在 $\mathbb{R}^2$ 中取基 $B = \{v_1, v_2\}$，其中 $v_1 = (1,1)^\top$、$v_2 = (1,-1)^\top$。求 $x = (3,1)^\top$ 在标准基下的坐标与在基 B 下的坐标，并解释两个坐标向量为什么不同。

习题 1.54 (线性相关性的判断) 判断下列各组向量是否线性无关：

(a) $(1,0,0)^\top,\ (0,1,0)^\top,\ (0,0,1)^\top \in \mathbb{R}^3$；
(b) $(1,2)^\top,\ (2,4)^\top \in \mathbb{R}^2$；
(c) $(1,1,0)^\top,\ (0,1,1)^\top,\ (1,2,1)^\top \in \mathbb{R}^3$；
(d) $(1,2,3)^\top,\ (4,5,6)^\top,\ (7,8,9)^\top \in \mathbb{R}^3$。

习题 1.55 (内积、范数与正交) 设 $x = (1,1,1)^\top$、$y = (1,-2,1)^\top \in \mathbb{R}^3$。计算 $\langle x, y\rangle$、$\|x\|_2$、$\|y\|_2$，判断二者是否正交，并验证此时勾股定理 $\|x+y\|_2^2 = \|x\|_2^2 + \|y\|_2^2$ 是否成立。

1.16.2 证明题

习题 1.56 (零空间的包含关系) 设 $A \in \mathbb{R}^{m\times n}$、$B \in \mathbb{R}^{n\times p}$。证明

$$\mathrm{Null}(B) \subseteq \mathrm{Null}(AB),$$

并给出一个使 $\mathrm{Null}(AB) = \mathrm{Null}(B)$ 成立的充分条件。（提示：Null 的维数由秩决定，比较 $\mathrm{rank}(AB)$ 与 $\mathrm{rank}(B)$。）

习题 1.57 (解集何时是子空间) 设 $A \in \mathbb{R}^{m\times n}$、$b \in \mathbb{R}^m$，且 $Ax = b$ 有解。（i）证明解集非空时必形如 $x_0 + \mathrm{Null}(A)$，其中 x_0 是任一特解；（ii）证明这个解集是 $\mathbb{R}^n$ 的子空间当且仅当 $b = 0$。

习题 1.58 (直和分解) 设 $U = \mathrm{span}\{(1,1)^\top\}$、$W = \mathrm{span}\{(1,-1)^\top\}$。证明 $\mathbb{R}^2 = U \oplus W$，并对任意 $x = (a,b)^\top$ 求出它在 $U \oplus W$ 下的唯一分解 $x = u + w$（$u \in U$、$w \in W$）。

习题 1.59 (核函数的封闭性) 设 $k_1, k_2 : \mathcal{X}\times\mathcal{X} \to \mathbb{R}$ 都是核函数，$a, b \ge 0$。证明 $ak_1 + bk_2$ 与 $k_1 k_2$ 也都是核函数。（提示：用 式 (1.32) 把 k_i 写成 ϕ_i 的内积；对乘积可考虑 $\phi(x) = \phi_1(x) \otimes \phi_2(x)$，即两个特征向量的张量积。）

习题 1.60 (★ 条件数的平方) 设 $A \in \mathbb{R}^{m\times n}$ 满列秩，$\kappa_2(A)$ 表示 A 的谱条件数（等于最大

《人工智能数学基础》 CC BY-NC-SA 4.0 禁止商业使用 · 著作权归全体著者共有

奇异值与最小奇异值之比）。证明

$$\kappa_2(A^\top A) = \kappa_2(A)^2.$$

提示：由奇异值分解 $A = U\Sigma V^\top$，有 $A^\top A = V\Sigma^2 V^\top$，故 $A^\top A$ 的奇异值为 $\sigma_i(A)^2$。

习题 1.61 (正交向量组线性无关) 证明：若 $v_1, \dots, v_m$ 两两正交且都非零，则它们线性无关。

习题 1.62 (Span 的最小性) 设 $S \subseteq V$。证明 $\operatorname{span} S$ 是 V 中包含 S 的最小子空间，即：（i）$\operatorname{span} S$ 是子空间且 $S \subseteq \operatorname{span} S$；（ii）若 W 是 V 的子空间且 $S \subseteq W$，则 $\operatorname{span} S \subseteq W$。

习题 1.63 (秩的不等式) 设 $A \in \mathbb{R}^{m\times n}$、$B \in \mathbb{R}^{n\times p}$、$C \in \mathbb{R}^{m\times n}$。证明

$$\operatorname{rank}(AB) \le \min\{\operatorname{rank}(A), \operatorname{rank}(B)\}, \qquad \operatorname{rank}(A+C) \le \operatorname{rank}(A) + \operatorname{rank}(C).$$

习题 1.64 (投影矩阵的等价刻画) 设 $P \in \mathbb{R}^{n\times n}$ 满足 $P^2 = P$ 且 $P^\top = P$。证明 $I - P$ 也是正交投影矩阵，并指出它投影到哪个子空间；另外证明 $\|Px\|_2 \le \|x\|_2$ 对一切 x 成立。

习题 1.65 (直和与维数公式) 设 U, W 是有限维向量空间 V 的子空间。证明

$$\dim(U+W) + \dim(U \cap W) = \dim U + \dim W,$$

并由此证明：$U + W = U \oplus W$ 当且仅当 $\dim(U+W) = \dim U + \dim W$。

习题 1.66 (★ 基的等势性) 设有限维向量空间 V 有两组基 $B_1 = \{u_1, \dots, u_m\}$ 与 $B_2 = \{v_1, \dots, v_n\}$。证明 $m = n$。提示：把 $v_1, \dots, v_n$ 用 B_1 表出，得到 n 个含 m 个未知量的齐次线性方程组；若 $n > m$，这类方程组必有非零解，从而 B_2 线性相关，矛盾。

习题 1.67 (正交补的性质) 设 $M, N \subseteq \mathbb{R}^n$ 是子空间。证明：

(a) $M \subseteq N \implies N^\perp \subseteq M^\perp$；
(b) $(M^\perp)^\perp = M$；
(c) $(M+N)^\perp = M^\perp \cap N^\perp$。

1.16.3 计算题

习题 1.68 (四个基本子空间的基与维数) 设

$$A = \begin{bmatrix} 1 & 2 & 3 \\ 0 & 1 & 1 \end{bmatrix}.$$

分别求 $\operatorname{Null}(A)$、$\operatorname{Col}(A)$、$\operatorname{Row}(A)$ 的一组基与维数，并验证 Rank–Nullity 定理 $\operatorname{rank}(A) + \operatorname{nullity}(A) = n$。再求 $\operatorname{Null}(A^\top)$ 的一组基，并验证四个维数之和的分解 $n = r + (n-r)$、$m = r + (m-r)$。

习题 1.69 (由基上的像确定线性映射) 设 $T : \mathbb{R}^2 \to \mathbb{R}^2$ 是线性映射，且 $T(e_1) = (1,2)^\top$、$T(e_2) = (3,1)^\top$。写出 T 的矩阵表示 A，计算 $T\big((2,-1)^\top\big)$，并验证 $T\big((2,-1)^\top\big) = 2T(e_1) - T(e_2)$。

《人工智能数学基础》 CC BY-NC-SA 4.0 禁止商业使用 · 著作权归作者共有

习题 1.70 (点到直线的投影) 设 $x=(2,3)^\top$、$u=(1,1)^\top\in\mathbb{R}^2$。求 x 在直线 $\mathrm{span}\{u\}$ 上的正交投影 $\hat{x}$ 与残差 $r=x-\hat{x}$，并验证 $\hat{x}\perp r$、$\hat{x}+r=x$。

习题 1.71 (秩一投影矩阵) 设 $u=\frac{1}{\sqrt{5}}(1,2)^\top\in\mathbb{R}^2$，$P=uu^\top$。验证 $P^2=P$、$P^\top=P$，并求 $\mathrm{rank}(P)$、$\mathrm{tr}(P)$ 以及 P 的全部特征值。解释为什么 P 是到 $\mathrm{span}\{u\}$ 的正交投影矩阵。

习题 1.72 (一般列空间上的投影矩阵) 设

$$A=\begin{bmatrix}1&1\\1&2\\1&3\end{bmatrix}.$$

计算 $A^\top A$ 与其逆，求出 $P=A(A^\top A)^{-1}A^\top$，并直接验证 $P^2=P$ 与 $P^\top=P$。指出 $\mathrm{Col}(P)$ 的维数。

习题 1.73 (最小二乘直线拟合) 给定数据点 $(0,2)$、$(1,1)$、$(2,3)$，用模型 $y=\beta_0+\beta_1 x$ 做最小二乘拟合。请

(a) 写出 A 与 b，用正规方程 $A^\top A\hat{\beta}=A^\top b$ 求出 $\hat{\beta}$；
(b) 用正交投影的观点求出 $\hat{b}=A\hat{\beta}$ 与残差 $r=b-\hat{b}$，验证 $A^\top r=0$；
(c) 解释残差的分量为什么有正有负，以及 $\sum_i r_i=0$ 的含义。

习题 1.74 (三次齐次核的显式特征映射) 证明 $k(x,z)=(x^\top z)^3$（$x,z\in\mathbb{R}^2$）是核函数，具体求出一个显式的特征映射 $\phi:\mathbb{R}^2\to\mathbb{R}^4$ 使 $k(x,z)=\phi(x)^\top\phi(z)$。（提示：把 $(x_1z_1+x_2z_2)^3$ 按多项式展开，再把每一项拆成“只含 x 的因子”与“只含 z 的因子”的乘积。）

习题 1.75 (Gram 矩阵的计算) 设 $x_1=(1,0)^\top$，$x_2=(0,1)^\top$，$x_3=(1,1)^\top\in\mathbb{R}^2$，取核 $k(x,z)=(x^\top z)^2$。写出 Gram 矩阵 $K\in\mathbb{R}^{3\times3}$，求 $\mathrm{rank}(K)$，并验证 $\mathrm{rank}(K)$ 不大于特征映射的像空间维数。再直接验证 $c^\top Kc\ge0$ 对一切 $c\in\mathbb{R}^3$ 成立。

习题 1.76 (Gram–Schmidt 正交化) 对 $\mathbb{R}^3$ 中的向量组 $a_1=(1,1,0)^\top$、$a_2=(1,0,1)^\top$、$a_3=(0,1,1)^\top$ 施行 Gram–Schmidt 正交化（引理 1.24），求出 $\mathrm{span}\{a_1,a_2,a_3\}$ 的一组标准正交基。

习题 1.77 (二次多项式的最小二乘拟合) 给定数据点 $(0,1)$、$(1,2)$、$(2,2)$、$(3,4)$，用二次多项式模型 $y=\beta_0+\beta_1x+\beta_2x^2$ 做最小二乘拟合。写出数据矩阵 A，求出 $\hat{\beta}$，并说明此时 $A^\top A$ 是否可逆、最小二乘解是否唯一。

1.16.4 AI 应用题

习题 1.78 (特征映射的非线性性) 设特征映射 $\phi(x_1,x_2)=\big(x_1,\ x_2,\ x_1x_2\big)^\top\in\mathbb{R}^3$。

(a) 判断 ϕ 是否为线性映射，并给出证明；
(b) 对于分类器 $w^\top\phi(x)+b=0$（$w=(w_1,w_2,w_3)^\top$），写出它在原空间 $\mathbb{R}^2$ 中的决策边界方程，说明它是什么曲线。

习题 1.79 (子空间去噪) 设信号子空间 $S=\mathrm{span}\big\{\frac{1}{\sqrt{5}}(1,2)^\top\big\}\subseteq\mathbb{R}^2$，观测向量 $x=(5,0)^\top$。已知 $x=s+n$，其中真实信号 $s\in S$、噪声 $n\in S^\perp$。求 P_Sx、$\hat{s}=P_Sx$ 与 $\hat{n}=(I-P_S)x$，并验证 $\hat{s}\in S$、$\hat{n}\in S^\perp$、$\hat{s}+\hat{n}=x$。

《人工智能数学基础》 CC BY-NC-SA 4.0 禁止商业使用，著作权归全体署名作者共有

习题 1.80 (核函数的合法性判定) 判断下列函数是否为合法的核函数，即是否存在特征空间 $\mathcal{H}$ 与特征映射 ϕ 使 $k(x,z)=\langle\phi(x),\phi(z)\rangle$（式 (1.32)），并说明理由：

(a) $k(x,z)=(x^{\top}z+c)^{q}$，其中 $c\geq 0$、q 为正整数；

(b) $k(x,z)=x^{\top}z-1$，$x,z\in\mathbb{R}^{2}$；

(c) $k(x,z)=\exp\!\big(-\|x-z\|_{2}^{2}/(2\sigma^{2})\big)$，其中 $\sigma>0$（RBF 核。提示：把 $\|x-z\|_{2}^{2}$ 展开，将指数拆成“只含 x”“只含 z”“含 $\langle x,z\rangle$”三部分的乘积，再用 (a) 的结论。）

习题 1.81 (最小二乘分类器) 二分类问题中，每个样本是一个向量 $a_i\in\mathbb{R}^{d}$，带一个标签 $y_i\in\{-1,+1\}$（$i=1,\dots,N$）。线性分类器取 $\operatorname{sign}(\langle w,a_i\rangle+b)$ 的形式：$\langle w,a_i\rangle+b>0$ 判为 $+1$，否则判为 -1。一个朴素的想法是直接用最小二乘去拟合标签，即求解

$$\min_{w\in\mathbb{R}^{d},\ b\in\mathbb{R}}\ \sum_{i=1}^{N}\big(\langle w,a_i\rangle+b-y_i\big)^{2}.$$

(a) 取 $z=(w^{\top},b)^{\top}\in\mathbb{R}^{d+1}$，写出矩阵 A 与向量 y，使上式等于 $\|Az-y\|_{2}^{2}$；

(b) 写出正规方程，并在 A 满列秩时给出 z 的表达式；

(c) 另一类做法是最大间隔分类器（SVM）：它只要求 $\langle w,a_i\rangle+b$ 与 y_i 同号且绝对值不小于 1，对已经满足这一条件的样本不再施加任何惩罚。据此说明：当某个样本被正确分类且离分界线很远（即 $y_i(\langle w,a_i\rangle+b)\gg 1$）时，最小二乘仍会把它计入平方误差，从而在拟合中被“过度惩罚”。

习题 1.82 (加权最小二乘) 设权重 $w_i>0$（$i=1,\dots,N$），考虑加权最小二乘问题

$$\min_{x\in\mathbb{R}^{n}}\ \sum_{i=1}^{N}w_i\big(a_i^{\top}x-b_i\big)^{2}.$$

(a) 令 $W=\operatorname{diag}(w_1,\dots,w_N)$，把目标函数写成 $\big\|W^{1/2}(Ax-b)\big\|_{2}^{2}$ 的形式；

(b) 导出加权正规方程 $A^{\top}WA\hat{x}=A^{\top}Wb$；

(c) 说明“给某个样本很大的权重”在几何上意味着什么。

习题 1.83 (词向量的子空间结构) 在自然语言处理中，每个词被表示为一个向量（词向量），语义相关的词其向量也相关。经验上常观察到如下的类比关系：

$$\text{king}-\text{man}+\text{woman}\approx\text{queen}.$$

本题给出一个可以用本章语言逐项检验的具体版本。设四个词的词向量都在 $\mathbb{R}^{2}$ 中：

$$\text{man}=(1,0)^{\top},\quad \text{woman}=(1,1)^{\top},\quad \text{king}=(3,0)^{\top},\quad \text{queen}=(3,1)^{\top}.$$

(a) 验证 $\text{king}-\text{man}=\text{queen}-\text{woman}$；令 $M=\operatorname{span}\{(1,0)^{\top}\}$，说明这四个词向量分别落在哪两条形如 $a+M$ 的仿射子空间上，这两条子空间的关系是什么。

(b) 令 $N=\operatorname{span}\{(0,1)^{\top}\}$。验证 $\mathbb{R}^{2}=M\oplus N$（定义 1.25），并写出 queen 在该直和下的唯一分解。

(c) 用正交投影的语言解释：“去掉性别、只保留与‘人/君主’有关的信息”这件事，可以

《人工智能数学基础》 © RY-INC-SA 全体署名作者共有 禁止商业使用 · 著作权归全体署名作者所有

写成往 M 作正交投影。算出 P_M 在这四个词向量上的作用，并说明它为什么把 man 与 woman 映到同一点、把 king 与 queen 映到同一点。

本章参考文献

[1] **Carl D. Meyer. *Matrix Analysis and Applied Linear Algebra*, 2nd ed. SIAM, 2023.**

[2] **Carl D. Meyer. *Study and Solutions Guide for Matrix Analysis and Applied Linear Algebra*. SIAM, 2023.**

[3] **Stephen Boyd and Lieven Vandenberghe. *Introduction to Applied Linear Algebra: Vectors, Matrices, and Least Squares*. Cambridge University Press, 2018.**

[4] **Lloyd N. Trefethen and David Bau III. *Numerical Linear Algebra*, 25th Anniversary Edition. SIAM, 2022.**

[5] **Marc Peter Deisenroth, A. Aldo Faisal, and Cheng Soon Ong. *Mathematics for Machine Learning*. Cambridge University Press, 2020.**

[6] **Bernhard Schölkopf and Alexander J. Smola. *Learning with Kernels: Support Vector Machines, Regularization, Optimization, and Beyond*. MIT Press, 2002.**

[7] **Gilbert Strang. *Linear Algebra and Its Applications*, 4th ed. Cengage Learning, 2006.**

[8] **Sheldon Axler. *Linear Algebra Done Right*, 3rd ed. Springer, 2015.**

[9] **张贤达. 矩阵分析与应用（第 2 版）. 清华大学出版社, 2013.**

[10] **耿修瑞. 矩阵之美. 科学出版社, 2022.**

[11] **韩丛英, 李伯男. 人工智能基础数学理论和算法 · 第一篇矩阵代数（课程课件）. 中国科学院大学, 2025.**

《人工智能数学基础》 CC BY NC SA 4.0 禁止商业使用，著作权归全体署名作者共有

Chapter 2

矩阵代数——范数理论与正则化

本章作者：Yijia Liu　初审：Xinpei Zhang　二审：Yunze Wu

终审：Haoran Cao　人工智能例子审核：× × ×

本章导读

第一章建立了向量空间、线性映射和正交投影的基本结构。沿着这些结构，本章进一步讨论大小与远近：向量的误差有多大，矩阵会把扰动放大多少，两个样本在什么意义下相似？这些问题都需要先选择度量，再讨论计算与建模。

全章围绕一条主线展开：

向量范数 → 单位球与参数惩罚 → 矩阵的放大能力 → 内积与方向 → 度量学习。

其中有两条直接联系人工智能的线索：用范数惩罚参数，得到正则化；用距离比较表示，得到检索和度量学习。两者共享同一组数学工具，但回答的问题不同，分别在本章的向量范数部分和综合案例中展开。

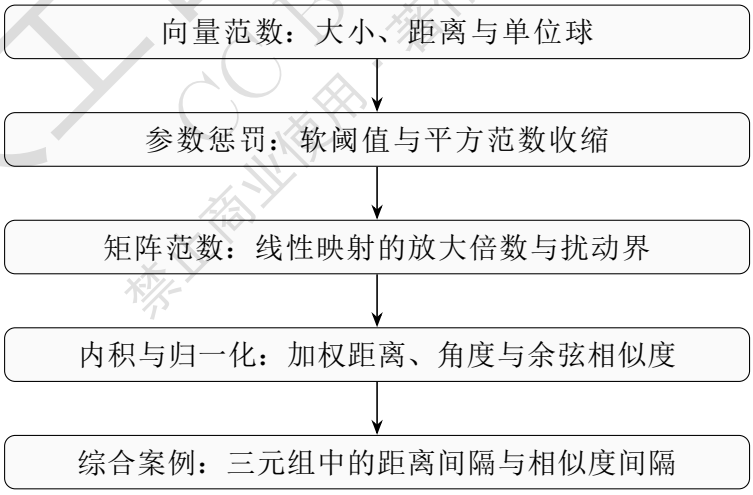


图 2.1: 本章的阅读主线。矩阵范数与内积均以向量范数为基础，综合案例使用归一化与距离比较。

《人工智能数学基础》 CC BY-NC-SA 4.0 禁止商业使用，著作权归全体署名作者共有

内容边界

本章给出基本范数不等式和案例中主要结论的证明，将部分基础验证留作习题。涉及更一般理论时，明确保留到后续章节的内容。

内容	本章处理	后续去向
谱范数的分解计算	定义、基本界及对角例子	第三章
一般正则化问题的求解	可分离二次例子	第八、九章
反向传播	给出目标，不推导网络梯度	第四章
约束与惩罚的等价条件	不作无条件等价断言	第十一章
模型完整架构	仅讨论相关数学操作	模型案例附录

阅读层次。 首次阅读重点掌握范数定义、常用计算、软阈值和归一化距离关系；最大值可达与半正定半范数的证明用于核查论证完整性；函数范数与尺度退化作为进一步理解的内容。

本章约定

(1) 数域与向量。默认在有限维实空间中讨论，向量为列向量，转置记为 $x^\top$。

(2) 范数下标。向量的 $\|x\|_p$ 与矩阵的 $\|A\|_p$ 分别表示向量范数及其诱导范数，$\|A\|_F$ 专指 **Frobenius** 范数。两类对象的维度由上下文明确给出。

(3) 数据方向。数据矩阵的行为样本、列为特征；线性预测写作 Xw，单个样本的预测写作 $w^\top x$。

(4) 正则化系数。本章二次损失使用 $1/2$ 系数，平方 ℓ_2 惩罚使用 $\lambda/2$。改变这个约定时，解公式中的系数也应相应调整。

(5) 归一化。除非另有说明，单位归一化指非零向量除以其欧氏范数；平方距离与距离分别书写，不混用二者的间隔参数。

2.1 向量范数与稀疏性

第一章讨论最小二乘时，用欧氏长度衡量残差：在所有 Aw 中，寻找离观测向量 b 最近的一个。这里的“最近”由 $\|Aw-b\|_2$ 决定。换一种长度，最近点是否会改变？要回答这个问题，先要说明向量的长度可以怎样定义。

以二维误差向量为例。设两次预测的误差分别为 $u=(3,0)^\top$ 与 $v=(2,2)^\top$。若关心误差绝对值的总和，二者分别为 3 与 4，前者较小；若关心最大的单项误差，二者分别为 3 与 2，后者较小。欧氏长度又给出 3 与 $2\sqrt{2}$。因此，“误差较小”必须连同所用的度量一起说明。

本节将这些长度统一到范数的概念下。先说明范数应满足哪些性质，再用单位球比较不同范数的几何形状，最后将范数用于参数约束，解释 ℓ_1 惩罚为何能在一个简单模型中产生零系数。以下主要在 $\mathbb{R}^d$ 中讨论，其中 $d\geq 1$。

《人工智能数学基础》 CC BY-NC-SA 4.0 禁止商业使用 · 著作权归全体署名者共有

2.1.1 范数：长度的三个基本要求

在实数轴上，$|t|$ 表示点 t 到原点的距离。在平面上，欧氏长度 $\sqrt{x_1^2+x_2^2}$ 也具有这一含义。要将“长度”推广到一般向量空间，需要提取这两个例子的共同性质：长度非负，且只有零向量的长度为零；将向量放大若干倍，其长度按标量绝对值同比例变化；沿 x 再沿 y 移动的总长度，给直接沿 $x+y$ 移动的长度提供上界。这三个要求构成范数的定义。

定义 2.1 (范数) 设 V 是实向量空间。若映射 $\|\cdot\|: V \to \mathbb{R}$ 对任意 $x, y \in V$ 与 $\alpha \in \mathbb{R}$ 满足

(1) **正定性**：$\|x\| \geq 0$，且 $\|x\| = 0$ 当且仅当 $x = 0$；
(2) **绝对齐次性**：$\|\alpha x\| = |\alpha| \, \|x\|$；
(3) **三角不等式**：$\|x + y\| \leq \|x\| + \|y\|$，

则称 $\|\cdot\|$ 为 V 上的**范数**（norm）。

例 2.2 (实数上的绝对值与两个反例) 在 $\mathbb{R}$ 上，$\|t\| = |t|$ 是范数：正定性与绝对齐次性由绝对值的性质得到，三角不等式为 $|s+t| \leq |s| + |t|$。

在 $\mathbb{R}^2$ 上，$g(x) = |x_1|$ 满足绝对齐次性和三角不等式，但 $g((0,1)^\top) = 0$，故不满足正定性。它在第二个坐标方向上无法区分不同向量。

另一个常见量为 $h(x) = x_1^2 + x_2^2$。取 $x = (1,0)^\top$，有 $h(2x) = 4$，而 $2h(x) = 2$，故它不满足绝对齐次性。平方欧氏长度可用作损失或惩罚，但不满足范数公理。

命题 2.3 (反三角不等式) *对任意范数与任意 $x, y \in V$，有*

$$\big|\|x\| - \|y\|\big| \leq \|x - y\| . \tag{2.1}$$

证明. 由定义 2.1的三角不等式，$\|x\| = \|(x-y)+y\| \leq \|x-y\| + \|y\|$，故 $\|x\| - \|y\| \leq \|x-y\|$。交换 x, y，再由绝对齐次性得到 $\|y - x\| = \|x - y\|$，即得结论。 □

注. 范数给出距离 $d(x,y) = \|x - y\|$。正定性保证不同点之间的距离为正，绝对齐次性给出距离的对称性，三角不等式给出 $d(x,z) \leq d(x,y) + d(y,z)$。因此，选择范数同时确定了向量空间中的一种距离。

2.1.2 三种常用范数与单位球

定义 2.4 (常用向量范数) 对 $x = (x_1, \ldots, x_d)^\top \in \mathbb{R}^d$，定义

$$\|x\|_1 = \sum_{i=1}^{d} |x_i| , \qquad \|x\|_2 = \left(\sum_{i=1}^{d} x_i^2 \right)^{1/2} , \qquad \|x\|_\infty = \max_{1 \leq i \leq d} |x_i| . \tag{2.2}$$

分别称为 ℓ_1 范数、ℓ_2 范数（欧氏范数）与 ℓ_∞ 范数。

命题 2.5 (三种范数的公理验证) *式 (2.2)中的三个映射均满足定义 2.1。*

证明留作习题，见习题 2.38。

定义 2.6 (闭单位球与单位球面) 给定 $\mathbb{R}^d$ 上的范数，集合 $B = \{x : \|x\| \leq 1\}$ 称为**闭单位球**

《人工智能数学基础》 CC BY NC-SA 4.0 禁止商业使用，著作权归全体署名作者共有

（closed unit ball），集合 $S = \{x : \|x\| = 1\}$ 称为**单位球面**（unit sphere）。

单位球把“某个范数不超过给定上界”转化为一个可观察的集合。例如，若要求二维参数满足 $\|w\|_1 \le 1$，就允许取菱形内部及边界上的参数；若要求 $\|w\|_\infty \le 1$，就分别限制两个分量的绝对值不超过 1。这些条件允许的向量不同，所以对应不同的参数约束。

在 $\mathbb{R}^2$ 中，三种闭单位球具有如下形状：

范数	闭单位球的条件	几何形状
ℓ_1	$\lvert x_1\rvert + \lvert x_2\rvert \le 1$	顶点为 $(\pm 1, 0), (0, \pm 1)$ 的菱形
ℓ_2	$x_1^2 + x_2^2 \le 1$	以原点为圆心、半径为 1 的圆盘
ℓ_∞	$\max(\lvert x_1\rvert, \lvert x_2\rvert) \le 1$	正方形 $[-1, 1]^2$

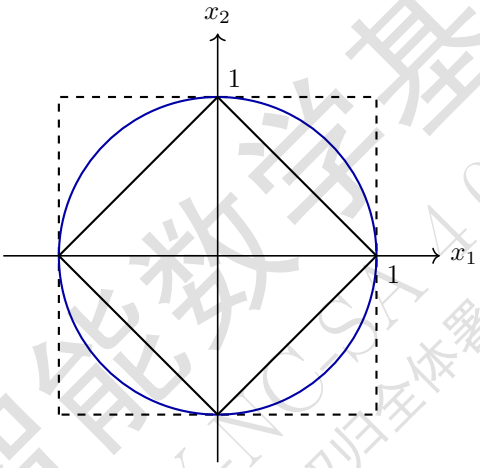


图 2.2: 同一坐标尺度下的三个闭单位球边界：内层菱形为 ℓ_1，圆为 ℓ_2，外层虚线正方形为 ℓ_∞。

例 2.7 (同一向量的三种大小) 取 $x = (3, -4)^\top$，则 $\|x\|_1 = 7$、$\|x\|_2 = 5$、$\|x\|_\infty = 4$。沿同一射线分别归一化，得到

$$\frac{x}{7} = \left(\frac{3}{7}, -\frac{4}{7}\right)^\top, \qquad \frac{x}{5} = \left(\frac{3}{5}, -\frac{4}{5}\right)^\top, \qquad \frac{x}{4} = \left(\frac{3}{4}, -1\right)^\top.$$

三个点依次位于对应的单位球面。归一化使用的范数不同，所得点的位置也不同。

注 (计算中使用的内积界). 欧氏 Cauchy–Schwarz 不等式为 $\left|x^\top y\right| \le \|x\|_2 \, \|y\|_2$。它可由平方和非负直接验证：当 $y \neq 0$ 时，将 $t = (x^\top y)/\|y\|_2^2$ 代入 $\|x - ty\|_2^2 \ge 0$ 即得；$y = 0$ 时直接成立。下面的范数比较使用这一结论。

命题 2.8 (常用范数的比较) 对任意 $x \in \mathbb{R}^d$，有

$$\|x\|_\infty \le \|x\|_2 \le \|x\|_1 \le \sqrt{d}\, \|x\|_2 \le d\, \|x\|_\infty . \tag{2.3}$$

《人工智能数学基础》 CC BY-NC-SA 4.0 禁止商业使用 · 著作权归全体署名作者共有

证明. 最大分量的平方不超过平方和，故 $\|x\|_\infty \le \|x\|_2$。由

$$\left(\sum_i |x_i|\right)^2 = \sum_i x_i^2 + 2\sum_{i<j} |x_i|\,|x_j| \ge \sum_i x_i^2$$

得到 $\|x\|_2 \le \|x\|_1$。将欧氏 Cauchy–Schwarz 不等式用于 $(|x_1|,\dots,|x_d|)^\top$ 与全 1 向量，得到 $\|x\|_1 \le \sqrt{d}\,\|x\|_2$。最后，$\sum_i x_i^2 \le d\,\|x\|_\infty^2$，故 $\|x\|_2 \le \sqrt{d}\,\|x\|_\infty$。 □

直观解释. 记三种闭单位球为 B_1, B_2, B_∞。由式 (2.3)，有 $B_1 \subseteq B_2 \subseteq B_\infty$。同一个向量的范数值越大，在该范数下满足单位上界就越困难。比较不同向量的大小次序时，则需指定所用范数。

注. 常用范数还包括 $\|x\|_p = (\sum_i |x_i|^p)^{1/p}$，其中 $1 \le p < \infty$。本节集中讨论 $p = 1, 2$ 及无穷范数。式 (2.3)中的维度因素不能省略：例如全 1 向量的三种范数分别为 $d, \sqrt{d}, 1$，它们之间的比值会随维数增长。

扩展：范数等价。 同一向量空间上的两个范数 q_1, q_2 若存在与向量无关的常数 $c, C > 0$，使 $cq_1(x) \le q_2(x) \le Cq_1(x)$ 对所有 x 成立，就称二者等价。式 **(2.3)**给出了常用范数的具体比较常数。有限维空间上的任意两个范数都等价，证明作为进阶习题；这些常数可以依赖维数，等价也不表示它们给出相同的最近邻或优化解。

函数的 $L^p(I)$ 范数将有限求和推广为积分，定义与例子见章末进阶阅读（第**60**页）。首次阅读可先继续讨论有限维参数的正则化。

2.1.3 从参数大小到正则化

先考虑线性模型 $Xw \approx y$。这里 $X \in \mathbb{R}^{N\times d}$ 的每一行是一个样本的特征，$w \in \mathbb{R}^d$ 是待求参数，$y \in \mathbb{R}^N$ 是观测值。最小二乘用 $L(w) = \frac{1}{2}\|Xw - y\|_2^2$ 评价拟合：$L(w)$ 越小，训练样本上的预测越接近观测。

训练数据可能包含噪声，能够很好拟合训练数据的参数也可能有很多组。正则化加入额外偏好，以限制模型如何使用这些自由度；它是否改善未见数据上的预测，需要通过适当的验证判断。仅给出拟合目标，还没有表达对参数本身的要求。例如，希望避免过大的系数，或者希望模型只使用一部分特征，就需要把相应要求写进数学模型。正则化（**regularization**）的一种常见形式为

$$\min_{w\in\mathbb{R}^d} \big\{L(w) + \lambda\Omega(w)\big\}, \qquad \lambda \ge 0, \tag{2.4}$$

其中 $\Omega(w)$ 是参数惩罚，λ 是非负权重。这个目标允许在拟合误差与参数大小之间作出取舍：若将 w 改为 $\widetilde{w}$ 后，拟合误差增加 $a > 0$，而参数惩罚减少 $b > 0$，则总目标的变化为 $a - \lambda b$。当 $\lambda b > a$ 时，$\widetilde{w}$ 的目标值更小，即使它对训练数据的拟合稍差。λ 的作用由此明确：它规定为了减小参数惩罚，可以接受多大的拟合代价。

常用选择为 $\Omega(w) = \|w\|_1$ 与 $\Omega(w) = \frac{1}{2}\|w\|_2^2$。前者将各系数的绝对值相加，后者将各系数的平方相加后乘以 $1/2$。对一个系数 t，线性绝对值惩罚为 $|t|$，平方惩罚为 $t^2/2$，后者随幅度按二次速度增长。两者的数值大小还取决于 $|t|$ 和权重，不能无条件比较谁更大；$1/2$ 是

系数约定，用来简化后面的公式。下文保持拟合项不变，分别求解这两种惩罚下的最优参数，以观察参数如何变化。

注意. 惩罚项的大小与特征尺度有关。例如，将某一特征扩大十倍，同时将对应系数缩小为原来的十分之一，预测值保持不变，系数受到的惩罚却会减小。因此，比较正则化效果之前，应先明确特征的尺度和预处理方式。

注 (损失的尺度). 若将求和损失改为平均损失 $\|Xw-y\|_2^2/(2N)$，要保持与求和形式相同的最优解，平均形式的惩罚系数应取原系数的 $1/N$。这是将整个目标除以正数 N 得到的结果。因此不同实现中同一个数值的 λ 未必表示同样的相对惩罚强度。

注. 约束 $\|w\| \le r$ 中的 r 指定可行区域的半径，惩罚目标中的 λ 指定惩罚权重，二者含义不同。它们之间的对应取决于损失及问题条件，不能直接令 $r=\lambda$；一般关系留待约束优化部分讨论。

定义 2.9 (稀疏向量与非零分量计数) 对 $w \in \mathbb{R}^d$，定义其**支撑集**为 $\operatorname{supp}(w) = \{i : w_i \neq 0\}$，并记 $\|w\|_0 = \#\operatorname{supp}(w)$。$\|\cdot\|_0$ 并非范数，因为它不满足绝对齐次性，见下例。给定整数 $0 \le k \le d$，若 $\|w\|_0 \le k$，则称 w 为 **k-稀疏向量**。这里 $\#$ 表示集合元素个数，$\|\cdot\|_0$ 是非零分量的计数记号。通常所说的稀疏性，是指非零分量数相对于维数较小；k-稀疏的定义给出了可检验的明确上界。

例 2.10 (非零分量计数的齐次性反例) 取 $w=(1,0)^\top$，有 $\|w\|_0 = \|2w\|_0 = 1$，而 $2\|w\|_0 = 2$，故该计数不满足绝对齐次性。对 $u=(2,0)^\top$ 与 $v=(1,1)^\top$，有 $\|u\|_1 = \|v\|_1 = 2$，但 $\|u\|_0 = 1$、$\|v\|_0 = 2$。因此，ℓ_1 惩罚的稀疏作用需要通过优化问题分析，不能单凭范数值判断。

2.1.4 手算例子：软阈值与平方范数收缩

例 2.11 (两种正则化的求解与比较) 给定 $z \in \mathbb{R}^d$ 与 $\lambda \ge 0$，分别求下列目标的最小值点：

$$F_1(w) = \tfrac{1}{2}\|w-z\|_2^2 + \lambda\|w\|_1, \quad w \in \mathbb{R}^d, \tag{2.5}$$

$$F_2(w) = \tfrac{1}{2}\|w-z\|_2^2 + \tfrac{\lambda}{2}\|w\|_2^2, \quad w \in \mathbb{R}^d. \tag{2.6}$$

再取 $z=(3,4/5,-2/5)^\top$、$\lambda=1$，核算两种解的拟合项与惩罚项，并比较非零分量数。

解：（1）ℓ_1 惩罚。由于 $F_1(w) = \sum_i[\frac{1}{2}(w_i-z_i)^2 + \lambda|w_i|]$，各坐标可独立求解。令 $f(t) = \frac{1}{2}(t-a)^2 + \lambda|t|$，在两个半轴上配方：

$$f(t) = \begin{cases} \frac{1}{2}(t-a+\lambda)^2 + \lambda a - \frac{1}{2}\lambda^2, & t \ge 0, \\ \frac{1}{2}(t-a-\lambda)^2 - \lambda a - \frac{1}{2}\lambda^2, & t \le 0. \end{cases}$$

两个半轴的唯一最小值点分别为 $\max(a-\lambda,0)$ 和 $\min(a+\lambda,0)$。若 $a>\lambda$，前者的函数值比 $f(0)$ 小 $(a-\lambda)^2/2$；若 $a<-\lambda$，对称地取后者；若 $|a| \le \lambda$，两者均为零。因此

$$w_i^{(1)} = \begin{cases} z_i - \lambda, & z_i > \lambda, \\ 0, & |z_i| \le \lambda, \\ z_i + \lambda, & z_i < -\lambda. \end{cases} \tag{2.7}$$

人工智能数学基础 CC BY-NC-SA 4.0 禁止商业使用，著作权归全体著作者共有

这称为**软阈值**。每项均在该坐标处唯一取到最小值，求和后即得 F_1 的唯一全局最小值点。

（2）平方 ℓ_2 惩罚。直接对向量配方：

$$F_2(w) = \frac{1+\lambda}{2}\left\| w - \frac{z}{1+\lambda}\right\|_2^2 + \frac{\lambda}{2(1+\lambda)}\,\|z\|_2^2 .$$

第二项与 w 无关，第一项仅在下式成立时为零，故唯一全局最小值点为

$$w^{(2)} = \frac{z}{1+\lambda}. \tag{2.8}$$

（3）数值核对。代入给定的 z 与 λ，得 $w^{(1)} = (2,0,0)^\top$、$w^{(2)} = (3/2, 2/5, -1/5)^\top$。第一种解的拟合项为 $\frac{1}{2}(1 + 16/25 + 4/25) = 9/10$；第二种解满足 $w^{(2)} - z = -z/2$，故拟合项与惩罚项均为 $49/40$。汇总如下：

惩罚	拟合项	惩罚项（含系数）	目标值	非零分量数
ℓ_1	$9/10$	2	$29/10$	1
平方 ℓ_2	$49/40$	$49/40$	$49/20$	3

两行采用不同目标函数，不能凭目标值的大小判断哪种模型更好。

软阈值把整个区间 $[-\lambda, \lambda]$ 映为零，因而可产生稀疏解；比例收缩对有限 $\lambda \geq 0$ 保留非零输入。本例第二、三个坐标落在阈值区间内，只有第一坐标被保留。若坐标代表特征系数，这意味着解仅使用第一项特征；零系数本身不能证明其他特征没有预测信息。

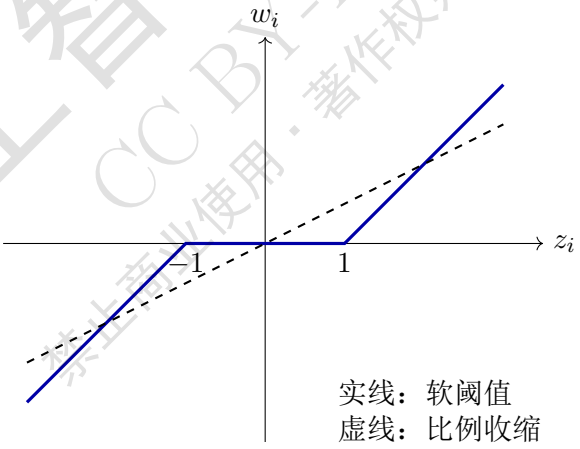


图 2.3: $\lambda = 1$ 时的标量解。软阈值将区间 $[-1, 1]$ 映到零，平方范数惩罚给出 $w_i = z_i/2$。

注意. 上述解依赖拟合项 $\frac{1}{2}\|w - z\|_2^2$。一般设计矩阵 X 下，$\frac{1}{2}\|Xw - y\|_2^2$ 的坐标耦合及曲率会改变求解，不能对未正则化解直接套用阈值 λ。即使在本例中，所有 $|z_i| > \lambda$ 时也不会产生零分量。正则化是否改善预测仍需验证。

《人工智能数学基础》 CC BY-NC-SA 4.0 禁止商业使用 · 著作权归全体署名作者共有

单位球怎样联系稀疏性？ 考虑二维约束问题

$$\min_{w} \tfrac{1}{2}\|w-z\|_2^2 \quad \text{使得} \quad \|w\|_1 \le r.$$

损失等高线是以 z 为圆心的圆；从小到大扩大半径，首次接触可行菱形的位置就是最近点。取 $z=(2,1/2)^\top$、$r=1$，接触点为 $w_*=(1,0)^\top$，第二个坐标为零。确实，对任意可行 w，$\langle z-w_*, w-w_*\rangle = w_1-1+w_2/2 \le -|w_2|+w_2/2 \le 0$，故

$$\|w-z\|_2^2 - \|w_*-z\|_2^2 = \|w-w_*\|_2^2 - 2\langle z-w_*, w-w_*\rangle \ge 0,$$

且等号仅在 $w=w_*$ 时成立。

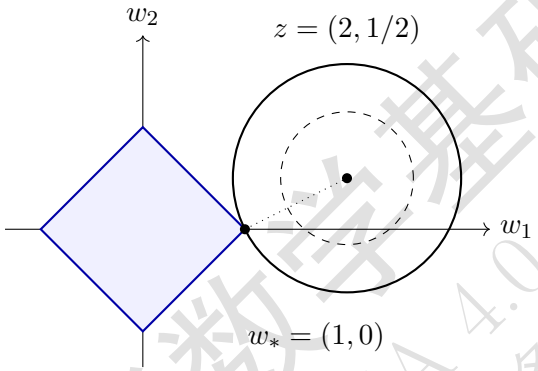


图 2.4: 损失等高线首次接触 ℓ_1 单位球的顶点，得到一个零坐标。虚线小圆尚未接触可行域。

菱形顶点落在坐标轴上，这使一部分外部点的最近点具有零坐标；也有最近点落在边内部的情形。因此该图解释一种稀疏机制，并不保证所有 ℓ_1 问题都产生零系数，也不直接给出约束半径 r 与惩罚权重 λ 的对应关系。

回到一般线性回归。设 $X\in\mathbb{R}^{N\times d}$、$y\in\mathbb{R}^N$。对平方惩罚目标

$$J(w)=\tfrac{1}{2}\|Xw-y\|_2^2+\tfrac{\lambda}{2}\|w\|_2^2, \qquad \lambda>0,$$

令 $H=X^\top X+\lambda I$。对非零 v，$v^\top Hv=\|Xv\|_2^2+\lambda\|v\|_2^2>0$，所以 H 正定且可逆。取

$$\widehat{w}=H^{-1}X^\top y,$$

展开得 $J(w)-J(\widehat{w})=\frac{1}{2}(w-\widehat{w})^\top H(w-\widehat{w})$，故 $\widehat{w}$ 是唯一最优解，即使 X 不满列秩也成立。

特别地，若 $X^\top X=I$，令 $z=X^\top y$，则

$$\tfrac{1}{2}\|Xw-y\|_2^2=\tfrac{1}{2}\|w-z\|_2^2+\tfrac{1}{2}(\|y\|_2^2-\|z\|_2^2).$$

末项与 w 无关，因此平方惩罚给出 $\widehat{w}=z/(1+\lambda)$；换成 $\lambda\|w\|_1$（$\lambda\ge0$）则对 z 逐坐标施加阈值 λ。这说明前面的手算例子也适用于列正交归一的设计矩阵；一般 X 下不能沿用这一化简。

《人工智能数学基础》 CC BY-NC-SA 4.0 禁止商业使用 著作权归全体署名作者共有

2.2 矩阵范数

向量范数回答了一个向量有多大。对矩阵，这个问题有两种自然的理解：把矩阵的所有元素合在一起衡量，或者考察它作用于向量时能把长度放大多少。前者适合描述参数矩阵的整体大小，后者直接联系线性映射的作用。先从一个例子看出区别：I_d 有 d 个非零元素，但它作用于任意向量都不改变长度。因此，按元素累计的大小可能随维数增长，按放大倍数衡量的大小则应为 1。

2.2.1 Frobenius 范数：把矩阵看成一个向量

定义 2.12 (Frobenius 范数) 对 $A=(a_{ij})\in\mathbb{R}^{m\times n}$，定义

$$\|A\|_F=\left(\sum_{i=1}^{m}\sum_{j=1}^{n}a_{ij}^2\right)^{1/2}. \tag{2.9}$$

称其为 **Frobenius 范数**。它就是将矩阵元素排成一个长向量之后的欧氏范数，因而满足范数的三个公理。

例如，$A=\left[\begin{smallmatrix}1&2\\0&-1\end{smallmatrix}\right]$ 的 **Frobenius 范数为** $\sqrt{6}$，而 $\|I_d\|_F=\sqrt{d}$。注意，矩阵元素绝对值的最大值虽然也是矩阵空间上的一种范数，却通常不满足矩阵乘法所需的次乘性：取全 1 的二阶矩阵 J，则 $J^2=2J$，元素最大值由 1 变为 2。所以，使用“矩阵范数”时需要说明具体定义和所需性质。

2.2.2 诱导范数：线性映射的最大放大倍数

固定输入空间与输出空间上的同类 p-范数，其中本节取 $p=1,2,\infty$。若希望用一个常数同时控制所有输入，就需要寻找满足 $\|Ax\|_p\le C\,\|x\|_p$ 的最小 C。

定义 2.13 (诱导矩阵范数) 对 $A\in\mathbb{R}^{m\times n}$，定义

$$\|A\|_p=\sup_{x\neq 0}\frac{\|Ax\|_p}{\|x\|_p}=\max_{\|x\|_p=1}\|Ax\|_p. \tag{2.10}$$

称其为由向量 p-范数**诱导的矩阵范数**（induced matrix norm）。$p=2$ 时也称**谱范数**（spectral norm）。

第二个表达式由绝对齐次性得到：将非零 x 除以 $\|x\|_p$，比值保持不变。最大值能够取到，是因为有限维单位球面闭且有界，而 $x\mapsto\|Ax\|_p$ 连续。这里使用了两个分析学结论：欧氏空间中的闭有界集是紧集，紧集上的连续实函数能取到最大值。对本节的三种范数，单位球面的欧氏有界性由范数比较式得到，闭性由其显式公式的连续性得到。无限维情形需要另作讨论。

《人工智能数学基础》 CC BY-NC-ND 4.0 禁止商业使用，著作权归全体贡献者共有

命题 2.14 (相容性与次乘性) 诱导矩阵范数满足范数公理，并且对维度相容的矩阵与向量有

$$\|Ax\|_p \le \|A\|_p \|x\|_p, \qquad \|AB\|_p \le \|A\|_p \|B\|_p. \tag{2.11}$$

证明. 非负性与绝对齐次性直接来自向量范数。若 $\|A\|_p = 0$，则 $Ae_j = 0$ 对每个标准基向量都成立，故 A 的每一列都为零。对任意单位向量 x，$\|(A+B)x\|_p \le \|Ax\|_p + \|Bx\|_p \le \|A\|_p + \|B\|_p$，取最大值即得三角不等式。相容性由定义得到，$x = 0$ 时也成立。连续应用两次相容性，得到 $\|ABx\|_p \le \|A\|_p \|Bx\|_p \le \|A\|_p \|B\|_p \|x\|_p$，再对单位向量取最大值。 □

定理 2.15 (列和与行和公式) 对 $A = (a_{ij}) \in \mathbb{R}^{m\times n}$，

$$\|A\|_1 = \max_j \sum_i |a_{ij}|, \qquad \|A\|_\infty = \max_i \sum_j |a_{ij}|. \tag{2.12}$$

即矩阵 1-范数为最大绝对列和，无穷范数为最大绝对行和。

证明留作习题，见习题 2.44。

例 2.16 (同一矩阵的不同大小) 取 $A = \left[\begin{smallmatrix} 1 & 2 \\ 0 & -1 \end{smallmatrix}\right]$。两列绝对值之和为 $1, 3$，两行绝对值之和为 $3, 1$，故 $\|A\|_1 = \|A\|_\infty = 3$，而 $\|A\|_F = \sqrt{6}$。取 $x = (0,1)^\top$ 可达到 1-范数的放大倍数 3；取 $x = (1,1)^\top$ 可达到无穷范数的放大倍数 3。达到最大放大倍数的输入方向会随范数改变。

2.2.3 谱范数、Frobenius 范数与扰动

谱范数沿用式 (2.10)的定义。第三章将用奇异值计算它；本章先建立不依赖矩阵分解的界。

命题 2.17 (两种矩阵范数的比较) 对 $A \in \mathbb{R}^{m\times n}$，

$$\|A\|_2 \le \|A\|_F \le \sqrt{n}\, \|A\|_2. \tag{2.13}$$

此外，$\|AB\|_F \le \|A\|_F \|B\|_F$。

证明. 记 A 的第 i 行为 $r_i^\top$。由欧氏内积的 Cauchy–Schwarz 不等式，$\|Ax\|_2^2 = \sum_i (r_i^\top x)^2 \le \sum_i \|r_i\|_2^2 \|x\|_2^2 = \|A\|_F^2 \|x\|_2^2$，故第一个不等式成立。又有 $\|A\|_F^2 = \sum_{j=1}^n \|Ae_j\|_2^2 \le n\|A\|_2^2$，得到第二个不等式。若 B 的列为 b_j，则 $\|AB\|_F^2 = \sum_j \|Ab_j\|_2^2 \le \|A\|_2^2 \sum_j \|b_j\|_2^2 \le \|A\|_F^2 \|B\|_F^2$。 □

例 2.18 (对角映射的最大放大方向) 取 $D = \mathrm{diag}(3,1)$。对单位向量 x，$\|Dx\|_2^2 = 9x_1^2 + x_2^2 \le 9$，在 $x = (1,0)^\top$ 处取等号，故 $\|D\|_2 = 3$，而 $\|D\|_F = \sqrt{10}$。前者记录最强的放大方向，后者累计两个坐标方向的平方贡献。

注. 式 (2.13)表明，固定矩阵尺寸后，谱范数与 Frobenius 范数也是等价范数。谱范数记录最强方向上的放大倍数，Frobenius 范数则是各元素平方和的平方根。

设输入由 x 变为 $x+\delta$，输出变化为 $A\delta$。由式 (2.11)，

$$\|A(x+\delta) - Ax\|_p \le \|A\|_p \|\delta\|_p. \tag{2.14}$$

《人工智能数学基础》 CC BY-NC-SA 4.0 非商业使用，著作权归作者所有，署名保留

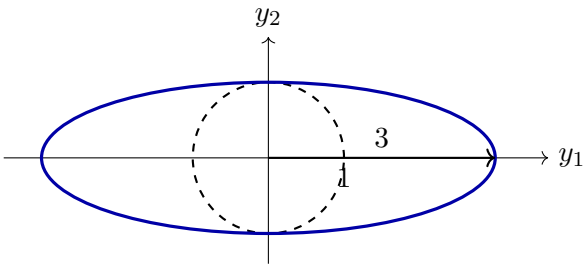


图 2.5: 单位圆（虚线）经 $D = \mathrm{diag}(3, 1)$ 映为椭圆（实线）。最大输出长度为 3，对应第一坐标方向；无需预先使用奇异值分解即可看出谱范数。

这是一条绝对误差界：已知输入扰动上界，就能给出输出变化上界。它没有自动给出输出的相对误差，尤其在 Ax 接近零时，两者需要区分。

定义 2.19 (Lipschitz 映射) 若存在 $K \geq 0$，使映射 f 对定义域内任意 x, y 都满足 $\|f(x) - f(y)\|_2 \leq K \|x - y\|_2$，则称 f 为 K-Lipschitz 映射。这个条件用一个统一常数控制任意两点的输出差异。

AI 应用

问题：神经网络的一层会把输入扰动放大多少？
数学建模：对仿射层 $f(x) = Wx + b$，有 $f(x + \delta) - f(x) = W\delta$。因此偏置抵消，欧氏扰动满足 $\|f(x + \delta) - f(x)\|_2 \leq \|W\|_2 \|\delta\|_2$。
理论联系：控制谱范数就控制了这一层的最大线性放大倍数。若后接逐坐标 **ReLU**，则由标量不等式 $|\max(s, 0) - \max(t, 0)| \leq |s - t|$，对各坐标平方求和可知 **ReLU** 的欧氏 **Lipschitz** 常数不超过 1。对顺序复合 $f_r \circ \cdots \circ f_1$，逐次应用定义可得上界 $\prod_j K_j$。若结构中还含残差相加，例如 $x + g(x)$，应先用三角不等式得到常数上界 $1 + K_g$，再分析复合。该上界可以很松；单层谱范数受控也不足以保证完整训练过程稳定。

2.3 内积空间、余弦相似度

范数给出长度，而内积同时描述长度与方向。第一章已经使用欧氏内积讨论正交和投影。节 2.1.2已在欧氏内积下用配方法证明了 **Cauchy–Schwarz** 不等式，下面将同一思路推广到任意实内积。本节把注意力放在两个问题上：哪些长度能够由内积产生，以及归一化之后的距离与夹角有什么关系。

2.3.1 从内积到范数

定义 2.20 (实内积与诱导范数) 实向量空间 V 上的**内积**是一个实值映射 $\langle \cdot, \cdot \rangle$，满足对称性 $\langle x, y \rangle = \langle y, x \rangle$、第一变量的线性 $\langle \alpha x + \beta z, y \rangle = \alpha \langle x, y \rangle + \beta \langle z, y \rangle$（任意 $x, y, z \in V$ 与 $\alpha, \beta \in \mathbb{R}$），以及正定性：$\langle x, x \rangle \geq 0$，且 $\langle x, x \rangle = 0$ 当且仅当 $x = 0$。特别地，$\langle 0, 0 \rangle = 0$。由对称性也得到第二变量的线性。记

$$\|x\| = \sqrt{\langle x, x \rangle}.$$

定理 2.21 (Cauchy–Schwarz 不等式与诱导范数) 任意实内积满足 $|\langle x,y\rangle| \le \|x\|\,\|y\|$，等号当且仅当 x,y 线性相关。定义 *2.20*定义的长度是范数。

证明. 若 $y=0$，不等式与等号条件直接成立。若 $y\neq 0$，取 $t=\langle x,y\rangle / \langle y,y\rangle$，则

$$0 \le \langle x-ty, x-ty\rangle = \|x\|^2 - \frac{\langle x,y\rangle^2}{\|y\|^2}.$$

等号恰在 $x=ty$ 时成立。诱导长度的正定性和绝对齐次性由内积公理得到，而 $\|x+y\|^2 \le \|x\|^2 + 2\|x\|\,\|y\| + \|y\|^2$ 给出三角不等式。 □

命题 2.22 (平行四边形恒等式) 内积诱导的范数满足

$$\|x+y\|^2 + \|x-y\|^2 = 2\|x\|^2 + 2\|y\|^2. \tag{2.15}$$

证明. 将左侧分别展开为内积，交叉项 $2\langle x,y\rangle$ 与 $-2\langle x,y\rangle$ 抵消，即得右侧。 □

这一恒等式提供了判别工具。例如在 $\mathbb{R}^2$ 中取 $x=e_1, y=e_2$，ℓ_1 范数下左侧为 8，右侧为 4，故该范数无法由内积诱导。无穷范数下左侧为 2，右侧为 4，也不满足。这里的反例限于维数至少为 2 的情形；一维时这三种范数都等于绝对值。

2.3.2 加权内积与距离

不同坐标可能具有不同单位或不同重要性。例如一个坐标记录长度，另一个记录温度，直接比较平方和会受到计量单位影响。先将各坐标无量纲化是一种做法，也可以明确指定一个加权内积。

定义 2.23 (加权内积) 设 $M\in\mathbb{R}^{d\times d}$ 对称正定，即 $M^\top = M$ 且 $x^\top Mx > 0$ 对所有非零 x 成立。定义

$$\langle x,y\rangle_M = x^\top My, \qquad \|x\|_M = \sqrt{x^\top Mx}, \qquad d_M(x,y) = \|x-y\|_M. \tag{2.16}$$

对称性、双线性与正定性分别由矩阵的对应性质得到，故这是内积，诱导的长度满足范数公理。如果 M 对称半正定但不正定，就需要放宽长度为零的条件。

定义 2.24 (半范数与伪距离) 若函数 $q: V\to[0,\infty)$ 满足绝对齐次性与三角不等式，则称其为**半范数**。它允许非零向量的值为零。

在集合 S 上，若 $d: S\times S\to[0,\infty)$ 满足 $d(x,x)=0$、对称性和三角不等式，则称为**伪距离**。若还满足 $d(x,y)=0\Rightarrow x=y$，则为**距离**（度量）。半范数给出的 $d(x,y)=q(x-y)$ 是伪距离；一般伪距离无需来自向量空间上的半范数。

命题 2.25 (半正定二次型产生半范数) 若 M 对称半正定，则 $q(x)=\sqrt{x^\top Mx}$ 是半范数。

证明. 非负性与绝对齐次性直接成立。令 $a=x^\top Mx$、$b=x^\top My$、$c=y^\top My$。对任意实数 t，有 $a+2bt+ct^2\ge 0$。若 $c>0$，取 $t=-b/c$ 得 $b^2\le ac$；若 $c=0$，一个对所有实数非负

《人工智能数学基础》 CC BY-NC-SA 4.0 禁止商业使用 · 著作权归作者所有 署名作者实名

的一次函数必须斜率为零，故 $b=0$，同样得到该不等式。于是

$$q(x+y)^2 = a + 2b + c \le a + 2\sqrt{ac} + c = (q(x)+q(y))^2.$$

取非负平方根即得三角不等式。若 M 不正定，按正定性定义存在非零 x 使 $x^\top M x = 0$，因此此时 q 无法区分所有非零向量。 □

例 2.26 (坐标缩放改变最近邻) 以原点为查询点，两个候选为 $u=(2,0)^\top$、$v=(0,1)^\top$。欧氏距离分别为 $2, 1$，故 v 较近。取 $M=\mathrm{diag}(1/16, 1)$，加权距离变为 $1/2, 1$，故 u 较近。该选择相当于先把第一坐标除以 4，再计算欧氏距离。改变度量会改变近邻关系，其合理性取决于坐标的实际含义。

命题 2.27 (线性变换产生的距离) 对 $L \in \mathbb{R}^{k\times d}$，令 $M = L^\top L$，则

$$(x-y)^\top M (x-y) = \|Lx - Ly\|_2^2. \tag{2.17}$$

M 总是半正定，并且当且仅当 L 满列秩时正定。

证明. 将 $M = L^\top L$ 代入即得等式。对任意 v，$v^\top M v = \|Lv\|_2^2 \ge 0$；它对非零 v 严格为正，恰好等价于 $\mathrm{Null}(L) = \{0\}$，即 L 满列秩。 □

因此，学习一个线性表示 Lx 也可以理解为学习原空间中的二次型平方距离。若 $k<d$，L 不可能满列秩，至少有一个方向会被压成零。降维表示上的欧氏距离仍然合法，但拉回原空间之后未必能区分所有样本。

2.3.3　余弦相似度与单位球上的距离

定义 2.28 (余弦相似度) 对非零向量 $x, y \in \mathbb{R}^d$，定义

$$s(x,y) = \frac{x^\top y}{\|x\|_2 \, \|y\|_2}. \tag{2.18}$$

由定理 2.21，$s(x,y) \in [-1,1]$，因此可将 $\arccos s(x,y)$ 定义为两向量的夹角。

对正数 a, b，$s(ax, by) = s(x,y)$，所以余弦相似度忽略正比例缩放。若只将一个向量乘以负数，相似度会变号。零向量没有由此公式定义的方向，不能直接代入。

命题 2.29 (归一化后的距离与余弦) 设 $x, y \in \mathbb{R}^d$ 均非零，令 $u = x/\|x\|_2$、$v = y/\|y\|_2$，则

$$\|u - v\|_2^2 = 2 - 2u^\top v = 2\big(1 - s(x,y)\big). \tag{2.19}$$

因此，对单位向量，最大化余弦相似度与最小化欧氏距离给出相同的排序。

证明. 展开 $\|u-v\|_2^2 = \|u\|_2^2 + \|v\|_2^2 - 2u^\top v$，利用两者范数均为 1 即得。右侧随相似度严格递减，而开平方保持距离的大小次序。 □

《人工智能数学基础》 CC BY-NC-SA 4.0 禁止商业使用 · 著作权归全体作者所有

注意. $1-s(x,y)$ 常被称作余弦距离，但一般不满足距离的三角不等式。在单位圆上取方向角为 $0,\pi/3,2\pi/3$ 的三个向量，首尾之间的值为 $3/2$，相邻两段的值均为 $1/2$，于是 $3/2>1/2+1/2$。使用“距离”一词时，应说明是否要求严格的度量公理。

AI 应用

问题：检索系统怎样比较两个表示向量的方向，同时消除它们长度不同的影响？
数学建模：将非零表示归一化为单位向量，再用内积评分。由式 **(2.19)**，此时按内积从大到小排序，与按欧氏距离从小到大排序一致。
理论联系：这一等价依赖候选向量均已归一化。若直接使用原始内积，较大的向量长度也会影响评分。长度是否携带置信度等有用信息，需要由具体模型和任务决定。

辨析：距离、平方距离、相似度与伪距离。 范数产生的 $\|x-y\|$ 是度量。平方欧氏距离保留非负距离的大小次序，却一般不满足三角不等式：实数 $0,1,2$ 给出 $4>1+1$。同样，$1-s(x,y)$ 一般也不满足三角不等式。差异量作为损失函数的一部分，并不必满足度量的全部公理。

表示空间中的欧氏距离是度量，但拉回原空间后是否仍能区分不同点，取决于表示是否单射。对 $\phi_L(x)=Lx/\|Lx\|_2$，在定义域 $\{x:Lx\neq 0\}$ 上有 $\phi_L(cx)=\phi_L(x)$（$c>0$）。即使 $L=I$，x 与 $2x$ 也有相同表示。因此拉回后的欧氏距离一般为伪距离；满列秩无法恢复被归一化舍弃的尺度信息。

单位归一化要求输入非零；输入接近零时，小扰动仍可能造成显著的方向变化。若输入范数均不小于 $\delta>0$，可得到常数为 $2/\delta$ 的扰动上界。反例及推导见章末进阶阅读（第60页）；加入稳定项后需重新分析相应映射。

2.3.4 从向量归一化看 LayerNorm 与 RMSNorm

对一个样本或一个 token 的特征向量 $x\in\mathbb{R}^d$，两种常见操作分别调整其中心位置与长度。令 $\mathbf{1}=(1,\dots,1)^\top$，并定义

$$\mu=\frac{1}{d}\mathbf{1}^\top x,\quad v=\frac{1}{d}\|x-\mu\mathbf{1}\|_2^2,\quad r^2=\frac{1}{d}\|x\|_2^2.$$

定义 2.30 (LayerNorm 与 RMSNorm) 本章采用如下带稳定项的形式：

$$\mathrm{LN}(x)=\gamma\odot\frac{x-\mu\mathbf{1}}{\sqrt{v+\varepsilon}}+\beta,\qquad \mathrm{RMSNorm}(x)=\gamma\odot\frac{x}{\sqrt{r^2+\varepsilon}}.$$

其中 $\gamma\in\mathbb{R}^d$ 为可学习的逐坐标增益，$\beta\in\mathbb{R}^d$ 为可学习的偏置；$\varepsilon>0$ 为预先选定的稳定常数，加在分母根号内，使分母严格为正；$\odot$ 表示对应分量相乘。RMSNorm 在此采用无偏置的形式。统计量沿当前向量的特征维计算，所有输出均为 d 维向量。

要理解二者与前文的联系，先令增益 $\gamma=\mathbf{1}$、偏置 $\beta=0$，并在分母非零的条件下令稳定常数 $\varepsilon=0$。令

$$P=I-\frac{1}{d}\mathbf{1}\mathbf{1}^\top.$$

直接计算得 $P^\top=P$、$P^2=P$、$P\mathbf{1}=0$，并且 $Px=x-\mu\mathbf{1}$。若 $\mathbf{1}^\top y=0$，则 $Py=y$。因此

P 是到零均值子空间 $\{y : \mathbf{1}^\top y = 0\}$ 的正交投影，去掉的是沿全 1 向量的均值分量。

理想核心公式为

$$\mathrm{LN}_0(x) = \sqrt{d}\,\frac{Px}{\|Px\|_2} \quad (Px \neq 0), \qquad \mathrm{RMS}_0(x) = \sqrt{d}\,\frac{x}{\|x\|_2} \quad (x \neq 0).$$

前者先投影到零均值子空间，再调整长度；后者直接调整原向量长度。两种输出的长度都为 $\sqrt{d}$。**LayerNorm** 的理想公式在所有常量向量 $x = c\mathbf{1}$ 上失去定义；**RMSNorm** 的理想公式只在零向量上失去定义。特别地，$d = 1$ 时所有输入都属于前一种退化情形。

例如 $x = (1, 3)^\top$，有 $\mu = 2, v = 1, r^2 = 5$，理想输出分别为 $(-1, 1)^\top$ 与 $(1, 3)^\top/\sqrt{5}$。两者长度均为 $\sqrt{2}$，前者均值为零，后者均值为 $2/\sqrt{5}$。

保留稳定常数 $\varepsilon > 0$，并令 $\gamma = \mathbf{1}$、$\beta = 0$ 时，输出长度分别为

$$\sqrt{\frac{dv}{v+\varepsilon}}, \qquad \sqrt{\frac{dr^2}{r^2+\varepsilon}}.$$

这说明 ε 会改变精确的长度约束。常量输入的 **LayerNorm** 核心输出变为零；加入参数后为 β。逐坐标增益与偏置还可能改变输出均值和长度，因此零均值与长度 $\sqrt{d}$ 的结论必须限定在对应的理想核心公式上。

2.4 案例：度量学习中的距离与三元组损失

2.4.1 从固定距离到学习表示

设一个检索任务希望同类样本相互接近、异类样本相互远离。原始特征的欧氏距离未必反映这种要求：与类别无关的背景变化，也可能占据很大的数值差异。度量学习希望借助带标签的样本，调整表示空间中的近邻关系。**FaceNet** 使用三元组训练学习人脸表示，是这一思路的一个实例。下面用低维教学模型讲清目标与计算。

假设 2.31 (案例的建模约定)　(1) 每个训练三元组由锚点 a、同类样本 p、异类样本 n 构成，标签已给定。

(2) 表示映射为 f_θ。计算归一化表示前，假定本例三个输出均非零，记 $u_x = f_\theta(x)/\|f_\theta(x)\|_2$。

(3) 使用平方欧氏距离比较单位表示，间隔参数 $\alpha > 0$ 预先指定。

本节的计算流程为

$$\text{固定输入和标签} \to f_\theta \to \text{归一化表示} \to \text{三元组损失} \to \text{调整共享参数}。$$

本节完成目标函数的构造与数值解释，如何利用梯度调整参数留待后续章节。训练时样本及其标签固定，可调整的是共享参数 θ。参数改变会同时改变三个表示，不能把它们作为三个独立的自由变量随意移动。希望满足的关系为

$$\|u_a - u_p\|_2^2 + \alpha \leq \|u_a - u_n\|_2^2 . \tag{2.20}$$

这比“同类距离小于异类距离”多了一个明确间隔：正样本还必须至少近 α，这里的差值按

平方距离计算。将违反约束的程度写成非负函数，得到

$$\ell(a,p,n)=\max\{0,\|u_a-u_p\|_2^2-\|u_a-u_n\|_2^2+\alpha\}. \tag{2.21}$$

当式 (2.20)成立时，损失为零；否则损失恰好等于左侧超出右侧的量。多个三元组可取平均形成训练目标。

若表示随参数连续，且当前三个表示均非零，则严格满足间隔的三元组在足够小的参数邻域内仍保持零损失，该三元组损失项不提供局部更新信号；因此三元组的选择也会影响训练。其他三元组或正则化项仍可能产生更新信号。怎样对该目标求导、选择优化器，属于后续章节的任务。

命题 2.32 (单位表示下的相似度间隔) *在假设 2.31下，*

$$\ell(a,p,n)=\max\{0,2(u_a^\top u_n-u_a^\top u_p)+\alpha\}.$$

零损失等价于 $u_a^\top u_p-u_a^\top u_n\ge\alpha/2$。

证明. 分别对两项平方距离使用式 (2.19)，常数 2 抵消。整理剩余项，即得两条结论。 □

2.4.2 完整算例：距离、间隔与损失

例 2.33 (一个三元组的逐步核算) 设归一化表示为

$$u_a=(1,0)^\top,\qquad u_p=(3/5,4/5)^\top,\qquad u_n=(0,1)^\top,\qquad \alpha=1.$$

(1) 检查假设。三个向量的平方长度依次为 $1,9/25+16/25,1$，均为 1，可以使用单位球上的距离公式。

(2) 计算正、负样本距离。

$$d_{ap}^2=(1-3/5)^2+(0-4/5)^2=4/5,\qquad d_{an}^2=(1-0)^2+(0-1)^2=2.$$

正样本较近，且平方距离之差为 $2-4/5=6/5$，超过所需间隔 1。

(3) 代入损失并独立核对。损失为 $\max(0,4/5-2+1)=0$。用内积核对，$u_a^\top u_p=3/5$、$u_a^\top u_n=0$，相似度之差 $3/5\ge1/2$，与命题 2.32一致。

(4) 换一个更接近锚点的负样本。取 $u_n'=(4/5,3/5)^\top$，仍为单位向量，但

$$d_{an'}^2=(1-4/5)^2+(3/5)^2=2/5,\qquad \ell(a,p,n')=4/5-2/5+1=7/5.$$

此时异类样本比同类样本更近，损失为正。由内积计算也得到 $2(4/5-3/5)+1=7/5$。

(5) 解释这个计算的作用。前四步比较了给定表示下的损失，说明目标偏好怎样的近邻关系。要展示参数改变的效果，还需要指定同一个映射，并将所有样本重新代入。下面给出这样的例子。

《人工智能数学基础》 CC BY-NC-SA 4.0 禁止商业使用 · 著作权归全体署名作者共有

例 2.34 (同一个线性映射的参数变化) 固定输入 $a=(1,0)^\top$、$p=(1,1)^\top$、$n=(-1,1)^\top$，取共享映射 $L_t=\mathrm{diag}(1,t)$，其中 $t>0$，并将输出归一化。三个表示为

$$u_a=(1,0)^\top,\quad u_p=\frac{(1,t)^\top}{\sqrt{1+t^2}},\quad u_n=\frac{(-1,t)^\top}{\sqrt{1+t^2}}.$$

由式 (2.19)，正、负平方距离分别为 $2-2/\sqrt{1+t^2}$ 与 $2+2/\sqrt{1+t^2}$。取 $\alpha=3$，得到

$$\ell_t=\max\left\{0,3-\frac{4}{\sqrt{1+t^2}}\right\}.$$

当 $t=1$ 时，$\ell_1=3-2\sqrt{2}>0$；当 $t=1/2$ 时，$\ell_{1/2}=\max\{0,3-8/\sqrt{5}\}=0$。这里改变的是同一个矩阵的第二个对角元，正、负样本的表示同时变化，锚点因第二坐标为零而保持不动。降低第二坐标的权重后，两个候选分别更靠近正、负第一坐标轴。本例比较了两个参数设置，尚未指定寻找这些参数的优化算法。

2.4.3 条件、退化情形与正则化

单位向量间的平方距离落在 $[0,4]$，所以单个三元组若要实现零损失，必须有 $\alpha\le 4$。这只是必要条件：共享表示和多个三元组可能提出互相制约的要求，选取 $\alpha\le 4$ 并不保证全部约束可行。

若所有样本都映到同一个单位向量，两种距离均为零，损失为 α。因此这种完全重合的表示无法达到零损失。该事实本身不构成训练收敛的保证；采样方式、标签错误、初始化和优化过程仍会影响结果。

未归一化的线性表示。若直接使用 Lx，则命题 **2.27**给出平方距离 $(x-y)^\top L^\top L(x-y)$。对一个已经满足正样本较近的三元组，整体替换 $L\mapsto cL$ 会把正、负平方距离之差乘以 c^2，因而可能仅靠放大尺度满足固定间隔。可考虑明确的目标

$$J(L)=\frac{1}{T}\sum_{j=1}^{T}\max\{0,\|L(a_j-p_j)\|_2^2-\|L(a_j-n_j)\|_2^2+\alpha\}+\lambda\|L\|_F^2,\qquad \lambda>0.$$

其中 T 是三元组数。惩罚项使放大参数产生代价，但其预测效果仍取决于数据与权重选择。

归一化的线性表示。本案例采用 $u_x=Lx/\|Lx\|_2$，每个分母依赖具体样本。因此归一化后的平方距离通常无法写成关于 $x-y$ 的固定二次型。前面的 $M=L^\top L$ 等式直接适用于未归一化输出，不能原样用于这里。

精确单位归一化具有正比例尺度不变性。若可行域只要求训练样本的表示非零，直接叠加正权重的平方参数惩罚，可能导致目标没有可行最小值点。具体条件及完整论证见章末进阶阅读（第60页）；设置额外尺度约束或改变归一化公式后，应重新分析。

核心思想

本案例将三种数学对象接在一起：范数给出距离，单位归一化把距离比较转化为角度比较，三元组损失将“同类更近”写成带间隔的不等式。每一步都依赖明确条件：非零表示

才能归一化，单位向量才满足式 (2.19)，零训练损失也只说明所检查的三元组满足约束。

2.5 本章小结

本章从向量的长度出发，将大小的度量推广到矩阵的放大能力，再由内积引出角度与加权距离。这些对象进入模型之后，分别成为参数惩罚、扰动上界和样本相似性的数学表达。

(1) 范数与单位球。范数的正定性、绝对齐次性和三角不等式见定义 2.1；常用范数的比较及其维度因素见式 (2.3)。单位球的形状显示不同度量对方向的不同处理。

(2) 正则化与稀疏性。在可分离二次拟合模型中，ℓ_1 惩罚给出软阈值，平方 ℓ_2 惩罚给出比例收缩，见例 2.11。一般设计矩阵需要重新求解。

(3) 矩阵范数。 Frobenius 范数是元素平方和的平方根，诱导范数衡量最大放大倍数。列和、行和公式见定理 2.15，相容性与次乘性见命题 2.14。

(4) 内积与距离。内积诱导范数并满足平行四边形恒等式。加权内积要求权矩阵正定；当 L 不满列秩时，$\|L(x-y)\|_2$ 在原空间给出无法区分某些不同点的伪距离，见命题 2.27。

(5) 归一化与度量学习。单位向量 u, v 的平方距离为 $2-2u^\top v$，见式 (2.19)。三元组损失以此把距离间隔转为相似度间隔，见命题 2.32。

2.6 习题

以下习题分为基础题、证明题、计算题与 AI 应用题。标 ★ 者附一句提示，章末提供部分计算题的简答。

2.6.1 基础题

习题 2.35 (范数与半范数) 在 $\mathbb{R}^2$ 上判断 $g_1(x)=|x_1|+2\,|x_2|$、$g_2(x)=|x_1+x_2|$、$g_3(x)=\max(2\,|x_1|\,,|x_2|)$ 是否为范数。成立者验证公理，不成立者指出失败的公理并给出反例。

习题 2.36 (单位球) 画出 $|x_1|+2|x_2|\le 1$ 和 $\max(2\,|x_1|\,,|x_2|)\le 1$ 的区域，标出顶点及两坐标轴上的截距。

习题 2.37 (方向与尺度) 计算 $x=(1,2)^\top$ 与 $y=(2,4)^\top$ 的余弦相似度及欧氏距离，再将 y 替换为 $-y$。说明两种指标分别保留了什么信息。

习题 2.38 (范数公理验证) 验证 $\ell_1,\ell_2,\ell_\infty$ 满足范数公理；欧氏情形可使用 Cauchy–Schwarz 不等式。

2.6.2 证明题

习题 2.39 (比较常数与取等条件) 证明 $\|x\|_1\le\sqrt{d}\,\|x\|_2$ 中常数 $\sqrt{d}$ 不能对所有 x 同时减小，并刻画等号条件。

AI 智能数学基础 CC BY-NC-SA 4.0 禁止商业使用；著作权归全体署名作者共有

习题 2.40 (加权范数) 设 $c_i > 0$，证明 $\sqrt{\sum_i c_i x_i^2}$ 是范数。若允许某个 $c_i = 0$，说明哪条公理可能失效。

习题 2.41 (转置与行列和) 证明 $\left\|A^\top\right\|_1 = \|A\|_\infty$，并给出 $\|A\|_1 \neq \|A\|_\infty$ 的二阶矩阵。

习题 2.42 (核方向与伪距离) 设 $L \in \mathbb{R}^{k\times d}$。证明 $d_L(x,y) = \|L(x-y)\|_2$ 非负、对称且满足三角不等式，并证明它是原空间上的距离当且仅当 L 满列秩。

习题 2.43 (★ 单位球与凸性) 证明任意范数的闭单位球是凸集，即球内任意 x, y 与 $0 \le t \le 1$ 都满足 $tx + (1-t)y$ 仍在球内。提示：对 $tx + (1-t)y$ 使用三角不等式与绝对齐次性，其中 $0 \le t \le 1$。

习题 2.44 (行列和公式) 证明式 (2.12)。先给出上界，再构造达到上界的单位向量。

习题 2.45 (★ 有限维范数等价) 证明有限维空间上任意两个范数等价。提示：先用一组基与三角不等式证明任意范数关于欧氏范数的上界及连续性，再在欧氏单位球面取正的最小值。

习题 2.46 (性质的适用边界) 分别构造反例说明平方欧氏距离不满足三角不等式、单位归一化可能使不同点重合、输入差异趋零不保证归一化差异趋零。

2.6.3 计算题

习题 2.47 (软阈值的适用范围) 取一维设计矩阵 $X = [2]$、观测 $y = 2$、$\lambda = 1$。求 $\frac{1}{2}(2w-2)^2 + |w|$ 的最优解，并与对未正则化解直接使用阈值 1 的结果比较。

习题 2.48 (矩阵范数) 对 $A = \left[\begin{smallmatrix} 1 & -2 & 0 \\ 3 & 0 & 1 \end{smallmatrix}\right]$，计算 $\|A\|_1, \|A\|_\infty, \|A\|_F$，并分别给出达到前两个诱导范数的输入向量。

习题 2.49 (两种收缩) 取 $z = (2, -1/2, 0)^\top$、$\lambda = 1/2$，求式 (2.5) and (2.6)的解，分别计算拟合项与惩罚项，并检查阈值边界处的坐标。

习题 2.50 (加权距离) 取 $M = \mathrm{diag}(4,1)$、$x = (1,1)^\top$、$y = (-1,2)^\top$，计算 $\langle x, y\rangle_M, \|x\|_M, d_M(x,y)$，并找出一个对角矩阵 L 使 $M = L^\top L$。

2.6.4 AI 应用题

习题 2.51 (三元组损失) 取 $u_a = (1,0)^\top$、$u_p = (4/5, 3/5)^\top$、$u_n = (3/5, 4/5)^\top$、$\alpha = 1/2$，分别通过平方距离和内积计算损失。求使该三元组损失为零的正间隔参数范围。

习题 2.52 (线性层的扰动) 取 $W = \mathrm{diag}(2, 1/2)$。若输入满足 $\|\delta\|_2 \le 1/10$，给出仿射层 $Wx + b$ 的输出扰动上界，并构造达到上界的扰动。说明偏置是否影响答案。

习题 2.53 (归一化的条件) 对 $x = (2,2)^\top$，分别计算保留 $\varepsilon > 0$ 的 LayerNorm 和 RMSNorm 核心输出，不加入可学习参数。分析令 $\varepsilon = 0$ 后两种表达式是否有定义，并解释原因。

习题 2.54 (★ 方盒中的最坏线性扰动) 设 $w \in \mathbb{R}^d$、$\varepsilon > 0$，求 $\max_{\|\delta\|_\infty \le \varepsilon} w^\top \delta$，给出达到最大值的扰动。提示：分别选择各坐标的符号，并用绝对值和给出上界。

《人工智能数学基础》 CC BY-NC-SA 4.0 禁止商业使用 · 著作权归全体著作者共有

部分计算题简答

习题 2.48： $\|A\|_1 = 4$，$\|A\|_\infty = 4$，$\|A\|_F = \sqrt{15}$。达到上界的输入可分别取 $(1,0,0)^\top$ 与 $(1,0,1)^\top$。

习题 2.51： 正、负平方距离分别为 $2/5, 4/5$，损失为 $1/10$，零损失的正间隔范围为 $0 < \alpha \le 2/5$。

习题 2.47： 最优解为 $w = 3/4$。将拟合项写成 $2(w-1)^2$，再将整个目标除以 4，得到 $\frac{1}{2}(w-1)^2 + \frac{1}{4}|w|$，故应使用阈值 $1/4$。对未正则化解 1 直接使用阈值 1 会错误地得到零。

《人工智能数学基础》
CC BY-NC-SA 4.0
禁止商业使用 · 著作权归全体署名作者共有

进阶阅读

本部分集中给出函数空间定义、归一化扰动界及尺度退化反例，供完成正文后进一步阅读。

一、从有限向量到函数的 L^p 范数

设 $I \subseteq \mathbb{R}$ 为区间，$1 \le p < \infty$。若实函数 f 在 I 上 **Lebesgue** 可测，且 $\int_I |f(t)|^p \, \mathrm{d}t < \infty$，则称 f 为 p 次可积函数。将几乎处处相等（仅在零测集上可能不同）的函数视为同一元素，所得等价类组成空间 $L^p(I)$，其范数为

$$\|f\|_{L^p(I)} = \left(\int_I |f(t)|^p \, \mathrm{d}t \right)^{1/p}.$$

$L^\infty(I)$ 由本质有界的可测函数按同样方式取等价类构成，范数为

$$\|f\|_{L^\infty(I)} = \operatorname*{ess\,sup}_{t \in I} |f(t)| = \inf\{M \ge 0 : |f(t)| \le M \text{ 对几乎处处的} t \in I \text{ 成立}\}.$$

按几乎处处相等取等价类，保证范数为零的元素恰为零元素。对 $I = [0,1]$ 上的连续函数，L^∞ 范数等于绝对值的最大值。有限向量的 ℓ_p 使用求和，函数的 L^p（$p < \infty$）使用积分。例如，在 $[0,1]$ 上，$f(t) = t$ 的 L^1, L^2, L^∞ 范数分别为 $1/2, 1/\sqrt{3}, 1$。有限维范数等价不能直接推广到函数空间：连续函数 $f_n(t) = \max(1 - nt, 0)$（$n \ge 1$）满足 $\|f_n\|_{L^\infty} = 1$、$\|f_n\|_{L^1} = 1/(2n)$。

二、归一化在接近零时的稳定性

取 $x_t = (t, 0)^\top, y_t = (0, t)^\top$，其中 $t > 0$。输入差异为 $\sqrt{2}t \to 0$，归一化后的差异却恒为 $\sqrt{2}$。因此有定义不等于具有统一的扰动控制。若 $\|x\|_2, \|y\|_2 \ge \delta > 0$，则由加减 $y/\|x\|_2$ 及反三角不等式得到

$$\left\| \frac{x}{\|x\|_2} - \frac{y}{\|y\|_2} \right\|_2 \le \frac{\|x - y\|_2 + |\|y\|_2 - \|x\|_2|}{\|x\|_2} \le \frac{2}{\delta} \|x - y\|_2 .$$

分母远离零时才有这里的统一上界；加入稳定项后，应对修改后的映射重新分析。

三、归一化与正则化组合时的反例

本段说明为什么把两个各自合理的操作组合起来仍需检查目标函数。初读时可先掌握归一化的尺度不变性。对精确单位归一化和任意 $c > 0$，有 $cLx/\|cLx\|_2 = Lx/\|Lx\|_2$。假定训练集非空，且可行域由所有使训练样本满足 $Lx \ne 0$ 的矩阵组成，没有额外尺度约束。如果在归一化三元组损失上直接加入 $\lambda \|L\|_F^2$，其中 $\lambda > 0$，取 $c \to 0^+$ 不改变三元组损失，却使惩罚趋于零；而 $L = 0$ 处归一化没有定义。对任意可行的非零 L，缩小它都能严格降低该惩罚，因而这种未经额外约束的目标没有可行的最小值点。若要结合二者，需要明确处理尺度，例如固定 $\|L\|_F$ 为一个正数，同时保留各样本 $Lx \ne 0$ 的条件；这只消除了整体缩放自由度，

《人工智能数学基础》 CC BY-NC-SA 4.0 禁止商业使用 · 著作权归全体署名作者共有

并不单独保证最优解存在。也可重新分析带稳定项的归一化。后者会改变精确的尺度不变性，不能继续照用上述等式。

《人工智能数学基础》
CC BY-NC-SA 4.0
禁止商业使用，著作权归全体署名作者共有

Chapter 3

矩阵代数——矩阵分解

本章作者：Yinghan Liu　初审：Wenchenjun Cao　二审：Zhuodong Liao

终审：Haihui Li　人工智能例子审核：× × ×

本章导读

第 1 章回答了“如何用矩阵表示线性变换”；本章处理这一问题的自然延续：给定一个矩阵，能否把它拆成结构更简单的因子的乘积？拆开之后，矩阵的秩、谱、条件数这些整体性质，以及最小二乘、降维、微调这些操作，都有了可以逐项处理的形式。本章的主线是：

线性变换的不变方向 $\to$ 特征值与特征向量 $\to$ 可对角化 $\to$ 谱定理 $\to$ 特征值分解 $\to$ ***Cholesky*** 与 ***QR*** $\to$ 奇异值分解 $\to$ 低秩逼近 $\to$ 大模型低秩微调。

这条主线有一个刻意的次序：先方阵、后任意矩阵，先特征分解、后奇异值分解。特征值分解要求矩阵是方阵且可对角化，这两条限制都很强；奇异值分解取消了这两条限制，代价是把“一个空间”换成“输入与输出两个空间”。主线末端的 **LoRA** 案例是这两条主线的汇合点：低秩约束施于权重更新矩阵，而秩与最优逼近的全部结论都来自奇异值分解。图 **3.1** 给出本章的数学依赖关系；虚线右侧是本章的工具性分解（**Cholesky** 与 **QR**），它们不依赖特征值理论，却依赖第 **1** 章的正交化与最小二乘，在后续章节与数值计算中反复出现。

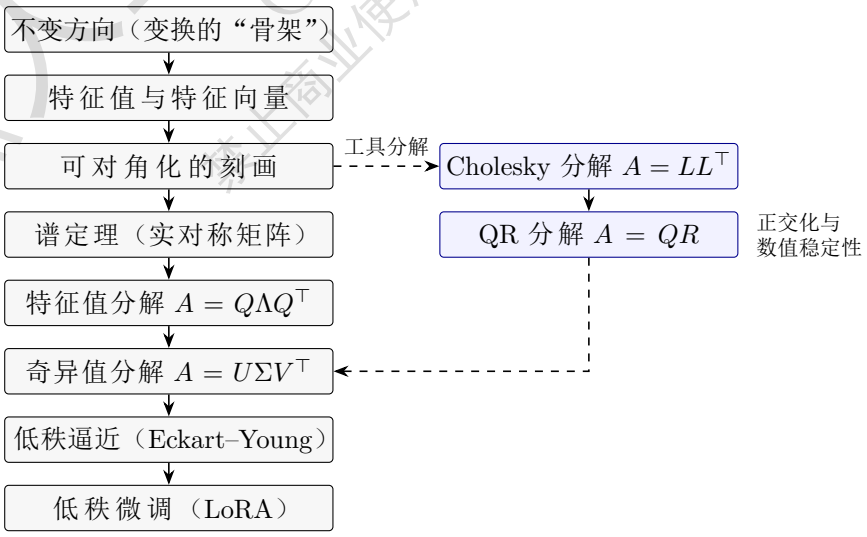


图 3.1: 本章的数学依赖关系：左侧为主线，右侧为工具性分解

内容边界

本章只保留“把一个矩阵拆开”所必需的结构性结果：特征值与特征向量的定义、可对角化的刻画、谱定理、Cholesky 与 QR 两个工具分解；奇异值分解与低秩逼近的完整展开见 节 3.2 与 节 3.3。与本章主线（分解的构造、性质与最优性）无直接关系的内容，一律推迟到相应章节或指出参考书，见表 3.1。

表 3.1: 本章内容边界与后续章节的分工

内容	本章处理方式	去向
行列式的系统理论	只使用基本计算（特征多项式、三角行列式）	附录 / 第 4 章；各类不等式不涉及
特征值的数值算法（QR 迭代、幂法收敛分析）	只作一句说明	数值线性代数方向专著，见 [1]
Jordan 标准形与不可对角化矩阵的分类	只给一个反例	[5]
广义特征值问题	只给定义与一句	线性判别分析归第 8 章；谱聚类只作一句
Moore–Penrose 伪逆的系统理论	只用结论	第 5 章（特殊运算与张量基础）
矩阵函数（A^k 的显式、e^A）	A^k 只作动机	微分方程方向教材
主成分分析的统计视角	只写线性代数结论	节 3.2 的 AI 应用框
Kronecker 积与 Hadamard 积	不展开	第 5 章

《人工智能数学基础》
CC BY-NC-SA 4.0
禁止商业使用 · 著作权归全体署名作者所有

本章约定

本章通用的约定一次列出如下；后续各章除非另行声明，也沿用这些约定。

(1) 数域。默认在实数域 $\mathbb{F}=\mathbb{R}$ 上讨论。特征值理论的第一次例外出现在本章：实矩阵的特征值可以是复数，届时会明确声明进入 $\mathbb{F}=\mathbb{C}$。复空间中的内积取埃尔米特内积 $\langle u,v\rangle=\overline{u}^{\top}v$（实空间退化为 $\langle u,v\rangle=u^{\top}v$）。

(2) 特征对与特征子空间。称 (λ,v) 为一个特征对（**eigenpair**），其中 $\lambda\in\mathbb{F}$ 为特征值、$v\neq 0$ 为对应特征向量。对应特征值 λ 的全部特征向量连同零向量组成特征子空间（**eigenspace**）

$$E_A(\lambda)\coloneqq\{\,v\in\mathbb{F}^n\mid Av=\lambda v\,\};$$

零向量本身不是特征向量，包含它是为了使 $E_A(\lambda)$ 成为一个向量空间。

(3) 谱与奇异值的记号分工。方阵 A 的全体特征值（含重数）记作 $\lambda(A)$，称为 A 的谱（**spectrum**）。字母 σ 本章不用于特征值：σ_i 一律留给 节 **3.2** 的奇异值。特征值与奇异值是两类不同的量——奇异值是 $A^{\top}A$ 特征值的平方根，只有对称半正定矩阵的奇异值才恰好等于其特征值——混用是本章最需防范的记号错误。

(4) 分解记号。一般方阵的可对角化分解写作 $A=P\Lambda P^{-1}$，其中 P 为可逆矩阵（由特征向量组成，不必正交）；实对称矩阵的正交对角化写作 $A=Q\Lambda Q^{\top}$，其中 Q 为正交矩阵（$Q^{\top}Q=I$）。本书中 P 专指“可逆的特征向量矩阵”、Q 专指“正交矩阵”，两者角色固定、不再混用。奇异值分解写作 $A=U\Sigma V^{\top}$（U,V 正交，Σ 为矩形对角矩阵），其中 Σ 一律用大写 **sigma**，不再另作他用；此外，薄 **QR** 分解中的 Q 是“列标准正交的长方形矩阵”（$Q^{\top}Q=I$ 但 Q 未必为方阵），应与方阵正交矩阵区分。

(5) 正定与半正定。沿用第 **1** 章口径：$A=A^{\top}$ 且 $x^{\top}Ax>0$ 对一切 $x\neq 0$ 成立时称 A 对称正定（**symmetric positive definite，SPD**）；把 $>$ 换成 $\geqslant$ 得到半正定。本章反复使用“对称正定”这一条件：由谱定理（定理 **3.13**）实对称矩阵可正交对角化，在此范围内它等价于全部特征值为正（推论 **3.15**）。

(6) 范数与内积。如无声明，向量范数为欧氏 2-范数 $\|x\|_2=\sqrt{\langle x,x\rangle}$；矩阵范数在 节 **3.2** 遇到谱范数与 **Frobenius** 范数时逐一给出。

《人工智能数学基础》 © 2026 人工智能学会 保留所有 禁止商业使用 未经授权不得转载

3.1 特征值分解

3.1.1 动机：寻找变换的不变方向

第 1 章把矩阵理解为线性变换的表示：给定 $A \in \mathbb{R}^{n\times n}$ 与 $x \in \mathbb{R}^n$，乘积 Ax 表示 x 经过该变换后的像。一般地，变换会同时改变向量的长度与方向。一个自然的问题是：是否存在一些方向，变换对它们只做缩放、不产生转动？

先看一个二维例子。取

$$A = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}, \qquad v_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \qquad v_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix}, \tag{3.1}$$

直接计算得

$$Av_1 = \begin{bmatrix} 4 \\ 4 \end{bmatrix} = 4v_1, \qquad Av_2 = \begin{bmatrix} 2 \\ -2 \end{bmatrix} = 2v_2. \tag{3.2}$$

向量 v_1 经过变换后方向不变、长度变为原来的 4 倍；v_2 同理，长度变为 2 倍。这两个方向就是变换 A 的“骨架”：一旦知道 A 在这两个方向上的作用，A 在整个平面上的作用也就确定了——任意 $x = c_1v_1 + c_2v_2$ 都满足

$$Ax = c_1Av_1 + c_2Av_2 = 4c_1v_1 + 2c_2v_2. \tag{3.3}$$

原坐标系下“先混合再缩放”的矩阵乘法，在 $\{v_1, v_2\}$ 这组基下变成了两个方向上互不相干的独立缩放。把这种思想推到 n 维、推到一般矩阵，就是本节的线索。

另一个同样重要的动机来自矩阵幂。许多迭代过程（第 8 章及以后的优化算法会反复遇到）的形式为 $x_{k+1} = Ax_k$，即 $x_k = A^kx_0$。若 A 能沿若干方向拆成独立缩放，A^k 的行为就能逐项读出，迭代是否收敛由这些缩放因子的绝对值决定。定理 3.9 之后给出的特征值分解就是实现这一目标的工具。

3.1.2 特征值与特征向量

定义 3.1 (特征值与特征向量) 设 $A \in \mathbb{R}^{n\times n}$。若存在标量 λ 与非零向量 $v \neq 0$ 使得

$$Av = \lambda v, \tag{3.4}$$

则称 λ 为 A 的一个**特征值**（eigenvalue），v 为对应于 λ 的一个**特征向量**（eigenvector），并称 (λ, v) 为一个特征对。

定义中的 $v \neq 0$ 不可省略：零向量对任意 λ 都满足 $A0 = \lambda 0$，不提供任何区分作用。按本章约定第 2 条，对应 λ 的全部特征向量连同零向量构成特征子空间 $E_A(\lambda)$。

例 3.2 在式 (3.2) 中，$(\lambda_1, v_1) = \left(4, (1,1)^\top\right)$ 与 $(\lambda_2, v_2) = \left(2, (1,-1)^\top\right)$ 都是 A 的特征对。对应地，$E_A(4) = \operatorname{span}(1,1)^\top$，$E_A(2) = \operatorname{span}(1,-1)^\top$。

《人工智能数学基础》 CC BY-NC-SA 4.0 禁止商业使用·衍生须署名作者共享

例 3.3 取 $A=\begin{bmatrix}0 & -1\\ 1 & 0\end{bmatrix}$，即把每个向量逆时针旋转 90°。对任意 $v\neq 0$，Av 与 v 垂直，故 Av 不可能落在 v 的张成空间内。于是 A **没有实的特征向量**。

例 3.3 的矩阵在复数域内却有两个特征值 $\pm\mathrm{i}$（$\mathrm{i}^2=-1$）。**把数域从** $\mathbb{R}$ **扩到** $\mathbb{C}$ **后，每个** n **阶方阵都有** n **个复特征值（计重数）——式 (3.6) 的特征多项式在其中恰好有** n **个根。**

为把特征值的计算落到方程上，把 式 (3.4) 改写为 $(A-\lambda I)v=0$。**该齐次方程有非零解，当且仅当系数矩阵奇异：**

$$\det(A-\lambda I)=0. \tag{3.5}$$

式 (3.5) 称为 A **的特征方程；由它导出的首一多项式**

$$p_A(\lambda)\coloneqq\det(\lambda I-A) \tag{3.6}$$

称为 A **的特征多项式（characteristic polynomial）。注意** $p_A(\lambda)=(-1)^n\det(A-\lambda I)$，**故两者有相同的根。**

例 3.4 取

$$A=\begin{bmatrix}3 & 1 & 0\\ 1 & 3 & 0\\ 0 & 0 & 1\end{bmatrix}. \tag{3.7}$$

由 式 (3.6)，

$$p_A(\lambda)=\det\begin{bmatrix}\lambda-3 & -1 & 0\\ -1 & \lambda-3 & 0\\ 0 & 0 & \lambda-1\end{bmatrix}=(\lambda-1)\big((\lambda-3)^2-1\big)=(\lambda-1)(\lambda-2)(\lambda-4). \tag{3.8}$$

故 A 的三个特征值为 $\lambda_1=4$、$\lambda_2=2$、$\lambda_3=1$。逐个求解 $(A-\lambda I)v=0$ 得（未归一化）：

$$v_1=\begin{bmatrix}1\\1\\0\end{bmatrix},\qquad v_2=\begin{bmatrix}1\\-1\\0\end{bmatrix},\qquad v_3=\begin{bmatrix}0\\0\\1\end{bmatrix}. \tag{3.9}$$

三个向量两两正交、线性无关。

例 3.4 的矩阵还展示了一个值得记住的核算关系：$\operatorname{tr}(A)=3+3+1=7=\lambda_1+\lambda_2+\lambda_3$，**且** $\det(A)=8=\lambda_1\lambda_2\lambda_3$。

命题 3.5 (特征值的两个恒等式) *设* $A\in\mathbb{R}^{n\times n}$ *的特征值为* $\lambda_1,\dots,\lambda_n$（*在* $\mathbb{C}$ *上计重数*）。则

$$\operatorname{tr}(A)=\sum_{i=1}^{n}\lambda_i,\qquad \det(A)=\prod_{i=1}^{n}\lambda_i. \tag{3.10}$$

证明. 对特征多项式 式 (3.6) 比较两端 λ^{n-1} 项与常数项系数即可。$\det(\lambda I-A)$ 展开后 λ^{n-1} 的系数为 $-\operatorname{tr}(A)$，而 $(\lambda-\lambda_1)\cdots(\lambda-\lambda_n)$ 中对应系数为 $-\sum_i\lambda_i$；常数项分别为 $\det(-A)=$

《人工智能数学基础》 CC BY-NC-SA 4.0 禁止商业使用 · 著作权归全体署名作者共有

$(-1)^n \det(A)$ 与 $(-1)^n \prod_i \lambda_i$。 □

命题 3.6 (三角矩阵的特征值) 设 $A \in \mathbb{R}^{n\times n}$ 为（上或下）三角矩阵。则 A 的特征值恰为其对角线元素。

证明. 上三角矩阵的 $\det(A-\lambda I)$ 是三角行列式，等于 $\prod_i (a_{ii}-\lambda)$，其根恰为全部对角元；下三角情形相同。 □

特征值分解的第一个结构性结论，是不同特征值对应的特征向量必然线性无关。它是 定理 3.9 的基石。

定理 3.7 (不同特征值的特征向量线性无关) 设 $\lambda_1, \dots, \lambda_k$ 是 $A \in \mathbb{R}^{n\times n}$ 的两两不同的特征值，v_i 是对应 λ_i 的特征向量。则 $v_1, \dots, v_k$ 线性无关。

证明. 设 $c_1 v_1 + \cdots + c_k v_k = 0$。两边左乘 A 并利用 $Av_i = \lambda_i v_i$，得

$$c_1 \lambda_1 v_1 + \cdots + c_k \lambda_k v_k = 0.$$

对原组合式乘以 λ_k 后与上式相减，消去第 k 项：

$$c_1(\lambda_1 - \lambda_k)v_1 + \cdots + c_{k-1}(\lambda_{k-1} - \lambda_k)v_{k-1} = 0.$$

对 $k-1, k-2, \dots$ 重复相减，最终得 $c_1 \prod_{j\neq 1}(\lambda_1 - \lambda_j) v_1 = 0$。特征向量非零且各 λ_i 两两不同，故 $c_1 = 0$；对称地可得全部 $c_i = 0$。 □

注. 当特征多项式有重根时，同一个 λ 可以对应多个线性无关的特征向量。把 p_A 中根 λ 的重数称为其**代数重数**，把 $\dim E_A(\lambda)$ 称为其**几何重数**。两者可以不相等（见 例 3.12），本章只在判断可对角化时用到这一区分，不展开约当标准形。

注. $\lambda = 0$ 是 A 的特征值，当且仅当 $\det A = 0$，即 A 奇异。这条等价关系把“可逆性”翻译成了谱语言，在 定理 3.13 的推论中会用到。

3.1.3 可对角化与特征值分解

定义 3.8 (可对角化) 称 $A \in \mathbb{R}^{n\times n}$ 可**对角化**（diagonalizable），如果存在可逆矩阵 $P \in \mathbb{C}^{n\times n}$ 与对角矩阵 $\Lambda = \operatorname{diag}(\lambda_1, \dots, \lambda_n)$ 使得

$$P^{-1} A P = \Lambda, \qquad \text{等价地} \qquad A = P \Lambda P^{-1}. \tag{3.11}$$

当 A 的特征值全部为实数时，P 可取实矩阵；实对称矩阵的情形还可进一步取 P 为正交矩阵（定理 3.13）。

可对角化与特征向量之间的联系，由下面的刻画给出。

定理 3.9 (可对角化的刻画) 设 $A \in \mathbb{R}^{n\times n}$。则 A 可对角化，当且仅当 A 有 n 个线性无关的特征向量，即 $\mathbb{C}^n$ 有一组由 A 的特征向量组成的基。

《人工智能数学基础》 CC BY-NC-SA 4.0 禁止商业使用，著作权归全体署名作者共有

证明. 记 $P=\begin{bmatrix}p_1 & \cdots & p_n\end{bmatrix}$，$\Lambda=\operatorname{diag}(\lambda_1,\dots,\lambda_n)$，两式 $AP=P\Lambda$ 按列比较：

$$A\begin{bmatrix}p_1 & \cdots & p_n\end{bmatrix}=\begin{bmatrix}Ap_1 & \cdots & Ap_n\end{bmatrix},\qquad P\Lambda=\begin{bmatrix}\lambda_1 p_1 & \cdots & \lambda_n p_n\end{bmatrix}.$$

故 $AP=P\Lambda$ 当且仅当 $Ap_i=\lambda_i p_i$ 对每个 i 成立，即 p_i 是特征向量。而 P 可逆当且仅当其列向量线性无关、构成一组基。 □

定义 3.10 (特征值分解) 若 $A\in\mathbb{R}^{n\times n}$ 可对角化，称分解

$$A=P\Lambda P^{-1} \tag{3.12}$$

为 A 的**特征值分解**（eigendecomposition），其中 P 的第 i 列是对应 λ_i 的特征向量。若进一步 A 为实对称矩阵，则 P 可取为正交矩阵 Q，分解写作

$$A=Q\Lambda Q^{\top},\qquad Q^{\top}Q=I. \tag{3.13}$$

例 3.11 对 例 3.4 的矩阵，把 式 (3.9) 的三个单位化特征向量按列排列：

$$Q=\begin{bmatrix}\frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} & 0\\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} & 0\\ 0 & 0 & 1\end{bmatrix},\qquad \Lambda=\operatorname{diag}(4,2,1).$$

直接验证 $AQ=Q\Lambda$；由于 Q 正交，$Q^{\top}Q=I$，故

$$A=Q\Lambda Q^{\top}. \tag{3.14}$$

特征值与特征向量的排列顺序必须一致；调换 Q 的列而不调换 Λ 的对角元，等式即被破坏。

直观解释. 特征值分解 式 (3.13) 把一次矩阵乘法读成三个动作：

$$x\ \xrightarrow{\ Q^{\top}\ }\ \text{特征坐标}\ \xrightarrow{\ \Lambda\ }\ \text{逐项缩放}\ \xrightarrow{\ Q\ }\ Ax.$$

第一步 $Q^{\top}$ 把原坐标换成沿特征方向的新坐标；第二步只做 n 次独立的数乘；第三步换回原坐标。矩阵在原坐标系下混合了各个方向的缩放，在特征基下则解耦为逐维缩放。例 3.11 中，x 沿 $(1,1,0)/\sqrt{2}$ 的分量被放大 4 倍、沿 $(1,-1,0)/\sqrt{2}$ 的分量被放大 2 倍、沿 $(0,0,1)$ 的分量不变。

注. 可对角化之后，矩阵幂的计算不再需要逐次相乘：

$$A^k=(P\Lambda P^{-1})^k=P\Lambda^k P^{-1},\qquad \Lambda^k=\operatorname{diag}(\lambda_1^k,\dots,\lambda_n^k). \tag{3.15}$$

于是迭代 $x_{k+1}=Ax_k$ 在特征基下的分量各自按 λ_i^k 演化；当且仅当全部 $|\lambda_i|<1$ 时该迭代对任意初值收敛到零。这一判据在第 8 章讨论优化算法的线性迭代形式时会直接使用。

并非所有方阵都可对角化。

《人工智能数学基础》 CC BY-NC-SA 4.0 非商业使用，著作权归全体署名作者共有

例 3.12 (不可对角化的矩阵) 取 $B=\begin{bmatrix}1 & 1\\ 0 & 1\end{bmatrix}$。由 命题 3.6，其唯一特征值为 $\lambda=1$，而

$$E_B(1)=\{\,v\mid Bv=v\,\}=\operatorname{span}(1,0)^{\top},$$

只有一个方向。B 没有两个线性无关的特征向量，由 定理 3.9 不可对角化。一般的判据是：若 p_B 无重根，则 B 必可对角化（定理 3.7 保证 n 个特征向量线性无关）；有重根时需逐项核对几何重数与代数重数是否相等（节 3.1.2）。

注意. 特征值分解有四条限制，它们共同决定了本章后半部分的方向：

(i) 它只适用于方阵；

(ii) 并非所有方阵都可对角化（例 3.12）；

(iii) 非对称矩阵的特征向量未必正交，P 的条件数可能很大；

(iv) 人工智能中的数据矩阵多为长方形（见 式 (1.2)），不在特征值分解的定义域内。

节 3.2 的奇异值分解逐条取消了这些限制。

3.1.4 实对称矩阵的谱定理

定义 3.10 指出实对称矩阵的正交对角化写作 $A=Q\Lambda Q^{\top}$。本小节给出它的存在性依据——谱定理，以及证明。

定理 3.13 (谱定理（实对称矩阵）) 设 $A\in\mathbb{R}^{n\times n}$ 满足 $A=A^{\top}$。则存在正交矩阵 $Q\in\mathbb{R}^{n\times n}$ 与实对角矩阵 Λ，使得

$$A=Q\Lambda Q^{\top}. \tag{3.16}$$

并且：A 的全部特征值都是实数；不同特征值对应的特征向量正交。

证明. 分四步。

（i）特征值为实数。设 $Av=\lambda v$，$v\neq 0$，允许 $v\in\mathbb{C}^n$。考察 v^*Av（$v^*=\overline{v}^{\top}$）：一方面 $v^*Av=\lambda v^*v$，而 $v^*v=\sum_i|v_i|^2>0$ 是正实数，故 $\lambda=v^*Av/(v^*v)$；另一方面，由 A 为实对称，

$$\overline{v^*Av}=(v^*Av)^*=v^*A^*v=v^*Av,$$

故 v^*Av 为实数。于是 λ 为实数。

（ii）不同特征值的特征向量正交。设 $Av_i=\lambda_i v_i$（$i=1,2$），$\lambda_1\neq\lambda_2$，λ_1,λ_2 均为实数（（i）已证）。按约定第 1 条的内积（第一槽共轭线性、第二槽线性）计算同一个量 $\langle Av_1,v_2\rangle$：

$$\langle Av_1,v_2\rangle=\langle\lambda_1 v_1,v_2\rangle=\lambda_1\langle v_1,v_2\rangle,$$

另一方面，由 $A^{\top}=A$ 与伴随性质 $\langle Av_1,v_2\rangle=\langle v_1,A^{\top}v_2\rangle=\langle v_1,Av_2\rangle$，而 $Av_2=\lambda_2 v_2$，故

$$\langle Av_1,v_2\rangle=\langle v_1,\lambda_2 v_2\rangle=\lambda_2\langle v_1,v_2\rangle.$$

两式相等得 $(\lambda_1-\lambda_2)\langle v_1,v_2\rangle=0$；特征值不同，故 $\langle v_1,v_2\rangle=0$。

《人工智能数学基础》 CC BY-NC-SA 4.0 禁止商业使用 · 著作权归全体署名作者共有

（iii）存在一个实特征对。考虑单位球面 $S^{n-1}=\{x\in\mathbb{R}^n\mid \|x\|_2=1\}$ 上的连续函数 $R(x)=x^\top Ax$。S^{n-1} 是 $\mathbb{R}^n$ 中的有界闭集，R 在其上取得最大值，记最大值点为 x_0、最大值为 λ。对任意与 x_0 正交的单位向量 y（$\langle x_0,y\rangle=0$），考察过 x_0 沿 y 方向的曲线 $x(t)=(x_0+ty)/\|x_0+ty\|_2$（$t\in\mathbb{R}$，$x(0)=x_0$，$x(t)\in S^{n-1}$）。函数 $t\mapsto R(x(t))$ 在 $t=0$ 取极大值，故

$$0=\frac{\mathrm{d}}{\mathrm{d}t}R(x(t))\bigg|_{t=0}=2y^\top Ax_0.$$

上式对一切与 x_0 正交的 y 成立，说明 $Ax_0\in\operatorname{span}x_0$，即 $Ax_0=\lambda x_0$ 对某个实数 λ 成立。

（iv）归纳。记 $W=x_0^\perp$。对任意 $w\in W$，

$$\langle x_0,Aw\rangle=\langle Ax_0,w\rangle=\lambda\langle x_0,w\rangle=0,$$

故 $AW\subseteq W$，即 W 是 A 的不变子空间。$A|_W$ 在 W 的任一标准正交基下的矩阵表示仍为实对称矩阵；由归纳假设，W 存在一组标准正交特征基 $q_2,\dots,q_n$，满足 $Aq_i=\lambda'_{i-1}q_i$（$i=2,\dots,n$）。取 $q_1=x_0$、$Q=(q_1,q_2,\dots,q_n)$、$\Lambda=\operatorname{diag}(\lambda,\lambda'_1,\dots,\lambda'_{n-1})$，即得 式 (3.16)。不同特征值的正交性已由（ii）给出；同一特征值内部的特征向量可由（iv）的构造取得正交。 □

注. 对 $x\neq0$，量

$$R_A(x)\coloneqq\frac{x^\top Ax}{x^\top x}\tag{3.17}$$

称为 A 的 **Rayleigh 商**（Rayleigh quotient）。证明第（iii）步在单位球面上最大化的 $x^\top Ax$ 就是 $R_A(x)$（单位向量满足 $x^\top x=1$）；若 $Ax=\lambda x$，则直接代入得 $R_A(x)=\lambda$。

推论 3.14 (秩与非零特征值) 设 $A\in\mathbb{R}^{n\times n}$ 为实对称矩阵。则 $\operatorname{rank}(A)$ 等于 A 的非零特征值个数（计重数）。

证明. 由 式 (3.16)，$A=Q\Lambda Q^\top$，其中 Q 可逆。故 $\operatorname{rank}(A)=\operatorname{rank}(\Lambda)$，而 Λ 的秩恰为非零对角元个数。 □

推论 3.15 (正定性的谱刻画) 设 $A\in\mathbb{R}^{n\times n}$ 为实对称矩阵。则 A 对称正定，当且仅当 A 的全部特征值为正。

证明. 由 式 (3.16)，任取 $x=Qy$（$y\neq0$）有

$$x^\top Ax=y^\top\Lambda y=\sum_i\lambda_iy_i^2.$$

该二次型对一切 $y\neq0$ 取正值，当且仅当全部 $\lambda_i>0$。 □

直观解释. 谱定理说：一个实对称变换的全部作用，是沿一组彼此正交的方向做独立缩放；缩放因子就是特征值。这一几何图像把第 1 章的正交补 定义 1.23 从“投影”推广到了“一般的对称变换”。在人工智能中，协方差矩阵、Gram 矩阵、图拉普拉斯矩阵都是实对称矩阵，它们的谱分解因此在 节 3.2 与 节 3.3 中反复出现。

《人工智能数学基础》 CC BY-NC-SA 4.0 禁止商业使用·著作权归全体著作者共有

3.1.5 相关分解：Cholesky 与 QR

本节之前的主线围绕特征值展开。实践中还有两类不依赖谱理论的分解，它们只用到正交化与正定性，是本章乃至后续章节的工具。

Cholesky 分解

定理 3.16 (Cholesky 分解) 设 $A \in \mathbb{R}^{n\times n}$ 为对称正定矩阵。则存在唯一的下三角矩阵 $L \in \mathbb{R}^{n\times n}$，其对角元全为正，使得

$$A = LL^{\top}. \tag{3.18}$$

称 L 为 A 的 *Cholesky* 因子。

证明. **存在性**。对 n 归纳。$n=1$ 时取 $L=(\sqrt{a_{11}})$。设命题对 $n-1$ 成立，把 A 写成分块形式

$$A = \begin{bmatrix} a & b^{\top} \\ b & C \end{bmatrix},$$

其中 $a>0$（由正定性），$b\in\mathbb{R}^{n-1}$，$C\in\mathbb{R}^{(n-1)\times(n-1)}$ 对称。令

$$S = C - \frac{1}{a}bb^{\top},$$

即块矩阵 A 中标量块 a 的 Schur 补 $S = C - \frac{1}{a}bb^{\top}$。对任意 $y\neq 0$（$y\in\mathbb{R}^{n-1}$），取 $x=(-b^{\top}y/a,\, y)^{\top}$（标量块在前，与 A 的分块次序一致），则 $x^{\top}Ax = y^{\top}Sy$，由正定性得 S 对称正定。由归纳假设，$S = L_1L_1^{\top}$（L_1 下三角、正对角）。直接验证

$$\begin{bmatrix} \sqrt{a} & 0 \\ \dfrac{b}{\sqrt{a}} & L_1 \end{bmatrix}\begin{bmatrix} \sqrt{a} & \dfrac{b^{\top}}{\sqrt{a}} \\ 0 & L_1^{\top} \end{bmatrix} = \begin{bmatrix} a & b^{\top} \\ b & C \end{bmatrix} = A.$$

唯一性。设 $A = L_1L_1^{\top} = L_2L_2^{\top}$ 均为满足条件的分解。由 $L_2^{-1}L_1L_1^{\top}L_2^{-\top} = I$ 知 $L_2^{-1}L_1$ 为正交矩阵；又 $L_2^{-1}L_1$ 是下三角矩阵（下三角矩阵之积仍为下三角）。既是正交又为下三角的矩阵只能是对角矩阵，且对角元为 ±1；而 L_2^{-1} 与 L_1 的对角元均为正（正对角下三角矩阵之逆仍正对角），其乘积的对角元也为正，故只能全取 $+1$。于是 $L_2^{-1}L_1 = I$，即 $L_1 = L_2$。 □

证明的归纳过程给出直接算法。按 L 的逐列递推，其元素满足

$$l_{11} = \sqrt{a_{11}}, \qquad l_{ij} = \frac{a_{ij} - \sum_{k<j} l_{ik}l_{jk}}{l_{jj}} \quad (i>j), \qquad l_{jj} = \sqrt{a_{jj} - \sum_{k<j} l_{jk}^2}. \tag{3.19}$$

例 3.17 取 $A = \begin{bmatrix} 4 & 2 \\ 2 & 5 \end{bmatrix}$。$A$ 对称，且 $4>0$、$\det A = 16>0$，故对称正定（2×2 情形由 推论 3.15 亦可核对：$\lambda = \frac{1}{2}(9\pm\sqrt{17})>0$）。按 式 (3.19)：

$$l_{11} = \sqrt{4} = 2, \qquad l_{21} = \frac{2}{2} = 1, \qquad l_{22} = \sqrt{5-1^2} = 2.$$

《人工智能数学基础》 CC BY-NC-SA 4.0 禁止商业用途 · 版权归作者署名作者共有

故

$$A = \begin{bmatrix} 4 & 2 \\ 2 & 5 \end{bmatrix} = \begin{bmatrix} 2 & 0 \\ 1 & 2 \end{bmatrix} \begin{bmatrix} 2 & 1 \\ 0 & 2 \end{bmatrix}. \tag{3.20}$$

注. Cholesky 分解在人工智能中的常见用法都与“协方差”有关：多元高斯分布的采样、高斯过程回归的预测方差、正定核矩阵的方程求解。这些用法的共同前提是矩阵对称正定；协方差矩阵是对称半正定的；当任一非零线性组合的方差均为正时，它是正定的。对于样本协方差矩阵，这等价于中心化后的数据矩阵列满秩。由 式 (3.18) 还可高效计算行列式：$\det A = \prod_i l_{ii}^2$。

QR 分解

定义 3.18 (QR 分解) 设 $A \in \mathbb{R}^{m\times n}$ 列满秩，$m \geqslant n$。称分解

$$A = QR \tag{3.21}$$

为 A 的 **QR 分解**，其中 $Q \in \mathbb{R}^{m\times n}$ 的列向量两两正交且均为单位向量（$Q^\top Q = I_n$），$R \in \mathbb{R}^{n\times n}$ 为上三角矩阵。

QR 分解的存在性来自第 1 章的正交化。把 A 按列写成 $A = (a_1, \dots, a_n)$，对 $a_1, \dots, a_n$ 依次作 Gram–Schmidt 正交化，得到标准正交向量组 $q_1, \dots, q_n$；由于 A 列满秩，q_i 均非零。Gram–Schmidt 过程的中间系数恰好构成一个上三角矩阵 R，使 $A = QR$ 成立。

例 3.19 取 $A = \begin{bmatrix} 1 & 1 \\ 1 & 0 \end{bmatrix}$。对其列作 Gram–Schmidt：$q_1 = \frac{1}{\sqrt{2}}(1,1)^\top$，$r_{11} = \sqrt{2}$，$r_{12} = q_1^\top a_2 = \frac{1}{\sqrt{2}}$，$v_2 = a_2 - r_{12}q_1 = \frac{1}{2}(1,-1)^\top$，故 $q_2 = \frac{1}{\sqrt{2}}(1,-1)^\top$、$r_{22} = \frac{1}{\sqrt{2}}$。于是

$$Q = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}, \qquad R = \begin{bmatrix} \sqrt{2} & \frac{1}{\sqrt{2}} \\ 0 & \frac{1}{\sqrt{2}} \end{bmatrix}, \qquad QR = \begin{bmatrix} 1 & 1 \\ 1 & 0 \end{bmatrix} = A. \tag{3.22}$$

命题 3.20 (QR 分解与最小二乘) 设 $A \in \mathbb{R}^{m\times n}$ 列满秩，$A = QR$ 为其 QR 分解，$b \in \mathbb{R}^m$。则最小二乘问题

$$\min_x \ \|Ax - b\|_2^2 \tag{3.23}$$

的唯一解 x^* 满足

$$Rx^* = Q^\top b. \tag{3.24}$$

证明. 由第 1 章正规方程（定理 1.38 and 式 (1.29)），x^* 满足 $A^\top A x^* = A^\top b$。代入 $A = QR$ 得

$$R^\top Q^\top Q R x^* = R^\top Q^\top b.$$

利用 $Q^\top Q = I$ 化简得 $R^\top R x^* = R^\top Q^\top b$。$R$ 上三角且对角元非零（Gram–Schmidt 的系数），故 R 可逆，两边左乘 $R^{-\top}$ 得 式 (3.24)。 □

注. 式 (3.24) 的实践意义在数值稳定性。正规方程 $A^\top A x = A^\top b$ 需要显式形成 $A^\top A$，其条件数是 A 的条件数的平方；QR 路线直接对 A 做正交变换：正交变换本身不放大欧氏范数，稳定的 QR 实现也避免显式形成 $A^\top A$。但解的扰动敏感性仍受谱条件数 $\kappa_2(A)$ 控制（条件

《人工智能数学基础》 CC BY-NC-SA 4.0 禁止商业使用，著作权归全体署名作者所有

数平方关系见第 1 章 习题 1.60）——QR 不会把病态问题自动变为良态。QR 分解也是计算特征值的标准算法（QR 迭代）的基础；该算法及其收敛性分析超出本书范围，见 [1]。

注 (广义特征值问题). 把 式 (3.4) 中的单位矩阵 I 换成正定矩阵 B，得到**广义特征值问题**

$$Av = \lambda Bv, \qquad v \neq 0,$$

其中 λ 称为矩阵束 (A, B) 的广义特征值。当 B 可逆时它等价于 $B^{-1}A$ 的普通特征值问题；当 A 亦为实对称矩阵时，可取 B-标准正交的广义特征向量组成可逆矩阵 T，使 $T^\top BT = I$、$T^\top AT = \Lambda$。两个重要应用各归其位：线性判别分析中类间/类内散度矩阵的比值 $\frac{w^\top S_B w}{w^\top S_W w}$ 属分类模型，见第 8 章；谱聚类中的归一化割准则 $Lu = \lambda Du$ 是图上的广义特征值问题，本章不展开。

3.2 奇异值分解

3.2.1 动机：长方形矩阵与两个空间

节 3.1 末尾的注意框列了特征值分解的四条限制，其中限制最强的一条是：它只对方阵有定义。人工智能中的数据矩阵几乎都是长方形的。设 $X \in \mathbb{R}^{N\times d}$，其中 N 为样本数、d 为特征数，$N \neq d$ 是常态：N 张图像展平后组成 $N \times (HWC)$ 的数据矩阵，文档–词语矩阵是 $N_{\mathbf{doc}} \times N_{\mathbf{word}}$ 个数，用户–物品评分矩阵是 $N_{\mathbf{user}} \times N_{\mathbf{item}}$ 个数，神经网络的特征矩阵是 $N \times d$ 个数。

这些矩阵没有“特征值”可谈。奇异值分解（singular value decomposition，SVD）把问题换成：沿哪些输入方向观察时变换的伸缩最强？像又落在哪些输出方向上？输入与输出可以是不同维数的两个空间，长方形矩阵因此也能分解。

3.2.2 秩一模式

奇异值分解的基本构件是秩一矩阵。先给出构成秩一矩阵的基本运算。设 $u \in \mathbb{R}^m$、$v \in \mathbb{R}^n$，称矩阵

$$uv^\top \in \mathbb{R}^{m\times n}$$

为 u 与 v 的外积（outer product），其 (i, j) 元为 $u_i v_j$；作为对照，内积针对同维向量：对 $a, b \in \mathbb{R}^n$，$a^\top b$ 是一个数（见第 1 章 定义 1.22）。

命题 3.21 (外积的秩一结构) 设 $u \in \mathbb{R}^m$、$v \in \mathbb{R}^n$ 均为非零向量。则外积 $uv^\top \in \mathbb{R}^{m\times n}$ 的秩为 1，且对任意 $x \in \mathbb{R}^n$，

$$(uv^\top)x = (v^\top x)\, u. \tag{3.25}$$

证明. 式 (3.25) 由结合律直接得到。像空间为 $\operatorname{span} u$，故秩至多为 1；又 $u, v \neq 0$ 保证至少一列非零，故秩恰为 1。 □

式 (3.25) 把秩一矩阵的作用分成两步：先用 $v^\top x$ 测量输入 x 与方向 v 的相似程度，再把该系数乘到输出方向 u 上。反过来，任一秩一矩阵都可写成外积 $uv^\top$：取其一个非零列为

u，其余各列关于 u 的系数排成 v 即可。奇异值分解所做的，正是把一个复杂矩阵拆成若干个相互正交的秩一模式之和——每个模式各自负责一个“测量、缩放、放置”的通道。

3.2.3 奇异值分解定理

定义 3.22 (正交矩阵) 称 $Q \in \mathbb{R}^{n\times n}$ 为**正交矩阵**（orthogonal matrix），若 $Q^{\top}Q = I$。等价地，Q 的列向量构成 $\mathbb{R}^n$ 的一组标准正交基；此时 $Q^{-1} = Q^{\top}$，且 $\|Qx\|_2 = \|x\|_2$、$\langle Qx, Qy\rangle = \langle x, y\rangle$ 对一切 x, y 成立。二维旋转 $\begin{bmatrix}\cos\theta & -\sin\theta \\ \sin\theta & \cos\theta\end{bmatrix}$ 与 例 3.11 中的 Q 都是正交矩阵。

在给出定理之前，先说明奇异值分解想做的事：把任意矩阵 $A \in \mathbb{R}^{m\times n}$ 写成

$$A = U\Sigma V^{\top}$$

的形式，其中三块各司其职——$V^{\top}$ 把输入空间的坐标换成一组彼此正交的方向 $v_1, \dots, v_n$；Σ 沿这些方向依次缩放 $\sigma_1, \dots, \sigma_n$，并允许把 $\mathbb{R}^n$ 送进更高维或更低维的 $\mathbb{R}^m$；U 把缩放后的结果摆进输出空间的正交坐标系。输入方向归 V 管、输出方向归 U 管、伸缩强度归 Σ 管。输入与输出因此可以是不同维数的两个空间——这正是长方形矩阵也能分解的原因。下面的定理说明：这样的分解不仅存在，而且可以约定奇异值按降序排列。

定理 3.23 (奇异值分解) *设 $A \in \mathbb{R}^{m\times n}$ 的秩为 r。则存在正交矩阵 $U \in \mathbb{R}^{m\times m}$ 与 $V \in \mathbb{R}^{n\times n}$，以及 $m \times n$ 矩形对角矩阵 Σ（$\Sigma_{ii} = \sigma_i \geqslant 0$，$\Sigma_{ij} = 0$（$i \neq j$）），使得*

$$A = U\Sigma V^{\top}, \tag{3.26}$$

其中 $\sigma_1 \geqslant \sigma_2 \geqslant \cdots \geqslant \sigma_r > 0$，且非零 σ_i 的个数恰为 r。记 U 的列为 $u_1, \dots, u_m$、V 的列为 $v_1, \dots, v_n$，则

$$Av_i = \sigma_i u_i \quad (i \leqslant r), \qquad A^{\top}u_i = \sigma_i v_i \quad (i \leqslant r). \tag{3.27}$$

按惯例，σ_i 称为 A 的**奇异值（singular value）**，u_i 称为**左奇异向量（left-singular vector）**，v_i 称为**右奇异向量（right-singular vector）**。

证明. 记 $A^{\top}A \in \mathbb{R}^{n\times n}$。它对称半正定（对任意 x，$x^{\top}A^{\top}Ax = \|Ax\|_2^2 \geqslant 0$）。由 定理 3.13，存在正交矩阵 V 与实对角矩阵 Λ_A 使

$$A^{\top}A = V\Lambda_A V^{\top}.$$

由半正定性，Λ_A 的对角元 $\lambda_1 \geqslant \cdots \geqslant \lambda_n \geqslant 0$ 全非负；由 推论 3.14，其中恰有 r 个为正。令 $\sigma_i \coloneqq \sqrt{\lambda_i}$（$i = 1, \dots, r$）。

对 $i \leqslant r$ 定义 $u_i \coloneqq Av_i/\sigma_i$。则 $\|u_i\|_2^2 = v_i^{\top}A^{\top}Av_i/\sigma_i^2 = \lambda_i/\sigma_i^2 = 1$；且对 $i \neq j$（均 $\leqslant r$），

$$\langle u_i, u_j\rangle = \frac{1}{\sigma_i\sigma_j}v_i^{\top}A^{\top}Av_j = \frac{\lambda_j}{\sigma_i\sigma_j}v_i^{\top}v_j = 0.$$

把 $u_1, \dots, u_r$ 补成 $\mathbb{R}^m$ 的标准正交基 $u_1, \dots, u_m$，取 $U = (u_1, \dots, u_m)$。按 式 (3.27) 逐列验

《人工智能数学基础》 CC BY-NC-SA 4.0 仅限非商业使用，著作权归全体著作者所有

证 $AV = U\Sigma$：$i \leqslant r$ 时 $Av_i = \sigma_i u_i$；$i > r$ 时 $v_i^\top A^\top A v_i = \lambda_i \|v_i\|_2^2 = 0$，即 $\|Av_i\|_2^2 = 0$，故 $Av_i = 0$，对应 Σ 的第 i 个零列（此处把奇异值补到 n 项，是为统一计数而作的补零约定；当 $m < n$ 且 $i > m$ 时 Σ 无第 i 个对角位置）。右乘 $V^\top$ 得 式 (3.26)。 □

例 3.24 (一个非平凡的长方形算例) 取 $A = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 0 \end{bmatrix} \in \mathbb{R}^{3\times 2}$。则

$$A^\top A = \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix},$$

其特征值为 $\lambda_1 = 2$、$\lambda_2 = 1$，相应标准正交特征向量 $v_1 = (1,0)^\top$、$v_2 = (0,1)^\top$。于是 $\sigma_1 = \sqrt{2}$、$\sigma_2 = 1$（$\operatorname{rank}(A) = 2$，非零奇异值个数吻合），且

$$u_1 = \frac{Av_1}{\sigma_1} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}, \qquad u_2 = \frac{Av_2}{\sigma_2} = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}.$$

把 (u_1, u_2) 补成 $\mathbb{R}^3$ 的标准正交基，取 $u_3 = \frac{1}{\sqrt{2}}(1,0,-1)^\top$。验证：

$$U\Sigma V^\top = \sqrt{2} \cdot \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix} \begin{bmatrix} 1 & 0 \end{bmatrix} + \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix} \begin{bmatrix} 0 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 0 \end{bmatrix} = A. \tag{3.28}$$

注. 把 式 (3.26) 与特征值分解 式 (3.12) 并排对照，差异正是奇异值分解取消那四条限制的方式：

(i) 输入与输出可以是不同维数的空间（$\mathbb{R}^n \to \mathbb{R}^m$，$m \neq n$ 无障碍）；

(ii) 分解对**任意**矩阵存在，不要求可对角化；

(iii) U, V 的列向量全部正交，特征向量矩阵 P 可能病态的问题在此不出现；

(iv) Σ 的对角元 σ_i 全为实数且非负——特征值分解的 Λ 对角元可以是负数或复数。

特别地，若 A 为实对称半正定矩阵，则奇异值分解与谱分解给出同一个分解（取 $U = V$ 即可）。

3.2.4 三种形态

按矩阵形状与秩，实践中常用三种写法。它们是同一个分解的三种截断：非零奇异值始终是同一组 $\sigma_1, \ldots, \sigma_r$，$\Sigma_n$、$\Sigma_r$ 都只是 Σ 的左上角块，差别仅在保留多少零行零列。

- **完整 SVD（full SVD）：式 (3.26) 的形式，$U \in \mathbb{R}^{m\times m}$、$V \in \mathbb{R}^{n\times n}$ 均为方阵。**
- **薄 SVD（thin SVD）：当 $m \geqslant n$ 时只保留 U 的前 n 列：**

$$A = U_n \Sigma_n V^\top,$$

其中 U_n 为列标准正交的 $m \times n$ 矩阵，Σ_n 为 $n \times n$ 对角矩阵。省去的是对 A 的列空

《人工智能数学基础》 CC BY-NC-SA 4.0 禁止商业使用 著作权归全体著作者共有

间毫无贡献的 $m-n$ 个方向。

- **紧致 SVD（compact SVD）：只保留 r 个非零奇异值：**

$$A = U_r \Sigma_r V_r^{\top},$$

其中 $U_r \in \mathbb{R}^{m\times r}$、$V_r \in \mathbb{R}^{n\times r}$。这是秩的直接体现：$\operatorname{rank}(A) = r$ 一目了然。

例 3.25 (同一分解的三种尺寸) 取

$$A = \begin{bmatrix} 2 & 0 \\ 0 & 0 \\ 0 & 0 \end{bmatrix} \in \mathbb{R}^{3\times 2}, \qquad m = 3, \quad n = 2, \quad r = 1.$$

由 $A^{\top}A = \operatorname{diag}(4, 0)$ 得 $\sigma_1 = 2$，相应的 $v_1 = (1, 0)^{\top} \in \mathbb{R}^2$、$u_1 = (1, 0, 0)^{\top} \in \mathbb{R}^3$。三种形态为

$$\text{完整：} \quad U = I_3, \qquad \Sigma = \begin{bmatrix} 2 & 0 \\ 0 & 0 \\ 0 & 0 \end{bmatrix}, \quad V = I_2;$$

$$\text{薄：} \quad U_n = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 0 \end{bmatrix}, \quad \Sigma_n = \begin{bmatrix} 2 & 0 \\ 0 & 0 \end{bmatrix}, \quad V = I_2;$$

$$\text{紧致：} \quad U_r = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \qquad \Sigma_r = (2), \qquad V_r = \begin{bmatrix} 1 \\ 0 \end{bmatrix}.$$

三者逐块相乘都得到 A；非零对角元始终是同一个 $\sigma_1 = 2$，被丢掉的只是与零奇异值相乘的方向。$m < n$ 时薄 SVD 对称地保留 V 的前 m 列，$\Sigma_m \in \mathbb{R}^{m\times m}$。

3.2.5 奇异值的极值刻画与外积形式

奇异值有直接的几何含义。这类通过“在约束集合上最大化某个量”来刻画数学对象的命题，文献中也称变分刻画（**variational characterization**）；名称中的“变分”指改变 x 取极值这一动作。设 $x \neq 0$，则

$$\frac{\|Ax\|_2^2}{\|x\|_2^2} = \frac{x^{\top}A^{\top}Ax}{x^{\top}x}$$

恰为 $A^{\top}A$ 的 **Rayleigh** 商（式 **(3.17)**）。由 定理 **3.13**，其在单位球面上的最大值为 $\lambda_{\max}(A^{\top}A)$，在对应特征向量处取得。

定理 3.26 (奇异值的极值刻画) 设 $A \in \mathbb{R}^{m\times n}$ 的奇异值按降序排列。则

$$\sigma_1 = \max_{\|x\|_2 = 1} \|Ax\|_2 , \tag{3.29}$$

《人工智能数学基础》 CC BY-NC-SA 4.0 禁止商业使用 · 著作权归全体署名作者共有

且一般地，对 $k \leqslant r$，

$$\sigma_k = \max_{\substack{\|x\|_2=1 \\ x\perp v_1,\dots,v_{k-1}}} \|Ax\|_2, \qquad \sigma_k^2 = \max_{\substack{\|x\|_2=1 \\ x\perp v_1,\dots,v_{k-1}}} x^\top A^\top A x. \tag{3.30}$$

证明. 式 (3.29) 即 定理 3.13 证明第（iii）步的 Rayleigh 商极值论证。对 式 (3.30)：在 $W_{k-1} \coloneqq \operatorname{span} v_1,\dots,v_{k-1}$ 的正交补上，$A^\top A$ 的限制仍是实对称矩阵，其最大特征值为 λ_k（谱定理对不变子空间的归纳用法，同 定理 3.13 证明第（iv）步）。 □

直观解释. 式 (3.30) 说：奇异值是按“矩阵能够产生的伸缩强度”依次确定的——先找放大程度最大的输入方向 v_1；在一切与 v_1 正交的方向里再找放大程度最大的 v_2；依此类推。σ_1 就是矩阵的最大伸缩倍数。于是“矩阵有多大”被分解为一组可以依次确定的量。

由 式 (3.27) 可得外积形式。对紧致 SVD，

$$A = \sum_{i=1}^{r} \sigma_i u_i v_i^\top, \qquad Ax = \sum_{i=1}^{r} \sigma_i \left(v_i^\top x\right) u_i. \tag{3.31}$$

式 (3.31) 右式把矩阵乘法读成三步的叠加：$v_i^\top x$ 提取输入在第 i 个方向上的成分，σ_i 缩放该成分，u_i 把结果放到输出空间。

3.2.6 矩阵范数、条件数与秩

定义 3.27 (谱范数) 矩阵 $A \in \mathbb{R}^{m\times n}$ 的**谱范数**（spectral norm）定义为

$$\|A\|_2 \coloneqq \max_{x\neq 0} \frac{\|Ax\|_2}{\|x\|_2}. \tag{3.32}$$

定理 3.28 (谱范数与最大奇异值) $\|A\|_2 = \sigma_1(A)$。

证明. 式 (3.32) 与 式 (3.29) 是同一个量：后者只在前者中取 $\|x\|_2 = 1$。 □

定义 3.29 (Frobenius 范数与核范数) 矩阵 $A = (a_{ij}) \in \mathbb{R}^{m\times n}$ 的 **Frobenius 范数**定义为

$$\|A\|_F \coloneqq \Big(\sum_{i,j} a_{ij}^2\Big)^{1/2}; \tag{3.33}$$

秩 r 矩阵的**核范数**（nuclear norm）定义为其全部奇异值之和：

$$\|A\|_* \coloneqq \sum_{i=1}^{r} \sigma_i(A). \tag{3.34}$$

定理 3.30 (Frobenius 范数的奇异值表示) $\|A\|_F^2 = \sum_{i=1}^{r} \sigma_i(A)^2$。

证明. 由 式 (3.26)，$A = U\Sigma V^\top$。Frobenius 范数在正交变换下不变（$\|QA\|_F = \|A\|_F$、$\|AR\|_F = \|A\|_F$：这由 式 (3.33) 的逐元素平方和定义与 定义 3.22 的正交不变性即得），故 $\|A\|_F = \|\Sigma\|_F$，而后者恰为 $\big(\sum_i \sigma_i^2\big)^{1/2}$。 □

《人工智能数学基础》 CC BY NC SA 4.0 禁止商业使用 · 著作权归全体署名作者所有

命题 3.31 (秩的奇异值计数) $\operatorname{rank}(A) = \#\{i : \sigma_i > 0\}$。

证明. 由 式 (3.26)，$\operatorname{rank}(A) = \operatorname{rank}(\Sigma)$，而 Σ 的秩即非零对角元个数。 □

定义 3.32 (条件数) 列满秩矩阵 $A \in \mathbb{R}^{m\times n}$（$m \geqslant n$）的（谱）**条件数**（condition number）定义为

$$\kappa_2(A) \coloneqq \frac{\sigma_{\max}(A)}{\sigma_{\min}(A)}. \tag{3.35}$$

条件数刻画矩阵在各个方向上伸缩的均匀程度：$\kappa_2(A)$ 接近 1 时各方向伸缩接近，问题较稳定；$\kappa_2(A)$ 很大时某些方向被强烈压缩，输入的小误差会被显著放大。若 A 不满列秩，则 $\sigma_{\min} = 0$，条件数为无穷大。

注意. 考虑解线性方程组 $Ax = b$，设 $b \in \operatorname{Col}(A)$（方程组相容）。由紧致 SVD 与 式 (3.31)，

$$x = \sum_{i=1}^{r} \frac{u_i^\top b}{\sigma_i}\, v_i$$

给出一个解：A 满列秩时它是唯一解，秩亏时它是最小范数解（系统讨论见第 5 章）。当某个 σ_i 很小时，$1/\sigma_i$ 很大，b 中沿 u_i 方向的微小噪声会被显著放大后进入解。这就是**病态**（ill-conditioning）问题的奇异值图像：问题本身对小扰动敏感。缓解的数学手段见 节 3.3 的正则化。

3.2.7 截断 SVD 与 Eckart–Young 定理

式 (3.31) 按奇异值从大到小排列各项。一个自然的压缩方案是只保留前 k 项：

定义 3.33 (截断 SVD) 设 $A \in \mathbb{R}^{m\times n}$ 秩为 r，$k < r$。称

$$A_k \coloneqq \sum_{i=1}^{k} \sigma_i u_i v_i^\top = U_k \Sigma_k V_k^\top \tag{3.36}$$

为 A 的（秩 k）**截断 SVD**（truncated SVD），其中 U_k, V_k 分别取 U, V 的前 k 列。

截断 SVD 的地位由下面的定理保证：在所有秩不超过 k 的矩阵中，它是误差最小的一个。

定理 3.34 (Eckart–Young 定理) 设 $A \in \mathbb{R}^{m\times n}$ 秩为 r，$k < r$，A_k 为 式 (3.36) 给出的截断 *SVD*。则对任意 $\operatorname{rank}(B) \leqslant k$ 的矩阵 B，

$$\|A - A_k\|_F \leqslant \|A - B\|_F, \qquad \|A - A_k\|_F^2 = \sum_{i=k+1}^{r} \sigma_i^2, \tag{3.37}$$

且

$$\|A - A_k\|_2 \leqslant \|A - B\|_2, \qquad \|A - A_k\|_2 = \sigma_{k+1}. \tag{3.38}$$

谱范数版. 设 $\operatorname{rank}(B) \leqslant k$。记 $N \coloneqq \operatorname{Null}(B)$，由秩–零化度定理的矩阵形式（定理 1.20、推

《人工智能数学基础》 CC BY-NC-SA 4.0 禁止商业使用，著作权归全体署名作者所有

论 1.21），

$$\dim N = n - \operatorname{rank}(B) \geqslant n - k.$$

再记 $V \coloneqq \operatorname{span} v_1, \ldots, v_{k+1}$，则 $\dim V = k+1$。因 $N + V \subseteq \mathbb{R}^n$，由子空间维数关系

$$\dim(N \cap V) = \dim N + \dim V - \dim(N+V) \geqslant (n-k) + (k+1) - n = 1,$$

故可取非零向量 $x \in N \cap V$。

由 $x \in N$ 得 $Bx = 0$，从而 $(A-B)x = Ax$；由 $x \in V$ 写 $x = \sum_{i \leqslant k+1} c_i v_i$，利用 $Av_i = \sigma_i u_i$ 与 u_i 两两正交，得

$$\|Ax\|_2^2 = \sum_{i \leqslant k+1} \sigma_i^2 c_i^2 \geqslant \sigma_{k+1}^2 \sum_{i \leqslant k+1} c_i^2 = \sigma_{k+1}^2 \|x\|_2^2,$$

即 $\|Ax\|_2 \geqslant \sigma_{k+1} \|x\|_2$。于是

$$\sigma_{k+1} \|x\|_2 \leqslant \|Ax\|_2 = \|(A-B)x\|_2 \leqslant \|A-B\|_2 \|x\|_2.$$

约去 $\|x\|_2 > 0$，得 $\sigma_{k+1} \leqslant \|A-B\|_2$。等号由 $B = A_k$ 取得（式 (3.36) 的尾项谱范数正是 σ_{k+1}，由 定理 3.28），式 (3.38) 成立。 □

Frobenius 版. 记 $W \coloneqq \operatorname{Row}(B)$（$\dim W = k' \leqslant k$），$P$ 为到 W 的正交投影。分两步。

第一步：化到投影。由 $B = BP$ 得 $(A-B)(I-P) = A(I-P)$，而 $I-P$ 是正交投影、谱范数为 1，故

$$\|A-B\|_F \geqslant \|(A-B)(I-P)\|_F = \|A(I-P)\|_F. \tag{3.39}$$

第二步：投影后的下界。由 式 (3.26)，$A(I-P) = U\Sigma V^\top (I-P)$，而 Frobenius 范数在正交变换下不变（定理 3.30 的证明）；按 Σ 为 $m \times n$ 矩形对角矩阵、约定 $\sigma_i = 0$（$i > r$），得

$$\|A(I-P)\|_F^2 = \left\|\Sigma V^\top (I-P)\right\|_F^2 = \sum_{i=1}^{n} \sigma_i^2 \left\|v_i^\top (I-P)\right\|_2^2 = \sum_{i=1}^{n} \sigma_i^2 \big(1 - \|Pv_i\|_2^2\big). \tag{3.40}$$

记 $x_i \coloneqq \|Pv_i\|_2^2$。每个 $x_i \in [0,1]$（投影不放大），且

$$\sum_{i=1}^{n} x_i = \sum_{i=1}^{n} v_i^\top P v_i = \operatorname{tr}(V^\top P V) = \operatorname{tr}(PVV^\top) = \operatorname{tr}(P) = k' \leqslant k,$$

其中用了 $VV^\top = I$（V 为方正交矩阵）。在约束 $0 \leqslant x_i \leqslant 1$、$\sum_i x_i = k'$ 之下，$\sum_i \sigma_i^2 x_i$ 的最大值由 $x_1 = \cdots = x_{k'} = 1$、其余为 0 取得：$\sigma_i^2$ 已按降序排列，若某个 $x_j > 0$（$j > k'$）而某个 $x_i < 1$（$i \leqslant k'$），把 x_j 的量挪到 x_i 上，加权和不减（交换论证）。于是

$$\|A(I-P)\|_F^2 = \sum_{i=1}^{n} \sigma_i^2 - \sum_{i=1}^{n} \sigma_i^2 x_i \geqslant \sum_{i=1}^{n} \sigma_i^2 - \sum_{i=1}^{k'} \sigma_i^2 = \sum_{i=k'+1}^{n} \sigma_i^2 \geqslant \sum_{i=k+1}^{n} \sigma_i^2. \tag{3.41}$$

结合 式 (3.39) 与 式 (3.41) 得 $\|A-B\|_F^2 \geqslant \sum_{i=k+1}^{n} \sigma_i^2$；由 $\sigma_i = 0$（$i > r$），右端即 $\sum_{i=k+1}^{r} \sigma_i^2 =$

《人工智能数学基础》 CC BY-NC-SA 4.0 禁止商业使用 · 著作权归全体署名作者所有

$\|A - A_k\|_F^2$（定理 3.30）。等号由 $B = A_k$（此时 P 为到 $\operatorname{span} v_1, \ldots, v_k$ 的投影）取得，式 (3.37) 成立。 □

直观解释. Eckart–Young 定理把“压缩”变成了有最优保证的操作：按奇异值从大到小截取，就是秩 k 矩阵中的最优近似。以灰度图像压缩为例：一张 1920×1080 的图像有 2073600 个数；保留前 50 个奇异值只需存 50 个奇异值和 50 对长度为 1920 与 1080 的向量，共 $50(1920 + 1080 + 1) = 150050$ 个数，约为原来的 7.2%。注意对固定的矩阵尺寸与截断秩 k，存储比例已经确定；真正随奇异值衰减快慢变化的是该比例下的逼近误差：衰减越快，达到给定误差所需的 k 越小（逼近误差越小）；衰减越慢，则要达到同样误差需要更大的 k（如随机噪声矩阵难以压缩）。

3.2.8 AI 应用：主成分分析与隐语义模型

AI 应用

问题：高维数据（如 $N \times d$ 且 d 很大的特征矩阵）直接存储与计算代价高，且许多维度的信息冗余。如何用更少的维数保留主要结构？

数学建模：主成分分析（**principal component analysis，PCA**）回答这一问题，它分四步，每步都只用本章已学的工具。

第一步（中心化）。把数据矩阵 $X \in \mathbb{R}^{N \times d}$ 的每一列减去该列的均值，使每个特征的均值为零；下文记中心化后的矩阵仍为 X。

第二步（找方向）。对 X 作紧致 **SVD**：$X = U_r \Sigma_r V_r^\top$。协方差矩阵（略去比例常数 $1/(N-1)$）为

$$X^\top X = \sum_{i=1}^{r} \sigma_i^2 \, v_i v_i^\top .$$

由 定理 **3.13**，V_r 的列向量就是协方差矩阵的特征向量，称为主成分方向；第 i 个方向的方差为 $\sigma_i^2/(N-1)$——奇异值越大，数据沿该方向的起伏越大，越值得保留。

第三步（投影）。取前 k 个主成分方向，把每个样本投影到它们张成的子空间：

$$Z = XV_k,$$

N 个样本由 d 维降到 k 维。保住了多少信息，由累计方差解释率量度：

$$\text{前}k\text{ 个主成分的累计方差解释率} = \frac{\sum_{i=1}^{k} \sigma_i^2}{\sum_{i=1}^{r} \sigma_i^2}.$$

由 $XV_k = U_k \Sigma_k$，降维表示也可直接由 $U_k \Sigma_k$ 读得。

第四步（两条路径）。 **PCA** 因此有两条等价路径：对协方差矩阵 $X^\top X$ 作特征值分解（定理 **3.13**），或直接对数据矩阵 X 作奇异值分解（定理 **3.23**）；两条路径给出同一组主成分方向。实践中走后者：它避开显式形成 $d \times d$ 的协方差矩阵，与 **QR** 分解在最小二乘中的用法（命题 **3.20**）属同一类数值稳定性考虑。

理论联系：推荐系统中的隐语义模型用的也是这个分解：把用户–物品评分矩阵作紧致

《人工智能数学基础》 CC BY-NC-SA 4.0 禁止商业使用 著作权归全体署名作者所有

SVD，左奇异向量 u_i 刻画“典型用户”、右奇异向量 v_i 刻画“典型物品”、奇异值 σ_i 给出第 i 种“用户类型 $\times$ 物品类型”模式的显著程度。一个具体算例见 [4]：三人对四部电影的评分矩阵中，第一对奇异向量把两位科幻影迷与两部科幻片归入同一模式，第二对则识别出第三位用户的文艺片口味——矩阵里看不见的“人群 $\times$ 口味”结构，被 SVD 逐项拆出。

3.3 低秩逼近

3.3.1 潜在因素模型

低秩逼近的出发点是一个建模假设：一个看似庞大的矩阵，其内容由少数潜在因素（**latent factors**）决定。设 m 名学生、n 门课程的成绩矩阵 $M \in \mathbb{R}^{m\times n}$。虽然矩阵有 mn 个元素，但成绩可能主要由少数几项能力解释：设学生 i 的能力向量为 $\ell_i \in \mathbb{R}^k$、课程 j 所需的能力向量为 $r_j \in \mathbb{R}^k$，则

$$M_{ij} \approx \ell_i^{\top} r_j. \tag{3.42}$$

将各潜在向量的转置分别按行排成矩阵

$$L = \begin{bmatrix} \ell_1^{\top} \\ \vdots \\ \ell_m^{\top} \end{bmatrix} \in \mathbb{R}^{m\times k}, \qquad R = \begin{bmatrix} r_1^{\top} \\ \vdots \\ r_n^{\top} \end{bmatrix} \in \mathbb{R}^{n\times k},$$

则 式 (3.42) 的矩阵形式为

$$M \approx LR^{\top}. \tag{3.43}$$

由 $\operatorname{rank}(LR^{\top}) \leqslant k$，少数潜在因素自然产生低秩结构；反过来，秩不超过 k 的矩阵也一定有这种分解：

命题 3.35 (秩 k 矩阵的因子化) 设 $X \in \mathbb{R}^{m\times n}$，$\operatorname{rank}(X) \leqslant k$。记 $q \coloneqq \operatorname{rank}(X)$（$q \leqslant k$）。则存在 $L \in \mathbb{R}^{m\times k}$、$R \in \mathbb{R}^{n\times k}$（两因子均恰有 k 列）使 $X = LR^{\top}$；等价地，X 可写成至多 k 个秩不超过一的外积项之和（当 $q < k$ 时，多余的列给出零外积项）。

证明. 取 X 的紧致 SVD $X = U_q \Sigma_q V_q^{\top}$（$U_q \in \mathbb{R}^{m\times q}$、$V_q \in \mathbb{R}^{n\times q}$、$q = \operatorname{rank}(X)$）。令

$$L = \begin{bmatrix} U_q\Sigma_q & 0_{m\times(k-q)} \end{bmatrix}, \qquad R = \begin{bmatrix} V_q & 0_{n\times(k-q)} \end{bmatrix},$$

则 $L \in \mathbb{R}^{m\times k}$、$R \in \mathbb{R}^{n\times k}$，且

$$LR^{\top} = \begin{bmatrix} U_q\Sigma_q & 0 \end{bmatrix} \begin{bmatrix} V_q^{\top} \\ 0 \end{bmatrix} = U_q\Sigma_q V_q^{\top} = X.$$

由 式 (3.31) 展开即得 $X = \sum_{i=1}^{q} \sigma_i u_i v_i^{\top}$，补零后写为 $\sum_{s=1}^{k} \ell_s r_s^{\top}$，其中后 $k-q$ 项为秩零（零矩阵）。故 X 是至多 k 个秩不超过一的外积项之和。 □

《人工智能数学基础》 CC BY-NC-SA 4.0 禁止商业使用 · 著作权归全体著名作者共有

3.3.2 从截断 SVD 到因子模型

把“用秩不超过 k 的矩阵逼近 M”写成优化问题：

$$\min_{\operatorname{rank}(X)\leqslant k} \ \tfrac{1}{2}\|M-X\|_F^2 . \tag{3.44}$$

由 **Eckart–Young** 定理（定理 **3.34**），其最优解就是截断 **SVD** M_k；再由 命题 **3.35** 的构造，$M_k = U_k\Sigma_k V_k^\top$ 给出最优因子 $L = U_k\Sigma_k$、$R = V_k$。若改用 式 **(3.43)** 的参数化直接优化，

$$\min_{L,R} \ \tfrac{1}{2}\left\|M - LR^\top\right\|_F^2, \tag{3.45}$$

两个问题的最优目标值相同，但可行集的形状不同：式 **(3.44)** 的可行集（低秩矩阵集合）非凸，式 **(3.45)** 则将非凸性转移到参数化中——固定 R 时目标关于 L 是二次函数，固定 L 时关于 R 是二次函数，关于 (L,R) 联合则不是凸函数。这个双线性结构是下一小节算法的基础。

3.3.3 交替最小二乘

命题 3.36 (交替最小二乘的更新) 设 $R^\top R$ 可逆（对称地，使用 式 (3.47) 时设 $L^\top L$ 可逆）。则 式 (3.45) 固定 R 关于 L 的最小值点为

$$L = MR(R^\top R)^{-1}; \tag{3.46}$$

固定 L 关于 R 的最小值点为

$$R = M^\top L(L^\top L)^{-1}. \tag{3.47}$$

证明. 展开目标：

$$f(L,R) = \tfrac{1}{2}\left\|M - LR^\top\right\|_F^2 = \tfrac{1}{2}\|M\|_F^2 - \operatorname{tr}(LR^\top M^\top) + \tfrac{1}{2}\operatorname{tr}(LR^\top RL^\top).$$

固定 R 对 L 求梯度（矩阵求导法则，第 4 章系统给出）得 $\nabla_L f = LR^\top R - MR$；令其为零即 式 (3.46)。对称地得 式 (3.47)。 □

由 式 **(3.46)** 与 式 **(3.47)** 交替执行，即交替最小二乘（**alternating least squares, ALS**）：固定当前 $R^{(t)}$ 更新 $L^{(t+1)}$，再固定 $L^{(t+1)}$ 更新 $R^{(t+1)}$，如此往复。

命题 3.37 (ALS 的单调性) 由 命题 *3.36* 生成的序列满足

$$f(L^{(t+1)},R^{(t)}) \leqslant f(L^{(t)},R^{(t)}), \qquad f(L^{(t+1)},R^{(t+1)}) \leqslant f(L^{(t+1)},R^{(t)}).$$

证明. 每步都是在另一半因子固定时对二次函数取精确最小值，目标值不增。 □

注. 使用 ALS 时还需注意以下几点：

- 目标值单调不增且有下界，因此目标值序列收敛；迭代点是否收敛、极限是否为驻点需另行证明，且不同初始化可能收敛到不同因子；

《人工智能数学基础》 CC BY-NC-SA 4.0 禁止商业使用 · 著作权归全体署名作者共有

- 因子本身不唯一（见 节 3.3.4）；
- 若某个 $R^\top R$ 奇异（如某列全零），式 (3.46) 失效，需加正则项或修正。

上式针对完整观测；缺失评分时，只在已观测集合 Ω 上累计误差，各行、各列的最小二乘问题相应只对被观测项求和。实践中 ALS 的优势正体现在大规模与含缺失数据的场景（如推荐系统只有少量观测评分），此时截断 SVD 的闭式解无法直接使用。

3.3.4 尺度非唯一性与正则化

注 (因子的尺度非唯一性). 对任意非零常数 c，

$$LR^\top = (cL)\Big(\frac{1}{c}R\Big)^\top.$$

即使预测矩阵不变，两个因子的范数也可以相差任意倍数。因此 L 与 R 本身不是模型的唯一表示，模型真正关心的是乘积 $LR^\top$。

为限制模型复杂度、缓解过拟合，并使两个因子的尺度更加平衡，可在目标中加入正则项（约定 $\lambda \geqslant 0$，讨论缩放抑制作用时取 $\lambda > 0$）：

$$\min_{L,R} \ \tfrac{1}{2}\left\|M - LR^\top\right\|_F^2 + \frac{\lambda}{2}\big(\|L\|_F^2 + \|R\|_F^2\big). \tag{3.48}$$

正则项有三个作用：防止因子数值过大；缓解过拟合；惩罚 节 3.3.4 的尺度不平衡（固定“尺度自由度”）。具体地，对 $c \neq 0$，变换 $(L, R) \mapsto (cL, R/c)$ 保持乘积 $LR^\top$ 不变，而正则项变为 $\frac{\lambda}{2}(c^2\|L\|_F^2 + c^{-2}\|R\|_F^2)$；当两个因子均非零且 $\lambda > 0$ 时，沿这组缩放取得最小值需满足 $\|cL\|_F = \|R/c\|_F$，由此把最优解约束到两个因子量级相称的状态。

注 (核范数与稀疏性). 式 (3.34) 的核范数 $\|X\|_*$ 是秩的常用凸松弛：$\|X\|_*$ 鼓励奇异值收缩，从而倾向低秩解。视频监控中“静止背景低秩、运动目标稀疏”的模型 $M = L + S$ 即为一例：

$$\min_{L,S} \ \|L\|_* + \lambda\|S\|_1 \quad \text{s.t.} \quad M = L + S,$$

其中 $\|S\|_1$ 为逐元素绝对值之和（ℓ_1 范数，第 2 章）。该问题的求解超出本书范围，此处只为说明核范数的用途。

3.3.5 AI 应用：LoRA 的位置

AI 应用

问题：大模型微调时，每个下游任务都要更新全部权重，存储与分发代价随任务数线性增长（完整讨论见 节 3.4）。

数学建模：若权重更新 ΔW 的秩不超过 $r \ll \min(d, k)$，则 $\Delta W = BA$（$B \in \mathbb{R}^{d\times r}$、$A \in \mathbb{R}^{r\times k}$）可精确参数化——这正是 命题 3.35 的 $k = r$ 情形；若 ΔW 只是近似低秩，则由 Eckart–Young 定理（定理 3.34），r 个模式已是对其最优的秩 r 逼近。LoRA（Low-Rank Adaptation，低秩自适应微调）把这个数学事实用作微调的参数化假设：

冻结预训练权重 W_0，只训练低秩因子的乘积 BA；它以常数缩放 α/r 注入网络，即实际注入的更新量为 $(\alpha/r)BA$（正数缩放不改变秩及左右奇异子空间，奇异值同比例缩放；假设、记号与训练动态见 节 **3.4**）。

理论联系：**LoRA** 的数学落点全部来自本章：r 的选取是“秩与误差”的权衡（式 **(3.37)** 的尾项平方和），因子非唯一性（节 **3.3.4**）解释了训练动态对缩放与初始化的敏感，而 ΔW 的奇异结构（节 **3.4**）给出训练后可解释的分析。幂法一类迭代算法还可用于只取最大的几个奇异三元组而不做完整 **SVD**，**PageRank** 的网页重要性向量同样是转移矩阵主特征向量（特征值 1）——两者共同说明：大规模场景通常只需少数几个主导模式，不必求完整分解。

3.4　案例：大模型训练中的加速方法

AI 应用 3.38　建模假设。设某线性层的预训练权重为 $W_0 \in \mathbb{R}^{d\times k}$（线性层在完整网络中的位置见 节 A.1，本案例只涉及单个线性层），完整微调允许学习任意更新矩阵 $\Delta W \in \mathbb{R}^{d\times k}$，微调后权重为 $W = W_0 + \Delta W$。本案例采用如下假设，逐条编号以便引用：

(1) **低内在秩假设。**适应下游任务所需的权重更新集中在少数方向上：$\operatorname{rank}(\Delta W) \leqslant r \ll \min(d,k)$。注意低秩的对象是更新量 ΔW，一般不是 W_0，也不是 $W_0 + \Delta W$。

(2) **冻结假设。** W_0 在微调中不变，可训练参数只有 ΔW 的因子。

(3) **缩放假设。**更新按 α/r 缩放后注入，$\alpha > 0$ 为常数。

以下约定 r 为正整数。r 是预设的参数化宽度，实际更新秩满足 $\operatorname{rank}(\Delta W) \leqslant r$，可以严格小于 r。例如初始化 $B = 0$ 时，$\Delta W = 0$。

参数化。由假设 1 与 命题 3.35，写

$$W = W_0 + \frac{\alpha}{r} BA, \qquad B \in \mathbb{R}^{d\times r}, \quad A \in \mathbb{R}^{r\times k},$$

即实际注入的更新量为 $\Delta W \coloneqq (\alpha/r)BA$。层的输出为

$$h = (W_0 + \Delta W)x = W_0 x + \frac{\alpha}{r} BAx.$$

信息只经过一个宽度至多为 r 的适应通道：$x \xrightarrow{A} Ax \xrightarrow{B} BAx$（实际 $\operatorname{rank}(\Delta W)$ 可能小于 r，例如初始化时 $B = 0$ 使 $\Delta W = 0$）。初始化取 $A_{ij} \sim \mathcal{N}(0, \tau^2)$、$B = 0$（$\tau$ 为初始化标准差；按约定第 3 条，σ 本章保留给奇异值），则训练开始时 $\Delta W = 0$，模型输出与预训练模型一致；训练中只更新 A, B。α/r 调节注入更新的幅度；原始 LoRA 在其优化器与初始化设定下，用该缩放减少改变秩时重新调节超参数的需要。

参数效率。完整更新需训练 dk 个参数，LoRA 只训练 $r(d+k)$ 个，比例为

$$\frac{r(d+k)}{dk}. \tag{3.49}$$

当 $d = k$ 时比例为 $2r/d$。以 $d = k = 4096$、$r = 8$ 为例：完整更新 $4096^2 = 16777216$ 个参

《人工智能数学基础》 CC BY-NC-SA 4.0 禁止商业使用 · 著作权归全体署名作者共有

数，LoRA 为 $8 \times 8192 = 65536$ 个，$2r/d = 16/4096 \approx 0.39\%$。

训练后的奇异结构。训练完成后对实际更新量 ΔW 作紧致 SVD（$s \leqslant r$ 为非零奇异值数；ΔW 与未缩放乘积 BA 只差常数倍 α/r，奇异方向相同）：

$$\Delta W = \sum_{i=1}^{s} \sigma_i u_i v_i^\top, \qquad \Delta W x = \sum_{i=1}^{s} \sigma_i \, (v_i^\top x) \, u_i.$$

由 式 (3.31) 的三步解读：右奇异向量 v_i 指出 LoRA 重点响应哪些输入特征组合，左奇异向量 u_i 指出修正量主要施加到哪些输出方向，奇异值 σ_i 给出各修正模式的强度。

适用条件与失效位置。本案例的结论依赖假设 1——当任务所需的更新本身接近满秩（如大规模领域迁移）时，低秩参数化的表达力不足，r 的增大又会稀释参数效率。r 的选取目前缺乏理论准则，实践中依赖验证集；α 与学习率的相互作用（假设 3）是复现实验中常见的不确定因素。这些正是前言所说“实践中有效、理论上尚未被充分理解”的一类现象：Eckart–Young 定理保证的是“给定秩 r 时的最优逼近”；而“秩 r 小到既节省参数又不损失精度”并无定理保证，只能凭经验选取。

3.5 本章小结

本章的主线是：为回答“矩阵能拆成什么”，先在可对角化方阵上建立特征值分解，再用谱定理处理最常用的一类（实对称矩阵），最后用奇异值分解把结论推广到任意矩阵，并以低秩逼近收束到应用。

(1) 特征向量刻画不变方向，特征值给出相应缩放因子。特征对满足 $Av = \lambda v$（式 **(3.4)**）；$\det(A - \lambda I) = 0$ 是特征方程（式 **(3.5)**）；不同特征值的特征向量线性无关（定理 **3.7**）；tr 与 det 分别是特征值的和与积（命题 **3.5**）。

(2) 可对角化的充要条件是特征向量成基。$A = P\Lambda P^{-1}$（定理 **3.9**、式 **(3.12)**）；矩阵幂与迭代收敛性由此读出（式 **(3.15)**）；重根时可能出现不可对角化的矩阵（例 **3.12**）。

(3) 实对称矩阵必可正交对角化。谱定理（定理 **3.13**）给出 $A = Q\Lambda Q^\top$；秩等于非零特征值数（推论 **3.14**），正定性等价于谱为正（推论 **3.15**）。

(4) 两类工具分解不依赖谱理论。**Cholesky** 分解 $A = LL^\top$ 存在唯一（定理 **3.16**）；**QR** 分解 $A = QR$ 把最小二乘化为三角方程（命题 **3.20**）。

(5) **SVD** 取消特征值分解的全部限制。任意矩阵有 $A = U\Sigma V^\top$（定理 **3.23**）；奇异值有极值刻画（定理 **3.26**），谱范数 $= \sigma_1$（定理 **3.28**），**Frobenius** 范数 $= \sqrt{\sum \sigma_i^2}$（定理 **3.30**），秩 $= \#\{\sigma_i > 0\}$（命题 **3.31**）。

(6) 截断 **SVD** 是最优低秩逼近。**Eckart–Young** 定理（定理 **3.34**）给出两种范数下的最优性与误差公式；**PCA** 由此获得两条等价路径（节 **3.2** 的 **AI** 应用框）。

(7) 低秩因子模型的算法与代价。**ALS** 逐块精确最小化（命题 **3.36**）且单调（命题 **3.37**），但联合非凸、因子不唯一（节 **3.3.3**、节 **3.3.4**）；正则项固定尺度并抑制过拟合（式 **(3.48)**）。

(8) 本章数学结构的总出口是低秩微调。**LoRA** 把低秩增量 $\Delta W = (\alpha/r)BA$ 的参数化假设（**AI** 应用 **3.38**）落到微调，参数效率由 式 **(3.49)** 量化；其适用边界同样在本案中写明。

《人工智能数学基础》 CC BY-NC-SA 4.0 禁止商业使用 著作权归全体署名作者共有

把本章的四种分解放回全书谱系中，各自的位置与输入条件一目明了：

表 3.2: 本书涉及的矩阵分解谱系

分解	输入矩阵	形式与要点
特征值分解	方阵、可对角化	$A = P\Lambda P^{-1}$；对称情形见谱定理
Cholesky 分解	对称正定	$A = LL^{\top}$；节 3.1
QR 分解	列满秩（长方形亦可）	$A = QR$；节 3.1
奇异值分解	任意矩阵	$A = U\Sigma V^{\top}$；节 3.2
（后续）伪逆分解	任意矩阵	$A^{+} = V_r\Sigma_r^{-1}U_r^{\top}$；第 5 章

后续章节（第 5 章的 Kronecker 与 Hadamard、第 8 章以后的优化算法）还会遇到新的分解，但最基本的就是这五类。

3.6 习题

3.6.1 基础题

习题 3.39 求 $A = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$ 的特征值分解 $A = Q\Lambda Q^{\top}$，并验证 $\operatorname{tr}(A)$ 与 $\det(A)$ 满足 命题 3.5。

习题 3.40 设 A 为对角元两两不同的上三角矩阵。证明 A 可对角化。

习题 3.41 求 $A = \begin{bmatrix} 9 & 3 \\ 3 & 5 \end{bmatrix}$ 的 Cholesky 分解，并验证唯一性论证（定理 3.16）中“既是正交又为下三角、且对角元均为正的矩阵只能是单位矩阵”这一步。

习题 3.42 求 $A = \begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix}$ 的 QR 分解，并用 命题 3.20 解最小二乘问题 $\min_x \|Ax - b\|_2$，其中 $b = (1, 2)^{\top}$。

3.6.2 证明题

习题 3.43 设 $A = A^{\top}$，$\lambda \neq \mu$ 为 A 的两个特征值。证明 $E_A(\lambda) \perp E_A(\mu)$（对各自向量取内积为零）。

习题 3.44 证明：若 A 对称正定，则 定理 3.16 证明中的 Schur 补 $S = C - \frac{1}{a}bb^{\top}$ 仍对称正定。

习题 3.45 设 $\operatorname{rank}(X) \leqslant k$，记 $q = \operatorname{rank}(X)$。证明：$X$ 可以写成至多 k 个秩不超过一的外积项之和，且所需秩一项的最少个数恰为 q。提示：上界由 命题 3.35（紧致 SVD）给出；下界用“秩一外积的秩不超过一、和的秩不超过各项秩之和”得 $t \geqslant \operatorname{rank}(X)$。

习题 3.46 设 $A \in \mathbb{R}^{n\times n}$ 对称半正定。证明存在 $C \in \mathbb{R}^{n\times n}$ 使 $A = C^{\top}C$，并说明 C 何时唯一。

《人工智能数学基础》 CC BY-NC-SA 4.0 禁止商业使用 · 著作权归全体署名作者共有

3.6.3 计算题

习题 3.47 对 例 3.4 的矩阵 $A=\begin{bmatrix}3&1&0\\1&3&0\\0&0&1\end{bmatrix}$：（a）写出其紧致 SVD；（b）求最佳秩一逼近 A_1（在 Frobenius 范数与谱范数下取到的最优矩阵相同）及 $\|A-A_1\|_F$、$\|A-A_1\|_2$；（c）验证 Eckart–Young 定理的误差公式 式 (3.37) 与 式 (3.38)。

习题 3.48 设 $M=\begin{bmatrix}5&4\\3&2\end{bmatrix}$，用 ALS（式 (3.46)、式 (3.47)）求秩一逼近。取 $L^{(0)}=0$、$R^{(0)}=(1,1)^\top$，按 命题 3.36 手算 $L^{(1)},R^{(1)}$ 两步，记录三步目标值（应为 $27\to\frac{1}{2}\to\frac{2}{53}$），核对 命题 3.37 的单调性（各步目标值用分数表示）。

习题 3.49 按 节 3.2.7 的口径核算：1440×1920 的图像保留前 30 个奇异值，存储量为原矩阵的百分之几？若奇异值尾部衰减缓慢（前 30 个奇异值之和仅占全部的 20%），这说明了什么？再思考：保留的“奇异值之和的比例”（核范数比例）能否直接决定“保留的平方能量比例”（Frobenius 误差）？给出理由或举反例说明两者的区别。

习题 3.50 设 $A=\begin{bmatrix}1&0\\1&1\\1&2\end{bmatrix}$，$b=(1,2,4)^\top$。（a）求 A 的 QR 分解；（b）用 式 (3.24) 解 $\min_x\|Ax-b\|_2$；（c）用正规方程核对（b）的结果。

3.6.4 AI 应用题

习题 3.51 设 $A=2I+\mathbf{1}\mathbf{1}^\top\in\mathbb{R}^{3\times3}$（$\mathbf{1}=(1,1,1)^\top$）。（a）求 A 的奇异值与一组左右奇异向量；（b）求最佳秩一逼近 A_1（在 Frobenius 范数与谱范数下取到的最优矩阵相同），计算 $\|A-A_1\|_2$、$\|A-A_1\|_F$ 与保留的平方能量比例 $\eta(1)=\|A_1\|_F^2/\|A\|_F^2$；（c）判断最佳秩二逼近（在 Frobenius 范数与谱范数下取到的最优矩阵相同）是否唯一；若不唯一，构造两个不同的最优解。

习题 3.52 将 习题 3.51（b）中的 A_1 写成 $LR^\top$（$L,R\in\mathbb{R}^{3\times1}$），说明这一因子分解为什么不唯一，并写出 节 3.3.4 中 c 的作用。

习题 3.53 ★（思考题，只给提示）考虑

$$\min_X\ \tfrac{1}{2}\|A-X\|_F^2+2\|X\|_*,$$

其中 A 同 习题 3.51。提示：最优解由奇异值软阈值给出；求出 X^* 并与 A_1 比较。

习题 3.54 按 AI 应用 3.38 的口径核算：$d=k=4096$、$r=8$ 时 LoRA 与完整微调的参数量之比；若要使比例降到 0.2% 以下，r 至多为多少？结合 式 (3.37) 说明：压低 r 的代价由哪一项度量。

人工智能数学基础 CC BY NC-SA 4.0 禁止商业使用 署名权归全体署名作者共有

本章参考文献

[1] **Lloyd N. Trefethen and David Bau III. *Numerical Linear Algebra*, 25th Anniversary Edition. SIAM, 2022.**

[2] **Gilbert Strang. *Linear Algebra and Its Applications*, 3rd ed. Brooks/Cole, Thomson Learning, 1988.**

[3] **Roger A. Horn and Charles R. Johnson. *Matrix Analysis*, 2nd ed. Cambridge University Press, 2013.**

[4] **Marc Peter Deisenroth, A. Aldo Faisal, and Cheng Soon Ong. *Mathematics for Machine Learning*. Cambridge University Press, 2020.**

[5] **Sheldon Axler. *Linear Algebra Done Right*, 4th ed. Springer, 2024.**

[6] **Stephen Boyd and Lieven Vandenberghe. *Introduction to Applied Linear Algebra: Vectors, Matrices, and Least Squares*. Cambridge University Press, 2018.**

[7] **张贤达. 矩阵分析与应用（第 2 版）. 清华大学出版社, 2013.**

[8] **耿修瑞. 矩阵之美（基础篇）. 科学出版社, 2023.**

[9] **韩丛英, 李伯男. 人工智能基础数学理论和算法 · 第一篇矩阵代数（课程课件）. 中国科学院大学, 2025.**

《人工智能数学基础》 CC BY-NC-SA 4.0 禁止商业使用 · 著作权归全体署名作者共有

Chapter 4

矩阵代数——矩阵微积分与反向传播

本章作者：×××　初审：×××　二审：×××

终审：×××　人工智能例子审核：×××

4.1 多元微分与 Jacobian 矩阵

4.2 标量、向量对矩阵的求导法则

4.3 迹函数与行列式的微分技巧

4.4 链式法则原理

4.5 案例：深度学习中的反向传播算法

本章参考文献

[1] 作者. 书名或论文名. 出版信息.

[2] 作者. 书名或论文名. 出版信息.

《人工智能数学基础》 CC BY-NC-SA 4.0 禁止商业使用 · 著作权归全体署名作者共有

Chapter 5

矩阵代数——特殊运算与张量基础

本章作者：×××　初审：×××　二审：×××

终审：×××　人工智能例子审核：×××

5.1 Kronecker 积和 Hadamard 积

5.2 广义逆矩阵与最小二乘解

5.3 张量的基本定义

5.4 案例：矩阵计算的 Python 实现

本章参考文献

[1] 作者. 书名或论文名. 出版信息.

[2] 作者. 书名或论文名. 出版信息.

《人工智能数学基础》
CC BY-NC-SA 4.0
禁止商业使用 · 著作权归全体署名作者共有

第二篇

概率论

《人工智能数学基础》
CC BY-NC-SA 4.0
禁止商业使用，著作权归全体署名作者共有

Chapter 6

概率论——多元随机变量与高斯分布

本章作者：×××　初审：×××　二审：×××

终审：×××　人工智能例子审核：×××

6.1 随机向量与统计特征

6.2 多元高斯分布

6.3 分布变换

本章参考文献

[1] 作者. 书名或论文名. 出版信息.

[2] 作者. 书名或论文名. 出版信息.

《人工智能数学基础》
CC BY-NC-SA 4.0
禁止商业使用·著作权归全体署名作者共有

Chapter 7

概率论——参数估计与信息论基础

本章作者：× × ×　初审：× × ×　二审：× × ×

终审：× × ×　人工智能例子审核：× × ×

7.1 参数估计框架

7.2 信息论与损失函数

7.3 案例：生成式模型中的相关算法

本章参考文献

[1] 作者. 书名或论文名. 出版信息.

[2] 作者. 书名或论文名. 出版信息.

《人工智能数学基础》
CC BY-NC-SA 4.0
禁止商业使用·著作权归全体署名作者共有

第三篇

最优化方法

《人工智能数学基础》
CC BY-NC-SA 4.0
禁止商业使用，著作权归全体署名作者共有

Chapter 8

最优化方法——优化视角下的 AI 模型

本章作者：××× 初审：××× 二审：×××

终审：××× 人工智能例子审核：×××

8.1 优化问题的直观理解

8.2 凸集与凸函数基础

8.3 全局最优和局部最优

8.4 案例：分类及回归的模型与算法

本章参考文献

[1] 作者. 书名或论文名. 出版信息.

[2] 作者. 书名或论文名. 出版信息.

《人工智能数学基础》
CC BY-NC-SA 4.0
禁止商业使用，著作权归全体署名作者共有

Chapter 9

最优化方法——一阶算法

本章作者：×××　初审：×××　二审：×××

终审：×××　人工智能例子审核：×××

9.1 梯度下降法

9.2 随机梯度下降

9.3 加速方法

9.4 自适应算法

9.5 案例：深度学习中的训练相关算法

本章参考文献

[1] 作者. 书名或论文名. 出版信息.

[2] 作者. 书名或论文名. 出版信息.

《人工智能数学基础》 CC BY-NC-SA 4.0 禁止商业使用，著作权归全体署名作者共有

Chapter 10

最优化方法——二阶算法

本章作者：×××　初审：×××　二审：×××

终审：×××　人工智能例子审核：×××

10.1 牛顿法与海森矩阵

10.2 曲率信息与收敛速度

10.3 案例：自然策略梯度

本章参考文献

[1] 作者. 书名或论文名. 出版信息.

[2] 作者. 书名或论文名. 出版信息.

《人工智能数学基础》
CC BY-NC-SA 4.0
禁止商业使用·著作权归全体署名作者共有

Chapter 11

最优化方法——约束优化与对偶理论

本章作者：× × ×　初审：× × ×　二审：× × ×

终审：× × ×　人工智能例子审核：× × ×

11.1 拉格朗日乘子法

11.2 KKT 条件与对偶理论

11.3 增广拉格朗日法

11.4 案例：深度学习中的约束优化问题

本章参考文献

[1] 作者. 书名或论文名. 出版信息.

[2] 作者. 书名或论文名. 出版信息.

《人工智能数学基础》
CC BY-NC-SA 4.0
禁止商业使用 · 著作权归全体署名作者共有

模型案例集

怎么读这份案例集

本书的十一章按数学结构划分：线性代数、概率论、最优化各成一篇，模型本身没有属于自己的章节。这份案例集补上模型这个视角，沿一条线读完四个影响最广的架构：多层感知机把仿射映射叠起来再插入非线性；卷积网络把「结构约束」直接写进线性算子；视觉 **Transformer** 把图像切成序列，用依赖数据的加权平均代替固定的线性组合；**CLIP** 则用对比目标把两种模态的表示对齐到同一个空间。

四节的结构相同，依次是结构（前向计算写成什么样的式子）、数学落点（这个式子用到本书哪些已证的结论）、规模与失效（参数量、适用条件、在什么地方失效），最后交代与相邻模型的关系。数学结论不在本附录重新证明，一律回指正文各章；本附录只负责把它们串成一条模型能读懂的线。

注. 本案例集写在各章之前。文中引用到的其余各章目前只列出了章名与节名，被引用的结论会在各章成稿时补齐。

本案例集不做什么

与第一章的做法一致，先说明边界。凡是需要本书没有的工具的内容，一律不写，见表 **A.1**。

表 A.1: 本案例集的内容边界与去向

内容	本案例集的处理方式	去向
通用逼近定理的证明	只在节 A.1陈述结论	逼近论与泛函分析课程
Fourier 变换与卷积定理	只在节 A.2提一句方向	信号与系统课程
注意力的工程优化（分块、稀疏、核化）	不涉及	系统与工程实现，本书不承担
扩散模型与强化学习的数学	不给	相关数学工具见节 6.2与节 10.3
习题	不设	以各章习题为准，AI 应用题已在各章按章分布

A.1 多层感知机：仿射映射与逐点非线性的复合

结构. 设一个 **batch** 的输入为 $X \in \mathbb{R}^{n\times d_0}$，第 l 层的计算写成

$$X_l = \sigma_l\big(X_{l-1}W_l^\top + \mathbf{1}_n b_l^\top\big), \qquad l = 1,\dots,L,$$

其中 $W_l \in \mathbb{R}^{d_l\times d_{l-1}}$ 是权重、$b_l \in \mathbb{R}^{d_l}$ 是偏置、$\mathbf{1}_n$ 是全一列向量、σ_l 逐元素作用（**ReLU**、**GELU** 等）。最后一层通常不带非线性，输出的每一行是一个样本的 d_L 维表示。用第一章

的语言，X 的每一行是一个样本，逐层的 **shape** 就是这条链上的账目（节 **1.1**）。

数学落点.

（**i**）单层是仿射映射。$x \mapsto W_l x + b_l$ 由一个线性映射加上一次平移组成，因此是仿射映射（定义 **1.15**）。通俗说法里的 **linear layer** 指的正是它。偏置取零时它才是线性映射。

（**ii**）去掉非线性，深度不增加表达力。若所有 σ_l 都是恒等映射，则复合仍是仿射：$X \mapsto X(W_L \cdots W_1)^\top +$ 常数，多层乘积可以并成一层。深度带来表达力，靠的是中间的非线性。

（**iii**）加入非线性后不再线性。取 $\mathbb{R}$ 上的 $f(x) = \max\{0, x\}$。由

$$f(1) + f(-1) = 1 + 0 = 1 \neq 0 = f(0)$$

可见 f 不满足式 **(1.10)**给出的加性条件，因此不是线性映射。这条判据本身就是第一章的定义在起作用：判断一个网络是否为线性映射，只需要找到一次破坏加性（或齐次性）的取值。

（**iv**）隐层的像不是子空间。 $f(x) = \max\{0, x\}$ 把 $\mathbb{R}$ 映到 $[0, +\infty)$，这个集合对取负不封闭，因此不是 $\mathbb{R}$ 的子空间（定义 **1.4**）。失效的方式与例 **1.7**中两条坐标轴之并属于同一类：集合看着像「半条直线」，代价是丢掉了对称性。这一点值得留意——第一章里大量结论（投影分解、最小二乘的几何解释）都以子结构为前提，而网络的隐层输出集不满足这些前提，所以那些结论不能直接搬过来。

（**v**）参数量与 **shape** 的乘积。第 l 层的参数量是 $d_l d_{l-1} + d_l$。宽度为 d、深度为 L 的网络，参数量随 L 线性增长、随 d 平方增长。这个简单的计数是后面比较卷积（节 **A.2**）与注意力（节 **A.3**）的基准。

规模与失效. 通用逼近定理说：在紧集 $K \subseteq \mathbb{R}^{d_0}$ 上连续的函数，可以用一个足够宽的单隐层网络在 K 上一致逼近到任意精度（激活函数取非多项式，如 **Sigmoid** 型）[**1**]。这条结论只陈述、不证明——它属于逼近论。它的意义是划出一条下界：在表达力这一层面，深度不是必需的。

需要立刻补上的是它的限度。稠密性说的是「存在一组参数使误差足够小」，它没有说 **SGD** 能找到这组参数，也没有说需要多少样本。此外，逼近所需的宽度可能随输入维数迅速增长，而同样精度的深层网络可以用少得多的参数达到——深度与宽度之间的权衡至今仍是理论问题。「一个模型为什么有效、在什么条件下失效」在神经网络里往往只有部分答案，这里如实呈现。

指向. 前向与反向传播的完整计算图见节 **4.5**（反向传播的原始文献见 [**2**]），链式法则见节 **4.4**；训练目标属于经验风险最小化的框架（节 **8.4**），具体算法的收敛性与调参见节 **9.5**。

A.2 卷积网络：把结构约束写进线性算子

结构. 先看一维、单通道的情形。给定信号 $x \in \mathbb{R}^n$ 与核 $w \in \mathbb{R}^k$，

$$y_i = \sum_{j=1}^{k} w_j \, x_{i+j-1}, \qquad i = 1, \ldots, m = n - k + 1,$$

即 $y = C_w x$，其中 $C_w \in \mathbb{R}^{m\times n}$ 的第 i 行是 w 平移 $i-1$ 位后的结果。这样的矩阵叫带状 **Toeplitz** 矩阵：同一条对角线上的元素取同一个值，非零只出现在带宽 k 之内。二维图像按行拉直后，$k\times k$ 的核给出分块 **Toeplitz** 矩阵（每块本身又是 **Toeplitz**）。

数学落点.

（**i**）卷积是线性映射。由 $C_w(\alpha x+\beta z)=\alpha C_w x+\beta C_w z$ 立得（定义 **1.15**）。加上偏置后是仿射映射，与节 **A.1**的单层同型。把卷积算子写成矩阵，是把「卷着算」翻译成第一个月的线性代数；节 **5.4**会用一个十来行的程序把这件事算出来看。

（**ii**）权值共享＝对矩阵的结构约束。$\mathbb{R}^n\to\mathbb{R}^m$ 的一般线性映射有 mn 个自由度（式 **(1.11)**）。**Toeplitz** 结构把 mn 压到 $m+n-1$，再限定带宽为 k 后只剩 k 个——也就是核 w 本身。自由度减少意味着模型类变小，性能要靠「约束选对了」来弥补，这就是归纳偏置的确切含义：把「同一条边出现在图像哪个位置都该被同样检测」写进参数化，只用 k 个参数表达它。

（**iii**）平移等变性。设 S_τ 为循环移位算子（把向量循环右移 τ 位）。当边界取循环时，C_w 是循环矩阵，并且对一切 τ 有

$$C_w S_\tau = S_\tau C_w.$$

用节 **1.4**的语言说：卷积算子与平移算子交换。「先平移再卷积」和「先卷积再平移」给出同一个结果，这正是「特征在哪里出现都要被检出」的代数形式。反过来的结论同样成立：与所有平移算子交换的线性算子必是循环卷积。于是等变性从一个经验性质变成一个可以证明的刻画。（循环矩阵能被离散 **Fourier** 基同时对角化是同一件事的谱版本，属信号处理的常规内容，本书不展开。）

（**iv**）边界是条件。上一条依赖循环边界。实际图像是有限长的，零填充的卷积只在内部位置严格等变，靠近边界的位置会受填充值影响；要得到全局等变，或者取循环边界，或者把边界位置单独处理。这是本节最该说清的一处失效位置：等变性在有限尺寸下是「除边界外」的性质。

（**v**）步长与池化。步长 s 的卷积输出是 $D_s C_w x$，其中 D_s 为隔 s 取一的下采样。因为 $D_s S_\tau = S_{\tau/s} D_s$ 只在 $s\mid\tau$ 时成立，步长 s 的卷积只对平移 s 的整数倍等变。池化中的取最大不是线性映射：取 $P(X)_i=\max_j X_{ij}$，则

$$P\big((1,0)\big)+P\big((0,1)\big)=1+1=2\neq 1=P\big((1,1)\big),$$

加性被破坏（式 **(1.10)**）。这一点在推公式时容易漏：整条前向通路一旦含池化，整体就不再是线性映射，也就不能再用线性映射的复合去分析。

（**vi**）多通道与张量。c 个输入通道、c' 个输出通道时，每个输出通道是各输入通道卷积的和，即一次张量收缩，**Kronecker** 结构是它的一种写法（节 **5.3**、节 **5.1**）。

（**vii**）感受野。每层核为 k 的 L 层卷积（步长 1），一个输出点看到的输入范围为 $1+L(k-1)$（每维），随深度线性增长。这与节 **A.3**的注意力形成对照：注意力的每个位置一层之内就看得到全部输入，代价见下一节。

规模与失效. 一个卷积网络由若干「卷积 ＋ 逐点非线性 ＋ 池化」组成，末端接一层仿射分类头（节 **A.1**的单层）[3]。参数量与图像尺寸无关，这是权值共享的直接后果；同一张 $n\times n$ 图像接一个全连接隐层，参数量会随 n^2 增长。代价是等变性带来的先验只在图像这类

具有平移结构的输入上成立，把它套到特征排列本身就携带含义的数据上（例如已经把列顺序定义好的表格数据），约束就从帮助变成限制。

指向. 证明层面（**Toeplitz** 与 **Kronecker** 结构、广义逆与最小二乘解）在节 **5.3**；数值验证在节 **5.4**；低秩与谱结构在节 **3.1**、节 **3.2**。

A.3 视觉 Transformer：把图像变成序列的注意力块

结构. 图像 $I \in \mathbb{R}^{H\times W\times C}$ 的处理分四步 [5]。

（i）切块与嵌入. 切成 $N = HW/P^2$ 个 $P \times P$ 的块，每块拉直为行向量 $p \in \mathbb{R}^{P^2C}$，再乘同一个矩阵：

$$z = pE^\top, \qquad E^\top \in \mathbb{R}^{P^2C\times d}.$$

得到 N 个 d 维词元（**token**）$X_0 \in \mathbb{R}^{N\times d}$。注意这里的权值共享与节 **A.2**是同一手法：同一个线性映射作用在每一块上，块的位置不同不影响它。

（ii）类别词元与位置编码. 在最前面拼一个可学习的类别词元，并给每个位置加一个可学习向量：$X_0 \leftarrow [X_{\text{cls}}; X_0] + E_{\text{pos}}$。切块这一步丢掉了位置信息，位置编码把它以加性项的形式放回。

（iii）L 个 **Transformer** 块. 每块含多头注意力、**LayerNorm**、残差连接，以及一个前馈网络——后者就是一个两层 **MLP**（节 **A.1**）[4]。

（iv）分类头. 取类别词元位置的输出，过一层仿射映射，得到类别分数。

数学落点.

（i）注意力的式子。设 $X \in \mathbb{R}^{N\times d}$，$Q = XW_Q$、$K = XW_K$、$V = XW_V$，

$$A = \operatorname{softmax}\!\left(\frac{QK^\top}{\sqrt{d_k}}\right), \qquad Z = AV,$$

其中 $\operatorname{softmax}$ 逐行作用。A 的第 (i,j) 元是 $\langle q_i, k_j\rangle$ 经逐行归一化后的权重。

（ii）分数矩阵与核矩阵的辨析。$QK^\top$ 的每一元都是内积，形状与核矩阵（定义 **1.43**、式 **(1.32)**）相同，但两者的性质不同。核矩阵 $K_{ij} = \langle \phi(x_i), \phi(x_j)\rangle$ 关于 i,j 对称且半正定（定理 **1.45**）。注意力分数矩阵一般不对称：

$$\langle W_Q x_i, W_K x_j\rangle = x_i^\top W_Q^\top W_K x_j,$$

交换 i,j 后中间变成 $W_K^\top W_Q$，两者不相等。只有当 $W_Q = W_K = W$ 时它才退化为 Wx_i 这组向量的 **Gram** 矩阵，此时对称半正定。把「注意力分数矩阵」与「核矩阵」当成同一个对象，是一种会出错的简化——它们共用内积这一形式，性质却不共享。

（iii）输出是 **value** 的凸组合。逐行 **softmax** 给出 $A_{ij} \geq 0$ 且 $\sum_j A_{ij} = 1$，于是

$$z_i = \sum_{j=1}^{N} A_{ij} v_j$$

人工智能数学基础公 CC BY-NC-SA 4.0 禁止商业使用，著作权归全体署名作者共有

是 V 各行向量的凸组合，落在这些行向量的凸包内。凸包与子空间是两种不同的集合：它一般不包含原点，对加法与取负都不封闭。这句话把注意力的作用说清楚了——它是一次依赖数据的加权平均，权重由输入自己决定。

（**iv**）因此整块不是线性映射。A 依赖 X，所以 $X \mapsto Z$ 关于 X 不是线性映射（同节 **A.2**中池化的情形）。卷积在核固定时是一个固定的线性算子，注意力则让算子的系数随输入变化。这两条路线的差别就在这里。

（**v**）**LayerNorm** 是逐行归一化。对每个词元（X 的每一行）去均值、除以标准差，再乘缩放、加平移。它是节 **2.1**与节 **2.2**里的范数工具在另一处的应用，与沿 **batch** 方向归一化的做法互为对照：归一化沿哪个方向进行，决定了统计量在什么范围内共享。

（**vi**）残差让 **Jacobian** 靠近单位阵。残差写 $X \leftarrow X + F(X)$，其 **Jacobian** 为 $I + J_F$。把 J_F 的元素视为小量，则 L 个块复合后的 **Jacobian** 是 $\prod_l (I + J_{F_l})$，其特征值聚集在 1 附近，不像 $\prod_l J_{F_l}$ 那样容易整体衰减到零。这是深网络可以训起来的一个结构性原因（推导见节 **4.4**）。它不构成保证：J_F 的谱范数大时，梯度同样可以爆炸。

规模与失效. 注意力矩阵是 $N \times N$，计算量随词元数近似平方增长，而 N 随图像分辨率平方增长，高分辨率下的开销由此成为后续工作的出发点（属于工程优化，见表 **A.1**）。

ViT 与卷积网络最实质的差别落在归纳偏置上。节 **A.2**的卷积把平移等变性写进算子结构，**ViT** 让位置关系从数据里学出来。后果是数据充分时两者的表现相当，数据有限时 **ViT** 更依赖强正则或在大规模数据上的预训练。这一句在全书只出现在这里，其余章节提到这一点时回指本节。

指向. 切块嵌入是每块上的线性映射（节 **1.4**）；归一化见节 **2.1**；反向传播与残差的 **Jacobian** 见节 **4.5**；前置微调的低秩方法见节 **3.3**[8]。

A.4 CLIP：对比对齐＝度量学习与信息论损失

结构. 取一个图像编码器 f（可以是节 **A.2**的卷积网络，也可以是节 **A.3**的 **ViT**）与一个文本编码器 g，一个 **batch** 内有 B 组配对的图文 [**6**]。两个编码器的输出都归一化到单位球：

$$\tilde{u}_i = \frac{f(I_i)}{\|f(I_i)\|_2}, \qquad \tilde{v}_j = \frac{g(T_j)}{\|g(T_j)\|_2}.$$

相似度矩阵取

$$S_{ij} = \frac{\cos\big(f(I_i),\, g(T_j)\big)}{\tau}, \qquad i, j = 1, \dots, B,$$

$\tau > 0$ 是温度参数。训练目标是让第 i 张图与第 i 段文本的相似度在对角线上取最大，损失对 S 的行与列各做一次交叉熵：

$$\mathcal{L} = \frac{1}{2}\left(-\frac{1}{B}\sum_{i=1}^{B} \log \frac{e^{S_{ii}}}{\sum_{j=1}^{B} e^{S_{ij}}} - \frac{1}{B}\sum_{j=1}^{B} \log \frac{e^{S_{jj}}}{\sum_{i=1}^{B} e^{S_{ij}}} \right).$$

数学落点.

（**i**）余弦相似度是单位球上的内积。两个单位向量之间的夹角满足 $\langle \tilde{u}, \tilde{v} \rangle = \cos\theta$（节 **2.3**），于

是 $S_{ij} \in [-1/\tau, 1/\tau]$。归一化这一步去掉了长度这一自由度，只保留方向——度量学习里的常规做法，与节 **2.4**的出发点相同。两者的分工是：那一节讲度量本身（怎么定义距离与相似度、怎样让它随训练改变），本节讲双塔对齐的完整流程。

（**ii**）损失是一类信息论目标。对每一行，$e^{S_{ii}}/\sum_j e^{S_{ij}}$ 就是一次 **softmax** 交叉熵：把 $-S_{ij}$ 读作「模型给第 j 段文本作为第 i 张图配对的打分」，整项就是把正样本从 $B-1$ 个候选里挑出来的多分类损失。这一类目标通常称为 **InfoNCE**[7]，它同时是两种模态之间互信息的一个下界。熵、**KL** 散度与交叉熵的工具见节 **7.2**。

（**iii**）温度与缩放因子是同一类尺度控制。节 **A.3**里的 $1/\sqrt{d_k}$ 与这里的 $1/\tau$ 都在调节 **softmax** 输入的量级。量级过大时分布接近 **one-hot**、梯度变小，量级过小时分布接近均匀、区分度不足。两处的动机相似，来源不同：$\sqrt{d_k}$ 由维度按内积随维度增长的估计固定下来，τ 通常作为可学参数。

（**iv**）零样本分类。把类别名写成文本提示 $\{T_c\}$，一张图归到相似度最大的类别：

$$\hat{c}(I) = \arg\max_c \left\langle \tilde{f}(I), \tilde{g}(T_c) \right\rangle .$$

这与节 **1.14**里从特征映射与投影出发的零样本预测是同一类做法，一处从内积与相似度出发，一处从子空间与最小二乘出发；推导不再重复。

规模与失效. 对比目标的失效位置值得逐条写明，它们都是「实践中有效、理论上尚在讨论」的具体形态。

- 下界的松紧依赖负样本。 **InfoNCE** 是互信息的下界，而负样本取自同一个 **batch**。B 越大，下界越紧；代价是显存与计算量随 B 增长。
- 假负样本。 **batch** 内与正样本语义相同的样本会被当成负样本，目标把两个本应靠近的表示推开。数据规模越大、主题越集中，这类错误越多。
- 温度与提示词。 τ 的取值、提示词的具体措辞都会明显改变零样本精度。这些是工程上反复观察到的经验事实，其理论解释并不完整。
- 表示空间的语义结构。对比训练得到的多模态嵌入空间中是否存在稳定的方向与类比关系，仍是开放问题。

本节的结论是可用且有限的：对齐目标的形式清楚，它在什么条件下给出有效的表示、又在什么条件下退化，目前只有部分答案。把它写成有限的形式，比给它一个整齐的定理更接近现在的认识。

指向. 相似度与范数见节 **2.3**；信息论工具见节 **7.2**；生成式模型中的相关算法见节 **7.3**；图像编码器本身见节 **A.2**与节 **A.3**。

A.5 四个模型的对照

表 **A.2**把四节并排放在一起。它们可以看成同一条线上的四步：先给线性映射加上逐点非线性（**MLP**），再把结构约束写进线性算子（卷积），然后让算子的系数依赖输入（注意力），最后用对比目标把两个模态对齐到同一个空间（**CLIP**）。

四个模型用到本书的工具各有侧重：**MLP** 与 **ViT** 依赖链式法则与 **Jacobian**（节 **4.4**）；

《人工智能数学基础》 CC BY-NC-SA 4.0 禁止商业使用，转载请注明出处及作者署名 全体署名作者共有

表 A.2: 四个模型的基本算子与结构性质

模型	基本算子	关于输入是否线性	结构与归纳偏置
MLP	仿射映射 + 逐点非线性	否（式 (1.10) 被破坏）	无结构约束,参数量随宽度平方增长
卷积网络	卷积（带状 Toeplitz 矩阵）	是；含池化后否	权值共享、平移等变（除边界外）
ViT	注意力（依赖输入的加权平均）	否（系数随输入变化）	位置关系由数据学得,需较大规模数据
CLIP	两个编码器 + 对比损失	逐层同其编码器	跨模态对齐,依赖负样本与温度

卷积网络把线性映射与矩阵结构用到极致（节 5.3）；CLIP 落在范数、内积与信息论损失上（节 2.3、节 7.2）。四个模型的训练过程则回到最优化那一篇：经验风险的框架（节 8.4）与一阶、二阶算法（节 9.5、节 10.3）。

本章参考文献

[1] **G. Cybenko. Approximation by superpositions of a sigmoidal function. *Mathematics of Control, Signals and Systems*, 2(4):303–314, 1989.**

[2] **D. E. Rumelhart, G. E. Hinton, and R. J. Williams. Learning representations by back-propagating errors. *Nature*, 323:533–536, 1986.**

[3] **Y. LeCun, Y. Bengio, and G. Hinton. Deep learning. *Nature*, 521:436–444, 2015.**

[4] **A. Vaswani, N. Shazeer, N. Parmar, et al. Attention Is All You Need. *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.**

[5] **A. Dosovitskiy, L. Beyer, A. Kolesnikov, et al. An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale. *International Conference on Learning Representations (ICLR)*, 2021.**

[6] **A. Radford, J. W. Kim, C. Hallacy, et al. Learning Transferable Visual Models From Natural Language Supervision. *International Conference on Machine Learning (ICML)*, 2021.**

[7] **A. van den Oord, Y. Li, and O. Vinyals. Representation Learning with Contrastive Predictive Coding. *arXiv:1807.03748*, 2018.**

[8] **E. J. Hu, Y. Shen, P. Wallis, et al. LoRA: Low-Rank Adaptation of Large Language Models. *International Conference on Learning Representations (ICLR)*, 2022.**

《人工智能数学基础》 CC BY-NC-SA 4.0 禁止商业使用 著作权归全体著作者共有

符号表

$\mathbb{R}$	实数域。
$\mathbb{R}^n$	n 维欧氏空间。
$A^\top$	矩阵 A 的转置。
A^+	**Moore–Penrose** 伪逆。
$\|x\|_p$	向量 p-范数。
$\mathbb{E}[X]$	随机变量 X 的数学期望。
$\mathrm{Cov}(X)$	随机向量 X 的协方差矩阵。
$\nabla f(x)$	标量函数 f 在 x 处的梯度。
$\nabla^2 f(x)$	f 在 x 处的 **Hessian** 矩阵。

全书参考文献

[1] **Gilbert Strang.** ***Linear Algebra and Its Applications.***

[2] **Sheldon Axler.** ***Linear Algebra Done Right.***

[3] **Roger A. Horn and Charles R. Johnson.** ***Matrix Analysis.***

[4] **Stephen Boyd and Lieven Vandenberghe.** ***Convex Optimization.***

[5] **Jorge Nocedal and Stephen J. Wright.** ***Numerical Optimization.***

[6] **Thomas M. Cover and Joy A. Thomas.** ***Elements of Information Theory.***

[7] 茆诗松，程依明，濮晓龙，《概率论与数理统计教程（第三版）》.

[8] 林宙辰，李欢，方聪，《机器学习中的加速一阶优化算法》.

《人工智能数学基础》 CC BY NC SA 4.0 禁止商业使用；著作权归全体署名作者共有